# Métodos Computacionalmente Intensivos em Estatística
# Unidade 01: Introdução e revisão

Daiane A Zuanetti
DEs – UFSCar

2026

## Desafios

Muitos problemas de inferência estatística, especialmente quando lidamos com modelos mais complexos, não possuem solução analítica exata e fechada.

**Exemplos:**

- a construção de intervalos de confiança ou testes de hipóteses necessitam, geralmente, da distribuição amostral do estimador pontual e essa distribuição quase nunca é conhecida (exceto por resultados assintóticos);
- vários estimadores, sejam clássicos ou Bayesianos, são obtidos através de maximização ou minimização de uma função objetivo e, muitas vezes, não possuem expressão analítica fechada (especialmente na presença de valores faltantes);

- em inferência Bayesiana, os estimadores (pontuais ou intervalares) são estatística resumo (esperança, quantis, variância, etc) de distribuições *a posteriori* complexas e calcular analiticamente esses valores que envolvem integrais, etc, quase nunca é possível;
- entre vários outros (encontrar distribuição preditiva de uma nova observação, calcular vício de um estimador ou constante normalizadora em inferência Bayesiana).

## Possíveis soluções

- aproximar analiticamente essas quantidades (usando técnicas de cálculo numérico, expansões em séries, transformações de Laplace ou resultados assintóticos, etc, por exemplo);
- **APROXIMAR computacionalmente essas quantidades via simulação de dados e amostras**; ou
- combinar as duas aproximações acima para um algoritmo de simulação escalável e computacionalmente mais eficiente.

Logo, nessa disciplina estudaremos vários métodos computacionais que nos permitem conduzir inferência frequentista e Bayesiana para modelos mais complexos, quando não existem soluções analíticas ou métodos já conhecidos não são aplicáveis.

## Revisão de testes de hipóteses (mas também utilizaremos conhecimento de estimação pontual e intervalar)

Teste de hipóteses é um procedimento estatístico para decidirmos com base em um conjunto de dados (amostra) se uma específica afirmação sobre a população a partir da qual essa amostra é proveniente é verdadeira ou não.

**Exemplo**: Suponha que estamos interessados na taxa de queima de um propelente sólido, usado para fornecer energia aos sistemas de escapamento de aeronaves. A taxa de queima é uma variável aleatória que pode ser descrita por um modelo Normal($\mu, \sigma^2$). O interesse no problema consiste em verificar se a taxa média de queima é ou não equivalente a 50 cm/s. Uma amostra de 9 espécimes foi testada e o valor da taxa de queima para cada uma foi observado.

**Passos para a construção de um teste de hipóteses**:

1. Definir as hipóteses a serem testadas: hipótese nula ($H_0$) e hipótese alternativa ($H_1$) de acordo com o problema;

   **No exemplo:**
   $H_0$: A taxa média de queima do propelente sólido é 50 cm/s.
   $H_1$: A taxa média de queima do propelente sólido não é 50 cm/s.

   **Em termos matemáticos:**
   $H_0 : \mu = 50$ cm/s.
   $H_1 : \mu \neq 50$ cm/s.

Como utilizaríamos nesse exemplo os dados amostrais para decidir sobre $H_0$?

2. Escolher uma estatística teste $T$, que traga informações sobre as hipóteses a serem testadas e cujo valor calculado com base nos dados será utilizado para rejeitar ou não $H_0$;

   **No exemplo:**
   Um valor da média amostral que caia próximo de $\mu = 50$ cm/s é uma evidência de que a média verdadeira $\mu$ é realmente 50 cm/s. Por outro lado, uma média amostral que seja consideravelmente diferente de 50 cm/s evidencia que a hipótese alternativa $H_1$ é válida.
   Assim a média amostral é a estatística de teste nesse caso.

Mas a média amostral (antes de observarmos nossos dados) pode assumir infinitos valores. Para quais valores da média vamos rejeitar $H_0$?

3. Definir a região crítica ($RC$) ou de rejeição (conjunto de valores de $T$ para os quais rejeitamos $H_0$);

   Buscamos a região crítica que reduz as chances de cometermos o erro tipo I (rejeitar $H_0$ dado que ela é verdadeira) e II (não rejeitar $H_0$ dado que ela é falsa). Em termos matemáticos, queremos a $RC$ que reduza $Pr_0(T \in RC)$ e $Pr_1(T \notin RC) = 1 - Pr_1(T \in RC)$.

   Como fazemos isso?

4. Especificamos um nível de significância $\alpha$=Pr(erro tipo I) aceitável e encontramos a $RC$ com base na distribuição de probabilidade de $T$ sob $H_0$ (distribuição amostral da estatística teste);

**No exemplo:**
Se $\sigma^2 = 9$ e sob $H_0$, $T \sim$Normal$(50, 9/9)$ e $RC = \{T : T < 48.04$ ou $T > 51.96\}$ para $\alpha = 0.05$.

5. Calculamos o valor de $T$ usando os dados observados, $T_{obs}$. Se esse valor estiver na região crítica, rejeitamos $H_0$; se o valor de $T_{obs}$ não cair na região crítica, não rejeitamos $H_0$.

**Passos para a definição de um teste de hipóteses**:

1. Definir as hipóteses a serem testadas;
2. Escolher uma estatística teste $T$;
3. Encontrar a distribuição de probabilidade de $T$ sob $H_0$;
4. Especificar um nível de significância $\alpha$ e determinar a região crítica ou calcular o valor-p (é o menor nível de significância para o qual a hipótese nula seria rejeitada com base na amostra observada e sob $H_0$);
5. Verificar se o valor de $T$ calculado com base nos dados pertence ou não a região crítica e concluir sobre a rejeição ou não de $H_0$.

Para construir a região crítica ou calcular o valor-p do teste, ou mesmo construir intervalos de confiança, é essencial conhecermos a distribuição amostral da estatística teste. No exemplo anterior, sabíamos pelas suposições do problema que, sob $H_0$, a estatística $T$ tinha distribuição Normal com sua respectiva média e variância.

E se não sabemos ou não conseguimos identificar analiticamente qual é essa distribuição? O que fazemos?

Para a construção de intervalos de confiança para parâmetros ou função deles também precisamos conhecer, em geral, a distribuição amostral do estimador pontual utilizado bem como sua variância ou desvio padrão. Isso pode não ser fácil para casos mais complexos. O que fazemos?

Veremos alguns métodos nas próximas aulas.