Métodos Computacionalmente Intensivos em Estatística
Unidade 03: Métodos de reamostragem

Daiane A Zuanetti
DEs – UFSCar

2026

Métodos de reamostragem

Chamamos de métodos de reamostragem o conjunto de técnicas que utilizam reamostras para descrever o comportamento (distribuição) ou analisar propriedades dos estimadores de parâmetros. Eles geralmente são muito úteis quando consideramos estimadores de máxima verossimilhança e/ou de mínimos quadrados.

Uma reamostra consiste de uma amostra (determinística ou aleatória) coletada a partir de uma amostra que chamaremos de amostra original.

Esses métodos geralmente se baseiam no princípio "plug-in".

Princípio plug-in: Usar a distribuição estimada da amostra no lugar da distribuição verdadeira dos dados. A função distribuição empírica $\hat{F}$, em que

$$\hat{F}(x) = \frac{\text{número de } y_i \leq x}{n}$$

é uma estimativa pontual da distribuição inteira F e podemos estimar as características da distribuição populacional (parâmetros) através das características da distribuição empírica (estimadores).

Desse modo, esses métodos consideram que a amostra é a população e selecionam amostras iid dessa "pseudo população".

Problemas:

1. Quais as estimativas do vício e variância desse estimador?
2. Qual seria um intervalo de confiança fidedigno para θ usando $\hat{\theta}$?
3. Pode-se testar determinada hipótese sobre θ com base na amostra disponível?

Solução: Usar o bootstrap para determinar as características da distribuição do estimador de certo parâmetro, mas sem fazer suposição sobre a distribuição dos dados (devido a isso, o método é conhecido como uma técnica não paramétrica).

Bootstrap

Foi inicialmente proposto por Bradley Efron em 1979 e é uma das várias técnicas não paramétricas disponíveis para se fazer inferência estatística e avaliar a acurácia de uma estimativa, estatística ou teste.

Ideia principal: tratar os dados como se eles fossem a (verdadeira e desconhecida) população, ou seja, $\hat{F}$ toma o papel de F. E retiramos amostras de tamanho n (com reposição) dos dados originais como se estivéssemos retirando amostras independentes e identicamente distribuídas da população.

Repetimos o procedimento um número grande de vezes (B, por exemplo) e a cada amostra calculamos a quantidade de interesse. Então, usamos os B valores da quantidade de interesse para estimar a distribuição desconhecida desse estimador.

Até o momento, comentamos o uso do bootstrap para conhecer a distribuição de uma estimador plug-in, mas ele pode ser usado também para estimadores que não sejam plug-in.

Procedimento:

1. Calcule $\hat{\theta}$ para a amostra original;
2. Amostre dos dados com reposição e construa uma nova amostra de tamanho n, $\mathbf{y}^* = (y_1^*, \ldots, y_n^*)$, chamada de amostra bootstrap e definida como uma amostra aleatória de $\hat{F}$;
3. Calcule $\hat{\theta}$ para a amostra bootstrap obtida em (2), chamado $\hat{\theta}^*$;
4. Repita os passos (2) e (3) B vezes;
5. Use as B realizações de $\hat{\theta}^*$ para obter, por exemplo, uma estimativa do desvio padrão bootstrap, também chamado de erro padrão bootstrap (EPB), de $\hat{\theta}$, dado por

$$EPB(\hat{\theta}) = \sqrt{\frac{1}{B-1}\sum_{b=1}^{B}(\hat{\theta}_b^* - \hat{\theta}_{(\cdot)}^*)^2},$$

em que $\hat{\theta}_{(\cdot)}^* = \frac{1}{B}\sum_{b=1}^{B}\hat{\theta}_b^*$.

Exemplo do coeficiente de correlação: Uma amostra aleatória de tamanho $n = 15$ foi retirada de uma população de $N = 82$ escolas de direito. Duas medidas foram feitas em turmas inteiras de cada universidade:

- LSAT= nota média da classe no exame nacional de direito e;
- GPA= nota média da classe na graduação.

O interesse é verificar se existe associação entre LSAT e GPA e qual a acurácia dessa estimativa.

Como para esses dados temos a população toda, também queremos comparar a distribuição da estimativa encontrada via método bootstrap com a distribuição obtida via amostras iid da população.

No R.

Além do desvio padrão como uma medida de acurácia do estimador $\hat{\theta}$, há outras medidas estatísticas importantes a serem checadas no estimador.

Uma delas é o vício definido como

$$vício_F(\hat{\theta}) = E_F(\hat{\theta}) - \theta.$$

Quando temos um estimador viciado, podemos obter um estimador de vício corrigido por correção analítica (matemática) ou por bootstrap (numericamente).

Estimativa bootstrap do vício: A estimativa bootstrap do vício é definida como

$$\begin{aligned} \textit{vício}_{\hat{F}}(\hat{\theta}) &= E_{\hat{F}}(\hat{\theta}) - \hat{\theta} = \frac{1}{B}\sum_{b=1}^{B}\hat{\theta}_b^* - \hat{\theta} \\ &= \hat{\theta}_{(\cdot)}^* - \hat{\theta}. \end{aligned}$$

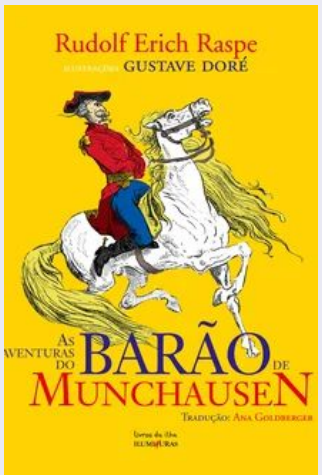
Uso do vício: Suponha que $\hat{\theta}$ é um estimador viciado de θ, mas apresenta outras propriedades boas. Se temos a estimativa $\textit{vício}_{\hat{F}}(\hat{\theta})$, podemos obter a estimativa corrigida pelo vício como

$$\begin{aligned} \tilde{\theta} = \hat{\theta} - \textit{vício}_{\hat{F}}(\hat{\theta}) &= \hat{\theta} - \left(\hat{\theta}_{(\cdot)}^* - \hat{\theta}\right) \\ &= 2\hat{\theta} - \hat{\theta}_{(\cdot)}^*. \end{aligned}$$

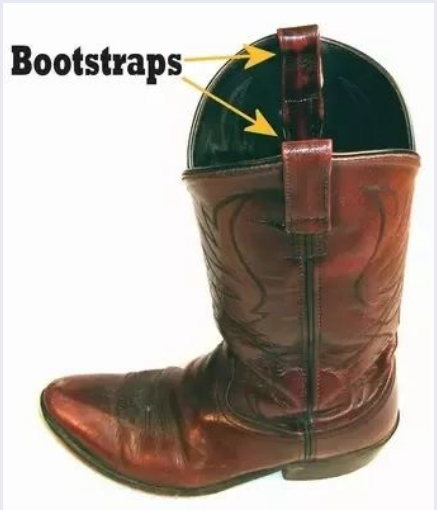
Exemplo: na lousa e no R.

Origem do nome:

- R. Tibshirani conta a origem do nome do método que seu orientador, B. Efron, criou;
- O termo Bootstrap vem do livro "As Aventuras do Barão de Munchausen" de Rudolph Erich Raspe.



(a)



(b)

Quão bem $\hat{F}$ se aproxima de F?

Pela desigualdade de Dvoretzky-Kiefer-Wolfowitz-Massart (DKW), para qualquer $\epsilon > 0$,

$$Pr\left(\sup_{x \in R} \left|F(x) - \hat{F}(x)\right| > \epsilon\right) \leq 2\exp(-2n\epsilon^2).$$

O número B de replicações bootstrap: A estimativa bootstrap ideal considera $B \to \infty$, mas o tempo de processamento aumenta linearmente ao valor de B.

Existem várias sugestões na literatura para a escolha de B:

- $B = 50$ é geralmente suficiente para uma boa estimativa de $EP_F(\hat{\theta})$. Raramente mais do que $B = 200$ replicações são necessárias para estimar o desvio padrão do estimador;
- No entanto, valores muito maiores de B são desejáveis para construir intervalos de confiança bootstrap;
- Pode-se rodar o bootstrap para diferentes valores de B e checar a partir de que valor as estimativas já estão estáveis.

Existem algumas maneiras de realizar o bootstrap. As duas mais comuns são:

- Bootstrap não-paramétrico (método que vimos até agora); e
- Bootstrap paramétrico.

Bootstrap não-paramétrico: a amostra bootstrap é obtida através de reamostragem aleatória com reposição dos dados originais, reamostrando de $\hat{F}$;

Bootstrap paramétrico: a amostra bootstrap é obtida através de reamostragem aleatória da distribuição geradora dos dados, com os parâmetros estimados através da amostra original, amostramos de $F(\hat{\theta})$.

O bootstrap não-paramétrico é mais robusto contra suposições de distribuições, enquanto que o bootstrap paramétrico é esperado ser mais eficiente (com estimativas mais precisas) quando as suposições paramétricas são corretas.

Também existe o bootstrap suavizado que em vez de amostrar de $\hat{F}$, amostra de uma distribuição suavizada (estimativa de Kernel da densidade dos dados, por exemplo).

Intervalo de confiança bootstrap

Interesse: construir um intervalo aleatório cujos limites não dependam de quantidades desconhecidas e que contém o verdadeiro valor do parâmetro desconhecido com uma específica probabilidade γ (0.95, por exemplo). Ou seja, queremos T_1 e T_2 tal que

$$Pr(T_1 \leq \theta \leq T_2) = \gamma.$$

Note que θ é uma quantidade fixa e o intervalo é aleatório.

Dado um $\hat{\theta}$ e seu erro padrão estimado $\widehat{EP}(\hat{\theta})$, o intervalo com 95% de confiança usual é

- $IC(\theta, 0.95) = (\hat{\theta} - 1.96\widehat{EP}(\hat{\theta}), \hat{\theta} + 1.96\widehat{EP}(\hat{\theta}))$, que pressupõe normalidade assintótica de $\hat{\theta}$; ou
- $IC(\theta, 0.95) = (\hat{\theta} - t_{n-1,0.975}\widehat{EP}(\hat{\theta}), \hat{\theta} + t_{n-1,0.975}\widehat{EP}(\hat{\theta}))$, usando a distribuição t-student; ou

- **Intervalo bootstrap por percentil:** Depois de obter a distribuição empírica $\hat{F}$ de $\hat{\theta}$ usando B amostras bootstrap, podemos construir um intervalo de $\gamma = (1 - \alpha)$ confiança por percentil através do cálculo dos percentis $\alpha/2$ e $1 - \alpha/2$ de $\hat{F}$.

  Nesse caso, o intervalo é

  $$(\hat{F}^{-1}(\alpha/2), \hat{F}^{-1}(1 - \alpha/2)), \text{ ou seja,}$$

  depois de ordenar crescentemente os valores de $\hat{\theta}_b^*$ obtido em cada uma das B amostras bootstrap, encontramos os limites inferior e superior do IC como sendo os valores de $\hat{\theta}_b^*$ nas posições $B\alpha/2$ e $B(1 - \alpha/2)$, respectivamente.

Observações:

- O intervalo bootstrap por percentil geralmente é preferido em relação ao IC que utiliza distribuição normal;
- Efron apresenta outros métodos bootstrap de estimação intervalar chamado de intervalo de confiança acelerado ou corrigido pelo vício e também o IC percentil t.

Exemplo 1: medida de associação entre as notas dos alunos de direito no R.

Exemplo 2: Intervalo de confiança para comparação de 2 médias independentes.

Considere 2 populações com distribuição F e G, respectivamente. Sejam $\mathbf{X} = (X_1, \ldots, X_n)$ e $\mathbf{Y} = (Y_1, \ldots, Y_m)$ amostras aleatórias independentes de F e G, respectivamente. As amostras fornecem estimadores $\hat{F}$ e $\hat{G}$ de F e G e queremos verificar via IC se F e G tem a mesma média, ou seja, se $\theta = \mu_F - \mu_G = 0$ que pode ser estimado por $\hat{\theta} = \bar{X} - \bar{Y}$.

Nesse caso, podemos fazer B reamostragens independentes de **x** e **y** e calcular $\hat{\theta}$ para cada uma das B reamostras e $\widehat{EP}(\hat{\theta})$. Com base nesses valores, calcular o IC para θ por percentil ou assumindo normalidade de $\hat{\theta}$.

Testes de hipóteses bootstrap

Nos casos em que há um teste paramétrico de verossimilhança ou Bayesiano alternativos ao bootstrap, eles são preferidos.

Para conduzir um teste de hipóteses bootstrap precisamos definir:

- A estatística do teste: $T(\mathbf{Y})$;
- A distribuição de $T(\mathbf{Y})$ sob H_0 e os dados, $\hat{F}_0$.

Considerando isso, geramos B amostras bootstrap, $\mathbf{y}^*$, sob H_0 e calculamos $T(\mathbf{y}^*)$ para cada amostra e o valor-p bootstrap como sendo

$$\hat{p}_{boot} = \frac{\#\{T(\mathbf{y}_b^*) \geq T(\mathbf{y})\}}{B},$$

em que $T(\mathbf{y})$ é o valor da estatística teste na amostra original e o sinal $\geq$ no cálculo do valor-p muda de acordo com H_1.

Rejeita-se H_0 se $\hat{p}_{boot} \leq \alpha$ fixo.

O que pode não ser óbvio, às vezes, é a escolha de $T(\mathbf{Y})$ e $\hat{F}_0$.

Exemplo 1: Teste de hipótese para uma população

Seja $\mathbf{y} = (94, 197, 16, 38, 99, 141, 23)$ os tempos de vida de 7 ratos que passaram por um específico tratamento e os pesquisadores querem testar se o tempo de vida médio dos ratos sob tratamento é menor que 129, ou seja, queremos testar

$H_0 : \mu_Y = 129$
$H_1 : \mu_Y < 129.$

Podemos basear nosso teste de hipótese bootstrap na estatística de teste

$$T(\mathbf{Y}) = \frac{\bar{Y} - 129}{\sqrt{\frac{S_Y^2}{7}}}.$$

Para os dados observados: $\bar{y} = 86.9$; $S_y = 66.8$ e

$$T(\mathbf{y}) = \frac{86.9 - 129}{\sqrt{\frac{4457.1}{7}}} = -1.67.$$

Mas qual é a distribuição de $T(\mathbf{Y})$ sob H_0? A distribuição empírica construída a partir dos dados observados $\hat{F}$ não atende $H_0 : \mu_Y = 129$, logo não pode ser usada.

Um jeito simples é transladar a distribuição empírica $\hat{F}$ de uma maneira que ela tenha a média sob H_0. E isso pode ser feito se considerarmos os valores

$$\tilde{y}_i = y_i - \bar{y} + 129, \text{ para } i = 1, \ldots, 7.$$

Assim, amostramos B amostras com reposição de $\tilde{\mathbf{y}} = (\tilde{y}_1, \ldots, \tilde{y}_7)$ e para cada amostra bootstrap $\tilde{\mathbf{y}}_b^*$ calculamos

$$T(\tilde{\mathbf{y}}_b^*) = \frac{\bar{\tilde{y}}_b^* - 129}{\sqrt{\frac{\tilde{s}_b^2}{7}}} \text{ e}$$

valor-p$=\hat{p}_{boot} = \frac{\#\{T(\tilde{\mathbf{y}}_b^*) \leq -1.67\}}{B}$.

No R.

Exemplo 2: Teste de hipótese para comparação de igualdade de médias

Seja $\mathbf{y} = (y_1, \ldots, y_m)$ uma amostra da distribuição G e $\mathbf{x} = (x_1, \ldots, x_n)$ uma amostra da distribuição F.
$\bar{y}$, $\bar{x}$ são as médias da amostra $\mathbf{y}$ e $\mathbf{x}$, respectivamente, e $\bar{z}$ é a média da amostra combinada. Queremos testar se

$H_0 : \mu_G = \mu_F$
$H_1 : \mu_G \neq \mu_F$.

Estatística teste: $T(\mathbf{z}) = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{s_x^2}{n} + \frac{s_y^2}{m}}}$, em que $\mathbf{z} = (\mathbf{x}, \mathbf{y})$ e assuma que as variâncias são diferentes.

Distribuição $\hat{F}_0$: os pontos $\tilde{x}_i = x_i - \bar{x} + \bar{z}$, para $i = 1, \ldots, n$ e $\tilde{y}_j = y_j - \bar{y} + \bar{z}$, para $j = 1, \ldots, m$, possuem a mesma média e podem ser utilizados para estimar F sob H_0.

Então amostre B amostras bootstrap $\mathbf{z}_b^* = (\mathbf{y}_b^*, \mathbf{x}_b^*)$, em que $\mathbf{y}_b^*$ é uma amostra com reposição de $\tilde{y}_1, \ldots, \tilde{y}_m$ e $\mathbf{x}_b^*$ é uma amostra com reposição de $\tilde{x}_1, \ldots, \tilde{x}_n$ e calcule

$$T(\mathbf{z}_b^*) = \frac{\bar{x}_b^* - \bar{y}_b^*}{\sqrt{\frac{S_{xb}^{2\,*}}{n} + \frac{S_{yb}^{2\,*}}{m}}}, \text{ para } b = 1, \ldots, B \text{ e}$$

valor-p$=\hat{p}_{boot} = \frac{\#\{|T(\tilde{\mathbf{z}}_b^*)| \geq |T(\mathbf{z})|\}}{B}$, em que $T(\mathbf{z})$ é o valor observado da estatística na amostra original.

Relação entre o teste de permutação para 2 populações e o bootstrap

- O valor-p calculado no teste de permutação é exato, enquanto que o valor-p no teste bootstrap é aproximado;
- Geralmente o teste de permutação é mais poderoso, mas exige que a distribuição de X e Y sejam iguais exceto, talvez, pelo parâmetro que está sendo analisado (para que a suposição de permutabilidade entre os dados total, sob H_0, seja válida);
- Geralmente o teste de permutação é mais poderoso do que todos os testes não-paramétrico vistos na disciplina de Estatística Não-paramétrica porque não conduz transformação e simplificação dos dados.

O uso do bootstrap para modelos de regressão: O método bootstrap em modelos de regressão foi inicialmente abordado por Friedman e colaboradores em 1981 para estimar a distribuição dos estimadores de mínimos quadrados em modelos de regressão (e depois em modelos de regressão generalizados, que em geral só utilizam teoria assintótica para construção de intervalos de confiança e testes de hipóteses).

Modelo de regressão linear múltipla: $\mathbf{Y} = \mathbf{X}\beta + \boldsymbol{\epsilon}$, em que

- $\mathbf{Y} = (Y_1, \ldots, Y_n)^T$ representa dos valores de Y;
- $\beta = (\beta_0, \ldots, \beta_{p-1})^T$ são os coeficientes de regressão;
- $\mathbf{X}$ é a matriz de planejamento $n \times p$ e sua i-ésima linha é dada por $\mathbf{x}_i = (1, x_{i1}, \ldots, x_{ip-1})$ e;
- $\boldsymbol{\epsilon} = (\epsilon_1, \ldots, \epsilon_n)^T$ são os erros aleatórios, $E[\epsilon_i] = 0$ e $\epsilon_i \sim F$ iid.

O estimador de mínimos quadrados de β é $\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}$.

Qual a acurácia do estimador $\hat{\beta}$?

Podemos estimar o desvio padrão bootstrap ou construir *IC*s para os coeficientes de regressão de 2 maneiras.

Reamostragem dos resíduos: Utilizamos os resíduos $e_i = y_i - \mathbf{x}_i\hat{\beta}$, $i = 1, 2, \ldots, n$, para construir $\hat{F}$ que é a estimativa empírica da distribuição F dos erros ϵ. Nesse caso,

- selecionamos B amostras bootstrap $\mathbf{e}_b^* = (e_{b1}^*, \ldots, e_{bn}^*)$ (de tamanho n) dos resíduos originais $\mathbf{e} = (e_1, ..., e_n)$. Deles calculamos $\mathbf{y}_b^*$, em que $y_{bi}^* = \mathbf{x}_i\hat{\beta} + e_{bi}^*$, para $b = 1, 2, \ldots, B$;
- para cada uma das B amostras, encontramos a estimativa $\hat{\beta}_b^* = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}_b^*$; e
- as estimativas $\hat{\beta}_b^*$ podem ser usadas da maneira usual para calcular o desvio padrão bootstrap e calcular IC para os coeficientes de regressão.

Note que $\mathbf{X}$ é fixo para todas as amostras bootstrap. Essa construção do bootstrap considera que o modelo linear é correto e que os erros são identicamente distribuídos (homocedásticos inclusive).

Reamostragem dos pares $(\mathbf{x}, y)$: Esse tipo de amostragem é menos sensível às suposições do modelo do que a reamostragem dos resíduos e permite estimativas razoáveis de desvios padrão mesmo que a variância dos erros não seja constante ou existam dúvidas sobre a adequabilidade da função linear entre x e Y.

A única suposição é que os pares originais $z_i = (\mathbf{x}_i, y_i)$ sejam uma amostra aleatória de alguma distribuição G de dimensão p. Nesse caso,

- sorteamos B amostras bootstrap $\mathbf{z}_b^* = (z_{b1}^*, \ldots, z_{bn}^*)$ (de tamanho n) da amostra original de $\mathbf{z} = (z_1, ..., z_n)$;
- para cada uma das B amostras, encontramos a estimativa $\hat{\beta}_b^* = (\mathbf{X}_b^{*T}\mathbf{X}_b^*)^{-1}\mathbf{X}_b^{*T}\mathbf{Y}_b^*$; e
- as estimativas $\hat{\beta}_b^*$ podem ser usadas da maneira usual para calcular o desvio padrão bootstrap e calcular IC para os coeficientes de regressão.

Exemplo: Considere um experimento em que se analisa a octanagem da gasolina (Y) em função da adição de um novo aditivo (x). Para isso, foram realizados ensaios com os percentuais de 1, 2, 3, 4, 5 e 6% de aditivo. Os dados são representados no gráfico abaixo.

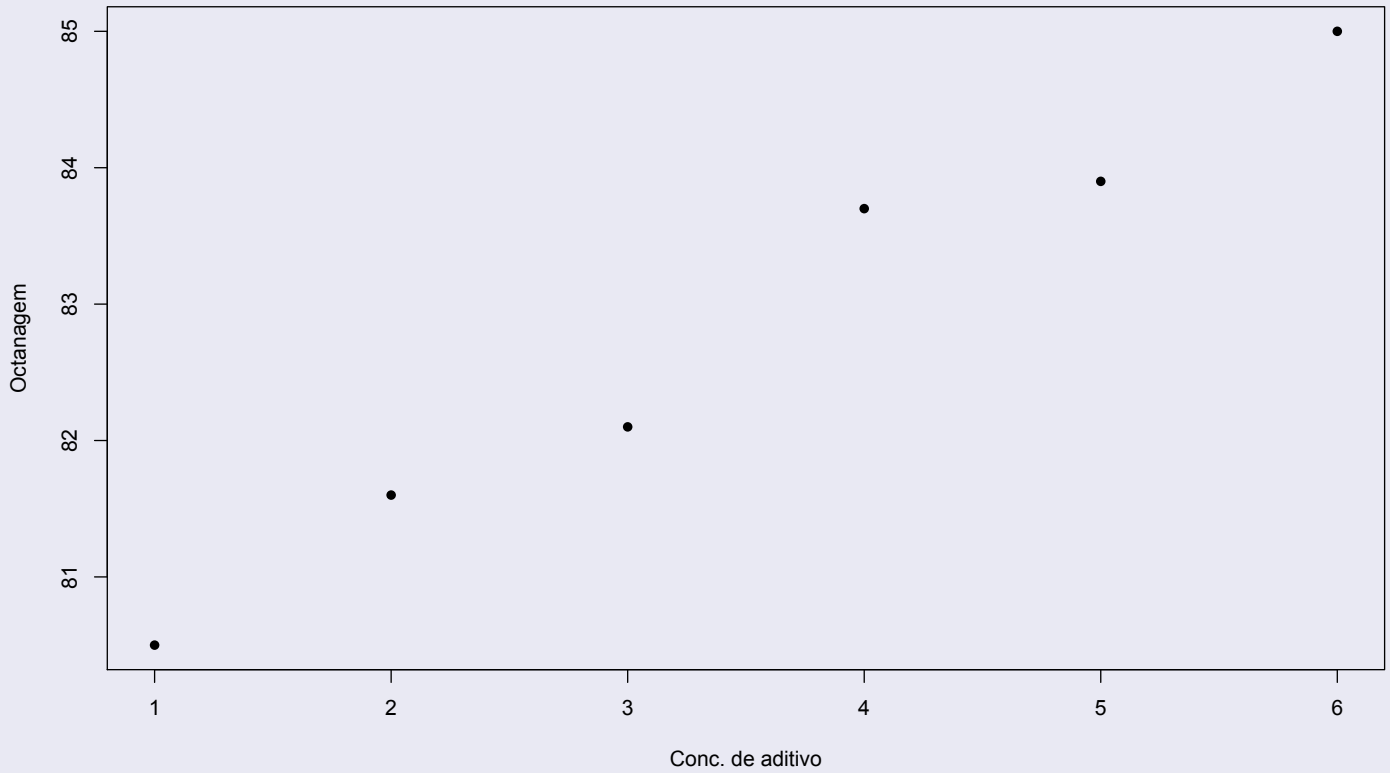


Figura: Gráfico de dispersão com dados do exemplo.

No R.

Jackknife

- Quenouille (1947) propôs a ideia, Tukey(1958) reconhece seu potencial e atribui o nome e Muller (1964 e 1974) desenvolve a técnica;
- Ele precede o bootstrap e a proposta inicial é para estimar o vício e o erro padrão dos estimadores. É visto como uma aproximação do bootstrap.

Suponha uma amostra $\mathbf{y} = (y_1, \ldots, y_n)$ e um estimador $\hat{\theta}(\mathbf{y})$ para θ. Desejamos estimar o erro padrão e o vício associado a $\hat{\theta}(\mathbf{y})$. A i-ésima amostra jackknife $\mathbf{y}_{-i}$ é definida como $\mathbf{y}$ com a i-ésima observação removida.

Temos então n diferentes amostras jackknife comparadas as n^n amostras bootstrap (considerando que a ordem selecionada na amostra é importante e que não temos valores repetidos).

O estimador do $vício_F(\hat{\theta})$ é

$$\widehat{vício}_{jack} = (n-1)(\hat{\theta}_{(\cdot)} - \hat{\theta}),$$

em que $\hat{\theta}_{(\cdot)} = \frac{\sum_{i=1}^{n} \hat{\theta}_{(i)}}{n}$ e $\hat{\theta}_{(i)}$ é o valor de $\hat{\theta}$ na i-ésima amostra jackknife.

O erro padrão de $\hat{\theta}$ ($EP(\hat{\theta})$) é estimado como

$$\widehat{EP}_{jack}(\hat{\theta}) = \sqrt{\frac{n-1}{n} \sum_{i=1}^{n} \left(\hat{\theta}_{(i)} - \hat{\theta}_{(\cdot)}\right)^2},$$

o fator inflacionário $\frac{n-1}{n}$ é necessário porque as amostras jackknife são muito mais similares que a amostra original do que as amostras bootstrap e foi obtido fazendo com que $\widehat{EP}_{jack}(\hat{\theta})$ seja um estimador não viciado para $EP(\hat{\theta})$ quando $\hat{\theta} = \bar{Y}$.

Relação entre jackknife e bootstrap

- Jackknife requer o cálculo de $\hat{\theta}$ somente n vezes enquanto que no bootstrap o número de simulações é maior e exige mais esforço computacional (o que não é um grande problema nos dias de hoje);
- Para n pequeno, o método jackknife usa informação limitada de $\hat{\theta}$ e, em geral, é menos eficiente que o bootstrap;
- O jackknife também pode ser processado com "d" elementos removidos da amostra a cada passo e, se assim for aplicado, tem correção na fórmula do erro padrão.

Métodos de validação cruzada

Apesar de ter um objetivo diferente dos métodos de reamostragem vistos anteriormente (cujo objetivo principal é inferencial), os métodos de validação cruzada, muito utilizados em métodos de aprendizado de máquinas (ou aprendizado estatístico), também são métodos de reamostragem.

O objetivo principal agora é avaliar a capacidade (o desempenho) de um modelo estatístico ajustado em prever o resultado de novas observações que não foram usadas para estimá-lo, a fim de sinalizar problemas como *overfitting* ou viés de seleção. Ou seja, o objetivo é preditivo.

A ideia principal da validação cruzada é dividir aleatoriamente os dados em duas partes, ajustar o modelo usando o primeiro subconjunto e testar e avaliar o modelo ajustado (através da comparação de valor predito e observado) no segundo subconjunto. Esse procedimento é repetido várias vezes.

Diversas formas de realizar o particionamento dos dados foram sugeridas, sendo as três mais utilizadas: o método *holdout*, o *k-fold* e o *leave-one-out* ou *leave-d-out*.

O jackknife é o método mais utilizado quando usamos o *leave-one-out* ou *leave-d-out*.

O bootstrap também tem sido utilizado em várias técnicas de aprendizado de máquinas (ou estatístico), como por exemplo o *bagging*. Mais detalhes sobre esses métodos são vistos na disciplina de mineração de dados.

O jackknife também é bastante utilizado em inferência Bayesiana para verificar a adequabilidade do modelo, através da distribuição a posteriori ou preditiva deixando uma observação fora do ajuste.

A influência de uma observação no modelo ajustado pode ser verificada através de métricas baseadas nessas distribuições.

Mais detalhes devem ser vistos na disciplina de Estatística Bayesiana.