Métodos Computacionalmente Intensivos em Estatística
Unidade 04: Métodos de otimização estatística

Daiane A Zuanetti
DEs – UFSCar

2026

Método delta

- é um método utilizado para aproximar a variância de um estimador ou sua distribuição amostral;
- é, portanto, geralmente utilizado para conduzir inferência frequentista e uma alternativa aos métodos de reamostragem que vimos anteriomente.
- alguns autores também o citam com uma versão generalizada do teorema central do limite (TCL).

Teorema simplificado: Seja $Y_1, Y_2, \ldots$ uma sequência de variáveis aleatórias que satisfazem $\sqrt{n}\,(Y_n - \theta) \overset{n\to\infty}{\sim} N(0, \sigma^2)$ ou, equivalentemente, $\sqrt{n}\left(\frac{Y_n - \theta}{\sigma}\right) \overset{n\to\infty}{\sim} N(0,1)$. Seja g uma função contínua e derivável tal que $g'(\theta) \neq 0$. Então,

$$\sqrt{n}\,(g(Y_n) - g(\theta)) \overset{n\to\infty}{\sim} N(0, \sigma^2(g'(\theta))^2)$$

ou, equivalentemente,

$$\sqrt{n}\left(\frac{g(Y_n) - g(\theta)}{|g'(\theta)|\sigma}\right) \overset{n\to\infty}{\sim} N(0,1).$$

Aplicação (corolário): Talvez a aplicação mais usual desse teorema seja para encontrar a distribuição de uma função da média amostral.
Seja $X_1, X_2, \ldots, X_n$ uma sequência de variáveis aleatórias iid de uma distribuição qualquer com média μ e variância finita σ^2. Pelo TCL, sabemos que

$$Y_n = \bar{X}_n \overset{n\to\infty}{\sim} N(\mu, \tfrac{\sigma^2}{n}),$$

que implica que

$$g(Y_n) = g(\bar{X}_n) \overset{n\to\infty}{\sim} N(g(\mu), \tfrac{\sigma^2}{n}(g'(\mu))^2)$$

ou, equivalentemente,

$$\sqrt{n}\left(\tfrac{g(Y_n)-g(\mu)}{|g'(\mu)|\sigma}\right) \overset{n\to\infty}{\sim} N(0,1).$$

Exemplo 1: Seja $X_1, X_2, \ldots, X_n$ uma amostra aleatória com média μ e variância finita σ^2 e, pelo TCL, sabemos que $\bar{X}_n \overset{n\to\infty}{\sim} N(\mu, \frac{\sigma^2}{n})$. Seja $W_n = \exp(\bar{X}_n)$, então, como as suposições do método delta estão verificadas para a sequência de $\bar{X}_n$,

$$W_n \overset{n\to\infty}{\sim} N(\exp(\mu), \frac{\sigma^2}{n}\exp(2\mu)).$$

Exemplo 2: Seja $X_1, X_2, \ldots, X_n$ uma amostra aleatória de uma distribuição Bernoulli(p) com média p e variância finita $p(1-p)$. Desejamos encontrar a variância de $\frac{\hat{p}}{1-\hat{p}} = \frac{\bar{X}_n}{1-\bar{X}_n} = g(\bar{X}_n)$.

Pelo TCL, sabemos que $\bar{X}_n \overset{n\to\infty}{\sim} N(p, \frac{p(1-p)}{n})$ e o método delta pode ser aplicado pois suas suposições estão satisfeitas para a sequência de $\bar{X}_n$. Então,

$$
\begin{aligned}
Var(Y_n) &= Var(g(\bar{X}_n)) \\
&= Var\left(\frac{\hat{p}}{1-\hat{p}}\right) \overset{n\to\infty}{=} \frac{p(1-p)}{n}(g'(p))^2 \\
&= \frac{p(1-p)}{n}\left(\frac{1}{1-p} + \frac{p}{(1-p)^2}\right)^2 \\
&= \frac{p(1-p)}{n}\left(\frac{1}{(1-p)^2}\right)^2 = \frac{p}{n(1-p)^3}. \qquad (1)
\end{aligned}
$$

Teorema geral: Seja $Y_1, Y_2, \ldots$ uma sequência de variáveis aleatórias, F^* uma distribuição contínua, θ um número real e $a_1, a_2, \ldots$ uma sequência de números positivos que aumentam quando $n \to \infty$.

Suponha que $a_n(Y_n - \theta)$ converge em distribuição para F^* e seja g uma função contínua e derivável tal que $g'(\theta) \neq 0$. Então,

$$a_n \left(\frac{g(Y_n) - g(\theta)}{|g'(\theta)|} \right) \overset{n \to \infty}{\sim} F^*.$$

Prova: aqui temos apenas uma ideia da demonstração.

Como $a_n \to \infty$, Y_n fica perto de θ com alta probabilidade quando $n \to \infty$ e, porque g é contínua, $g(Y_n)$ também deve ficar perto de $g(\theta)$ com alta probabilidade.

Expandindo $g(Y_n)$ em séries de Taylor ao redor de θ e ignorando todos os termos envolvendo $(Y_n - \theta)^2$ e de maior potência na expansão, temos

$$g(Y_n) \approx g(\theta) + g'(\theta)(Y_n - \theta).$$

Subtraindo $g(\theta)$ de ambos os lados da expressão e depois multiplicando os dois lados por $\frac{a_n}{g'(\theta)}$, temos

$$\frac{a_n}{g'(\theta)}(g(Y_n) - g(\theta)) \approx a_n(Y_n - \theta), \text{ ou seja,}$$

a distribuição do lado esquerdo é aproximadamente a mesma distribuição do lado direito da equação.

Observações:

1. o método delta é um método assintótico, logo os resultados só valem (a aproximação é boa) para grandes amostras;
2. com base nessa distribuição e variância assintóticas, podemos construir intervalos de confiança e conduzir testes de hipóteses;
3. se $g'(\theta) = 0$ mas $g''(\theta) \neq 0$, podemos utilizar o método delta de segunda ordem (obtido através da expansão de Taylor até a segunda derivada);
4. em inferência estatística, vimos que a distribuição assintótica de estimadores de máxima verossimilhança é normal. Logo, a distribuição assintótica de funções suaves desses estimadores podem ser determinadas pelo método delta.

Caso multivariado: Seja $\mathbf{Y}_1, \mathbf{Y}_2, \ldots$ uma sequência de vetores aleatórios, em que $\mathbf{Y}_n = (Y_{n1}, \ldots, Y_{np})^\top$, que satisfazem $\sqrt{n}\,(\mathbf{Y}_n - \boldsymbol{\theta}) \overset{n\to\infty}{\sim} N_p(\mathbf{0}, \boldsymbol{\Sigma})$.

Assuma $\mathbf{g} : \mathbb{R}^p \to \mathbb{R}^k$, $k < p$, com derivadas parciais de primeira ordem contínuas e não zeros em $\boldsymbol{\theta}$ e ∇ a matriz $(p \times k)$ de derivadas parciais de primeira ordem de $\mathbf{g}$, ou seja, $\nabla = \begin{pmatrix} \frac{\partial g_1}{\partial y_1} & \ldots & \frac{\partial g_k}{\partial y_1} \\ \vdots & \ldots & \vdots \\ \frac{\partial g_1}{\partial y_p} & \ldots & \frac{\partial g_k}{\partial y_p} \end{pmatrix}$ e avaliada em $\mathbf{y} = \boldsymbol{\theta}$. Então,

$$\sqrt{n}\,(\mathbf{g}(\mathbf{Y}_n) - \mathbf{g}(\boldsymbol{\theta})) \overset{n\to\infty}{\sim} N_k(\mathbf{0}, \nabla^\top \boldsymbol{\Sigma} \nabla).$$

Exemplo 3: Seja $\mathbf{X}_1, \mathbf{X}_2, \ldots, \mathbf{X}_n$ vetores aleatórios iid, em que $\mathbf{X}_n = (X_{n1}, X_{n2})^\top$, com média $\boldsymbol{\mu} = (\mu_1, \mu_2)^\top$ e matriz de variância e covariância $\boldsymbol{\Sigma}$.
Seja $g : \mathbb{R}^2 \to \mathbb{R} = \bar{X}_{n1}\bar{X}_{n2}$ e desejamos encontrar a distribuição desse estimador.

Pelo TCL, sabemos que
$\sqrt{n}\begin{pmatrix} \bar{X}_{n1} - \mu_1 \\ \bar{X}_{n2} - \mu_2 \end{pmatrix} = \sqrt{n}\begin{pmatrix} Y_{n1} - \mu_1 \\ Y_{n2} - \mu_2 \end{pmatrix} = \sqrt{n}\,(\mathbf{Y}_n - \boldsymbol{\mu}) \overset{n\to\infty}{\sim} N(0, \boldsymbol{\Sigma})$ e o método delta pode ser aplicado pois suas suposições estão satisfeitas para a sequência $\mathbf{Y}_n$.

Como $\nabla = \begin{pmatrix} \bar{X}_{n2} \\ \bar{X}_{n1} \end{pmatrix}$, e avaliada em $\boldsymbol{\mu}$, $\nabla = \begin{pmatrix} \mu_2 \\ \mu_1 \end{pmatrix}$, então $\nabla^T \Sigma \nabla =$
$\begin{pmatrix} \mu_2 & \mu_1 \end{pmatrix}\begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{pmatrix}\begin{pmatrix} \mu_2 \\ \mu_1 \end{pmatrix} = \mu_2^2\sigma_{11} + 2\mu_1\mu_2\sigma_{12} + \mu_1^2\sigma_{22}.$

Assim, $\sqrt{n}\,(\bar{X}_{n1}\bar{X}_{n2} - \mu_1\mu_2) \overset{n\to\infty}{\sim} N(0, \mu_2^2\sigma_{11} + 2\mu_1\mu_2\sigma_{12} + \mu_1^2\sigma_{22})$.

Método escore de Fisher

Em muitas situações, a função de verossimilhança é uma função contínua dos parâmetros e é possível resolver o sistema de equações oriundo das derivadas parciais de primeira ordem da log-verossimilhança e encontrar, analiticamente, as expressões matemáticas dos estimadores.

No entanto, em alguns casos, não é possível obter a solução analítica desse sistema de equações e métodos numéricos são necessários para solucioná-las.

O método escore de Fisher é um dos métodos geralmente usados para resolver numericamente esses sistemas de equações. Ele é baseado no método de Newton-Raphson (cálculo numérico) e sua fundamentação teórica vem da expansão em séries de Taylor da função escore.

Seja $Y_1, \ldots, Y_n$ uma amostra aleatória da distribuição com função densidade $f(y;\theta)$ duplamente diferenciável e seja o interesse encontrar o estimador de máxima verossimilhança θ^* de θ (pode ser uni ou multidimensional).

A função de verossimilhança é dada por $\mathcal{L}(\theta|\mathbf{y}) = \prod_{i=1}^{n} f(y_i;\theta)$ e a log-verossimilhança por $\log(\mathcal{L}(\theta|\mathbf{y})) = l(\theta|\mathbf{y}) = \sum_{i=1}^{n} \log(f(y_i;\theta))$.

A função escore é definida como $V(\theta) = \frac{\partial l(\theta|\mathbf{y})}{\partial \theta}$.

Primeiramente, suponha que temos um valor inicial θ_0 e considere a expansão de Taylor da função escore, $V(\theta)$, ao redor de θ_0, dada por

$$V(\theta) \approx V(\theta_0) - \mathcal{J}(\theta_0)(\theta - \theta_0),$$

em que $\mathcal{J}(\theta_0) = -V'(\theta_0) = -\frac{\partial^2 l(\theta_0|\mathbf{y})}{\partial \theta_0^2}$ é a matriz de informação observada em θ_0.

Assuma agora $\theta = \theta^*$. Usando que $V(\theta^*) = 0$ e isolando θ^* na equação anterior, temos:

$$\theta^* \approx \theta_0 + \mathcal{J}^{-1}(\theta_0)V(\theta_0).$$

A relação $\theta_{m+1} = \theta_m + \mathcal{J}^{-1}(\theta_m)V(\theta_m)$ pode ser utilizada, então, para encontrar iterativa e numericamente a estimativa de θ.

Sob certas condições de regularidade, pode ser mostrado que θ_m converge em probabilidade para θ^*.

Esse método é conhecido como método de Newton-Raphson e apresenta, em alguns casos, convergência lenta e não é muito eficiente. O método escore de Fisher surge, então, como uma alternativa mais eficiente para encontrar iterativamente a estimativa de θ.

Na prática, o método escore de Fisher, substitui $\mathcal{J}(\theta)$ por $\mathcal{I}(\theta) = \mathrm{E}[\mathcal{J}(\theta)]$, conhecida como Informação de Fisher.

Por esse motivo (usar a esperança da matriz de informação observada em relação a **y**), o método também é conhecido como a versão estocástica do método Newton-Raphson.

Logo, temos uma nova relação iterativa para encontrar a estimativa de θ, dada por:

$$\theta_{m+1} = \theta_m + \mathcal{I}^{-1}(\theta_m) V(\theta_m).$$

Algoritmo:

1. Inicializa-se θ um valor inicial θ_0 (se o valor inicial for muito distante do verdadeiro valor do parâmetro podemos ter problema de convergência);
2. Com o valor inicial, gera-se uma nova estimativa para o parâmetro através da relação iterativa do slide anterior;
3. Verifica-se se o critério de parada foi satisfeito. Se sim, termina-se o processo iterativo. Caso contrário, gera-se um novo valor com base na estimativa anterior até que o critério de parada seja alcançado.

Um critério de parada geralmente utilizado é $||\theta_{m+1} - \theta_m|| < \epsilon$, para $\epsilon > 0$.

Obs: Como a estimativa final de θ obtida por esse processo se trata de uma estimativa de máxima verossimilhança (MV), todas as propriedades de um estimador MV são válidas.

Exemplo 1: Seja $Y_1, \ldots, Y_n$ uma amostra aleatória de $Y \sim Gama(\alpha, \beta)$, com $\beta > 0$ conhecido e $\alpha > 0$. Descreva o método para obtenção do estimador de α.

Na lousa e no R.

Exemplo 2: E se no Exemplo 1 o β também fosse desconhecido?

Na lousa e no R.

Algoritmo EM

O algoritmo EM (do inglês, Expectation and Maximization), proposto em 1977 por Dempster, Laird e Rubin, é um dos algoritmos mais utilizados para encontrarmos estimativas de máxima verossimilhança quando há:

- dados faltantes (a função de verossimilhança possivelmente tem uma forma mais complicada e depende de valores não observados);
- a introdução de variáveis latentes (ou não observáveis) para facilitar a escrita da função de verossimilhança e torná-la computacionalmente mais eficiente (metodologia de dados aumentados ou modelos mistos).

A ideia é transformar o problema de encontrar o máximo de uma função complicada em dois problemas mais simples: o E (esperança) e o M (maximização) e alternar entre esses dois passos iterativamente.

Seja $Y_1, \ldots, Y_n$ variáveis aleatórias observadas da distribuição $g(\mathbf{y}; \boldsymbol{\theta})$ e $S_1, \ldots, S_m$ variáveis aleatórias não observadas da distribuição conjunta $f(\mathbf{y}, \mathbf{s}; \boldsymbol{\theta})$.

A função de verossimilhança, considerando os dados faltantes, é dada por:

$$\mathcal{L}(\boldsymbol{\theta}|\mathbf{y}) = \int f(\mathbf{y}, \mathbf{s}; \boldsymbol{\theta}) d\mathbf{s},$$

que geralmente não é simples de ser maximizada.

Obs: se a integral acima não pode ser analiticamente resolvida, integrações numéricas ou por Monte Carlo podem ser utilizadas (aprendidas por vocês em cálculo numérico e programação estatística).

Sabemos que a distribuição condicional de $\mathbf{S}$ faltante dado $\mathbf{Y}$ observada é dada por:

$$h(\mathbf{s};\boldsymbol{\theta}|\mathbf{y}) = \frac{f(\mathbf{y},\mathbf{s};\boldsymbol{\theta})}{g(\mathbf{y};\boldsymbol{\theta})}.$$

Logo,

$$\log\left(h(\mathbf{s};\boldsymbol{\theta}|\mathbf{y})\right) = l(\boldsymbol{\theta}|\mathbf{y},\mathbf{s}) - l(\boldsymbol{\theta}|\mathbf{y}),$$

em que $l(\boldsymbol{\theta}|\mathbf{y},\mathbf{s})$ é conhecida como a log-verossimilhança completa (ou aumentada) e $l(\boldsymbol{\theta}|\mathbf{y})$ a log-verossimilhança incompleta (ou marginal), ou seja,

$$l(\boldsymbol{\theta}|\mathbf{y}) = l(\boldsymbol{\theta}|\mathbf{y},\mathbf{s}) - \log\left(h(\mathbf{s};\boldsymbol{\theta}|\mathbf{y})\right).$$

Calculando a esperança da expressão anterior em relação às informações faltantes, ou seja, em relação à distribuição de $\mathbf{S}|\mathbf{y}$ em $\boldsymbol{\theta} = \boldsymbol{\theta}^{(0)}$, temos

$$E_{\mathbf{S}|\mathbf{y}}(l(\boldsymbol{\theta}|\mathbf{y})) = E_{\mathbf{S}|\mathbf{y}}(l(\boldsymbol{\theta}|\mathbf{y}, \mathbf{S})) - E_{\mathbf{S}|\mathbf{y}}(\log(h(\mathbf{S}; \boldsymbol{\theta}|\mathbf{y}))).$$

Observe que $l(\boldsymbol{\theta}|\mathbf{y})$ não depende de $\mathbf{S}$ e se $E_{\mathbf{S}|\mathbf{y}}(\log(h(\mathbf{S}; \boldsymbol{\theta}|\mathbf{y})))$ for ignorado, temos

$$l(\boldsymbol{\theta}|\mathbf{y}) = E_{\mathbf{S}|\mathbf{y}}(l(\boldsymbol{\theta}|\mathbf{y}, \mathbf{S})),$$

ou seja, maximizar $l(\boldsymbol{\theta}|\mathbf{y})$ é equivalente a maximizar $E_{\mathbf{S}|\mathbf{y}}(l(\boldsymbol{\theta}|\mathbf{y}, \mathbf{S}))$.

O algoritmo, então, se resume em:

1. Passo E: encontrar
   $Q(\boldsymbol{\theta}|\boldsymbol{\theta}^{(t=0)}) = E_{\mathbf{S}|\mathbf{y}}(l(\boldsymbol{\theta}|\mathbf{y}, \mathbf{S})) = \int l(\boldsymbol{\theta}|\mathbf{y}, \mathbf{s}) h(\mathbf{s}; \boldsymbol{\theta}^{(t=0)}|\mathbf{y}) d\mathbf{s}$;
2. Passo M: maximizar $Q(\boldsymbol{\theta}|\boldsymbol{\theta}^{(t=0)})$ em relação a $\boldsymbol{\theta}$, ou seja, encontrar $\boldsymbol{\theta}^{(t+1=1)} = \arg\max Q(\boldsymbol{\theta}|\boldsymbol{\theta}^{(t=0)})$;
3. repetir passos 1 e 2 até alcançar a convergência, para $t = 1, \ldots, T$.

Intuitivamente, se $\mathbf{S}$ representa dados faltantes, o passo E tenta completá-los, com base nos dados observados e na estimativa anterior para $\boldsymbol{\theta}$ dada por $\boldsymbol{\theta}^{(t)}$, e o passo M atualiza essa estimativa com base nesse complemento.

Observações:

- O algoritmo encontra um máximo local próximo de $\boldsymbol{\theta}^{(0)}$, que é a estimativa de máxima verossimilhança caso a função de verossimilhança seja unimodal;
- Ele precisa de um valor inicial $\boldsymbol{\theta}^{(0)}$. Geralmente o algoritmo é sensível a esse valor inicial e pode apresentar convergência muito lenta se ele for ruim;
- Pela desigualdade de Jensen, podemos mostrar que o termo $E_{\mathbf{S}|\mathbf{y}}(\log(h(\mathbf{S};\boldsymbol{\theta}|\mathbf{y})))$ pode ser desconsiderado (não veremos isso em aula);
- L. Wasserman no livro All of Statistics apresenta uma ideia da prova da convergência do algoritmo. Em particular, ele mostra que as iterações do algoritmo EM sempre aumentam o valor da função de verossimilhança.

Exemplo: modelos de mistura com dados aumentados

Seja $\mathbf{y} = (y_1, \ldots, y_n)$ uma amostra de uma variável para n indivíduos provenientes de K diferentes subpopulações, em que

- cada população é representada por uma distribuição de probabilidade $f(\cdot; \boldsymbol{\theta}_k)$, $k = 1, \ldots, K$;
- $\boldsymbol{\theta}_k$ pode ser um vetor paramétrico (no caso de $f(\cdot)$ ser a função densidade normal, por exemplo) ou um único parâmetro (no caso de $f(\cdot)$ ser a função de probabilidade Poisson, por exemplo); e
- K é conhecido, mas não sabemos de qual das K populações cada observação da amostra é proveniente.

Nesse caso, a distribuição de probabilidade de y_i é dada por

$$f(y_i; \boldsymbol{\theta}, \mathbf{w}) = \sum_{k=1}^{K} w_k f(y_i; \boldsymbol{\theta}_k), \tag{2}$$

em que w_k é o peso (ou probabilidade) da $k-$ésima distribuição (população) e $\sum_{k=1}^{K} w_k = 1$.

O modelo descrito em (2) é um modelo de mistura e cada distribuição em (2) é chamada de componente da mistura.

A distribuição conjunta de $\mathbf{y}$ ou a função de verossimilhança de $\boldsymbol{\theta}$ e $\mathbf{w}$, assumindo y_is independentes é dada por

$$L(\boldsymbol{\theta}, \mathbf{w} \mid \mathbf{y}) = f(\mathbf{y}; \boldsymbol{\theta}, \mathbf{w}) = \prod_{i=1}^{n} f(y_i; \boldsymbol{\theta}, \mathbf{w}) = \prod_{i=1}^{n} \sum_{k=1}^{K} w_k f(y_i; \boldsymbol{\theta}_k). \quad (3)$$

Ilustração: Seja $Y_1, \ldots, Y_n$ uma amostra da altura de n pessoas de uma população composta por: homens e mulheres adultas e crianças, em que Y_i = altura em metros da $i-$ésimo indivíduo da amostra, para $i = 1, \ldots, n$.

Composição da população:

- 40 homens com altura proveniente de uma $N(\mu = 1.80; \sigma^2 = 0.1^2)$;
- 40 mulheres com altura proveniente de uma $N(1.60; 0.05^2)$; e
- 20 crianças com altura proveniente de uma $N(1.20; 0.13^2)$.

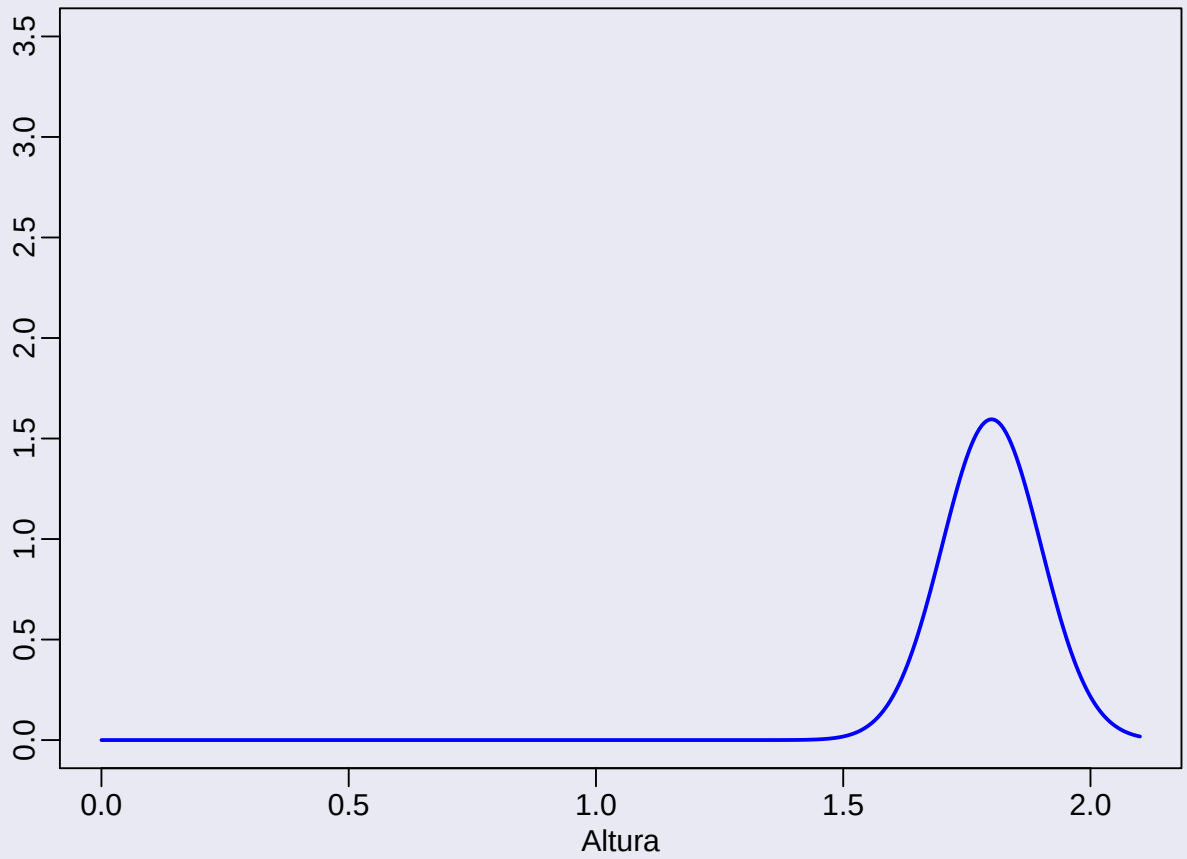


Figura: Distribuição da altura na população.

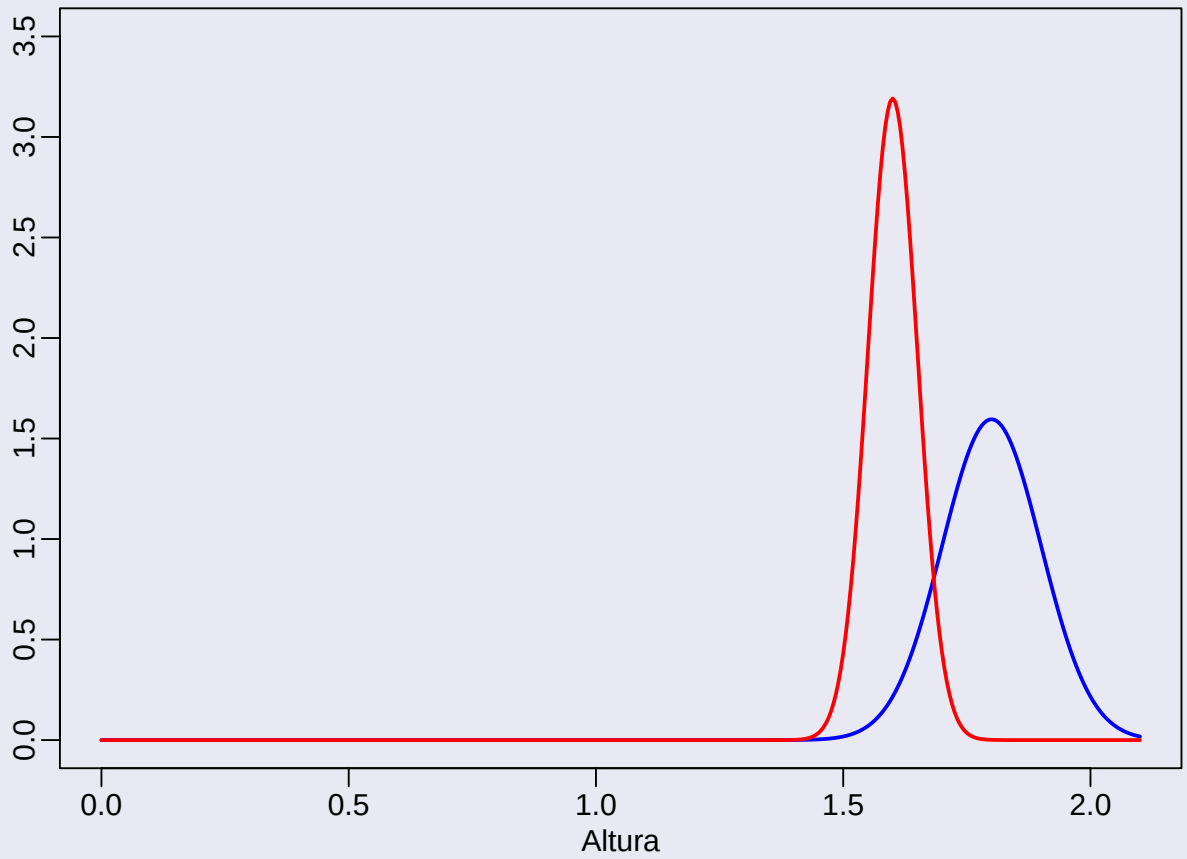


Figura: Distribuição da altura na população.

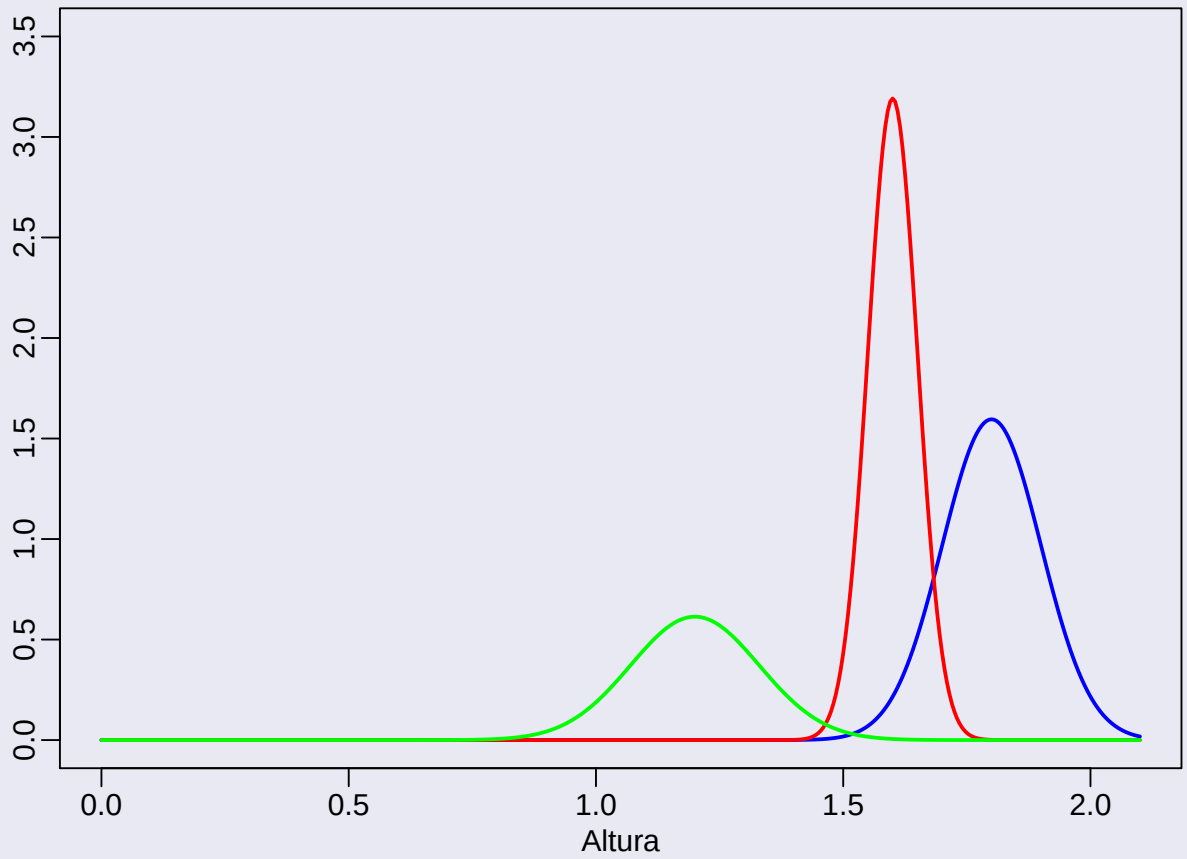


Figura: Distribuição da altura na população.

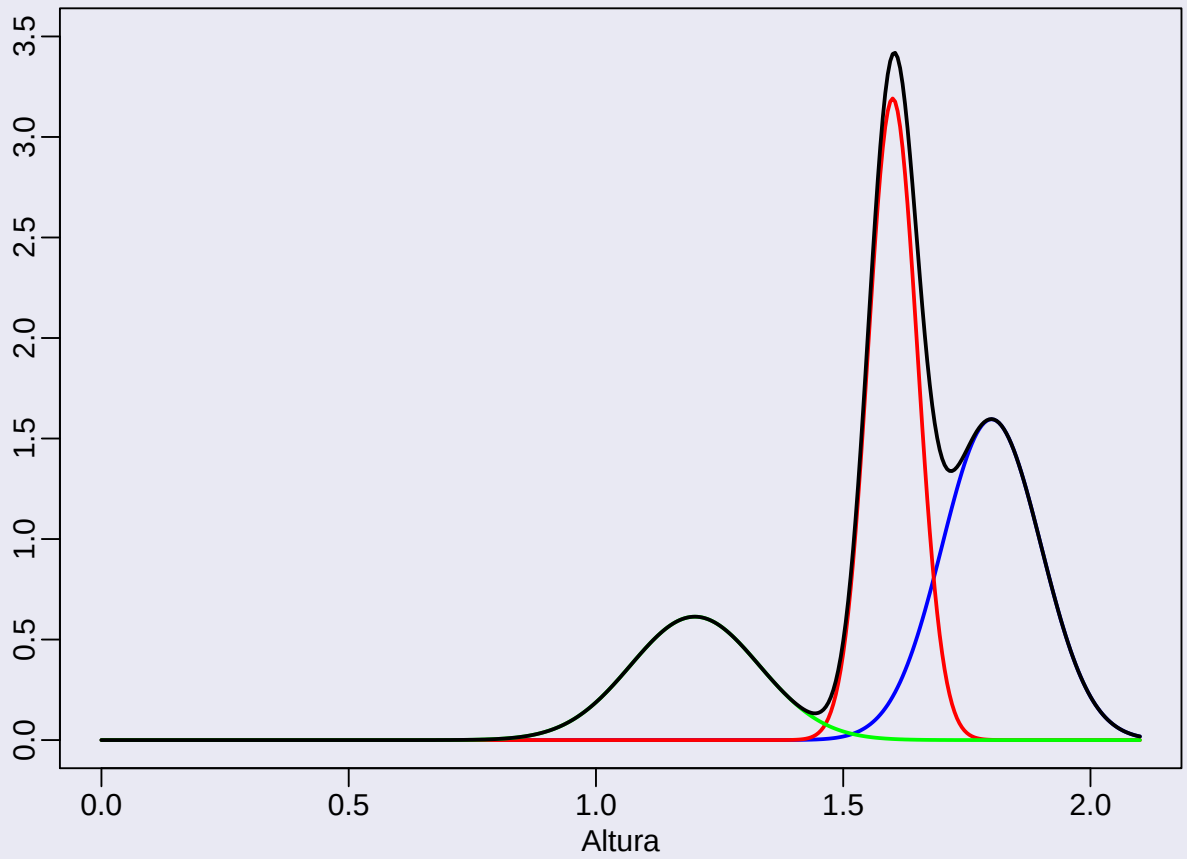


Figura: Distribuição da altura na população.

Observações:

- A população é formada por $K = 3$ subpopulações heterogêneas em relação à característica altura (em estudo); e
- assumiremos que as alturas de pessoas diferentes são independentes.

Problema: Suponha agora que a única informação que você tenha é a altura dos 100 indivíduos da amostra $\mathbf{y} = (y_1, \ldots, y_{100})$ e precisa definir um modelo estatístico para a variável aleatória altura e estimar seus parâmetros.

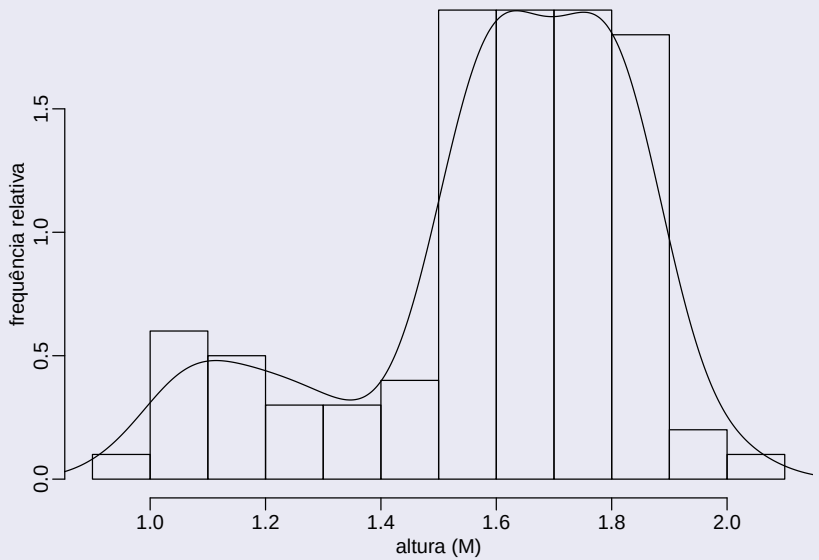


Figura: Histograma da altura para a amostra.

Assumir um modelo de mistura para essa amostra é o ideal.

Estimar esse modelo por máxima verossimilhança em (3) não é computacionalmente eficiente devido à presença do somatório em k.

Estrutura hierárquica dos modelos de mistura – aumento de dados (*data augmentation*): O modelo descrito em (2) pode ser escrito de forma hierárquica adicionando uma vetor aleatório $\mathbf{S} = (S_1, \ldots, S_n)$, em que S_i representa de qual população ou distribuição o $i-$ésimo indivíduo é proveniente. Nesse caso, $S_i \in \{1, \ldots, K\}$ e $P(S_i = k) = w_k$ para $k = 1, \ldots, K$.

Assim, (2) pode ser representado pelo seguinte modelo

$$Y_i \mid S_i = k \overset{indep}{\sim} f(y_i; \boldsymbol{\theta}_k), \quad S_i \overset{iid}{\sim} Discreta(w_1, \ldots, w_K). \tag{4}$$

A configuração conhecida ou predita de $\mathbf{s}$ define naturalmente os grupos que buscamos identificar. Ou seja, todos os indivíduos da amostra com $S_i = 1$ são provenientes da primeira componente da mistura e, consequentemente, constituem o primeiro grupo e, assim, sucessivamente.

Verossimilhança do modelo hierárquico (com dados aumentados):

$$L(\boldsymbol{\theta}, \mathbf{w}|\mathbf{y}, \mathbf{s}) = \prod_{i=1}^{n} f(y_i, s_i; \boldsymbol{\theta}, \mathbf{w}) = \prod_{i=1}^{n} f(y_i; \boldsymbol{\theta}|S_i = k)P(S_i = k) \quad (5)$$

$$= \prod_{i=1}^{n} \prod_{k=1}^{K} (f(y_i; \boldsymbol{\theta}_k)w_k)^{I_{S_i}(k)},$$

em que $I_{S_i}(k) = 1$, se $S_i = k$ ou $I_{S_i}(k) = 0$, caso contrário. Uma outra forma de representar essa função de verossimilhança é

$$L(\boldsymbol{\theta}, \mathbf{w}|\mathbf{y}, \mathbf{s}) = \prod_{i:S_i=1} f(y_i; \boldsymbol{\theta}_1|S_i = 1)w_1 \times \ldots \times \prod_{i:S_i=K} f(y_i; \boldsymbol{\theta}_K|S_i = K)w_K. \quad (6)$$

Na maioria dos casos, S_is não são observadas e, nesse caso, o algoritmo EM (Expectation-Maximization) é um método eficiente para encontrar os estimadores de máxima verossimilhança dos parâmetros.

Algoritmo EM:
Maximizar $l(\boldsymbol{\theta}, \mathbf{w}|\mathbf{y}, \mathbf{s})$ diretamente pode ser difícil e a estratégia é repetidamente construir um limite inferior para $l(\boldsymbol{\theta}, \mathbf{w}|\mathbf{y}, \mathbf{s})$ (passo E) e então encontrar os valores de $\boldsymbol{\theta}$ e $\mathbf{w}$ que maximizam o limite inferior (passo M).

- **Passo E:** consiste em calcular o valor esperado da função $l(\boldsymbol{\theta}, \mathbf{w}|\mathbf{y}, \mathbf{s})$ com respeito à distribuição condicional de $\mathbf{S}$ dado $\mathbf{Y}$ sob a estimativa corrente $\boldsymbol{\theta}^{(t)}$ e $\mathbf{w}^{(t)}$. Ou seja, queremos calcular

$$Q(\boldsymbol{\theta}, \mathbf{w}|\boldsymbol{\theta}^{(t)}, \mathbf{w}^{(t)}) = E_{\mathbf{S}|\mathbf{y}}\left(l(\boldsymbol{\theta}, \mathbf{w}|\mathbf{y}, \mathbf{s})\right); \tag{7}$$

- **Passo M:** encontrar os valores dos parâmetros que maximizam $Q(\boldsymbol{\theta}, \mathbf{w}|\boldsymbol{\theta}^{(t)}, \mathbf{w}^{(t)})$, ou seja,

$$(\boldsymbol{\theta}^{(t+1)}, \mathbf{w}^{(t+1)}) = \arg\max Q(\boldsymbol{\theta}, \mathbf{w}|\boldsymbol{\theta}^{(t)}, \mathbf{w}^{(t)}). \tag{8}$$

Considere o caso de um modelo de mistura de K distribuições normais, cada uma com média μ_k e variância σ_k^2 para $k = 1, \ldots, K$.

$$l(\boldsymbol{\theta} = (\mu_1, \ldots, \mu_K, \sigma_1^2, \ldots, \sigma_K^2), \mathbf{w} | \mathbf{y}, \mathbf{s}) =$$

$$\sum_{k=1}^{K} \sum_{i=1}^{n} I_{S_i}(k) \left(\log w_k + \log \left((2\pi\sigma_k^2)^{-1/2} \exp \left(-(2\sigma_k^2)^{-1} (y_i - \mu_k)^2 \right) \right) \right) \tag{9}$$

$$= \sum_{k=1}^{K} \sum_{i=1}^{n} \left\{ I_{S_i}(k) \log w_k - \frac{1}{2} I_{S_i}(k) \log(2\pi\sigma_k^2) - \frac{1}{2\sigma_k^2} I_{S_i}(k)(y_i - \mu_k)^2 \right\}. \tag{10}$$

Assim, $E_{\mathbf{S}|\mathbf{y}}\left(l(\boldsymbol{\theta}, \mathbf{w}|\mathbf{y}, \mathbf{s})\right) =$

$$= \sum_{k=1}^{K}\sum_{i=1}^{n}\left\{ p_{ik}^{(t)} \log w_k - \frac{p_{ik}^{(t)}}{2}\log(2\pi\sigma_k^2) - \frac{p_{ik}^{(t)}}{2\sigma_k^2}(y_i - \mu_k)^2 \right\}, \qquad (11)$$

em que $p_{ik}^{(t)} = P(S_i = k|\mathbf{y}) = \frac{w_k^{(t)} f(y_i;\boldsymbol{\theta}_k^{(t)})}{\sum_{j=1}^{K} w_j^{(t)} f(y_i;\boldsymbol{\theta}_j^{(t)})}$.

Calculando as derivadas parciais de $E_{\mathbf{S}|\mathbf{y}}\left(l(\boldsymbol{\theta}, \mathbf{w}|\mathbf{y}, \mathbf{s})\right)$ em relação aos parâmetros μ_k e σ_k^2, $k = 1, \ldots, K$ e igualando a zero obtemos as seguintes expressões para cada parâmetro.

$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^{n} y_i p_{ik}^{(t)}}{\sum_{i=1}^{n} p_{ik}^{(t)}} \tag{12}$$

$$\sigma_k^{2(t+1)} = \frac{\sum_{i=1}^{n} p_{ik}^{(t)} (y_i - \mu_k^{(t+1)})^2}{\sum_{i=1}^{n} p_{ik}^{(t)}}. \tag{13}$$

Para encontrar o estimador de w_ks não podemos apenas maximizar $E_{\mathbf{S}|\mathbf{y}}\left(l(\boldsymbol{\theta}, \mathbf{w}|\mathbf{y}, \mathbf{s})\right)$ desde que $\sum_{k=1}^{K} w_k = 1$. Temos que considerar essa restrição e usar multiplicadores de Lagrange para maximizar a seguinte quantidade $E_{\mathbf{S}|\mathbf{y}}\left(l(\boldsymbol{\theta}, \mathbf{w}|\mathbf{y}, \mathbf{s})\right) - \lambda(\sum_{k=1}^{K} w_k - 1)$ que equivale a maximizar $\sum_{k=1}^{K}\sum_{i=1}^{n}\left(p_{ik}^{(t)} \log w_k\right) - \lambda(\sum_{k=1}^{K} w_k - 1)$.

Consequentemente,

$$w_k^{(t+1)} = \frac{\sum_{i=1}^{n} p_{ik}^{(t)}}{n}. \tag{14}$$

Passos do Algoritmo EM para mistura de K distribuições normais univariadas

1. Atribui um valor inicial para $\boldsymbol{\theta} = (\mu_1, \ldots, \mu_K, \sigma_1^2, \ldots, \sigma_K^2)$ e $\mathbf{w}$;
2. **Passo E:** calcular $p_{ik}^{(t)} = P(S_i = k|\mathbf{y})$, para $i = 1, \ldots, n$ e $k = 1, \ldots, K$.
3. **Passo M:**
   - calcular $\mu_k^{(t)}$ para $k = 1, \ldots, K$;
   - calcular $\sigma_k^{2(t)}$ para $k = 1, \ldots, K$;
   - calcular $w_k^{(t)}$ para $k = 1, \ldots, K$.
4. repetir passos 2 e 3 até a convergência.

Como $l(\boldsymbol{\theta}^{(t+1)}, \mathbf{w}^{(t+1)}|\mathbf{y}, \mathbf{s}) > l(\boldsymbol{\theta}^{(t)}, \mathbf{w}^{(t)}|\mathbf{y}, \mathbf{s})$ sempre, paramos o processamento do algoritmo quando $l(\boldsymbol{\theta}^{(t+1)}, \mathbf{w}^{(t+1)}|\mathbf{y}, \mathbf{s}) - l(\boldsymbol{\theta}^{(t)}, \mathbf{w}^{(t)}|\mathbf{y}, \mathbf{s}) < \epsilon$ para ϵ bem pequeno.

No R.

Exemplos da integração por Monte Carlo ou aplicação do algoritmo EM para calcular distribuições marginais e estimar modelos na presença de dados faltantes podem ser visto na tese de doutorado de Taís Roberta Ribeiro (disponível no repositório da biblioteca da UFSCar).

Variações do algoritmo EM estão disponíveis na literatura com o objetivo de melhorar a convergência e reduzir a sensibilidade do algoritmo ao chute inicial. Exemplos são: o EM estocástico, o EM condicional, entre outros que não veremos em aula.