Revisão de Cadeias de Markov

Luis Milan
Daiane Aparecida Zuanetti
DEs-UFSCar

Processos Estocásticos

Um processo estocástico consiste de uma família (seq.) de vas $\{X_t;\ t \in T\}$ todas definidas sobre o mesmo espaço de probabilidades; $X_t : \Omega \rightarrow E$; sendo T um conjunto de índices ("tempo") e E é o Espaço de Estados.

O conjunto T pode ser contínuo, $t \in [0,+\infty)$, ou discreto, $t \in N=\{0,1,2, \ldots\}$.

Trata-se de uma definição ampla que permite muitas composições como veremos a seguir.

Processos Estocásticos

Composições possíveis:

1. Tempo discreto e espaço de estado discreto
   Exemplo: Número de ligações de telemarketing (hora a hora);
2. Tempo discreto e espaço de estado contínuo
   Exemplo: Preços, temperaturas (diários);
3. Tempo contínuo e espaço de estado discreto
   Exemplo: Número de pessoas na fila de banco;
4. Tempo contínuo e espaço de estado contínuo
   Exemplo: Tensão superficial, coordenadas da força e tempo.

Processos Estocásticos

Referências

1.James Norris, (2004) Markov Chains, http://www.statslab.cam.ac.uk/~james/Markov/

2.Hoel, P.G., Port, S.C., Stone, G.J. - (1972) - Introduction to Stochastic Processes. Boston, Mifflin.

3.Sheldon M. Ross (1996) Stochastic Processes, 2nd Edition, Wiley

Cadeia de Markov

Considere a sequência de vas $\{X_t\}$, com $t \in T$ e espaço de estados $E=\{s_1, s_2,\ldots\}$.

Se valer a propriedade

$$Pr(X_t=x_t \mid X_{t-1}=x_{t-1}, X_{t-2}=x_{t-2},\ldots,X_0=x_0) = Pr(X_t=x_t \mid X_{t-1}=x_{t-1})$$

então dizemos que $\{X_t\}$ é uma Cadeia de Markov (CM).

A probabilidade de transição do estado s_i para o estado s_j em um passo pode ser representada por

$$Pr(X_t=s_j \mid X_{t-1}=s_i) = p_{ij} \quad .$$

Cadeia de Markov

Matriz de transição:

As probabilidades de transição p_{ij} podem ser arranjadas em forma de matriz, $P=\{p_{ij}\}$, chamada de matriz de transição (MT) ou matriz estocástica.

Uma característica da MT é que suas linhas somam 1, ie,

$$\Sigma_j \, p_{ij} = 1, \text{ para } i=1, 2,\ldots$$

A distribuição condicional da va X_t dado que $X_{t-1}=s_i$, $X_t \mid X_{t-1}=s_i$, é dada pela i-ésima linha de P, $P_i=(p_{i1}, p_{i2},\ldots)$,

ie, $X_t \mid X_{t-1}=s_i \sim$ Discreta(P_i).

Exemplo: Linha de produção

Considere que a sequência de itens produzidos em uma linha de produção $\{X_t\}$ pode ser modelada por uma CM com $t \in T=\{1, 2,\ldots\}$ e $E=\{1, 2\}$, sendo $\Omega=\{\text{“C”}, \text{“NC”}\}$, C= “Conforme” e NC= “Não Conforme”.

As probabilidades iniciais são dadas por $\pi_0=(p_1 , 1-p_1)$, $p_1=0.99$, e a matriz de transição P é dada por

	Estado no tempo t, st	
Estado no tempo t-1, st-1	1	2
1	p_{11}	$1-p_{11}$
2	$1-q_{22}$	q_{22}

em que $(p_{11} , q_{22})=(.99, .20)$.

Exemplo: Linha de produção

A partir dos parâmetros estabelecidos podemos simular o comportamento da linha de produção simulando um valor s_0 para X_0 a partir de π_0, um valor s_1 para X_1 a partir de s_0 e da MT P, e assim por diante, um valor s_{t+1} para X_{t+1} a partir de s_t e da MT P, para t=1,2,....

Exercício:

Simular o comportamento dessa linha de produção. Escreva um algoritmo e transforme-o em código R.

Cadeia de Markov

Transição em 2 passos do estado s_i para o estado s_j :

$$Pr(X_t=s_j \mid X_{t-2}=s_i)= \Sigma_k \, Pr(X_t=s_j , X_{t-1}=s_k \mid X_{t-2}=s_i) =$$

$$= \Sigma_k Pr(X_t=s_j \mid X_{t-1}=s_k) \, Pr(X_{t-1}=s_k \mid X_{t-2}=s_i)= \Sigma_k \, p_{ik} \, p_{kj.}$$

Note que a transição de passo 2 assume a forma de multiplicação matricial, P^2.

Pode ser provado por indução que a transição em n passos do estado s_i para o estado s_j assume a forma P^n.

Cadeia de Markov

Distribuição marginal de X_t : $\pi_t=(\pi_{t1}, \pi_{t2}, \ldots)$, sendo

$Pr(X_t= s_j) = \pi_{tj}$, em que $\pi_{tj} > 0$, $\Sigma_j \pi_{tj}=1$ e

$\pi_{tj} = \Sigma_i Pr(X_t= s_j , X_{t-1}= s_i)$

$= \Sigma_i Pr(X_{t-1}= s_i) Pr(X_t=s_j \mid X_{t-1}= s_i) = \Sigma_i \pi_{t-1,i} p_{ij}$

para k=1, 2, …;

Matricialmente, temos $\pi_t= \pi_{t-1} P = \pi_0 P^t$.

Consequentemente e considerando π_t a distribuição no momento atual,a distribuição n passos a frente será

$$\pi_{t+n} = \pi_t P^n$$

Exemplo: Time de futebol

Considere que a sequência de resultados obtidos nos jogos por um time de futebol seja uma cadeia de Markov.
Os resultados possíveis em cada partida, que são Derrota, Empate ou Vitória, ocorrem com probabilidades expressas pela distribuição de probabilidades inicial π_0 e pela matriz de transição P abaixo.

		Próximo Jogo		
D			E	V
Jogo Anterior	D	0.4	0.3	0.3
	E	0.4	0.2	0.4
	V	0.2	0.4	0.4

Exemplo: Time de futebol

Suponha que o último resultado do time tenha sido um empate, o qual consideramos como ponto inicial da cadeia.

A probabilidade de empate no referido jogo é 1 e os demais resultados tem probabilidade 0, levando a distribuição de probabilidades no momento 0, $\pi_0 = (0\ 1\ 0)$

Calculando a distribuição para n passos, n=1, 2, … temos:

1 passo a frente: $\pi_1 = \pi_0 P = (0.4000\ \ 0.2000\ \ 0.4000)$

2 passos a frente: $\pi_2 = \pi_1 P = (0.3200\ \ 0.3200\ \ 0.3600)$

Repetindo esse procedimento obtemos o quadro a seguir.

Exemplo: Time de futebol

$$\pi_1 = \pi_0 P = (0.4000 \quad 0.2000 \quad 0.4000)$$

$$\pi_2 = \pi_1 P = (0.3200 \quad 0.3200 \quad 0.3600)$$

$$\pi_3 = \pi_2 P = (0.3280 \quad 0.3040 \quad 0.3680)$$

$$\pi_4 = \pi_3 P = (0.3264 \quad 0.3064 \quad 0.3672)$$

$$\pi_5 = \pi_4 P = (0.3265 \quad 0.3060 \quad 0.3673)$$

$$\pi_6 = \pi_5 P = (0.3265 \quad 0.3061 \quad 0.3673)$$

$$\pi_7 = \pi_6 P = (0.3265 \quad 0.3061 \quad 0.3673)$$

$$\pi_8 = \pi_7 P = (0.3265 \quad 0.3061 \quad 0.3673)$$

No R.

Observações

O slide anterior mostra a evolução da distribuição π_t a medida que t aumenta, para o exemplo em questão.

Como podemos observar, após seis passos (t=6) a distribuição estabiliza (considerando até a quarta casa decimal). Esse resultado ilustra a convergência em distribuição da cadeia.

Nesse exemplo, a cadeia convergiu para uma distribuição Discreta(0.3265,0.3061,0.3673).

Observações

O resultado desse experimento é útil para simulação, pois mostra que simulando valores da sequência de variáveis aleatórias que compõe a CM, $\{X_t\}$, a partir de um certo tempo estaremos simulando valores de uma variável aleatória cuja distribuição é muito próxima da distribuição para qual a CM converge.

Em outras palavras, podemos, partindo de um valor inicial arbitrário, simular a CM e obter valores (amostra) da distribuição para a qual a CM converge. Chamaremos essa distribuição de **distribuição de equilíbrio** da CM.

Para que essa convergência aconteça, a matriz de transição precisa ser irredutível, reversível (em relação à distribuição de equilíbrio e não necessariamente em relação à distribuição inicial) e aperiódica.

Condições

Irredutibilidade: Uma CM é irredutível se é possível chegar a qualquer estado (através de um número finito de transições) a partir de qualquer estado inicial.

Exemplos:

A CM da linha de produção é irredutível pois cada um dos estados, “C” e “NC”, sempre podem ser acessados a partir dele mesmo ou a partir do outro, assim como a cadeia de resultados de um time de futebol.

Condições

Periodicidade: Um estado s_i tem período k se o retorno ao estado i ocorrer em múltiplos de passos de tempo k. Mais formalmente, uma cadeia é aperiódica se $\min\{n>=1: \{P_{ii}^{n}\} >0\}=1$.

Ou seja, o retorno ao estado s_i pode ocorrer em períodos irregulares.

Exemplo:

Cadeia da Linha de Produção

Os estados de uma cadeia de 3 estados e matriz de transição dada por

		Estado atual		
		1	2	3
Estado Anterior	1	0	1	0
	2	0	0	1
	3	1	0	0

tem período k=3, por exemplo.

Condições

Reversibilidade à distribuição π: Uma CM é reversível se existe uma distribuição π sobre os seus estados de forma que

$$\pi_j \, p_{ji} = \pi_i \, p_{ij} \ ,$$

ou seja, a probabilidade de estar no estado s_j e fazer a transição para s_i é igual a probabilidade de estar no estado s_i e fazer a transição para o estado s_j, para quaisquer estados s_j e s_i e qualquer tempo t.

Distribuição de Equilíbrio

Toda CM que atenda a essas condições estabelecidas, converge para uma distribuição de equilíbrio.

A distribuição de equilíbrio é também chamada de distribuição estacionária ou invariante.

Distribuição de Equilíbrio

Note que se π é a distribuição de equilíbrio, então

$$\pi = \pi P$$

Logo, a distribuição de equilíbrio para o exemplo do time de futebol pode ser encontrada analiticamente, através da solução da equação acima.

Desafio

Construir e simular amostras de cadeias de Markov que possuam como distribuição de equilíbrio a distribuição desejada, geralmente multivariada e complexa.

Com base nessas amostras, calcular informações inferenciais e preditivas de interesse.

Como os métodos vistos a partir daqui são métodos de simulação aproximados, eles só devem ser utilizados quando um método exato não é possível.