Métodos Computacionalmente Intensivos em Estatística

Profa. Daiane Aparecida Zuanetti

Trabalho 1

Os estudantes devem se dividir em grupos de 2 pessoas. Talvez seja necessário um ou dois grupos de 3 estudantes. Por agora, quero que se formem duplas e me passem o mais rápido possível os integrantes de cada dupla. Cada grupo deve coletar um conjunto de dados que permita a aplicação das metodologias de reamostragem e permutação tratadas na disciplina (intervalos de confiança e/ou testes de hipóteses para duas populações independentes, duas populações pareadas, $K > 2$ populações independentes ou modelos de regressão lineares ou generalizados).

Não é necessário entregar um relatório escrito no formato de texto, mas sim os slides de apresentação do trabalho. Como a professora fará a correção do trabalho através dos slides, eles precisam conter as informações necessárias para uma boa avaliação. Por exemplo:

1. A descrição de cada variável aleatória utilizada no trabalho; local de coleta; forma de coleta e unidade de medida utilizada. No caso dos dados serem extraídos de algum site, o link do site também deve estar no trabalho;

2. Uma tabela mostrando os dados analisados ou parte deles;

3. Descrição clara do(s) objetivo(s) das análises;

4. Antes de realizar os testes, conduzir análises descritivas (gráficos e/ou medidas resumo) dos dados que permitam verificar pontos atípicos e indiquem quais possíveis conclusões teremos com a realização dos testes e que também justifiquem a abordagem de testes não-paramétricos em detrimento de testes paramétricos;

5. Apresentação das hipóteses a serem testadas (tanto em termos matemáticos quanto em palavras e em termos do problema);

6. Apresentação das suposições e justificativa de cada metodologia conduzida (argumentos estatísticos e não subjetivos do tipo: porque eu achei melhor);

7. Verificação (se possível), mesmo que através de estatísticas descritivas (gráficos ou medidas resumos apropriados), das suposições dos métodos conduzidos;

8. A interpretação e conclusão dos resultados obtidos.

Conduza os testes e/ou intervalos de confiança paramétrico, de permutação e bootstrap para a obtenção das conclusões desejadas. Compare os resultados, discuta suas diferenças, vantagens e desvantagens e deixe claro qual seria o método escolhido por vocês como sendo o mais adequado para a situação considerada e justifique.

A escolha do número B de reamostras bootstrap pode ser justificado através do processamento do algoritmo para vários valores de B e a escolha do melhor.

Entrega:

A entrega dos slides será no dia 16/outubro até às 8:00h e alguns grupos serão sorteados para fazerem a apresentação do seu trabalho no horário da aula.

Observações:

1. Bancos de dados podem ser obtidos nos sites abaixo ou em outros sites (e podem aproveitar banco de dados que vocês já usaram em outras disciplinas, tais como: introdução à inferência, estatística não-paramétrica, planejamento e análise de experimentos, modelos de regressão, etc):

   - `https://www.r-bloggers.com/datasets-to-practice-your-data-mining/`;
   - `https://kdd.ics.uci.edu/`;
   - `https://www.csie.ntu.edu.tw/~cjlin/libsvmtools/datasets/`;
   - `https://www.kaggle.com/datasets`;
   - `http://www.statsci.org/data/index.html`.

2. Trabalhos de grupos diferentes analisando o mesmo conjunto de dados não serão aceitos. Então avisem, entre vocês, qual o conjunto de dados que cada grupo está utilizando para não termos "coincidência";

3. Trabalhos muito parecidos com estudos disponíveis na literatura, livros, internet ou de plataformas de inteligência artificial, terão nota zero.