Lista 2 - MLG

Lara, Marcelo

1. Obtenha a expressão, em função dos EMV dos parâmetros $\tilde{y}$ e $\hat{x}$. das estatísticas da R.V, escore Wald e gradiente p/ testar $\beta_1 = 0$, modelo: dist Bernoulli, g é logito. apenas 1 preditora. se $y = \dots$ $x = \dots$, qual valor da estatística? e conclusão?

dist Bernoulli e g é logito $\Rightarrow$ $g(\mu_i) = \dfrac{e^{\eta_i}}{e^{\eta_i}+1} \Leftrightarrow \eta_i = \log \dfrac{\mu_i}{1-\mu_i}$

$$f(y_i) = \mu_i^{y_i}(1-\mu_i)^{1-y_i} \Rightarrow f(y) = \prod_{i=1}^{n} f(y_i) = \prod_{i=1}^{n} \mu_i^{y_i}(1-\mu_i)^{1-y_i} = L(\beta)$$

$$\Rightarrow \ell(\beta) = \sum \left[y_i \log \mu_i + (1-y_i)\log(1-\mu_i) \right] = \sum_{i=1}^{n} \left[y_i \log \frac{\mu_i}{1-\mu_i} + \log(1-\mu_i) \right]$$

* $\eta_i = \log \frac{\mu_i}{1-\mu_i}$

$$= \sum \left[y_i \eta_i + \log\left(1 - \frac{e^{\eta_i}}{e^{\eta_i}+1}\right) \right] = \sum \left[y_i \eta_i + \log\left(\frac{1}{e^{\eta_i}+1}\right) \right]$$

$$= \sum \left[y_i \eta_i - \log(e^{\eta_i}+1) \right] \qquad \text{note: } \eta_i = x_i^T \beta = \beta_0 + \beta_1 x$$

$$\ell(\beta) = \sum y_i(\beta_0 + \beta_1 x_i) - \log(1 + e^{\beta_0 + \beta_1 x_i})$$

Além disso,

$$U(\beta) = X^T(y-\mu), \quad K(\beta) = X^T W X, \quad \text{onde } W = \text{diag}\{\mu_1(1-\mu_1), \dots \mu_n(1-\mu_n)\}$$

Razão de Verossimilhança:

$$\xi_{RV} = Q_{RV} = 2\cdot\left[l(\hat{\beta}) - l(\tilde{\beta})\right]$$, onde $\hat{\beta} = [\hat{\beta}_0\ \hat{\beta}_1]^T$ é o EMV do modelo completo e $\tilde{\beta} = [\tilde{\beta}_0\ 0]^T$ o EMV sob H_0

note que se $\beta_1 = 0$ sob H_0, então naturalmente $\tilde{\eta}_i = \tilde{\beta}_0 = \log\left(\frac{\tilde{\mu}_i}{1-\tilde{\mu}_i}\right)$ $\tilde{\mu}_i = \bar{y}$

$$\Rightarrow Q_{RV} = 2\cdot\left[\sum\left[y_i \log\frac{\hat{\mu}_i}{1-\hat{\mu}_i} - \log(1-\hat{\mu}_i)\right] - \sum\left[y_i \log\frac{\tilde{\mu}}{1-\tilde{\mu}} - \log(1-\tilde{\mu})\right]\right]$$

$$= 2\cdot\sum\left[y_i \log\frac{\hat{\mu}_i}{\tilde{\mu}} + (1-y_i)\log\left(\frac{1-\hat{\mu}_i}{1-\tilde{\mu}}\right)\right]$$

↑ forma simplificada mas não necessariamente conveniente.

Com os dados: $\bar{y} = 0{,}5 = \tilde{\mu} \Rightarrow \tilde{\beta}_0 = 0$ (sob H_0)

os EMV: $\hat{\beta}_0 = 8{,}53$ $\hat{\beta}_1 = -0{,}1865$ (do modelo completo)

(e com Newton-Raphson)

se $\alpha = 5\%$

$\Rightarrow l(\hat{\beta}) = -3{,}048$, $l(\tilde{\beta}) = -6{,}931$

* $\chi^2_{1\,crit} = \chi^2_{1\,0{,}95} = 3{,}841$

$\Rightarrow Q_{RV} = 2\cdot(-3{,}048 + 6{,}931) \cong 7{,}76 > \chi^2_{1\,crit}$

$\Rightarrow$ Rejeita H_0.

Teste de Escore

$$\xi_{SR} = Q_E = U_{\tilde{\beta}}^T K_{\tilde{\beta}}^{-1} U_{\tilde{\beta}} \quad , \quad \tilde{U}_\beta = \begin{bmatrix} \Sigma (y_i - \tilde{\mu}_i) \\ \Sigma x_i (y_i - \tilde{\mu}_i) \end{bmatrix}$$

Lembre que $\tilde{\mu}_i = \tilde{\mu} = \bar{y} \Rightarrow \Sigma y_i - \tilde{\mu}_i = \Sigma y_i - \bar{y} = 0$

$$\Rightarrow \tilde{U}_\beta = \begin{bmatrix} 0 \\ \Sigma x_i (y_i - \bar{y}) \end{bmatrix},$$

Além disso: $K_\beta = X^T W X = \begin{bmatrix} \Sigma w_i & \Sigma w_i x_i \\ \Sigma w_i x_i & \Sigma w_i x_i^2 \end{bmatrix}$ e $w_i = \mu_i(1-\mu_i)$

sob H_0, $\tilde{\mu}_i = \bar{y} = 0{,}5 \Rightarrow K_{\tilde{\beta}} = \bar{y}(1-\bar{y}) \cdot \begin{bmatrix} n & \Sigma x_i \\ \Sigma x_i & \Sigma x_i^2 \end{bmatrix} \Rightarrow$

$$K_{\tilde{\beta}}^{-1} = \frac{1}{\bar{y}(1-\bar{y})} \begin{bmatrix} \Sigma x_i^2 & -\Sigma x_i \\ \Sigma x_i & n \end{bmatrix} \cdot \frac{1}{n\Sigma x_i^2 - (\Sigma x_i)^2} = \frac{1}{\bar{y}(1-\bar{y}) \cdot n\Sigma(x_i - \bar{x})^2} \begin{bmatrix} \Sigma x_i^2 & -\Sigma x_i \\ -\Sigma x_i & n \end{bmatrix}$$

$x_i^2 - 2x_i\bar{x} + \bar{x}^2 = (x_i - \bar{x})(x_i - \bar{x})$

$$n\Sigma x_i^2 - n\bar{x}^2 = n(\Sigma x_i^2 - n\bar{x}^2) = n(\Sigma x_i^2 - \Sigma \bar{x}^2) = n(\Sigma(x_i^2 - \bar{x}^2)) = n\Sigma(x_i^2 - 2x_i\bar{x} + \bar{x}^2)$$

$$\Rightarrow Q_E = U_{\tilde{\beta}}^T K_{\tilde{\beta}}^{-1} U_{\tilde{\beta}} = \begin{bmatrix} 0 \\ \Sigma x_i(y_i - \bar{y}) \end{bmatrix}^T \begin{bmatrix} \Sigma x_i^2 & -\Sigma x_i \\ -\Sigma x_i & n \end{bmatrix} \begin{bmatrix} 0 \\ \Sigma x_i(y_i - \bar{y}) \end{bmatrix} \frac{1}{\bar{y}(1-\bar{y})} \cdot \frac{1}{n\Sigma(x_i - \bar{x})^2}$$

$1 \times 2 \quad 2 \times 2 \quad 2 \times 2$

$$= \begin{bmatrix} \Sigma x_i(y_i - \bar{y}) \cdot -\Sigma x_i & n\Sigma x_i y_i - \bar{y} \end{bmatrix} \begin{bmatrix} 0 \\ \Sigma x_i(y_i - \bar{y}) \end{bmatrix} \frac{1}{\bar{y}(1-\bar{y}) \Sigma(x_i - \bar{x})^2 \cdot n}$$

$$= \frac{(\Sigma x_i(y_i - \bar{y}))^2}{\bar{y}(1-\bar{y}) \Sigma(x_i - \bar{x})^2} \quad . \quad \text{Com os dados: } Q_E = \frac{(-81)^2}{0{,}25 \cdot (484{,}4)} = 5{,}477$$

$\Rightarrow$ Rejeita H_0 ao α de 5%

Teste de Wald

$$Q_W = \left[\hat{\beta}_b - \beta_b^{(0)}\right]\left[\hat{K}^{\beta_b\beta_b}\right]^{-1}\cdot\left[\hat{\beta}_b - \beta_b^{(0)}\right]$$

$$= \begin{bmatrix}\hat{\beta}_0 - \hat{\beta}_0 \\ \hat{\beta}_1 - 0\end{bmatrix}\begin{bmatrix}\sum\hat{w}_i & \sum\hat{w}_i x_i \\ \sum\hat{w}_i x_i & \sum\hat{w}_i x_i^2\end{bmatrix}^{-1}_{22}\begin{bmatrix}0 \\ \hat{\beta}_1\end{bmatrix} = \hat{\beta}_1^2\left(\frac{\sum\hat{w}_i}{\sum\hat{w}_i x_i^2\sum\hat{w}_i - \left(\sum x_i\hat{w}_i\right)^2}\right)^{-1}$$

$$= \hat{\beta}_1^2\cdot\left(\sum\tilde{w}_i x_i^2 - \frac{\left(\sum\hat{w}_i x_i\right)^2}{\sum\hat{w}_i}\right) = 1{,}66 \quad < \chi^2_{1,\,crit.}$$

$\tilde{n}$ rejeita H_0

Gradiente:

$$Q_G = \left[\tilde{U}_{\beta_b}\right]^T\left[\hat{\beta}_b - \beta_b^{(0)}\right]$$

$$= \left[\sum(y_i-\bar{y}) \quad \sum x_i(y_i-\bar{y})\right]\begin{bmatrix}0 \\ \tilde{\beta}_1\end{bmatrix} = \hat{\beta}_1\cdot\sum x_i(y_i-\bar{y})$$

$$= (-0{,}186)\cdot(-81) = 15{,}11$$

$$> \chi^2_{1\,crit.}$$ Rejeita H_0

Conclusão dos 4 testes, exceto o de Wald, Rejeitamos H_0 ao a de 5%

ou seja, há evidências de associação entre x e a probabilidade de sucesso.

Porém esses testes dependem da distribuição

assintotica χ^2, mas temos apenas 10 dados.

A qualidade da aproximação pode ser pequena. Não usaria os testes.

2. Considere: modelo: resposta gama, $g(\mu_i) = \log \mu_i$, duas covariáveis: uma binária e uma contínua.

Gere dados seguindo o procedimento ...

obtenha o valor das estatísticas de rv, Escore, Wald, e gradiente.

$H_0: \beta_2 = 0$, $\alpha = 5\%$

Gamma e $g(\mu_i) = \log \mu_i = \eta_i \Rightarrow x_i\beta = \log \mu_i \Rightarrow \mu_i = e^{x_i\beta}$

↳ na parametrização de μ_i e ϕ, $\mu = \alpha\beta$, e $Var(y) = \phi V(\mu) = \phi\mu^2 = \alpha\beta^2$

$\Rightarrow \beta = \mu/\alpha \Rightarrow \alpha = \frac{1}{\phi}$ e $\beta = \phi\mu \Rightarrow Y = np.gamma(shape = 1/\phi, scale = \phi/\mu)$

$$\Rightarrow f(y_i; \mu_i, \phi) = \frac{1}{\Gamma(1/\phi)(\phi\mu_i)^{1/\phi}} y_i^{\frac{1}{\phi}-1} \exp\left\{\frac{-y_i}{\phi\mu_i}\right\}, \quad y_i > 0$$

$$\Rightarrow L(\mu, \phi; \underset{\sim}{y}) = \Pi \cdots \Rightarrow$$

$$\ell(\mu, \phi; \underset{\sim}{y}) = \Sigma\left[-\log\Gamma(1/\phi) - \frac{1}{\phi}\log(\phi\mu_i) + \left(\frac{1}{\phi} - 1\right)\log y_i - \frac{y_i}{\phi\mu_i}\right]$$

e $\mu_i \overset{H_1}{=} x_i^T\beta = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2}$ ($\phi = 1$ conhecido)

$\mu_i \overset{H_0}{=} \beta_0 + \beta_1 x_{i1}$

$\hat{\mu}_i = x_i^T\hat{\beta}$ (H_1), $\tilde{\mu}_i = x_i^T\tilde{\beta}$ (H_0)

*

$$l(\beta,\phi) = \left(n \cdot \log \Gamma(\phi) - n\left(\frac{1}{\phi}\right)\log(\phi)\right) + \Sigma\left[\frac{1}{\phi}\log\mu_i + \left(\frac{1}{\phi}-1\right)\log y_i - \frac{y_i}{\phi\mu_i}\right]$$

$$Q_{RV} = 2\cdot\left(l(\hat{\beta}^{H_1},\phi) - l(\hat{\beta}^{H_0},\phi)\right) = 2\cdot\left[\Sigma \frac{1}{\phi}\log\frac{\hat{\mu}_i}{\tilde{\mu}_i} - \frac{y_i}{\phi}\left(\frac{1}{\tilde{\mu}_i} - \frac{1}{\hat{\mu}_i}\right)\right]$$

$$= 2\cdot\frac{1}{\phi}\Sigma\left[\log\frac{\hat{\mu}_i}{\tilde{\mu}_i} - y_i\left(\frac{1}{\hat{\mu}_i} - \frac{1}{\tilde{\mu}_i}\right)\right]$$

como obter os $\hat{\mu}_i$ e $\tilde{\mu}_i$? tem que ter os $\hat{\beta}_1, \hat{\beta}_2$ e $\tilde{\beta}_1$.

=> `fit_H1 <- glm(Y ~ X1+X2, family = Gamma(link = "log")`

`fit_H1 <- glm(Y ~ X1, family = Gamma(link = "log")`

=> `mu_H1 <- fitted(fit_H1)` # os $\hat{\mu}_i$'s

`mu_H0 <- fitted(fit_H0)` # os $\tilde{\mu}_i$'s

com n=10 e seed = 1002

= calculando em R : $Q_{RV} = 2\cdot[l(\hat{\beta}|y) - l(\tilde{\beta}|y)] = 7{,}04$

Se repetir isso 1000 vezes em R : % de Q_{RV} que passa de χ^2_1 qas é 0,004

=> 99,6 % das vezes não rejeitamos H_0, ao α de 5% com Q_{RV}. (0,4% das vezes rejeita na 1000 ou outras)

$$Q_W = (\hat{\beta}_b - \beta_b^0)^T (K^{\beta_b\beta_b})^{-1} (\hat{\beta}_b - \beta_b^0) = (\hat{\beta}_2 - 0)\cdot \frac{(X^TWX)^{-1}_{33}}{\phi}(\hat{\beta}_2 - 0) = \frac{\hat{\beta}_2^2}{Var(\hat{\beta}_2)}$$

*

Gamma e log => $w_i = 1$ => $W = I$

*sempre que β_b é um parâmetro e H_0 é $\beta_b = 0$, então $Q_W = \hat{\beta}_2^2 / Var(\hat{\beta}_2)$

⇒ Em R: $\hat{\beta}$ <- coef(fit_H1)

X_H1 <- model.matrix(fit_H1)

I_H1 <- crossprod(X_H1)/phi # $I_{H1} = X^TX/\phi$

$(I_{H1})^{-1}$ <- solve(I_H1)

⇒ Q_W <- $(\hat{\beta}_2)^2 / (I_{H1})^{-1}_{33} = 5{,}579 > \chi^2_{1,0,95}$ ⇒ Rejeita H_0.

& rodar 1000 vezes, com $n_1 = 100$ (pois se $n_1 = 10$ as vezes o código estoura em estima μ_i^{m+1}, pois se $\mu_i^m = 0 \Rightarrow \log(\mu_i) = -\infty \Rightarrow$ NA na matriz X^TWz ⇒ R buga) temos que apenas 6,2% das amostras rejeitamos H_0.

Teste escore:

$$Q_S = [\tilde{U}_{\beta_b}]^T \tilde{K}^{\beta_b\beta_b} [\tilde{U}_{\beta_b}]$$

~: indica que tá sob H_0

$\beta_b = \beta_2$

e $\tilde{U}_\beta = X^T \cdot w$, $w_i = \frac{y_i - \mu_i}{\phi \mu_i}$ no caso de Gama e log

pois $U_\beta = \phi X^T W G (y - \mu)$

e $\tilde{K} = \frac{X^TX}{\phi} \Rightarrow Q_S = [\tilde{U}_{\beta_2}]^T \left[\frac{(X^TX)^{-1}}{\phi}\right] [\tilde{U}_{\beta_2}]$

⇒ com seed(1002) $n = 20$, temos $Q_S = 1{,}3 \Rightarrow \tilde{n}$ rejeita H_0

e teste de Gradiente:

$$\mathcal{Q}_G = (\tilde{U}_{\beta_b})^T (\hat{\beta}_b - \beta_b^{(0)}) = (\tilde{U}_{\beta_2})^T (\hat{\beta}_2 - 0)$$

em R: $\tilde{U}_{\beta_2}$ <- U_H0[3]

$\hat{\beta}_2$ <- coef(fit_H1)["X2"]

$\tilde{\beta}_2 = 0$ # H_0

$\Rightarrow \mathcal{Q}_G$ <- $\tilde{U}_{\beta_2}(\hat{\beta}_2)$

em seed 1001, n = 20, temos

$\mathcal{Q}_G = 1{,}2 \Rightarrow$ Não rejeita H_0 ao $\alpha = 5\%$.

Resultados com diferentes n's.

% de Rejeitar H_0 testes \ n	10	20	30	40	50	100	500	1000	
RV	x	5,3%	6,1	4,5	4,6	5,15	4,6	5,8	
Wald	x	6,6%	6,3	5,5	5,3	5,7	4,5	5,9	← liberal
Escore	x	4,3%	4,9	3,7	4,3	5,14	4,8	5,15	
Gradiente	x	4,9%	5,9	4,3	4,6	5,15	4,6	5,8	

↑ convergem em 1000

3. Considere: resposta Gaussiana Inversa, função de ligação logaritimca, uma covariável continua e outra qualitativa com 3 níveis.

* 1º nível é a referência, IC p/ $\frac{\mu_i | X = \text{nível } 2}{\mu_i | X = \text{nível } 3} = \frac{\mu_2}{\mu_3}$

Obtenha a expressão do intervalo de confiança assintotico

$\eta_i = g(\mu_i) = \log \mu_i \qquad Y_{ij} \sim IG(\mu_i, \phi) = V(\mu) = \mu^3$

$\Rightarrow \log \mu_i = \beta_0 + \beta_2 x_2 + \beta_3 x_3 \Rightarrow \mu_i | x_2 = 1 = \exp\{\beta_0 + \beta_2\}$ e $\mu_i | x_3 = 1 = \exp\{\beta_0 + \beta_3\}$

$\text{Interesse} = \theta = \frac{\mu_i | x_2 = 1}{\mu_i | x_3 = 1} = \frac{\exp\{\beta_0 + \beta_2\}}{\exp\{\beta_0 + \beta_3\}} = e^{(\beta_2 - \beta_3)} = \exp\{c^T \beta\}$

$c = [0 \ 1 \ -1]^T$

note $w_i = \frac{(\partial \mu_i / \partial \eta_i)^2}{V(\mu_i)} = \frac{(\mu_i)^2}{\mu_i^3} = \frac{1}{\mu_i} \Rightarrow \hat{\beta} \overset{\text{assimto}}{\sim} N_3(\beta, \phi(X^T W X)^{-1})$

e $\mu_i = e^{\eta_i} \Rightarrow \partial \mu_i / \partial \eta_i = \mu_i$ com $W = \text{diag}\{1/\mu_i\}$

$\Rightarrow \hat{\theta} = e^{(c^T \hat{\beta})} = e^{\hat{\beta}_2 - \hat{\beta}_3} \overset{\text{assimt}}{\sim} N(\theta, c^T (X^T W X)^{-1} c)$

Se modelo saturado: $\hat{\mu}_j = \bar{y}_j \Rightarrow \hat{\beta}_2 = \log\left(\frac{\bar{y}_2}{\bar{y}_1}\right)$ e $\hat{\beta}_3 = \log\left(\frac{\bar{y}_3}{\bar{y}_1}\right)$

* $\hat{\beta}_2 = \log(\hat{\mu}_2) - \log(\hat{\mu}_1) = \log(\bar{y}_2) - \log(\bar{y}_1)$

$\Rightarrow \hat{\beta}_2 - \hat{\beta}_3 = \log\left(\frac{\bar{y}_2}{\bar{y}_3}\right)$

$\Rightarrow$ IC p/ $\beta_2 - \beta_3 = \left[\hat{\beta}_2 - \hat{\beta}_3 \mp z_{1-\frac{\alpha}{2}} \sqrt{\hat{\phi} c^T (X^T \hat{W} X) c}\right]$ $\Rightarrow$ propriedade de invariância.

IC p/ $\theta = e^{\beta_2 - \beta_3} = \left[\exp^{\hat{\beta}_2 - \hat{\beta}_3 - z_{1-\frac{\alpha}{2}} \sqrt{\hat{\phi} c^T (X^T \hat{W} X)^{-1} c}} ; \exp^{\hat{\beta}_2 - \hat{\beta}_3 + z_{1-\frac{\alpha}{2}} \sqrt{\hat{\phi} c^T (X^T \hat{W} X)^{-1} c}} \right]$

* $\hat{\phi} c^T X^T W X^{-1} c = Var(\hat{\beta}_2 - \hat{\beta}_3) = Var(\hat{\beta}_2) + Var(\hat{\beta}_3) - 2 \cdot Cov(\hat{\beta}_2, \hat{\beta}_3)$

4. Obtenha a expressão do resíduo de Anscombe p/ modelo de regressão com resposta Poisson.

$$t_{Ai} = \frac{\hat{\phi}^{1/2} \cdot [\psi(y_i) - \psi(\hat{\mu}_i)]}{\psi'(\hat{\mu}_i) \sqrt{\hat{V}_i (1 - h_{ii})}} \quad \text{onde} \quad \psi(\mu) = \int_0^{\mu} V(t)^{-1/3} dt$$

mas como a resposta é Poisson, $V(\mu) = \mu \Rightarrow \psi(\mu) = \int_0^{\mu} u^{-1/3} du = \left[\frac{u^{2/3}}{2/3} \right]_0^{\mu} = \frac{3}{2} \cdot \mu^{2/3}$

e $\phi = 1$

$$\Rightarrow \psi(y_i) = \frac{3}{2} y_i^{2/3} \quad \text{e} \quad \psi(\hat{\mu}_i) = \frac{3}{2} \hat{\mu}_i^{2/3}, \quad \psi'(\mu_i) = \mu^{1/3}$$

$$V_i = \mu_i \Rightarrow t_{Ai} = \frac{1 \cdot \left[\frac{3}{2} \left(y_i^{2/3} - \hat{\mu}_i^{2/3} \right) \right]}{\hat{\mu}_i^{-1/3} \cdot \hat{\mu}_i^{1/2} \cdot \sqrt{(1 - h_{ii})}} = \frac{3}{2} \cdot \frac{\left[y^{2/3} - \mu^{2/3} \right]}{\hat{\mu}^{1/6} \cdot \sqrt{1 - h_{ii}}}$$

5. Quais efeitos de ter um m na construção de envelope de Atkinson?

Sugestão de m era 19.

os resíduos tem m replicas, e se o modelo for correto,

os m simulados e o resíduo originam formam uma amostra iid

$$\Rightarrow Pr(t_{(i)_{obs}} > \max t_i = t_{[i]_{[m]}}) = \frac{1}{m+1}$$

e $Pr\left(t_{(i)_{obs}} < \min t_i = t_{[i],[1]}\right) = \frac{1}{m+1}$

$\Rightarrow Pr(t_{(i)\,obs} \text{ fica fora}) = Pr(T_{(i)obs} < \min t_i) + Pr(T_{(i)obs} > \max t_i)$

$= \frac{2}{m+1}$

com $m = 19$, temos $Pr(t_{(i)obs} \text{ fica fora}) = \frac{2}{19+1} = 10\%$

se aumentar m, essa probabilidade diminui $\Rightarrow$ envelope fica mais largo $\Rightarrow$ menor sensibilidade e maior estabilidade e maior custo computacional.

dá para manter a interpretação de faixa de 90%, se m grande, deve se usar $t_{[i],5\%}$ e $t_{[i],95\%}$.

6. Para cada possível valor da amostra, ordene o termo de penalização do AIC, BIC e HQC. Supondo que $n=500$, 10 variáveis preditoras. e seleção de variáveis sugere que o melhor modelo tenha 5. Quais as possibilidades para o número de variáveis do melhor modelo se AIC e HQC

note que $AIC = -2\ell(\hat{\beta}) + 2 \cdot k^*$

$BIC = -2\ell(\hat{\beta}) + k^* \log n$

$HQC = -2\ell(\hat{\beta}) + 2k^* \log\log n$

é tudo $-2\ell(\hat{\beta})$ + penalização

AIC vs BIC : $2k^* < k^* \log n$ se $n > e^2 = 7{,}39 \Rightarrow n \geq 8$

$\Rightarrow$ AIC < BIC se $n \geq 8$

AIC vs HQC : $2k^* < 2k^* \log\log n$ se $n > e^e = 15{,}19 \Rightarrow n \geq 16$

$\Rightarrow$ AIC < HQC se $n \geq 16$

BIC vs HQC : $k^* \log n < 2k^* \log\log n$ se $\log n < 2 \cdot \log\log n$

$\Rightarrow n < 2 \log n$, isso nunca é verdade $\forall n$.

$\Rightarrow$ BIC > HQC sempre

$\Rightarrow$ se $3 \leq n \leq 7$: HQC < BIC < AIC

se $7 \leq n \leq 15$ HQC < AIC < BIC

se $n \geq 16$ AIC < HQC < BIC

$n = 500$, e AIC escolhem 5, então por HQC e BIC teríamos pelo menos 5 variáveis também. (no máximo 10)

7. Em relação à max de R^2_{csm} p/ R^2_N

a) mostre que se resposta Bernoulli e $n_{sucesso} = n_{fracasso}$, então

max $R^2_{csm} = 0{,}75$

note que $R^2_{csm} = 1 - \exp\left\{-\frac{2}{n}(l(\hat{\gamma}) - l(0))\right\}$ (0 indica só tem β_0)

$$= 1 - \left[\frac{L(0)}{L(\hat{\gamma})}\right]^{2/n}$$

Se Bernoulli, então $f(y_i|\mu_i) = \mu_i^{y_i}(1-\mu_i)^{1-y_i} \Rightarrow L(\mu) = \prod \mu_i^{y_i}(1-\mu_i)^{1-y_i}$

e note que $L(\hat{\gamma}) \leq 1$ e R^2_{csm} é maximo se só se $L(\hat{\mu}) = 1$ $\Rightarrow$ vamos dizer que $L(\hat{\mu}) = 1$

$$\Rightarrow \max R^2_{csm} = 1 - \frac{(L(0))^{2/n}}{1}$$. sobre $L(0)$: note que

$$Y \in \{0,1\} \Rightarrow L(0) = \prod (x_i^T \hat{\beta}_0)^{y_i} (1 - x_i^T \hat{\beta}_0)^{1-y_i} = \prod \hat{\beta}_0^{y_i} (1-\hat{\beta}_0)^{1-y_i}$$

seja n o tamanho da amostra e n_1 o # de sucesso e

n_0 o # de fracasso,

temos então $\hat{\beta}_0 = \frac{n_1}{n}$ e $n_1 = \sum y_i$, $n_0 = n - n_1$

$$\Rightarrow L(0) = \left(\frac{n_1}{n}\right)^{n_1} \cdot \left(\frac{n_0}{n}\right)^{n_0}$$. Agora se $n_1 = n_0 \Rightarrow L(0) = \left(\frac{1}{2}\right)^n$

$$\Rightarrow \max R^2_{csm} = 1 - \left[\left(\frac{1}{2}\right)^n\right]^{\frac{2}{n}} = 1 - \left(\frac{1}{2}\right)^2 = 1 - 0{,}25 = 0{,}75$$

b) Se $n_{sucesso} = 2 \cdot n_{fracasso}$?

$\Rightarrow n_1 = 2 \cdot n_0$ $\Rightarrow L(0) = \left(\frac{2n_0}{n}\right)^{2n_0} \cdot \left(\frac{n_0}{n}\right)^{n_0} = \left(\frac{2}{3}\right)^{\frac{2}{3}n} \cdot \left(\frac{1}{3}\right)^{\frac{n}{3}} = \left[\left(\frac{2}{3}\right)^{2/3} \left(\frac{1}{3}\right)^{1/3}\right]^n$

$\Rightarrow 3n_0 = n$ $\Rightarrow n_1 = \frac{2}{3}n$

$a^{an} \cdot b^{bn} = (a^n)(b^n) = (a \cdot b)^n$

$$\Rightarrow \max R^2_{csm} = 1 - \left\{\left[\left(\frac{2}{3}\right)^{2/3} \cdot \left(\frac{1}{3}\right)^{1/3}\right]^n\right\}^{\frac{2}{n}} = 1 - \left(\frac{2}{3}\right)^{4/3} \cdot \left(\frac{1}{3}\right)^{2/3} = 1 - \frac{2^{4/3}}{3^{3/3}} = 1 - \frac{2^{4/3}}{3}$$

$$= 1 - \frac{\sqrt[3]{16}}{9} \cong 0{,}72$$