Modelos lineares generalizados

Introdução

Limitações do modelo linear geral

Limitações do modelo linear geral

No MLGer que estudamos, assuminos que $\epsilon \sim N_n(0, \sigma^2 \mathbf{I})$ para a obtenção da maioria dos resultados,

Limitações do modelo linear geral

No MLGer que estudamos, assuminos que $\epsilon \sim N_n(0, \sigma^2\mathbf{I})$ para a obtenção da maioria dos resultados, o que é equivalente a assumirmos que $\mathbf{y}|\mathbf{X} \sim N_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$.

Limitações do modelo linear geral

No MLGer que estudamos, assuminos que $\epsilon \sim N_n(0, \sigma^2\mathbf{I})$ para a obtenção da maioria dos resultados, o que é equivalente a assumirmos que $\mathbf{y}|\mathbf{X} \sim N_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$. No entanto, muitas vezes:

Limitações do modelo linear geral

No MLGer que estudamos, assuminos que $\epsilon \sim N_n(0, \sigma^2\mathbf{I})$ para a obtenção da maioria dos resultados, o que é equivalente a assumirmos que $\mathbf{y}|\mathbf{X} \sim N_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$. No entanto, muitas vezes:

- Não é razoável admitir que $\mathbf{y}|\mathbf{X}$ tem distribuição normal e/ou;

Limitações do modelo linear geral

No MLGer que estudamos, assuminos que $\epsilon \sim N_n(0, \sigma^2\mathbf{I})$ para a obtenção da maioria dos resultados, o que é equivalente a assumirmos que $\mathbf{y}|\mathbf{X} \sim N_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$. No entanto, muitas vezes:

- Não é razoável admitir que $\mathbf{y}|\mathbf{X}$ tem distribuição normal e/ou;
- Não é razoável admitir que $y_i|x_i$ tem variância constante e/ou;

Limitações do modelo linear geral

No MLGer que estudamos, assuminos que $\epsilon \sim N_n(0, \sigma^2\mathbf{I})$ para a obtenção da maioria dos resultados, o que é equivalente a assumirmos que $\mathbf{y}|\mathbf{X} \sim N_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$. No entanto, muitas vezes:

- Não é razoável admitir que $\mathbf{y}|\mathbf{X}$ tem distribuição normal e/ou;
- Não é razoável admitir que $y_i|x_i$ tem variância constante e/ou;
- Não é razoável admitir que $\mathrm{E}(y_i)$ varia linearmente em função de variáveis preditoras,

Limitações do modelo linear geral

No MLGer que estudamos, assuminos que $\epsilon \sim N_n(0, \sigma^2\mathbf{I})$ para a obtenção da maioria dos resultados, o que é equivalente a assumirmos que $\mathbf{y}|\mathbf{X} \sim N_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$. No entanto, muitas vezes:

- Não é razoável admitir que $\mathbf{y}|\mathbf{X}$ tem distribuição normal e/ou;
- Não é razoável admitir que $y_i|x_i$ tem variância constante e/ou;
- Não é razoável admitir que $\mathrm{E}(y_i)$ varia linearmente em função de variáveis preditoras, e efetuar transformações na variável resposta ou considerar modelos polinomiais dificulta a interpretação dos parâmetros.

Limitações do modelo linear geral

No MLGer que estudamos, assuminos que $\epsilon \sim N_n(0, \sigma^2\mathbf{I})$ para a obtenção da maioria dos resultados, o que é equivalente a assumirmos que $\mathbf{y}|\mathbf{X} \sim N_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$. No entanto, muitas vezes:

- Não é razoável admitir que $\mathbf{y}|\mathbf{X}$ tem distribuição normal e/ou;
- Não é razoável admitir que $y_i|x_i$ tem variância constante e/ou;
- Não é razoável admitir que $\mathrm{E}(y_i)$ varia linearmente em função de variáveis preditoras, e efetuar transformações na variável resposta ou considerar modelos polinomiais dificulta a interpretação dos parâmetros.

Nessas situações, podemos utilizar uma classe mais ampla de modelos de regressão denominada modelos lineares generalizados (MLGen).

Limitações do modelo linear geral

No MLGer que estudamos, assuminos que $\epsilon \sim N_n(0, \sigma^2\mathbf{I})$ para a obtenção da maioria dos resultados, o que é equivalente a assumirmos que $\mathbf{y}|\mathbf{X} \sim N_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$. No entanto, muitas vezes:

- Não é razoável admitir que $\mathbf{y}|\mathbf{X}$ tem distribuição normal e/ou;
- Não é razoável admitir que $y_i|x_i$ tem variância constante e/ou;
- Não é razoável admitir que $\mathrm{E}(y_i)$ varia linearmente em função de variáveis preditoras, e efetuar transformações na variável resposta ou considerar modelos polinomiais dificulta a interpretação dos parâmetros.

Nessas situações, podemos utilizar uma classe mais ampla de modelos de regressão denominada modelos lineares generalizados (MLGen). Os MLGen assumem que $y_i|x_i$ tem uma distribuição de probabilidades que pertence à família exponencial linear.

Família exponencial

Família exponencial

A família exponencial uniparamétrica é caracterizada por uma função (densidade) de probabilidade especificada na forma

$$f(y;\theta) = h(y)\exp[\eta(\theta)t(y) - b(\theta)], \tag{1}$$

Família exponencial

A família exponencial uniparamétrica é caracterizada por uma função (densidade) de probabilidade especificada na forma

$$f(y;\theta) = h(y)\exp[\eta(\theta)t(y) - b(\theta)], \tag{1}$$

em que as funções $\eta(\theta)$, $b(\theta)$, $t(y)$ e $h(y)$ tem valores em subconjuntos dos reais e as três primeiras em geral não são únicas.

Família exponencial

A família exponencial uniparamétrica é caracterizada por uma função (densidade) de probabilidade especificada na forma

$$f(y;\theta) = h(y)\exp[\eta(\theta)t(y) - b(\theta)], \tag{1}$$

em que as funções $\eta(\theta)$, $b(\theta)$, $t(y)$ e $h(y)$ tem valores em subconjuntos dos reais e as três primeiras em geral não são únicas. O suporte da família exponencial, isto é, $\{y : f(y;\theta) > 0\}$ não pode depender de θ.

Família exponencial

A família exponencial uniparamétrica é caracterizada por uma função (densidade) de probabilidade especificada na forma

$$f(y;\theta) = h(y)\exp[\eta(\theta)t(y) - b(\theta)], \tag{1}$$

em que as funções $\eta(\theta)$, $b(\theta)$, $t(y)$ e $h(y)$ tem valores em subconjuntos dos reais e as três primeiras em geral não são únicas. O suporte da família exponencial, isto é, $\{y : f(y;\theta) > 0\}$ não pode depender de θ.

A família exponencial na forma canônica, é definida por (1) considerando que as funções $\eta(\theta)$ e $t(y)$ são iguais à função identidade,

Família exponencial

A família exponencial uniparamétrica é caracterizada por uma função (densidade) de probabilidade especificada na forma

$$f(y;\theta) = h(y)\exp[\eta(\theta)t(y) - b(\theta)], \tag{1}$$

em que as funções $\eta(\theta)$, $b(\theta)$, $t(y)$ e $h(y)$ tem valores em subconjuntos dos reais e as três primeiras em geral não são únicas. O suporte da família exponencial, isto é, $\{y : f(y;\theta) > 0\}$ não pode depender de θ.

A família exponencial na forma canônica, é definida por (1) considerando que as funções $\eta(\theta)$ e $t(y)$ são iguais à função identidade, de forma que

$$f(y;\theta) = h(y)\exp[\theta y - b(\theta)]. \tag{2}$$

Família exponencial

A família exponencial uniparamétrica é caracterizada por uma função (densidade) de probabilidade especificada na forma

$$f(y;\theta) = h(y)\exp[\eta(\theta)t(y) - b(\theta)], \tag{1}$$

em que as funções $\eta(\theta)$, $b(\theta)$, $t(y)$ e $h(y)$ tem valores em subconjuntos dos reais e as três primeiras em geral não são únicas. O suporte da família exponencial, isto é, $\{y : f(y;\theta) > 0\}$ não pode depender de θ.

A família exponencial na forma canônica, é definida por (1) considerando que as funções $\eta(\theta)$ e $t(y)$ são iguais à função identidade, de forma que

$$f(y;\theta) = h(y)\exp[\theta y - b(\theta)]. \tag{2}$$

Na parametrização (2), θ é denominado parâmetro canônico.

Família exponencial

Família exponencial na forma canônica: $f(y;\theta) = h(y)\exp[\theta y - b(\theta)]$.

Família exponencial

Família exponencial na forma canônica: $f(y;\theta) = h(y)\exp[\theta y - b(\theta)]$.

Os MLGen são definidos a partir da família (2) com a introdução de um parâmetro de perturbação $\phi > 0$,

Família exponencial

Família exponencial na forma canônica: $f(y;\theta) = h(y)\exp[\theta y - b(\theta)]$.

Os MLGen são definidos a partir da família (2) com a introdução de um parâmetro de perturbação $\phi > 0$, em que ϕ^{-1} (ou ϕ de acordo com alguns livros) é uma medida de dispersão da distribuição.

Família exponencial

Família exponencial na forma canônica: $f(y;\theta) = h(y)\exp[\theta y - b(\theta)]$.

Os MLGen são definidos a partir da família (2) com a introdução de um parâmetro de perturbação $\phi > 0$, em que ϕ^{-1} (ou ϕ de acordo com alguns livros) é uma medida de dispersão da distribuição. Assim, a família de distribuições consideradas nos modelos lineares generalizados é dada por

$$f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}, \tag{3}$$

Família exponencial

Família exponencial na forma canônica: $f(y;\theta) = h(y)\exp[\theta y - b(\theta)]$.

Os MLGen são definidos a partir da família (2) com a introdução de um parâmetro de perturbação $\phi > 0$, em que ϕ^{-1} (ou ϕ de acordo com alguns livros) é uma medida de dispersão da distribuição. Assim, a família de distribuições consideradas nos modelos lineares generalizados é dada por

$$f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}, \tag{3}$$

em que $b(.)$ e $c(.)$ são funções conhecidas.

Família exponencial

Família exponencial na forma canônica: $f(y;\theta) = h(y)\exp[\theta y - b(\theta)]$.

Os MLGen são definidos a partir da família (2) com a introdução de um parâmetro de perturbação $\phi > 0$, em que ϕ^{-1} (ou ϕ de acordo com alguns livros) é uma medida de dispersão da distribuição. Assim, a família de distribuições consideradas nos modelos lineares generalizados é dada por

$$f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}, \tag{3}$$

em que $b(.)$ e $c(.)$ são funções conhecidas.

Quando ϕ é conhecido, a família de distribuições (3) é idêntica à família exponencial na forma canônica.

Família exponencial

Família exponencial na forma canônica: $f(y;\theta) = h(y)\exp[\theta y - b(\theta)]$.

Os MLGen são definidos a partir da família (2) com a introdução de um parâmetro de perturbação $\phi > 0$, em que ϕ^{-1} (ou ϕ de acordo com alguns livros) é uma medida de dispersão da distribuição. Assim, a família de distribuições consideradas nos modelos lineares generalizados é dada por

$$f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}, \tag{3}$$

em que $b(.)$ e $c(.)$ são funções conhecidas.

Quando ϕ é conhecido, a família de distribuições (3) é idêntica à família exponencial na forma canônica.

Denominamos à família (3) de família exponencial linear (FEL).

Outras famílias exponencial

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Outras famílias exponencial

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

A família exponencial biparamétrica tem função (densidade) de probabilidade na forma

Outras famílias exponencial

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

A família exponencial biparamétrica tem função (densidade) de probabilidade na forma

$$f(y;\theta) = h(y)\exp\left[\sum_{i=1}^{2}\eta_i(\theta)t_i(y) - b(\theta)\right]. \tag{4}$$

Outras famílias exponencial

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

A família exponencial biparamétrica tem função (densidade) de probabilidade na forma

$$f(y;\theta) = h(y)\exp\left[\sum_{i=1}^{2}\eta_i(\theta)t_i(y) - b(\theta)\right]. \tag{4}$$

A família exponencial não linear tem função (densidade) de probabilidade na forma

Outras famílias exponencial

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

A família exponencial biparamétrica tem função (densidade) de probabilidade na forma

$$f(y;\theta) = h(y)\exp\left[\sum_{i=1}^{2}\eta_i(\theta)t_i(y) - b(\theta)\right]. \tag{4}$$

A família exponencial não linear tem função (densidade) de probabilidade na forma

$$f(y;\theta,\phi) = \exp\{\phi[\theta t(y) - b(\theta)] + c(y,\phi)\}. \tag{5}$$

Outras famílias exponencial

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

A família exponencial biparamétrica tem função (densidade) de probabilidade na forma

$$f(y;\theta) = h(y)\exp\left[\sum_{i=1}^{2}\eta_i(\theta)t_i(y) - b(\theta)\right]. \tag{4}$$

A família exponencial não linear tem função (densidade) de probabilidade na forma

$$f(y;\theta,\phi) = \exp\{\phi[\theta t(y) - b(\theta)] + c(y,\phi)\}. \tag{5}$$

As distribuições normal, gama e gaussiana inversa pertencem às família (3), (4) e (5),

Outras famílias exponencial

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

A família exponencial biparamétrica tem função (densidade) de probabilidade na forma

$$f(y;\theta) = h(y)\exp\left[\sum_{i=1}^{2}\eta_i(\theta)t_i(y) - b(\theta)\right]. \tag{4}$$

A família exponencial não linear tem função (densidade) de probabilidade na forma

$$f(y;\theta,\phi) = \exp\{\phi[\theta t(y) - b(\theta)] + c(y,\phi)\}. \tag{5}$$

As distribuições normal, gama e gaussiana inversa pertencem às família (3), (4) e (5), mas a distribuição beta, por exemplo, pertence apenas às famílias (4) e (5).

Função geradora de momentos da FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Função geradora de momentos da FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Temos que

$$\int \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\} = 1$$

Função geradora de momentos da FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Temos que

$$\int \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\} = 1 \Leftrightarrow \int \exp\{\phi\theta y + c(y,\phi)\} = exp[\phi b(\theta)].$$

Função geradora de momentos da FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Temos que

$$\int \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\} = 1 \Leftrightarrow \int \exp\{\phi\theta y + c(y,\phi)\} = exp[\phi b(\theta)].$$

Assim,

$$M_y(t) = \mathrm{E}[exp(ty)]$$

Função geradora de momentos da FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Temos que

$$\int \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\} = 1 \Leftrightarrow \int \exp\{\phi\theta y + c(y,\phi)\} = exp[\phi b(\theta)].$$

Assim,

$$M_y(t) = \mathrm{E}[exp(ty)] = \int [exp(ty)] f(y;\theta,\phi) dy$$

Função geradora de momentos da FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Temos que

$$\int \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\} = 1 \Leftrightarrow \int \exp\{\phi\theta y + c(y,\phi)\} = exp[\phi b(\theta)].$$

Assim,

$$M_y(t) = \mathrm{E}[exp(ty)] = \int [exp(ty)] f(y;\theta,\phi) dy =$$

$$\int \exp\{\phi[(\phi^{-1}t + \theta)y - b(\theta)] + c(y,\phi)\} dy$$

Função geradora de momentos da FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Temos que

$$\int \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\} = 1 \Leftrightarrow \int \exp\{\phi\theta y + c(y,\phi)\} = exp[\phi b(\theta)].$$

Assim,

$$M_y(t) = \mathrm{E}[exp(ty)] = \int [exp(ty)] f(y;\theta,\phi) dy =$$

$$\int \exp\{\phi[(\phi^{-1}t + \theta)y - b(\theta)] + c(y,\phi)\} dy =$$

$$exp[-\phi b(\theta)] \int \exp\{\phi[(\phi^{-1}t + \theta)y] + c(y,\phi)\} dy$$

Função geradora de momentos da FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Temos que

$$\int \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\} = 1 \Leftrightarrow \int \exp\{\phi\theta y + c(y,\phi)\} = exp[\phi b(\theta)].$$

Assim,

$$M_y(t) = \mathrm{E}[exp(ty)] = \int [exp(ty)] f(y;\theta,\phi) dy =$$

$$\int \exp\{\phi[(\phi^{-1}t + \theta)y - b(\theta)] + c(y,\phi)\} dy =$$

$$exp[-\phi b(\theta)] \int \exp\{\phi[(\phi^{-1}t + \theta)y] + c(y,\phi)\} dy =$$

$$exp[-\phi b(\theta)] exp[\phi b(\phi^{-1}t + \theta)]$$

Função geradora de momentos da FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Temos que

$$\int \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\} = 1 \Leftrightarrow \int \exp\{\phi\theta y + c(y,\phi)\} = exp[\phi b(\theta)].$$

Assim,

$$M_y(t) = \mathrm{E}[exp(ty)] = \int [exp(ty)] f(y;\theta,\phi) dy =$$

$$\int \exp\{\phi[(\phi^{-1}t + \theta)y - b(\theta)] + c(y,\phi)\} dy =$$

$$exp[-\phi b(\theta)] \int \exp\{\phi[(\phi^{-1}t + \theta)y] + c(y,\phi)\} dy =$$

$$exp[-\phi b(\theta)] exp[\phi b(\phi^{-1}t + \theta)] = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}$$

Esperança da FEL

$$M_y(t) = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}.$$

$$\frac{\partial M_y(t)}{\partial t}$$

Esperança da FEL

$$M_y(t) = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}.$$

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}\phi b'(\phi^{-1}t + \theta)\phi^{-1}$$

Esperança da FEL

$$M_y(t) = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}.$$

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}\phi b'(\phi^{-1}t + \theta)\phi^{-1} =$$

$$exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta).$$

Esperança da FEL

$$M_y(t) = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}.$$

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}\phi b'(\phi^{-1}t + \theta)\phi^{-1} =$$

$$exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta).$$

Assim,

$$\mathrm{E}(y) =$$

Esperança da FEL

$$M_y(t) = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}.$$

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}\phi b'(\phi^{-1}t + \theta)\phi^{-1} =$$

$$exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta).$$

Assim,

$$\mathrm{E}(y) = exp\{\phi[b(\theta) - b(\theta)]\}b'(\theta)$$

Esperança da FEL

$$M_y(t) = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}.$$

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}\phi b'(\phi^{-1}t + \theta)\phi^{-1} =$$

$$exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta).$$

Assim,

$$\mathrm{E}(y) = exp\{\phi[b(\theta) - b(\theta)]\}b'(\theta) = b'(\theta)$$

Variância da FEL

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)$$

Variância da FEL

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)$$

$$\frac{\partial^2 M_y(t)}{\partial t^2}$$

Variância da FEL

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)$$

$$\frac{\partial^2 M_y(t)}{\partial t^2} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)b'(\phi^{-1}t + \theta)$$

Variância da FEL

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)$$

$$\frac{\partial^2 M_y(t)}{\partial t^2} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)b'(\phi^{-1}t + \theta) +$$

$$\exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b''(\phi^{-1}t + \theta)\phi^{-1}.$$

Variância da FEL

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)$$

$$\frac{\partial^2 M_y(t)}{\partial t^2} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)b'(\phi^{-1}t + \theta) +$$

$\exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b''(\phi^{-1}t + \theta)\phi^{-1}$.

Assim,

$$\mathrm{E}\left(y^2\right)$$

Variância da FEL

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)$$

$$\frac{\partial^2 M_y(t)}{\partial t^2} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)b'(\phi^{-1}t + \theta) +$$

$\exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b''(\phi^{-1}t + \theta)\phi^{-1}$.

Assim,

$$\mathrm{E}\left(y^2\right) = [b'(\theta)]^2 + b''(\theta)\phi^{-1},$$

Variância da FEL

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)$$

$$\frac{\partial^2 M_y(t)}{\partial t^2} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)b'(\phi^{-1}t + \theta) +$$

$\exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b''(\phi^{-1}t + \theta)\phi^{-1}$.

Assim,

$$\mathrm{E}\left(y^2\right) = [b'(\theta)]^2 + b''(\theta)\phi^{-1},$$

$$\mathrm{Var}(y)$$

Variância da FEL

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)$$

$$\frac{\partial^2 M_y(t)}{\partial t^2} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)b'(\phi^{-1}t + \theta) +$$

$\exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b''(\phi^{-1}t + \theta)\phi^{-1}$.

Assim,

$$\mathrm{E}\left(y^2\right) = [b'(\theta)]^2 + b''(\theta)\phi^{-1},$$

$$\mathrm{Var}(y) = \phi^{-1}b''(\theta).$$

Variância da FEL

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)$$

$$\frac{\partial^2 M_y(t)}{\partial t^2} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)b'(\phi^{-1}t + \theta) +$$

$\exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b''(\phi^{-1}t + \theta)\phi^{-1}$.

Assim,

$$\mathrm{E}\left(y^2\right) = [b'(\theta)]^2 + b''(\theta)\phi^{-1},$$

$$\mathrm{Var}(y) = \phi^{-1}b''(\theta).$$

A função $b''(\theta) = V(\mu)$ é denominada função de variância

Variância da FEL

$$\frac{\partial M_y(t)}{\partial t} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)$$

$$\frac{\partial^2 M_y(t)}{\partial t^2} = exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b'(\phi^{-1}t + \theta)b'(\phi^{-1}t + \theta) +$$

$\exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\}b''(\phi^{-1}t + \theta)\phi^{-1}$.

Assim,

$$\mathrm{E}\left(y^2\right) = [b'(\theta)]^2 + b''(\theta)\phi^{-1},$$

$$\mathrm{Var}(y) = \phi^{-1}b''(\theta).$$

A função $b''(\theta) = V(\mu)$ é denominada função de variância e caracteriza a distribuição na classe das distribuições da família exponencial linear.

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^{y}}{y!}$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\}$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\} = exp\{y\log\mu - \mu - \log y!\},$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\} = exp\{y\log\mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log\mu$, $b(\theta) = e^\theta$ e $c(y,\phi) = -\log y!$.

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\} = exp\{y\log\mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log\mu$, $b(\theta) = e^\theta$ e $c(y,\phi) = -\log y!$. Assim,

$$\mathrm{E}(y)$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\} = exp\{y\log\mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log\mu$, $b(\theta) = e^\theta$ e $c(y,\phi) = -\log y!$. Assim,

$$\mathrm{E}(y) = e^\theta$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\} = exp\{y\log\mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log\mu$, $b(\theta) = e^\theta$ e $c(y,\phi) = -\log y!$. Assim,

$$\mathrm{E}(y) = e^\theta = \mu,$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\} = exp\{y\log\mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log\mu$, $b(\theta) = e^\theta$ e $c(y,\phi) = -\log y!$. Assim,

$$\mathrm{E}(y) = e^\theta = \mu, V(\mu)$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\} = exp\{y\log\mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log\mu$, $b(\theta) = e^\theta$ e $c(y,\phi) = -\log y!$. Assim,

$$\mathrm{E}(y) = e^\theta = \mu, V(\mu) = e^\theta$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\} = exp\{y\log\mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log\mu$, $b(\theta) = e^\theta$ e $c(y,\phi) = -\log y!$. Assim,

$$\mathrm{E}(y) = e^\theta = \mu, V(\mu) = e^\theta = \mu,$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\} = exp\{y\log\mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log\mu$, $b(\theta) = e^\theta$ e $c(y,\phi) = -\log y!$. Assim,

$$\mathrm{E}(y) = e^\theta = \mu, V(\mu) = e^\theta = \mu, \mathrm{Var}(y)$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

As principais distribuições na FEL são: normal, gama, gaussiana inversa, poisson e binomial.

Exemplo 1: poisson

$$f(y;\mu) = \frac{e^{-\mu}\mu^y}{y!} = exp\{-\mu + y\log\mu - \log y!\} = exp\{y\log\mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log\mu$, $b(\theta) = e^\theta$ e $c(y,\phi) = -\log y!$. Assim,

$$\mathrm{E}(y) = e^\theta = \mu, V(\mu) = e^\theta = \mu, \mathrm{Var}(y) = \mu$$

Exemplos de distribuições na FEL

Exemplos de distribuições na FEL

Exemplo 2: gama

Uma das parametrizações usuais da distribuição gama tem f.d.p. dada por

$$f(y;\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} y^{\alpha-1} e^{-y/\beta}.$$

Exemplos de distribuições na FEL

Exemplo 2: gama

Uma das parametrizações usuais da distribuição gama tem f.d.p. dada por

$$f(y;\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} y^{\alpha-1} e^{-y/\beta}.$$

Nessa parametrização, $\mathrm{E}(y) = \alpha\beta$ e $\mathrm{Var}(y) = \alpha\beta^2$.

Exemplos de distribuições na FEL

Exemplo 2: gama

Uma das parametrizações usuais da distribuição gama tem f.d.p. dada por

$$f(y;\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} y^{\alpha-1} e^{-y/\beta}.$$

Nessa parametrização, $\mathrm{E}(y) = \alpha\beta$ e $\mathrm{Var}(y) = \alpha\beta^2$.

Reparametrizando de forma que $\mu = \alpha\beta$ e $\lambda = \alpha$,

Exemplos de distribuições na FEL

Exemplo 2: gama

Uma das parametrizações usuais da distribuição gama tem f.d.p. dada por

$$f(y;\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} y^{\alpha-1} e^{-y/\beta}.$$

Nessa parametrização, $\mathrm{E}(y) = \alpha\beta$ e $\mathrm{Var}(y) = \alpha\beta^2$.

Reparametrizando de forma que $\mu = \alpha\beta$ e $\lambda = \alpha$, o que resulta em $\alpha = \lambda$ e $\beta = \mu/\lambda$,

Exemplos de distribuições na FEL

Exemplo 2: gama

Uma das parametrizações usuais da distribuição gama tem f.d.p. dada por

$$f(y;\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} y^{\alpha-1} e^{-y/\beta}.$$

Nessa parametrização, $\mathrm{E}(y) = \alpha\beta$ e $\mathrm{Var}(y) = \alpha\beta^2$.

Reparametrizando de forma que $\mu = \alpha\beta$ e $\lambda = \alpha$, o que resulta em $\alpha = \lambda$ e $\beta = \mu/\lambda$, temos que $\mathrm{E}(y) = \mu$, $\mathrm{Var}(y) = \lambda(\mu/\lambda)^2$

Exemplos de distribuições na FEL

Exemplo 2: gama

Uma das parametrizações usuais da distribuição gama tem f.d.p. dada por

$$f(y;\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} y^{\alpha-1} e^{-y/\beta}.$$

Nessa parametrização, $\mathrm{E}(y) = \alpha\beta$ e $\mathrm{Var}(y) = \alpha\beta^2$.

Reparametrizando de forma que $\mu = \alpha\beta$ e $\lambda = \alpha$, o que resulta em $\alpha = \lambda$ e $\beta = \mu/\lambda$, temos que $\mathrm{E}(y) = \mu$, $\mathrm{Var}(y) = \lambda(\mu/\lambda)^2 = \mu^2/\lambda$

Exemplos de distribuições na FEL

Exemplo 2: gama

Uma das parametrizações usuais da distribuição gama tem f.d.p. dada por

$$f(y;\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} y^{\alpha-1} e^{-y/\beta}.$$

Nessa parametrização, $\mathrm{E}(y) = \alpha\beta$ e $\mathrm{Var}(y) = \alpha\beta^2$.

Reparametrizando de forma que $\mu = \alpha\beta$ e $\lambda = \alpha$, o que resulta em $\alpha = \lambda$ e $\beta = \mu/\lambda$, temos que $\mathrm{E}(y) = \mu$, $\mathrm{Var}(y) = \lambda(\mu/\lambda)^2 = \mu^2/\lambda$ e a f.dp. fica dada por

Exemplos de distribuições na FEL

Exemplo 2: gama

Uma das parametrizações usuais da distribuição gama tem f.d.p. dada por

$$f(y;\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} y^{\alpha-1} e^{-y/\beta}.$$

Nessa parametrização, $\mathrm{E}(y) = \alpha\beta$ e $\mathrm{Var}(y) = \alpha\beta^2$.

Reparametrizando de forma que $\mu = \alpha\beta$ e $\lambda = \alpha$, o que resulta em $\alpha = \lambda$ e $\beta = \mu/\lambda$, temos que $\mathrm{E}(y) = \mu$, $\mathrm{Var}(y) = \lambda(\mu/\lambda)^2 = \mu^2/\lambda$ e a f.dp. fica dada por

$$f(y;\mu,\lambda) = \frac{1}{\Gamma(\lambda)(\mu/\lambda)^{\lambda}} y^{\lambda-1} e^{-\lambda y/\mu}.$$

Exemplos de distribuições na FEL

Exemplo 2: gama

Uma das parametrizações usuais da distribuição gama tem f.d.p. dada por

$$f(y;\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} y^{\alpha-1} e^{-y/\beta}.$$

Nessa parametrização, $\mathrm{E}(y) = \alpha\beta$ e $\mathrm{Var}(y) = \alpha\beta^2$.

Reparametrizando de forma que $\mu = \alpha\beta$ e $\lambda = \alpha$, o que resulta em $\alpha = \lambda$ e $\beta = \mu/\lambda$, temos que $\mathrm{E}(y) = \mu$, $\mathrm{Var}(y) = \lambda(\mu/\lambda)^2 = \mu^2/\lambda$ e a f.dp. fica dada por

$$f(y;\mu,\lambda) = \frac{1}{\Gamma(\lambda)(\mu/\lambda)^{\lambda}} y^{\lambda-1} e^{-\lambda y/\mu}.$$

Exemplos de distribuições na FEL

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Exemplo 2: gama

$$f(y;\mu,\lambda) = \frac{1}{\Gamma(\lambda)(\mu/\lambda)^{\lambda}} y^{\lambda-1} e^{-\lambda y/\mu}$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Exemplo 2: gama

$$f(y;\mu,\lambda) = \frac{1}{\Gamma(\lambda)(\mu/\lambda)^{\lambda}} y^{\lambda-1} e^{-\lambda y/\mu} =$$

$$exp\{-\log\Gamma(\lambda) - \lambda\log\mu + \lambda\log\lambda + (\lambda-1)\log y - (\lambda y)/\mu\}$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Exemplo 2: gama

$$f(y;\mu,\lambda) = \frac{1}{\Gamma(\lambda)(\mu/\lambda)^{\lambda}} y^{\lambda-1} e^{-\lambda y/\mu} =$$

$$exp\{-\log\Gamma(\lambda) - \lambda\log\mu + \lambda\log\lambda + (\lambda-1)\log y - (\lambda y)/\mu\}$$

$$exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Exemplo 2: gama

$$f(y;\mu,\lambda) = \frac{1}{\Gamma(\lambda)(\mu/\lambda)^{\lambda}} y^{\lambda-1} e^{-\lambda y/\mu} =$$

$$exp\{-\log\Gamma(\lambda) - \lambda\log\mu + \lambda\log\lambda + (\lambda-1)\log y - (\lambda y)/\mu\}$$

$$exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$,

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Exemplo 2: gama

$$f(y;\mu,\lambda) = \frac{1}{\Gamma(\lambda)(\mu/\lambda)^{\lambda}} y^{\lambda-1} e^{-\lambda y/\mu} =$$

$$exp\{-\log\Gamma(\lambda) - \lambda\log\mu + \lambda\log\lambda + (\lambda-1)\log y - (\lambda y)/\mu\}$$

$$exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$,

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Exemplo 2: gama

$$f(y;\mu,\lambda) = \frac{1}{\Gamma(\lambda)(\mu/\lambda)^{\lambda}} y^{\lambda-1} e^{-\lambda y/\mu} =$$

$$exp\{-\log\Gamma(\lambda) - \lambda\log\mu + \lambda\log\lambda + (\lambda-1)\log y - (\lambda y)/\mu\}$$

$$exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta)$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Exemplo 2: gama

$$f(y;\mu,\lambda) = \frac{1}{\Gamma(\lambda)(\mu/\lambda)^{\lambda}} y^{\lambda-1} e^{-\lambda y/\mu} =$$

$$exp\{-\log\Gamma(\lambda) - \lambda\log\mu + \lambda\log\lambda + (\lambda-1)\log y - (\lambda y)/\mu\}$$

$$exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$

Exemplos de distribuições na FEL

Família exponencial linear: $f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$.

Exemplo 2: gama

$$f(y;\mu,\lambda) = \frac{1}{\Gamma(\lambda)(\mu/\lambda)^{\lambda}} y^{\lambda-1} e^{-\lambda y/\mu} =$$

$$exp\{-\log\Gamma(\lambda) - \lambda\log\mu + \lambda\log\lambda + (\lambda-1)\log y - (\lambda y)/\mu\}$$

$$exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

Exemplos de distribuições na FEL

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$,

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$,

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta)$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta)$$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta) = \frac{-1}{-\theta}(-1)$$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta) = \frac{-1}{-\theta}(-1) = -\frac{1}{\theta}$$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta) = \frac{-1}{-\theta}(-1) = -\frac{1}{\theta} \quad , b''(\theta)$$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta) = \frac{-1}{-\theta}(-1) = -\frac{1}{\theta} \quad , b''(\theta) = \frac{1}{\theta^2}.$$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta) = \frac{-1}{-\theta}(-1) = -\frac{1}{\theta} \quad , b''(\theta) = \frac{1}{\theta^2}.$$ Assim,

$$\mathrm{E}(y)$$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta) = \frac{-1}{-\theta}(-1) = -\frac{1}{\theta} \quad , b''(\theta) = \frac{1}{\theta^2}.$$ Assim,

$$\mathrm{E}(y) = \mu,$$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta) = \frac{-1}{-\theta}(-1) = -\frac{1}{\theta} \quad , b''(\theta) = \frac{1}{\theta^2}.$$ Assim,

$$E(y) = \mu, V(\mu)$$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta) = \frac{-1}{-\theta}(-1) = -\frac{1}{\theta} \quad , b''(\theta) = \frac{1}{\theta^2}. \text{ Assim,}$$

$$\mathrm{E}(y) = \mu, V(\mu) = \mu^2,$$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta) = \frac{-1}{-\theta}(-1) = -\frac{1}{\theta} \quad , b''(\theta) = \frac{1}{\theta^2}. \text{ Assim,}$$

$$\mathrm{E}(y) = \mu, V(\mu) = \mu^2, \mathrm{Var}(y)$$

Exemplos de distribuições na FEL

Exemplo 2: gama

$$f(y;\mu,\lambda) = exp\{\lambda[-y/\mu - \log\mu] + (\lambda-1)\log y + \lambda\log\lambda - \log\Gamma(\lambda)\},$$

que está na forma da FEL com $\theta = -1/\mu$, $\phi = \lambda$, $b(\theta) = \log(-1/\theta) = -\log(-\theta)$ e $c(y,\phi) = (\phi-1)\log y + \phi\log\phi - \log\Gamma(\phi)$.

$$b'(\theta) = \frac{-1}{-\theta}(-1) = -\frac{1}{\theta} \quad , b''(\theta) = \frac{1}{\theta^2}. \text{ Assim,}$$

$$\mathrm{E}(y) = \mu, V(\mu) = \mu^2, \mathrm{Var}(y) = \phi^{-1}\mu^2.$$

Modelos lineares generalizados

Modelos lineares generalizados

Definição:

Modelos lineares generalizados

Definição: Sejam $y_1, y_2, ..., y_n$ variáveis aleatórias independentes, cada uma delas com distribuição que pertence à família exponencial linear (FEL) definida na equação (3) da parte 1 desta aula

Modelos lineares generalizados

Definição: Sejam $y_1, y_2, ..., y_n$ variáveis aleatórias independentes, cada uma delas com distribuição que pertence à família exponencial linear (FEL) definida na equação (3) da parte 1 desta aula com parâmetros θ_i e ϕ.

Modelos lineares generalizados

Definição: Sejam $y_1, y_2, ..., y_n$ variáveis aleatórias independentes, cada uma delas com distribuição que pertence à família exponencial linear (FEL) definida na equação (3) da parte 1 desta aula com parâmetros θ_i e ϕ. Os modelos lineares generalizados (MLGen) são definidos pela equação (3) e pelo seguinte componente sistemático:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta},$$

Modelos lineares generalizados

Definição: Sejam $y_1, y_2, ..., y_n$ variáveis aleatórias independentes, cada uma delas com distribuição que pertence à família exponencial linear (FEL) definida na equação (3) da parte 1 desta aula com parâmetros θ_i e ϕ. Os modelos lineares generalizados (MLGen) são definidos pela equação (3) e pelo seguinte componente sistemático:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}, \tag{6}$$

em que $\boldsymbol{\mu}_i = \mathrm{E}(y_i) = b'(\theta_i)$,

Modelos lineares generalizados

Definição: Sejam $y_1, y_2, ..., y_n$ variáveis aleatórias independentes, cada uma delas com distribuição que pertence à família exponencial linear (FEL) definida na equação (3) da parte 1 desta aula com parâmetros θ_i e ϕ. Os modelos lineares generalizados (MLGen) são definidos pela equação (3) e pelo seguinte componente sistemático:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}, \tag{6}$$

em que $\boldsymbol{\mu}_i = \mathrm{E}(y_i) = b'(\theta_i)$, $\boldsymbol{\beta} = (\beta_0, \beta_1, ..., \beta_k)^\top$,

Modelos lineares generalizados

Definição: Sejam $y_1, y_2, ..., y_n$ variáveis aleatórias independentes, cada uma delas com distribuição que pertence à família exponencial linear (FEL) definida na equação (3) da parte 1 desta aula com parâmetros θ_i e ϕ. Os modelos lineares generalizados (MLGen) são definidos pela equação (3) e pelo seguinte componente sistemático:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}, \tag{6}$$

em que $\boldsymbol{\mu}_i = \mathrm{E}(y_i) = b'(\theta_i)$, $\boldsymbol{\beta} = (\beta_0, \beta_1, ..., \beta_k)^\top$,
$\mathbf{x}_i = (1, x_{i1}, x_{i2}, ..., x_{ik})^\top$ são constantes que representam os valores das variáveis preditoras

Modelos lineares generalizados

Definição: Sejam $y_1, y_2, ..., y_n$ variáveis aleatórias independentes, cada uma delas com distribuição que pertence à família exponencial linear (FEL) definida na equação (3) da parte 1 desta aula com parâmetros θ_i e ϕ. Os modelos lineares generalizados (MLGen) são definidos pela equação (3) e pelo seguinte componente sistemático:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}, \tag{6}$$

em que $\boldsymbol{\mu}_i = \mathrm{E}(y_i) = b'(\theta_i)$, $\boldsymbol{\beta} = (\beta_0, \beta_1, ..., \beta_k)^\top$,
$\mathbf{x}_i = (1, x_{i1}, x_{i2}, ..., x_{ik})^\top$ são constantes que representam os valores das variáveis preditoras e g é uma função de ligação estritamente monótona e pelo menos duplamente diferenciável.

Modelos lineares generalizados

Definição: Sejam $y_1, y_2, ..., y_n$ variáveis aleatórias independentes, cada uma delas com distribuição que pertence à família exponencial linear (FEL) definida na equação (3) da parte 1 desta aula com parâmetros θ_i e ϕ. Os modelos lineares generalizados (MLGen) são definidos pela equação (3) e pelo seguinte componente sistemático:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}, \tag{6}$$

em que $\boldsymbol{\mu}_i = \mathrm{E}(y_i) = b'(\theta_i)$, $\boldsymbol{\beta} = (\beta_0, \beta_1, ..., \beta_k)^\top$,
$\mathbf{x}_i = (1, x_{i1}, x_{i2}, ..., x_{ik})^\top$ são constantes que representam os valores das variáveis preditoras e g é uma função de ligação estritamente monótona e pelo menos duplamente diferenciável.

Modelos lineares generalizados

Definição: Sejam $y_1, y_2, ..., y_n$ variáveis aleatórias independentes, cada uma delas com distribuição que pertence à família exponencial linear (FEL) definida na equação (3) da parte 1 desta aula com parâmetros θ_i e ϕ. Os modelos lineares generalizados (MLGen) são definidos pela equação (3) e pelo seguinte componente sistemático:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}, \tag{6}$$

em que $\boldsymbol{\mu}_i = \mathrm{E}(y_i) = b'(\theta_i)$, $\boldsymbol{\beta} = (\beta_0, \beta_1, ..., \beta_k)^\top$, $\mathbf{x}_i = (1, x_{i1}, x_{i2}, ..., x_{ik})^\top$ são constantes que representam os valores das variáveis preditoras e g é uma função de ligação estritamente monótona e pelo menos duplamente diferenciável.

Podemos representar também (6) como $g(\mu_i) = \eta_i$,

Modelos lineares generalizados

Definição: Sejam $y_1, y_2, ..., y_n$ variáveis aleatórias independentes, cada uma delas com distribuição que pertence à família exponencial linear (FEL) definida na equação (3) da parte 1 desta aula com parâmetros θ_i e ϕ. Os modelos lineares generalizados (MLGen) são definidos pela equação (3) e pelo seguinte componente sistemático:

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}, \tag{6}$$

em que $\boldsymbol{\mu}_i = \mathrm{E}(y_i) = b'(\theta_i)$, $\boldsymbol{\beta} = (\beta_0, \beta_1, ..., \beta_k)^\top$, $\mathbf{x}_i = (1, x_{i1}, x_{i2}, ..., x_{ik})^\top$ são constantes que representam os valores das variáveis preditoras e g é uma função de ligação estritamente monótona e pelo menos duplamente diferenciável.

Podemos representar também (6) como $g(\mu_i) = \eta_i$, em que $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$ é denominado preditor linear.

Modelos lineares generalizados

Modelos lineares generalizados

Os MLGen possui 3 componentes:

Modelos lineares generalizados

Os MLGen possui 3 componentes:

- Componente aleatório: representado por um conjunto de variáveis aleatórias independentes $y_1, y_2, ..., y_n$

Modelos lineares generalizados

Os MLGen possui 3 componentes:

- Componente aleatório: representado por um conjunto de variáveis aleatórias independentes $y_1, y_2, ..., y_n$ cada uma delas com distribuição que pertence à família exponencial linear com parâmetros θ_i e ϕ.

Modelos lineares generalizados

Os MLGen possui 3 componentes:

- Componente aleatório: representado por um conjunto de variáveis aleatórias independentes $y_1, y_2, ..., y_n$ cada uma delas com distribuição que pertence à família exponencial linear com parâmetros θ_i e ϕ. Baseado nos resultados já vistos da FEL temos que a função (densidade) de probabilidade de y_i é dada por

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\},$$

Modelos lineares generalizados

Os MLGen possui 3 componentes:

- Componente aleatório: representado por um conjunto de variáveis aleatórias independentes $y_1, y_2, ..., y_n$ cada uma delas com distribuição que pertence à família exponencial linear com parâmetros θ_i e ϕ. Baseado nos resultados já vistos da FEL temos que a função (densidade) de probabilidade de y_i é dada por

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\},$$

em que $\mathrm{E}(y_i) = \mu_i = b'(\theta_i)$,

Modelos lineares generalizados

Os MLGen possui 3 componentes:

- Componente aleatório: representado por um conjunto de variáveis aleatórias independentes $y_1, y_2, ..., y_n$ cada uma delas com distribuição que pertence à família exponencial linear com parâmetros θ_i e ϕ. Baseado nos resultados já vistos da FEL temos que a função (densidade) de probabilidade de y_i é dada por

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\},$$

em que $\mathrm{E}(y_i) = \mu_i = b'(\theta_i)$, $\mathrm{Var}(y_i) = \phi^{-1} b''(\theta_i) = \phi^{-1} V_i$, $V_i = V(\mu_i)$.

Modelos lineares generalizados

Os MLGen possui 3 componentes:

- Componente aleatório: representado por um conjunto de variáveis aleatórias independentes $y_1, y_2, ..., y_n$ cada uma delas com distribuição que pertence à família exponencial linear com parâmetros θ_i e ϕ. Baseado nos resultados já vistos da FEL temos que a função (densidade) de probabilidade de y_i é dada por

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\},$$

em que $\mathrm{E}(y_i) = \mu_i = b'(\theta_i)$, $\mathrm{Var}(y_i) = \phi^{-1} b''(\theta_i) = \phi^{-1} V_i$, $V_i = V(\mu_i)$.

Modelos lineares generalizados

Modelos lineares generalizados

- Componente sistemático:

Modelos lineares generalizados

- Componente sistemático: representado pelo termo $\mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$.

Modelos lineares generalizados

- Componente sistemático: representado pelo termo $\mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$. O componente linear engloba tanto o vetor de parâmetros $\boldsymbol{\beta}$ como as variáveis preditoras do modelo.

Modelos lineares generalizados

- Componente sistemático: representado pelo termo $\mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$. O componente linear engloba tanto o vetor de parâmetros $\boldsymbol{\beta}$ como as variáveis preditoras do modelo. O componente sistemático é linear nos parâmetros

Modelos lineares generalizados

- Componente sistemático: representado pelo termo $\mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$. O componente linear engloba tanto o vetor de parâmetros $\boldsymbol{\beta}$ como as variáveis preditoras do modelo. O componente sistemático é linear nos parâmetros e assim podemos ter $x_{ij} = x_{il}^2$ ou $x_{ij} = \log x_{il}$, por exemplo.

Modelos lineares generalizados

- Componente sistemático: representado pelo termo $\mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$. O componente linear engloba tanto o vetor de parâmetros $\boldsymbol{\beta}$ como as variáveis preditoras do modelo. O componente sistemático é linear nos parâmetros e assim podemos ter $x_{ij} = x_{il}^2$ ou $x_{ij} = \log x_{il}$, por exemplo. Se um parâmetro tem valor conhecido, o termo correspondente é denominado offset.

Modelos lineares generalizados

- Componente sistemático: representado pelo termo $\mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$. O componente linear engloba tanto o vetor de parâmetros $\boldsymbol{\beta}$ como as variáveis preditoras do modelo. O componente sistemático é linear nos parâmetros e assim podemos ter $x_{ij} = x_{il}^2$ ou $x_{ij} = \log x_{il}$, por exemplo. Se um parâmetro tem valor conhecido, o termo correspondente é denominado offset.

- Função de ligação:

Modelos lineares generalizados

- Componente sistemático: representado pelo termo $\mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$. O componente linear engloba tanto o vetor de parâmetros $\boldsymbol{\beta}$ como as variáveis preditoras do modelo. O componente sistemático é linear nos parâmetros e assim podemos ter $x_{ij} = x_{il}^2$ ou $x_{ij} = \log x_{il}$, por exemplo. Se um parâmetro tem valor conhecido, o termo correspondente é denominado offset.

- Função de ligação: relaciona o componente aleatório ao sistemático,

Modelos lineares generalizados

- Componente sistemático: representado pelo termo $\mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$. O componente linear engloba tanto o vetor de parâmetros $\boldsymbol{\beta}$ como as variáveis preditoras do modelo. O componente sistemático é linear nos parâmetros e assim podemos ter $x_{ij} = x_{il}^2$ ou $x_{ij} = \log x_{il}$, por exemplo. Se um parâmetro tem valor conhecido, o termo correspondente é denominado offset.

- Função de ligação: relaciona o componente aleatório ao sistemático, sendo $g(.)$ uma função estritamente monótona e duplamente diferenciável.

Modelos lineares generalizados

Modelos lineares generalizados

Ajustar um MLGen consiste em: escolher uma distribuição adequada para a variável resposta,

Modelos lineares generalizados

Ajustar um MLGen consiste em: escolher uma distribuição adequada para a variável resposta, escolher as variáveis preditoras que entrarão no modelo

Modelos lineares generalizados

Ajustar um MLGen consiste em: escolher uma distribuição adequada para a variável resposta, escolher as variáveis preditoras que entrarão no modelo e escolher uma função de ligação.

Modelos lineares generalizados

Ajustar um MLGen consiste em: escolher uma distribuição adequada para a variável resposta, escolher as variáveis preditoras que entrarão no modelo e escolher uma função de ligação.

O MLGer estudado anteriormente pode ser escrito como $\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}$.

Modelos lineares generalizados

Ajustar um MLGen consiste em: escolher uma distribuição adequada para a variável resposta, escolher as variáveis preditoras que entrarão no modelo e escolher uma função de ligação.

O MLGer estudado anteriormente pode ser escrito como $\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Assim, o MLGer é um caso particular de MLGen quando a variável resposta tem distribuição normal e a função de ligação é a identidade.

Modelos lineares generalizados

Ajustar um MLGen consiste em: escolher uma distribuição adequada para a variável resposta, escolher as variáveis preditoras que entrarão no modelo e escolher uma função de ligação.

O MLGer estudado anteriormente pode ser escrito como $\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Assim, o MLGer é um caso particular de MLGen quando a variável resposta tem distribuição normal e a função de ligação é a identidade.

Nos MLGen, o modelo é representado por $g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}$.

Modelos lineares generalizados

Ajustar um MLGen consiste em: escolher uma distribuição adequada para a variável resposta, escolher as variáveis preditoras que entrarão no modelo e escolher uma função de ligação.

O MLGer estudado anteriormente pode ser escrito como $\mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Assim, o MLGer é um caso particular de MLGen quando a variável resposta tem distribuição normal e a função de ligação é a identidade.

Nos MLGen, o modelo é representado por $g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}$. Assim, nessa classe especificamos uma distribuição de probabilidade para a variável resposta (dadas as variáveis preditoras) e não para os erros.

Modelos lineares generalizados

Modelos lineares generalizados

Os MLGen resolve várias limitações do MLGer, pois:

Modelos lineares generalizados

Os MLGen resolve várias limitações do MLGer, pois:

- Nos MLGen, a distribuição da variável resposta não precisa ser normal, podendo pertencer à FEL.

Modelos lineares generalizados

Os MLGen resolve várias limitações do MLGer, pois:

- Nos MLGen, a distribuição da variável resposta não precisa ser normal, podendo pertencer à FEL.
- Não é necessário fazer transformações de variáveis preditoras ou da resposta caso a relação entre μ_i e as preditoras não for linear.

Modelos lineares generalizados

Os MLGen resolve várias limitações do MLGer, pois:

- Nos MLGen, a distribuição da variável resposta não precisa ser normal, podendo pertencer à FEL.
- Não é necessário fazer transformações de variáveis preditoras ou da resposta caso a relação entre μ_i e as preditoras não for linear. Basta escolher uma conveniente função de ligação.

Modelos lineares generalizados

Os MLGen resolve várias limitações do MLGer, pois:

- Nos MLGen, a distribuição da variável resposta não precisa ser normal, podendo pertencer à FEL.
- Não é necessário fazer transformações de variáveis preditoras ou da resposta caso a relação entre μ_i e as preditoras não for linear. Basta escolher uma conveniente função de ligação.
- A variância da variável resposta (dadas as preditoras) não precisa ser constante,

Modelos lineares generalizados

Os MLGen resolve várias limitações do MLGer, pois:

- Nos MLGen, a distribuição da variável resposta não precisa ser normal, podendo pertencer à FEL.
- Não é necessário fazer transformações de variáveis preditoras ou da resposta caso a relação entre μ_i e as preditoras não for linear. Basta escolher uma conveniente função de ligação.
- A variância da variável resposta (dadas as preditoras) não precisa ser constante, pois nos MLGen $\text{Var}(y_i) = \phi^{-1} V(\mu_i)$

Modelos lineares generalizados

Os MLGen resolve várias limitações do MLGer, pois:

- Nos MLGen, a distribuição da variável resposta não precisa ser normal, podendo pertencer à FEL.
- Não é necessário fazer transformações de variáveis preditoras ou da resposta caso a relação entre μ_i e as preditoras não for linear. Basta escolher uma conveniente função de ligação.
- A variância da variável resposta (dadas as preditoras) não precisa ser constante, pois nos MLGen $\text{Var}(y_i) = \phi^{-1} V(\mu_i)$ e assim a variância pode variar em função das variáveis preditoras.

Função de ligação

Função de ligação

A função de ligação $g(.)$ pode ser qualquer função que seja monótona e duplamente diferenciável.

Função de ligação

A função de ligação $g(.)$ pode ser qualquer função que seja monótona e duplamente diferenciável. Se $g(\mu_i) = \theta_i$, o preditor linear modela diretamente o parâmetro canônico θ_i

Função de ligação

A função de ligação $g(.)$ pode ser qualquer função que seja monótona e duplamente diferenciável. Se $g(\mu_i) = \theta_i$, o preditor linear modela diretamente o parâmetro canônico θ_i e neste caso a função de ligação é denominada canônica.

Função de ligação

A função de ligação $g(.)$ pode ser qualquer função que seja monótona e duplamente diferenciável. Se $g(\mu_i) = \theta_i$, o preditor linear modela diretamente o parâmetro canônico θ_i e neste caso a função de ligação é denominada canônica.

No caso da distribuição de Poisson, em que $y_i \sim Poisson(\mu_i)$, $\mu_i = \mathrm{E}(y_i)$,

Função de ligação

A função de ligação $g(.)$ pode ser qualquer função que seja monótona e duplamente diferenciável. Se $g(\mu_i) = \theta_i$, o preditor linear modela diretamente o parâmetro canônico θ_i e neste caso a função de ligação é denominada canônica.

No caso da distribuição de Poisson, em que $y_i \sim Poisson(\mu_i)$, $\mu_i = \mathrm{E}(y_i)$, vimos que $\theta_i = \log \mu_i$.

Função de ligação

A função de ligação $g(.)$ pode ser qualquer função que seja monótona e duplamente diferenciável. Se $g(\mu_i) = \theta_i$, o preditor linear modela diretamente o parâmetro canônico θ_i e neste caso a função de ligação é denominada canônica.

No caso da distribuição de Poisson, em que $y_i \sim Poisson(\mu_i)$, $\mu_i = \mathrm{E}(y_i)$, vimos que $\theta_i = \log \mu_i$.

Assim, a função de ligação canônica para a Poisson é dada por $g(\mu_i) = \log \mu_i$

Função de ligação

A função de ligação $g(.)$ pode ser qualquer função que seja monótona e duplamente diferenciável. Se $g(\mu_i) = \theta_i$, o preditor linear modela diretamente o parâmetro canônico θ_i e neste caso a função de ligação é denominada canônica.

No caso da distribuição de Poisson, em que $y_i \sim Poisson(\mu_i)$, $\mu_i = \mathrm{E}(y_i)$, vimos que $\theta_i = \log \mu_i$.

Assim, a função de ligação canônica para a Poisson é dada por $g(\mu_i) = \log \mu_i$ e o MLGen com esta função de ligação pode ser escrito como

$$\log \mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}$$

Função de ligação

A função de ligação $g(.)$ pode ser qualquer função que seja monótona e duplamente diferenciável. Se $g(\mu_i) = \theta_i$, o preditor linear modela diretamente o parâmetro canônico θ_i e neste caso a função de ligação é denominada canônica.

No caso da distribuição de Poisson, em que $y_i \sim Poisson(\mu_i)$, $\mu_i = \mathrm{E}(y_i)$, vimos que $\theta_i = \log \mu_i$.

Assim, a função de ligação canônica para a Poisson é dada por $g(\mu_i) = \log \mu_i$ e o MLGen com esta função de ligação pode ser escrito como

$$\log \mu_i = \mathbf{x}_i^\top \boldsymbol{\beta} \quad \text{ou} \quad \mu_i = e^{\mathbf{x}_i^\top \boldsymbol{\beta}}.$$

Função de ligação canônica

Função de ligação canônica

A tabela a seguir apresenta a função de ligação canônica para as principais distribuições da família exponencial linear.

Função de ligação canônica

A tabela a seguir apresenta a função de ligação canônica para as principais distribuições da família exponencial linear.

Função de ligação canônica para as principais distribuições da FEL

Função de ligação canônica

A tabela a seguir apresenta a função de ligação canônica para as principais distribuições da família exponencial linear.

Função de ligação canônica para as principais distribuições da FEL

Distribuição	Função de ligação canônica
Normal	Identidade - $g(\mu_i) = \mu_i$

Função de ligação canônica

A tabela a seguir apresenta a função de ligação canônica para as principais distribuições da família exponencial linear.

Função de ligação canônica para as principais distribuições da FEL

Distribuição	Função de ligação canônica
Normal	Identidade - $g(\mu_i) = \mu_i$
Poisson	Logarítmica - $g(\mu_i) = \log \mu_i$

Função de ligação canônica

A tabela a seguir apresenta a função de ligação canônica para as principais distribuições da família exponencial linear.

Função de ligação canônica para as principais distribuições da FEL

Distribuição	Função de ligação canônica
Normal	Identidade - $g(\mu_i) = \mu_i$
Poisson	Logarítmica - $g(\mu_i) = \log \mu_i$
Binomial	Logito - $g(\mu_i) = \log[\mu_i/(1 - \mu_i)]$

Função de ligação canônica

A tabela a seguir apresenta a função de ligação canônica para as principais distribuições da família exponencial linear.

Função de ligação canônica para as principais distribuições da FEL

Distribuição	Função de ligação canônica
Normal	Identidade - $g(\mu_i) = \mu_i$
Poisson	Logarítmica - $g(\mu_i) = \log \mu_i$
Binomial	Logito - $g(\mu_i) = \log[\mu_i/(1-\mu_i)]$
Gama	Recíproca - $g(\mu_i) = 1/\mu_i$

Função de ligação canônica

A tabela a seguir apresenta a função de ligação canônica para as principais distribuições da família exponencial linear.

Função de ligação canônica para as principais distribuições da FEL

Distribuição	Função de ligação canônica
Normal	Identidade - $g(\mu_i) = \mu_i$
Poisson	Logarítmica - $g(\mu_i) = \log \mu_i$
Binomial	Logito - $g(\mu_i) = \log[\mu_i/(1-\mu_i)]$
Gama	Recíproca - $g(\mu_i) = 1/\mu_i$
Gaussiana inversa	Recíproca ao quadrado - $g(\mu_i) = 1/\mu_i^2$

Função de ligação canônica

Função de ligação canônica

O uso da função de ligação canônica apresenta as seguintes vantagens:

Função de ligação canônica

O uso da função de ligação canônica apresenta as seguintes vantagens:

- Garantia da unicidade do EMV.

Função de ligação canônica

O uso da função de ligação canônica apresenta as seguintes vantagens:

- Garantia da unicidade do EMV.
- Facilidade da obtenção de estatística suficiente para β.

Função de ligação canônica

O uso da função de ligação canônica apresenta as seguintes vantagens:

- Garantia da unicidade do EMV.
- Facilidade da obtenção de estatística suficiente para β.
- Simplificação do algoritmo de estimação de β.

Função de ligação canônica

O uso da função de ligação canônica apresenta as seguintes vantagens:

- Garantia da unicidade do EMV.
- Facilidade da obtenção de estatística suficiente para β.
- Simplificação do algoritmo de estimação de β.

Embora do ponto de vista teórico a função de ligação canônica seja interessante, nem sempre ela é a mais conveniente do ponto de vista prático.

Função de ligação canônica

O uso da função de ligação canônica apresenta as seguintes vantagens:

- Garantia da unicidade do EMV.
- Facilidade da obtenção de estatística suficiente para β.
- Simplificação do algoritmo de estimação de β.

Embora do ponto de vista teórico a função de ligação canônica seja interessante, nem sempre ela é a mais conveniente do ponto de vista prático.

Normalmente deseja-se que $g(\mu_i)$ seja escolhida de tal forma que $\hat{\mu}_i$ necessariamente pertença ao espaço paramétrico de μ_i.

Outras Funções de ligação

Outras Funções de ligação

Na distribuição gama, $\mu_i > 0$

Outras Funções de ligação

Na distribuição gama, $\mu_i > 0$ e a função de ligação canônica é $g(\mu_i) = 1/\mu_i$.

Outras Funções de ligação

Na distribuição gama, $\mu_i > 0$ e a função de ligação canônica é $g(\mu_i) = 1/\mu_i$. Assim, se adotarmos a função de ligação canônica,

$$g(\mu_i) = \frac{1}{\mu_i} = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow$$

Outras Funções de ligação

Na distribuição gama, $\mu_i > 0$ e a função de ligação canônica é $g(\mu_i) = 1/\mu_i$. Assim, se adotarmos a função de ligação canônica,

$$g(\mu_i) = \frac{1}{\mu_i} = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow \hat{\mu}_i = \frac{1}{\mathbf{x}_i^\top \hat{\boldsymbol{\beta}}}$$

e assim $\hat{\mu}_i$ não é necessariamente positivo.

Outras Funções de ligação

Na distribuição gama, $\mu_i > 0$ e a função de ligação canônica é $g(\mu_i) = 1/\mu_i$. Assim, se adotarmos a função de ligação canônica,

$$g(\mu_i) = \frac{1}{\mu_i} = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow \hat{\mu}_i = \frac{1}{\mathbf{x}_i^\top \hat{\boldsymbol{\beta}}}$$

e assim $\hat{\mu}_i$ não é necessariamente positivo.

Por esse motivo, para as distribuições gama e gaussian inversa, a função de ligação mais usada é

$$g(\mu_i) = \log \mu_i = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow$$

Outras Funções de ligação

Na distribuição gama, $\mu_i > 0$ e a função de ligação canônica é $g(\mu_i) = 1/\mu_i$. Assim, se adotarmos a função de ligação canônica,

$$g(\mu_i) = \frac{1}{\mu_i} = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow \hat{\mu}_i = \frac{1}{\mathbf{x}_i^\top \hat{\boldsymbol{\beta}}}$$

e assim $\hat{\mu}_i$ não é necessariamente positivo.

Por esse motivo, para as distribuições gama e gaussian inversa, a função de ligação mais usada é

$$g(\mu_i) = \log \mu_i = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow \hat{\mu}_i = e^{\mathbf{x}_i^\top \hat{\boldsymbol{\beta}}},$$

Outras Funções de ligação

Na distribuição gama, $\mu_i > 0$ e a função de ligação canônica é $g(\mu_i) = 1/\mu_i$. Assim, se adotarmos a função de ligação canônica,

$$g(\mu_i) = \frac{1}{\mu_i} = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow \hat{\mu}_i = \frac{1}{\mathbf{x}_i^\top \hat{\boldsymbol{\beta}}}$$

e assim $\hat{\mu}_i$ não é necessariamente positivo.

Por esse motivo, para as distribuições gama e gaussian inversa, a função de ligação mais usada é

$$g(\mu_i) = \log \mu_i = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow \hat{\mu}_i = e^{\mathbf{x}_i^\top \hat{\boldsymbol{\beta}}},$$

que garante que $\hat{\mu}_i$ é positivo.

Outras Funções de ligação

Na distribuição gama, $\mu_i > 0$ e a função de ligação canônica é $g(\mu_i) = 1/\mu_i$. Assim, se adotarmos a função de ligação canônica,

$$g(\mu_i) = \frac{1}{\mu_i} = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow \hat{\mu}_i = \frac{1}{\mathbf{x}_i^\top \hat{\boldsymbol{\beta}}}$$

e assim $\hat{\mu}_i$ não é necessariamente positivo.

Por esse motivo, para as distribuições gama e gaussian inversa, a função de ligação mais usada é

$$g(\mu_i) = \log \mu_i = \mathbf{x}_i^\top \boldsymbol{\beta} \Leftrightarrow \hat{\mu}_i = e^{\mathbf{x}_i^\top \hat{\boldsymbol{\beta}}},$$

que garante que $\hat{\mu}_i$ é positivo.

Para as distribuições normal, poisson e binomial, a função de ligação canônica é a mais usada.

Outras Funções de ligação

Outras Funções de ligação

Para variáveis respostas que assumem apenas valores positivos, uma generalização da função de ligação logarítmica é a classe de funções de ligação de Box-Cox

Outras Funções de ligação

Para variáveis respostas que assumem apenas valores positivos, uma generalização da função de ligação logarítmica é a classe de funções de ligação de Box-Cox dada por

$$g(\mu_i) = \begin{cases} \frac{\mu_i^\lambda - 1}{\lambda}, & \text{se } \lambda \neq 0 \\ \log \mu_i, & \text{se } \lambda = 0 \end{cases}.$$

Outras Funções de ligação

Para variáveis respostas que assumem apenas valores positivos, uma generalização da função de ligação logarítmica é a classe de funções de ligação de Box-Cox dada por

$$g(\mu_i) = \begin{cases} \frac{\mu_i^\lambda - 1}{\lambda}, & \text{se } \lambda \neq 0 \\ \log \mu_i, & \text{se } \lambda = 0 \end{cases}.$$

Para variáveis respostas binárias, além da ligação canônica, diversas outras funções de ligação são comuns,

Outras Funções de ligação

Para variáveis respostas que assumem apenas valores positivos, uma generalização da função de ligação logarítmica é a classe de funções de ligação de Box-Cox dada por

$$g(\mu_i) = \begin{cases} \frac{\mu_i^\lambda - 1}{\lambda}, & \text{se } \lambda \neq 0 \\ \log \mu_i, & \text{se } \lambda = 0 \end{cases}.$$

Para variáveis respostas binárias, além da ligação canônica, diversas outras funções de ligação são comuns, como por exemplo:

- probito: $g(\mu_i) = \Phi^{-1}(\mu_i)$, em que $\Phi(.)$ é função distribuição acumulada da normal padrão.

Outras Funções de ligação

Para variáveis respostas que assumem apenas valores positivos, uma generalização da função de ligação logarítmica é a classe de funções de ligação de Box-Cox dada por

$$g(\mu_i) = \begin{cases} \frac{\mu_i^\lambda - 1}{\lambda}, & \text{se } \lambda \neq 0 \\ \log \mu_i, & \text{se } \lambda = 0 \end{cases}.$$

Para variáveis respostas binárias, além da ligação canônica, diversas outras funções de ligação são comuns, como por exemplo:

- probito: $g(\mu_i) = \Phi^{-1}(\mu_i)$, em que $\Phi(.)$ é função distribuição acumulada da normal padrão.
- complemento log-log: $g(\mu_i) = \log[-\log(1 - \mu_i)]$.

Função desvio

Função desvio

No caso do MLGer, a soma dos quadrados dos resíduos é uma medida absoluta associada a performance preditiva do modelo.

Função desvio

No caso do MLGer, a soma dos quadrados dos resíduos é uma medida absoluta associada a performance preditiva do modelo. No caso do MLGen, a medida que exerce papel equivalente é denominada função desvio.

Função desvio

No caso do MLGer, a soma dos quadrados dos resíduos é uma medida absoluta associada a performance preditiva do modelo. No caso do MLGen, a medida que exerce papel equivalente é denominada função desvio.

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen,

Função desvio

No caso do MLGer, a soma dos quadrados dos resíduos é uma medida absoluta associada a performance preditiva do modelo. No caso do MLGen, a medida que exerce papel equivalente é denominada função desvio.

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen, em que $\mu_i = g^{-1}(\eta_i)$

Função desvio

No caso do MLGer, a soma dos quadrados dos resíduos é uma medida absoluta associada a performance preditiva do modelo. No caso do MLGen, a medida que exerce papel equivalente é denominada função desvio.

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen, em que $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$.

Função desvio

No caso do MLGer, a soma dos quadrados dos resíduos é uma medida absoluta associada a performance preditiva do modelo. No caso do MLGen, a medida que exerce papel equivalente é denominada função desvio.

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen, em que $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Se $k + 1 = n$, o modelo é denominado saturado

Função desvio

No caso do MLGer, a soma dos quadrados dos resíduos é uma medida absoluta associada a performance preditiva do modelo. No caso do MLGen, a medida que exerce papel equivalente é denominada função desvio.

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen, em que $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Se $k + 1 = n$, o modelo é denominado saturado e $\tilde{\mu}_i = y_i$, para todo i.

Função desvio

No caso do MLGer, a soma dos quadrados dos resíduos é uma medida absoluta associada a performance preditiva do modelo. No caso do MLGen, a medida que exerce papel equivalente é denominada função desvio.

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen, em que $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Se $k + 1 = n$, o modelo é denominado saturado e $\tilde{\mu}_i = y_i$, para todo i. Nesse caso, $l(\boldsymbol{\mu}, \mathbf{y})$ é estimado por

$$l(\mathbf{y}, \mathbf{y}) = \sum_{i=1}^{n} l(y_i, y_i).$$

Função desvio

No caso do MLGer, a soma dos quadrados dos resíduos é uma medida absoluta associada a performance preditiva do modelo. No caso do MLGen, a medida que exerce papel equivalente é denominada função desvio.

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen, em que $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Se $k + 1 = n$, o modelo é denominado saturado e $\tilde{\mu}_i = y_i$, para todo i. Nesse caso, $l(\boldsymbol{\mu}, \mathbf{y})$ é estimado por

$$l(\mathbf{y}, \mathbf{y}) = \sum_{i=1}^{n} l(y_i, y_i).$$

Quando $k + 1 < n$, denotamos o estimador de $l(\boldsymbol{\mu}, \mathbf{y})$ por $l(\hat{\boldsymbol{\mu}}, \mathbf{y})$.

Função desvio

No caso do MLGer, a soma dos quadrados dos resíduos é uma medida absoluta associada a performance preditiva do modelo. No caso do MLGen, a medida que exerce papel equivalente é denominada função desvio.

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen, em que $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Se $k + 1 = n$, o modelo é denominado saturado e $\tilde{\mu}_i = y_i$, para todo i. Nesse caso, $l(\boldsymbol{\mu}, \mathbf{y})$ é estimado por

$$l(\mathbf{y}, \mathbf{y}) = \sum_{i=1}^{n} l(y_i, y_i).$$

Quando $k + 1 < n$, denotamos o estimador de $l(\boldsymbol{\mu}, \mathbf{y})$ por $l(\hat{\boldsymbol{\mu}}, \mathbf{y})$.

Função desvio

Função desvio

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen, em que $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Se $k + 1 = n$, o modelo é denominado saturado e $\tilde{\mu}_i = y_i$, para todo i. Nesse caso, $l(\boldsymbol{\mu}, \mathbf{y})$ é estimado por

$$l(\mathbf{y}, \mathbf{y}) = \sum_{i=1}^{n} l(y_i, y_i).$$

Quando $k + 1 < n$, denotamos o estimador de $l(\boldsymbol{\mu}, \mathbf{y})$ por $l(\hat{\boldsymbol{\mu}}, \mathbf{y})$.

Função desvio

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen, em que $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Se $k + 1 = n$, o modelo é denominado saturado e $\tilde{\mu}_i = y_i$, para todo i. Nesse caso, $l(\boldsymbol{\mu}, \mathbf{y})$ é estimado por

$$l(\mathbf{y}, \mathbf{y}) = \sum_{i=1}^{n} l(y_i, y_i).$$

Quando $k + 1 < n$, denotamos o estimador de $l(\boldsymbol{\mu}, \mathbf{y})$ por $l(\hat{\boldsymbol{\mu}}, \mathbf{y})$.

Assim, uma medida absoluta da capacidade preditiva do MLGen é dada por

Função desvio

Seja $l(\boldsymbol{\mu}, \mathbf{y}) = \sum_{i=1}^{n} l(\mu_i, y_i)$ o logaritmo da função de verossimilhança de um MLGen, em que $\mu_i = g^{-1}(\eta_i)$ e $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$. Se $k + 1 = n$, o modelo é denominado saturado e $\tilde{\mu}_i = y_i$, para todo i. Nesse caso, $l(\boldsymbol{\mu}, \mathbf{y})$ é estimado por

$$l(\mathbf{y}, \mathbf{y}) = \sum_{i=1}^{n} l(y_i, y_i).$$

Quando $k + 1 < n$, denotamos o estimador de $l(\boldsymbol{\mu}, \mathbf{y})$ por $l(\hat{\boldsymbol{\mu}}, \mathbf{y})$.

Assim, uma medida absoluta da capacidade preditiva do MLGen é dada por

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2[l(\mathbf{y}, \mathbf{y}) - l(\hat{\boldsymbol{\mu}}, \mathbf{y})].$$

Função desvio

Assim, uma medida absoluta da capacidade preditiva do MLGen é dada por

$$D(\mathbf{y}, \hat{\mu}) = 2[l(\mathbf{y}, \mathbf{y}) - l(\hat{\mu}, \mathbf{y})].$$

Uma função desvio pequena indica que, para um número menor de parâmetros, obtemos um ajuste quase tão bom quanto o ajuste com o modelo saturado.

Função desvio

Assim, uma medida absoluta da capacidade preditiva do MLGen é dada por

$$D(\mathbf{y}, \hat{\mu}) = 2[l(\mathbf{y}, \mathbf{y}) - l(\hat{\mu}, \mathbf{y})].$$

Uma função desvio pequena indica que, para um número menor de parâmetros, obtemos um ajuste quase tão bom quanto o ajuste com o modelo saturado.

Pode-se mostrar que a função desvio pode ser reescrita como

Função desvio

Assim, uma medida absoluta da capacidade preditiva do MLGen é dada por

$$D(\mathbf{y}, \hat{\mu}) = 2[l(\mathbf{y}, \mathbf{y}) - l(\hat{\mu}, \mathbf{y})].$$

Uma função desvio pequena indica que, para um número menor de parâmetros, obtemos um ajuste quase tão bom quanto o ajuste com o modelo saturado.

Pode-se mostrar que a função desvio pode ser reescrita como

$$D(\mathbf{y}, \hat{\mu}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 1: Normal

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 1: Normal - $\theta_i = \mu_i$, $b(\theta_i) = \theta_i^2/2$ e $\phi = 1/\sigma^2$.

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 1: Normal - $\theta_i = \mu_i$, $b(\theta_i) = \theta_i^2/2$ e $\phi = 1/\sigma^2$.

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}})$$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 1: Normal - $\theta_i = \mu_i$, $b(\theta_i) = \theta_i^2/2$ e $\phi = 1/\sigma^2$.

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = \frac{2}{\sigma^2} \sum_{i=1}^{n} \left[y_i(y_i - \hat{\mu}_i) + \hat{\mu}_i^2/2 - y_i^2/2 \right]$$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 1: Normal - $\theta_i = \mu_i$, $b(\theta_i) = \theta_i^2/2$ e $\phi = 1/\sigma^2$.

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = \frac{2}{\sigma^2} \sum_{i=1}^{n} \left[y_i(y_i - \hat{\mu}_i) + \hat{\mu}_i^2/2 - y_i^2/2 \right] =$$

$$\frac{2}{\sigma^2} \sum_{i=1}^{n} \left[y_i^2/2 - y_i\hat{\mu}_i + \hat{\mu}_i^2/2 \right]$$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 1: Normal - $\theta_i = \mu_i$, $b(\theta_i) = \theta_i^2/2$ e $\phi = 1/\sigma^2$.

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = \frac{2}{\sigma^2} \sum_{i=1}^{n} \left[y_i(y_i - \hat{\mu}_i) + \hat{\mu}_i^2/2 - y_i^2/2 \right] =$$

$$\frac{2}{\sigma^2} \sum_{i=1}^{n} \left[y_i^2/2 - y_i\hat{\mu}_i + \hat{\mu}_i^2/2 \right] = \frac{\sum_{i=1}^{n}(y_i - \hat{\mu}_i)^2}{\sigma^2}$$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 1: Normal - $\theta_i = \mu_i$, $b(\theta_i) = \theta_i^2/2$ e $\phi = 1/\sigma^2$.

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = \frac{2}{\sigma^2} \sum_{i=1}^{n} \left[y_i(y_i - \hat{\mu}_i) + \hat{\mu}_i^2/2 - y_i^2/2 \right] =$$

$$\frac{2}{\sigma^2} \sum_{i=1}^{n} \left[y_i^2/2 - y_i\hat{\mu}_i + \hat{\mu}_i^2/2 \right] = \frac{\sum_{i=1}^{n}(y_i - \hat{\mu}_i)^2}{\sigma^2} = \frac{\text{SQRes}}{\sigma^2}.$$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 2: Gama

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 2: Gama - $\theta_i = -1/\mu_i$, $b(\theta_i) = -\log(-\theta_i)$ e $\phi = \lambda$.

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 2: Gama - $\theta_i = -1/\mu_i$, $b(\theta_i) = -\log(-\theta_i)$ e $\phi = \lambda$.

$D(\mathbf{y}, \hat{\boldsymbol{\mu}})$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 2: Gama - $\theta_i = -1/\mu_i$, $b(\theta_i) = -\log(-\theta_i)$ e $\phi = \lambda$.

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\lambda \sum_{i=1}^{n} [y_i(-1/y_i + 1/\hat{\mu}_i) - \log(1/\hat{\mu}_i) + \log(1/y_i)]$$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 2: Gama - $\theta_i = -1/\mu_i$, $b(\theta_i) = -\log(-\theta_i)$ e $\phi = \lambda$.

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\lambda \sum_{i=1}^{n} [y_i(-1/y_i + 1/\hat{\mu}_i) - \log(1/\hat{\mu}_i) + \log(1/y_i)] =$$

$$2\lambda \sum_{i=1}^{n} [y_i/\hat{\mu}_i - 1 + \log(\hat{\mu}_i) - \log(y_i)]$$

Função desvio

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\}.$$

Exemplo 2: Gama - $\theta_i = -1/\mu_i$, $b(\theta_i) = -\log(-\theta_i)$ e $\phi = \lambda$.

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\lambda \sum_{i=1}^{n} [y_i(-1/y_i + 1/\hat{\mu}_i) - \log(1/\hat{\mu}_i) + \log(1/y_i)] =$$

$$2\lambda \sum_{i=1}^{n} [y_i/\hat{\mu}_i - 1 + \log(\hat{\mu}_i) - \log(y_i)] =$$

$$2\lambda \sum_{i=1}^{n} \left[\log\left(\frac{\hat{\mu}_i}{y_i}\right) + \frac{y_i - \hat{\mu}_i}{\hat{\mu}_i} \right].$$