Modelos lineares generalizados

Estimação pontual

Estimação de β

Estimação de β

Usualmente o vetor de parâmetros β é estimado por máxima versossimilhança.

Estimação de β

Usualmente o vetor de parâmetros β é estimado por máxima versossimilhança. Para isso inicialmente obtemos o logaritmo da função de verossimilhança do modelo.

Estimação de β

Usualmente o vetor de parâmetros β é estimado por máxima versossimilhança. Para isso inicialmente obtemos o logaritmo da função de verossimilhança do modelo. Temos que

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\}.$$

Estimação de β

Usualmente o vetor de parâmetros β é estimado por máxima versossimilhança. Para isso inicialmente obtemos o logaritmo da função de verossimilhança do modelo. Temos que

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\}.$$

Assim,

$$l(\beta, \phi) = \sum_{i=1}^{n}\{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi)$$

Estimação de β

Usualmente o vetor de parâmetros β é estimado por máxima versossimilhança. Para isso inicialmente obtemos o logaritmo da função de verossimilhança do modelo. Temos que

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\}.$$

Assim,

$$l(\beta, \phi) = \sum_{i=1}^{n}\{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

Estimação de β

Usualmente o vetor de parâmetros β é estimado por máxima versossimilhança. Para isso inicialmente obtemos o logaritmo da função de verossimilhança do modelo. Temos que

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\}.$$

Assim,

$$l(\beta, \phi) = \sum_{i=1}^{n}\{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

O vetor que contém as derivadas parciais de primeira ordem de $l(\beta, \phi)$ é denominado vetor escore

Estimação de β

Usualmente o vetor de parâmetros β é estimado por máxima versossimilhança. Para isso inicialmente obtemos o logaritmo da função de verossimilhança do modelo. Temos que

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\}.$$

Assim,

$$l(\beta, \phi) = \sum_{i=1}^{n}\{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

O vetor que contém as derivadas parciais de primeira ordem de $l(\beta, \phi)$ é denominado vetor escore e será denotado como $U(\gamma)$

Estimação de β

Usualmente o vetor de parâmetros β é estimado por máxima versossimilhança. Para isso inicialmente obtemos o logaritmo da função de verossimilhança do modelo. Temos que

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\}.$$

Assim,

$$l(\beta, \phi) = \sum_{i=1}^{n}\{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

O vetor que contém as derivadas parciais de primeira ordem de $l(\beta, \phi)$ é denominado vetor escore e será denotado como $U(\gamma) = U(\beta, \phi)$

Estimação de β

Usualmente o vetor de parâmetros β é estimado por máxima versossimilhança. Para isso inicialmente obtemos o logaritmo da função de verossimilhança do modelo. Temos que

$$f(y_i; \theta_i, \phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i, \phi)\}.$$

Assim,

$$l(\beta, \phi) = \sum_{i=1}^{n}\{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

O vetor que contém as derivadas parciais de primeira ordem de $l(\beta, \phi)$ é denominado vetor escore e será denotado como $U(\gamma) = U(\beta, \phi)$ e tem dimensão $k + 2$,

Estimação de β

Usualmente o vetor de parâmetros β é estimado por máxima versossimilhança. Para isso inicialmente obtemos o logaritmo da função de verossimilhança do modelo. Temos que

$$f(y_i;\theta_i,\phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i,\phi)\}.$$

Assim,

$$l(\beta,\phi) = \sum_{i=1}^{n}\{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i,\phi) = \sum_{i=1}^{n} l_i(\beta,\phi).$$

O vetor que contém as derivadas parciais de primeira ordem de $l(\beta,\phi)$ é denominado vetor escore e será denotado como $U(\gamma) = U(\beta,\phi)$ e tem dimensão $k+2$, podendo ser decomposto em

$$U(\gamma) = U(\beta,\phi) = \begin{bmatrix} U(\beta) \\ U(\phi) \end{bmatrix}.$$

Estimação de β

$$l(\beta, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi)$$

Estimação de β

$$l(\beta, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

Estimação de β

$$l(\beta, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

Temos que $\theta_i = q(\mu_i)$,

Estimação de β

$$l(\beta, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i)$

Estimação de β

$$l(\beta, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$

Estimação de β

$$l(\beta, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$.

Estimação de β

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\boldsymbol{\beta}, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\boldsymbol{\beta})$ é dado por

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r}$$

Estimação de β

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\boldsymbol{\beta}, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\boldsymbol{\beta})$ é dado por

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r}$$

Estimação de $\boldsymbol{\beta}$

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\boldsymbol{\beta}, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\boldsymbol{\beta})$ é dado por

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

Estimação de β

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\boldsymbol{\beta}, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\boldsymbol{\beta})$ é dado por

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i}$$

Estimação de β

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\boldsymbol{\beta}, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\boldsymbol{\beta})$ é dado por

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)]$$

Estimação de β

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\boldsymbol{\beta}, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\boldsymbol{\beta})$ é dado por

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

Estimação de β

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\boldsymbol{\beta}, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\boldsymbol{\beta})$ é dado por

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

$$\frac{\partial \mu_i}{\partial \theta_i}$$

Estimação de β

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\boldsymbol{\beta}, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\boldsymbol{\beta})$ é dado por

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

$$\frac{\partial \mu_i}{\partial \theta_i} = V_i$$

Estimação de β

$$l(\beta, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\beta, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\beta)$ é dado por

$$U_r = \frac{\partial l(\beta, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\beta, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\beta, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\beta, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

$$\frac{\partial \mu_i}{\partial \theta_i} = V_i \Rightarrow \frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{V_i},$$

Estimação de β

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\boldsymbol{\beta}, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\boldsymbol{\beta})$ é dado por

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

$$\frac{\partial \mu_i}{\partial \theta_i} = V_i \Rightarrow \frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{V_i}, \qquad \frac{\partial \eta_i}{\partial \beta_r}$$

Estimação de β

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} l_i(\boldsymbol{\beta}, \phi).$$

Temos que $\theta_i = q(\mu_i)$, $\mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\eta_i = \sum_{r=0}^{k} x_{ir}\beta_r$. Assim, o elemento correspondente a β_r de $U(\boldsymbol{\beta})$ é dado por

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

$$\frac{\partial \mu_i}{\partial \theta_i} = V_i \Rightarrow \frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{V_i}, \qquad \frac{\partial \eta_i}{\partial \beta_r} = x_{ir}.$$

Estimação de β

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

$$\frac{\partial \mu_i}{\partial \theta_i} = V_i \Rightarrow \frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{V_i}, \qquad \frac{\partial \eta_i}{\partial \beta_r} = x_{ir}.$$

Estimação de β

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

$$\frac{\partial \mu_i}{\partial \theta_i} = V_i \Rightarrow \frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{V_i}, \qquad \frac{\partial \eta_i}{\partial \beta_r} = x_{ir}.$$

Assim,

$$U_r = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}.$$

Estimação de β

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

$$\frac{\partial \mu_i}{\partial \theta_i} = V_i \Rightarrow \frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{V_i}, \qquad \frac{\partial \eta_i}{\partial \beta_r} = x_{ir}.$$

Assim,

$$U_r = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}.$$

O EMV de β é obtido igualando-se U_r a zero, para $r = 0, 1 \ldots, k$ e resolvendo-se o sistema de equações.

Estimação de β

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

$$\frac{\partial \mu_i}{\partial \theta_i} = V_i \Rightarrow \frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{V_i}, \qquad \frac{\partial \eta_i}{\partial \beta_r} = x_{ir}.$$

Assim,

$$U_r = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}.$$

O EMV de β é obtido igualando-se U_r a zero, para $r = 0, 1 \ldots, k$ e resolvendo-se o sistema de equações. Em geral, as equações $U_r = 0$ são não lineares

Estimação de β

$$U_r = \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{l_i(\boldsymbol{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_r},$$

$$\frac{\partial l_i(\boldsymbol{\beta}, \phi)}{\partial \theta_i} = \phi[y_i - b'(\theta_i)] = \phi(y_i - \mu_i),$$

$$\frac{\partial \mu_i}{\partial \theta_i} = V_i \Rightarrow \frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{V_i}, \qquad \frac{\partial \eta_i}{\partial \beta_r} = x_{ir}.$$

Assim,

$$U_r = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}.$$

O EMV de β é obtido igualando-se U_r a zero, para $r = 0, 1 \ldots, k$ e resolvendo-se o sistema de equações. Em geral, as equações $U_r = 0$ são não lineares e assim têm que ser resolvidas numericamente por processos iterativos.

Método de Newton-Raphson

Método de Newton-Raphson

A espansão de Taylor de primeira ordem de uma função $f(x)$ em torno de x_0 é dada por

Método de Newton-Raphson

A espansão de Taylor de primeira ordem de uma função $f(x)$ em torno de x_0 é dada por

$$f(x) \approx f(x_0) + (x - x_0)f'(x_0).$$

Método de Newton-Raphson

A espansão de Taylor de primeira ordem de uma função $f(x)$ em torno de x_0 é dada por

$$f(x) \approx f(x_0) + (x - x_0)f'(x_0).$$

O método iterativo de Newton-Raphson para a solução de uma equação $f(x) = 0$ utiliza a expansão de Taylor fazendo

Método de Newton-Raphson

A espansão de Taylor de primeira ordem de uma função $f(x)$ em torno de x_0 é dada por

$$f(x) \approx f(x_0) + (x - x_0)f'(x_0).$$

O método iterativo de Newton-Raphson para a solução de uma equação $f(x) = 0$ utiliza a expansão de Taylor fazendo

$$f(x_0) + (x - x_0)f'(x_0) = 0$$

Método de Newton-Raphson

A espansão de Taylor de primeira ordem de uma função $f(x)$ em torno de x_0 é dada por

$$f(x) \approx f(x_0) + (x - x_0)f'(x_0).$$

O método iterativo de Newton-Raphson para a solução de uma equação $f(x) = 0$ utiliza a expansão de Taylor fazendo

$$f(x_0) + (x - x_0)f'(x_0) = 0 \Rightarrow x = x_0 - \frac{f(x_0)}{f'(x_0)}.$$

Método de Newton-Raphson

A espansão de Taylor de primeira ordem de uma função $f(x)$ em torno de x_0 é dada por

$$f(x) \approx f(x_0) + (x - x_0)f'(x_0).$$

O método iterativo de Newton-Raphson para a solução de uma equação $f(x) = 0$ utiliza a expansão de Taylor fazendo

$$f(x_0) + (x - x_0)f'(x_0) = 0 \Rightarrow x = x_0 - \frac{f(x_0)}{f'(x_0)}.$$

Na forma de um processo iterativo, isso fica dado por

$$x^{(m+1)} = x^{(m)} - \frac{f(x^{(m)})}{f'(x^{(m)})},$$

sendo $x^{(m)}$ e $x^{(m+1)}$ o valor de x no passo m e $(m+1)$, respectivamente, do processo iterativo.

Método de Newton-Raphson

$$x^{(m+1)} = x^{(m)} - \frac{f(x^{(m)})}{f'(x^{(m)})}.$$

Método de Newton-Raphson

$$x^{(m+1)} = x^{(m)} - \frac{f(x^{(m)})}{f'(x^{(m)})}.$$

Se queremos estimar um único parâmetro λ por máxima verossimilhança, obtemos

Método de Newton-Raphson

$$x^{(m+1)} = x^{(m)} - \frac{f(x^{(m)})}{f'(x^{(m)})}.$$

Se queremos estimar um único parâmetro λ por máxima verossimilhança, obtemos

$$\lambda^{(m+1)} = \lambda^{(m)} - \frac{\partial l(\lambda)}{\partial \lambda} \left(\frac{\partial^2 l(\lambda)}{\partial \lambda^2} \right)^{-1}.$$

Método de Newton-Raphson

$$x^{(m+1)} = x^{(m)} - \frac{f(x^{(m)})}{f'(x^{(m)})}.$$

Se queremos estimar um único parâmetro λ por máxima verossimilhança, obtemos

$$\lambda^{(m+1)} = \lambda^{(m)} - \frac{\partial l(\lambda)}{\partial \lambda} \left(\frac{\partial^2 l(\lambda)}{\partial \lambda^2} \right)^{-1}.$$

No nosso caso, temos um vetor de parâmetros β e assim

Método de Newton-Raphson

$$x^{(m+1)} = x^{(m)} - \frac{f(x^{(m)})}{f'(x^{(m)})}.$$

Se queremos estimar um único parâmetro λ por máxima verossimilhança, obtemos

$$\lambda^{(m+1)} = \lambda^{(m)} - \frac{\partial l(\lambda)}{\partial \lambda} \left(\frac{\partial^2 l(\lambda)}{\partial \lambda^2} \right)^{-1}.$$

No nosso caso, temos um vetor de parâmetros $\boldsymbol{\beta}$ e assim

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}},$$

em que $\boldsymbol{\beta}^{(m+1)}$ e $\boldsymbol{\beta}^{(m)}$ são os vetores de parâmetros estimados nos passos m e $(m+1)$, respectivamente,

Método de Newton-Raphson

$$x^{(m+1)} = x^{(m)} - \frac{f(x^{(m)})}{f'(x^{(m)})}.$$

Se queremos estimar um único parâmetro λ por máxima verossimilhança, obtemos

$$\lambda^{(m+1)} = \lambda^{(m)} - \frac{\partial l(\lambda)}{\partial \lambda} \left(\frac{\partial^2 l(\lambda)}{\partial \lambda^2} \right)^{-1}.$$

No nosso caso, temos um vetor de parâmetros $\boldsymbol{\beta}$ e assim

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)},$$

em que $\boldsymbol{\beta}^{(m+1)}$ e $\boldsymbol{\beta}^{(m)}$ são os vetores de parâmetros estimados nos passos m e $(m+1)$, respectivamente, $U_{\boldsymbol{\beta}}^{(m)}$ é o vetor escore avaliado no passo m

Método de Newton-Raphson

$$x^{(m+1)} = x^{(m)} - \frac{f(x^{(m)})}{f'(x^{(m)})}.$$

Se queremos estimar um único parâmetro λ por máxima verossimilhança, obtemos

$$\lambda^{(m+1)} = \lambda^{(m)} - \frac{\partial l(\lambda)}{\partial \lambda} \left(\frac{\partial^2 l(\lambda)}{\partial \lambda^2} \right)^{-1}.$$

No nosso caso, temos um vetor de parâmetros $\boldsymbol{\beta}$ e assim

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}},$$

em que $\boldsymbol{\beta}^{(m+1)}$ e $\boldsymbol{\beta}^{(m)}$ são os vetores de parâmetros estimados nos passos m e $(m+1)$, respectivamente, $U^{(m)}_{\boldsymbol{\beta}}$ é o vetor escore avaliado no passo m e $\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ é o negativo da matriz de derivadas de segunda ordem de $l(\boldsymbol{\beta}, \phi)$ avaliada no passo m

Método de Newton-Raphson

$$x^{(m+1)} = x^{(m)} - \frac{f(x^{(m)})}{f'(x^{(m)})}.$$

Se queremos estimar um único parâmetro λ por máxima verossimilhança, obtemos

$$\lambda^{(m+1)} = \lambda^{(m)} - \frac{\partial l(\lambda)}{\partial \lambda}\left(\frac{\partial^2 l(\lambda)}{\partial \lambda^2}\right)^{-1}.$$

No nosso caso, temos um vetor de parâmetros $\boldsymbol{\beta}$ e assim

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}},$$

em que $\boldsymbol{\beta}^{(m+1)}$ e $\boldsymbol{\beta}^{(m)}$ são os vetores de parâmetros estimados nos passos m e $(m+1)$, respectivamente, $U^{(m)}_{\boldsymbol{\beta}}$ é o vetor escore avaliado no passo m e $\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ é o negativo da matriz de derivadas de segunda ordem de $l(\boldsymbol{\beta}, \phi)$ avaliada no passo m (matriz de informação observada).

Método Scoring de Fisher

Método Newton-Raphson: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} \boldsymbol{U}^{(m)}_{\boldsymbol{\beta}}$.

Método Scoring de Fisher

Método Newton-Raphson: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} \boldsymbol{U}^{(m)}_{\boldsymbol{\beta}}$.

No método scoring de Fisher, substituímos **J** por E(**J**) que é denotada por **K**,

Método Scoring de Fisher

Método Newton-Raphson: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} \boldsymbol{U}^{(m)}_{\boldsymbol{\beta}}$.

No método scoring de Fisher, substituímos **J** por E(**J**) que é denotada por **K**, sendo denominada matriz de informação de Fisher,

Método Scoring de Fisher

Método Newton-Raphson: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}}$.

No método scoring de Fisher, substituímos **J** por E(**J**) que é denotada por **K**, sendo denominada matriz de informação de Fisher, sendo seus elementos expressos como

$$K_{r,s} = -\mathrm{E}\left[\frac{\partial^2 l(\boldsymbol{\beta}, \phi)}{\partial \beta_r \beta_s}\right]$$

Método Scoring de Fisher

Método Newton-Raphson: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}}$.

No método scoring de Fisher, substituímos **J** por E(**J**) que é denotada por **K**, sendo denominada matriz de informação de Fisher, sendo seus elementos expressos como

$$K_{r,s} = -\mathrm{E}\left[\frac{\partial^2 l(\boldsymbol{\beta}, \phi)}{\partial \beta_r \beta_s}\right] = \mathrm{E}\left[\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_s}\right]$$

Método Scoring de Fisher

Método Newton-Raphson: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}}$.

No método scoring de Fisher, substituímos $\mathbf{J}$ por E($\mathbf{J}$) que é denotada por $\mathbf{K}$, sendo denominada matriz de informação de Fisher, sendo seus elementos expressos como

$$K_{r,s} = -\mathrm{E}\left[\frac{\partial^2 l(\boldsymbol{\beta}, \phi)}{\partial \beta_r \beta_s}\right] = \mathrm{E}\left[\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_s}\right]$$

Assim, o processo iterativo fica dado por

Método Scoring de Fisher

Método Newton-Raphson: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}}$.

No método scoring de Fisher, substituímos $\mathbf{J}$ por E($\mathbf{J}$) que é denotada por $\mathbf{K}$, sendo denominada matriz de informação de Fisher, sendo seus elementos expressos como

$$K_{r,s} = -\mathrm{E}\left[\frac{\partial^2 l(\boldsymbol{\beta}, \phi)}{\partial \beta_r \beta_s}\right] = \mathrm{E}\left[\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_s}\right]$$

Assim, o processo iterativo fica dado por

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}},$$

Método Scoring de Fisher

Método Newton-Raphson: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{J}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}}$.

No método scoring de Fisher, substituímos $\mathbf{J}$ por $\mathrm{E}(\mathbf{J})$ que é denotada por $\mathbf{K}$, sendo denominada matriz de informação de Fisher, sendo seus elementos expressos como

$$K_{r,s} = -\mathrm{E}\left[\frac{\partial^2 l(\boldsymbol{\beta}, \phi)}{\partial \beta_r \beta_s}\right] = \mathrm{E}\left[\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_r} \frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \beta_s}\right]$$

Assim, o processo iterativo fica dado por

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}},$$

em que $\mathbf{K}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ é a matriz de informação de Fisher avaliada no passo m.

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \boldsymbol{U}_{\boldsymbol{\beta}}^{(m)}$.

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \boldsymbol{U}_{\boldsymbol{\beta}}^{(m)}$.

Pode-se demonstrar que o elemento correspondente a β_r e β_s (posição $(r+1) \times (s+1)$) de $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ é dado por

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \boldsymbol{U}_{\boldsymbol{\beta}}^{(m)}$.

Pode-se demonstrar que o elemento correspondente a β_r e β_s (posição $(r+1) \times (s+1)$) de $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ é dado por

$$\mathbf{K}_{r,s} = \phi \sum_{i=1}^{n} w_i x_{ir} x_{is},$$

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \boldsymbol{U}_{\boldsymbol{\beta}}^{(m)}$.

Pode-se demonstrar que o elemento correspondente a β_r e β_s (posição $(r+1) \times (s+1)$) de $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ é dado por

$$\mathbf{K}_{r,s} = \phi \sum_{i=1}^{n} w_i x_{ir} x_{is}, \text{ em que } \quad w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2.$$

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \mathbf{U}_{\boldsymbol{\beta}}^{(m)}$.

Pode-se demonstrar que o elemento correspondente a β_r e β_s (posição $(r+1) \times (s+1)$) de $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ é dado por

$$\mathbf{K}_{r,s} = \phi \sum_{i=1}^{n} w_i x_{ir} x_{is}, \text{ em que } \quad w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2.$$

Assim, $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ pode ser escrito como

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \mathbf{U}_{\boldsymbol{\beta}}^{(m)}$.

Pode-se demonstrar que o elemento correspondente a β_r e β_s (posição $(r+1) \times (s+1)$) de $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ é dado por

$$\mathbf{K}_{r,s} = \phi \sum_{i=1}^{n} w_i x_{ir} x_{is}, \text{ em que } \quad w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2.$$

Assim, $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ pode ser escrito como

$$\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X},$$

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \mathbf{U}_{\boldsymbol{\beta}}^{(m)}$.

Pode-se demonstrar que o elemento correspondente a β_r e β_s (posição $(r+1) \times (s+1)$) de $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ é dado por

$$\mathbf{K}_{r,s} = \phi \sum_{i=1}^{n} w_i x_{ir} x_{is}, \text{ em que } \quad w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2.$$

Assim, $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ pode ser escrito como

$$\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X},$$

em que $\mathbf{W} = \text{diag}\{w_1, w_2, \ldots, w_n\}$.

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \boldsymbol{U}_{\boldsymbol{\beta}}^{(m)}$.

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \boldsymbol{U}_{\boldsymbol{\beta}}^{(m)}$.

Podemos reescrever o elemento de $U_{\boldsymbol{\beta}}$ correspondente a β_r como

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \boldsymbol{U}_{\boldsymbol{\beta}}^{(m)}$.

Podemos reescrever o elemento de $U_{\boldsymbol{\beta}}$ correspondente a β_r como

$$U_r = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}$$

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \mathbf{U}_{\boldsymbol{\beta}}^{(m)}$.

Podemos reescrever o elemento de $U_{\boldsymbol{\beta}}$ correspondente a β_r como

$$U_r = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \frac{\partial \mu_i}{\partial \eta_i} x_{ir} = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \frac{\partial \eta_i}{\partial \mu_i} x_{ir}$$

Método Scoring de Fisher

Método Scoring de Fisher: $\beta^{(m+1)} = \beta^{(m)} + [\mathbf{K}_{\beta\beta}^{(m)}]^{-1} U_{\beta}^{(m)}$.

Podemos reescrever o elemento de U_β correspondente a β_r como

$$U_r = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \frac{\partial \mu_i}{\partial \eta_i} x_{ir} = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \frac{\partial \eta_i}{\partial \mu_i} x_{ir} =$$

$$\phi \sum_{i=1}^{n} (y_i - \mu_i) w_i \frac{\partial \eta_i}{\partial \mu_i} x_{ir}.$$

Método Scoring de Fisher

Método Scoring de Fisher: $\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} \mathbf{U}_{\boldsymbol{\beta}}^{(m)}$.

Podemos reescrever o elemento de $U_{\boldsymbol{\beta}}$ correspondente a β_r como

$$U_r = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \frac{\partial \mu_i}{\partial \eta_i} x_{ir} = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{Vi} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \frac{\partial \eta_i}{\partial \mu_i} x_{ir} =$$

$$\phi \sum_{i=1}^{n} (y_i - \mu_i) w_i \frac{\partial \eta_i}{\partial \mu_i} x_{ir}.$$

Assim, $U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$,

em que $\mathbf{G} = \text{diag}\{g'(\mu_1), g'(\mu_2), \ldots, g'(\mu_n)\}$.

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}^{(m)}_{\boldsymbol{\beta}\boldsymbol{\beta}}]^{-1} U^{(m)}_{\boldsymbol{\beta}}, U_{\boldsymbol{\beta}} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu}), \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{X}$$

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)}, U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu}), \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher.

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)}, U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu}), \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)}$$

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\beta^{(m+1)} = \beta^{(m)} + [\mathbf{K}_{\beta\beta}^{(m)}]^{-1} U_{\beta}^{(m)}, U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \mu), \mathbf{K}_{\beta\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\beta^{(m+1)} = \beta^{(m)} + [\mathbf{K}_{\beta\beta}^{(m)}]^{-1} U_{\beta}^{(m)} \Rightarrow \mathbf{K}_{\beta\beta}^{(m)} \beta^{(m+1)} = \mathbf{K}_{\beta\beta}^{(m)} \beta^{(m)} + U_{\beta}^{(m)}$$

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\beta^{(m+1)} = \beta^{(m)} + [\mathbf{K}_{\beta\beta}^{(m)}]^{-1} U_{\beta}^{(m)}, U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \mu), \mathbf{K}_{\beta\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\beta^{(m+1)} = \beta^{(m)} + [\mathbf{K}_{\beta\beta}^{(m)}]^{-1} U_{\beta}^{(m)} \Rightarrow \mathbf{K}_{\beta\beta}^{(m)} \beta^{(m+1)} = \mathbf{K}_{\beta\beta}^{(m)} \beta^{(m)} + U_{\beta}^{(m)} \Rightarrow$$

$$\phi \mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{X} \beta^{(m+1)}$$

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)}, U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu}), \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)} \Rightarrow \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m+1)} = \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m)} + U_{\boldsymbol{\beta}}^{(m)} \Rightarrow$$

$$\phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m)}$$

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)}, U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu}), \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)} \Rightarrow \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m+1)} = \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m)} + U_{\boldsymbol{\beta}}^{(m)} \Rightarrow$$

$$\phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m)} + \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)})$$

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)}, U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu}), \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)} \Rightarrow \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m+1)} = \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m)} + U_{\boldsymbol{\beta}}^{(m)} \Rightarrow$$

$$\phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m)} + \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)}) \Rightarrow$$

$$\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)}$$

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\beta^{(m+1)} = \beta^{(m)} + [\mathbf{K}_{\beta\beta}^{(m)}]^{-1} U_{\beta}^{(m)}, U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \mu), \mathbf{K}_{\beta\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\beta^{(m+1)} = \beta^{(m)} + [\mathbf{K}_{\beta\beta}^{(m)}]^{-1} U_{\beta}^{(m)} \Rightarrow \mathbf{K}_{\beta\beta}^{(m)} \beta^{(m+1)} = \mathbf{K}_{\beta\beta}^{(m)} \beta^{(m)} + U_{\beta}^{(m)} \Rightarrow$$

$$\phi \mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{X} \beta^{(m+1)} = \phi \mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{X} \beta^{(m)} + \phi \mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{G}^{(m)} (\mathbf{y} - \mu^{(m)}) \Rightarrow$$

$$\mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{X} \beta^{(m+1)} = \mathbf{X}^{\top} \mathbf{W}^{(m)} [\eta^{(m)}$$

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)}, U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu}), \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)} \Rightarrow \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m+1)} = \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m)} + U_{\boldsymbol{\beta}}^{(m)} \Rightarrow$$

$$\phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m)} + \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)}) \Rightarrow$$

$$\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \mathbf{X}^\top \mathbf{W}^{(m)} [\boldsymbol{\eta}^{(m)} + \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)})].$$

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)}, U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu}), \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)} \Rightarrow \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m+1)} = \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m)} + U_{\boldsymbol{\beta}}^{(m)} \Rightarrow$$

$$\phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m)} + \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)}) \Rightarrow$$

$$\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \mathbf{X}^\top \mathbf{W}^{(m)} [\eta^{(m)} + \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)})].$$

Denotando $\mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu})$, obtemos

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)}, U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu}), \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} + [\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)}]^{-1} U_{\boldsymbol{\beta}}^{(m)} \Rightarrow \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m+1)} = \mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}^{(m)} \boldsymbol{\beta}^{(m)} + U_{\boldsymbol{\beta}}^{(m)} \Rightarrow$$

$$\phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m)} + \phi \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)}) \Rightarrow$$

$$\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \mathbf{X}^\top \mathbf{W}^{(m)} [\eta^{(m)} + \mathbf{G}^{(m)} (\mathbf{y} - \boldsymbol{\mu}^{(m)})].$$

Denotando $\mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu})$, obtemos

$$\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X} \boldsymbol{\beta}^{(m+1)} = \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{z}^{(m)}$$

Mínimos quadrados reponderados iterativos

Método scoring de Fisher

$$\beta^{(m+1)} = \beta^{(m)} + [\mathbf{K}_{\beta\beta}^{(m)}]^{-1} U_{\beta}^{(m)}, U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \mu), \mathbf{K}_{\beta\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{X}$$

O método dos mínimos quadrados reponderados iterativos é apenas uma variação do método de scoring de Fisher. Temos que

$$\beta^{(m+1)} = \beta^{(m)} + [\mathbf{K}_{\beta\beta}^{(m)}]^{-1} U_{\beta}^{(m)} \Rightarrow \mathbf{K}_{\beta\beta}^{(m)} \beta^{(m+1)} = \mathbf{K}_{\beta\beta}^{(m)} \beta^{(m)} + U_{\beta}^{(m)} \Rightarrow$$

$$\phi \mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{X} \beta^{(m+1)} = \phi \mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{X} \beta^{(m)} + \phi \mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{G}^{(m)} (\mathbf{y} - \mu^{(m)}) \Rightarrow$$

$$\mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{X} \beta^{(m+1)} = \mathbf{X}^{\top} \mathbf{W}^{(m)} [\eta^{(m)} + \mathbf{G}^{(m)} (\mathbf{y} - \mu^{(m)})].$$

Denotando $\mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \mu)$, obtemos

$$\mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{X} \beta^{(m+1)} = \mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{z}^{(m)} \Rightarrow \beta^{(m+1)} = \left(\mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{X} \right)^{-1} \mathbf{X}^{\top} \mathbf{W}^{(m)} \mathbf{z}^{(m)}.$$

Mínimos quadrados reponderados iterativos

$$\boldsymbol{\beta}^{(m+1)} = \left(\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{z}^{(m)}, \mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu}), w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2.$$

Mínimos quadrados reponderados iterativos

$$\boldsymbol{\beta}^{(m+1)} = \left(\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{z}^{(m)}, \mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu}), w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2.$$

A estimação de $\boldsymbol{\beta}$ nos MLGen é usualmente feita pelo método da máxima verossimilhança usando o seguinte algoritmo de mínimos quadrados reponderados iterativos.

Mínimos quadrados reponderados iterativos

$$\boldsymbol{\beta}^{(m+1)} = \left(\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{z}^{(m)}, \mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu}), w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2.$$

A estimação de $\boldsymbol{\beta}$ nos MLGen é usualmente feita pelo método da máxima verossimilhança usando o seguinte algoritmo de mínimos quadrados reponderados iterativos.

1. Fornecemos um valor inicial para $\boldsymbol{\eta}$,

Mínimos quadrados reponderados iterativos

$$\boldsymbol{\beta}^{(m+1)} = \left(\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{z}^{(m)}, \mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu}), w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2.$$

A estimação de $\boldsymbol{\beta}$ nos MLGen é usualmente feita pelo método da máxima verossimilhança usando o seguinte algoritmo de mínimos quadrados reponderados iterativos.

1. Fornecemos um valor inicial para $\boldsymbol{\eta}$, usualmente $\eta_i = g(y_i)$

Mínimos quadrados reponderados iterativos

$$\boldsymbol{\beta}^{(m+1)} = \left(\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{z}^{(m)}, \mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu}), w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2.$$

A estimação de $\boldsymbol{\beta}$ nos MLGen é usualmente feita pelo método da máxima verossimilhança usando o seguinte algoritmo de mínimos quadrados reponderados iterativos.

1. Fornecemos um valor inicial para $\boldsymbol{\eta}$, usualmente $\eta_i = g(y_i)$ e assim calculamos $w_i^{(0)}$ e $z_i^{(0)}$ para todo i.

Mínimos quadrados reponderados iterativos

$$\boldsymbol{\beta}^{(m+1)} = \left(\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{z}^{(m)}, \mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu}), w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2.$$

A estimação de $\boldsymbol{\beta}$ nos MLGen é usualmente feita pelo método da máxima verossimilhança usando o seguinte algoritmo de mínimos quadrados reponderados iterativos.

1. Fornecemos um valor inicial para $\boldsymbol{\eta}$, usualmente $\eta_i = g(y_i)$ e assim calculamos $w_i^{(0)}$ e $z_i^{(0)}$ para todo i.
2. Obtemos $\boldsymbol{\beta}^{(1)} = \left(\mathbf{X}^\top \mathbf{W}^{(0)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(0)} \mathbf{z}^{(0)}$.

Mínimos quadrados reponderados iterativos

$$\boldsymbol{\beta}^{(m+1)} = \left(\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{z}^{(m)}, \mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu}), w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2.$$

A estimação de $\boldsymbol{\beta}$ nos MLGen é usualmente feita pelo método da máxima verossimilhança usando o seguinte algoritmo de mínimos quadrados reponderados iterativos.

1. Fornecemos um valor inicial para $\boldsymbol{\eta}$, usualmente $\eta_i = g(y_i)$ e assim calculamos $w_i^{(0)}$ e $z_i^{(0)}$ para todo i.
2. Obtemos $\boldsymbol{\beta}^{(1)} = \left(\mathbf{X}^\top \mathbf{W}^{(0)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(0)} \mathbf{z}^{(0)}$.
3. Usamos $\boldsymbol{\beta}^{(1)}$ para calcular $\mathbf{W}^{(1)}$ e $\mathbf{z}^{(1)}$.

Mínimos quadrados reponderados iterativos

$$\boldsymbol{\beta}^{(m+1)} = \left(\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{z}^{(m)}, \mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu}), w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2.$$

A estimação de $\boldsymbol{\beta}$ nos MLGen é usualmente feita pelo método da máxima verossimilhança usando o seguinte algoritmo de mínimos quadrados reponderados iterativos.

1. Fornecemos um valor inicial para $\boldsymbol{\eta}$, usualmente $\eta_i = g(y_i)$ e assim calculamos $w_i^{(0)}$ e $z_i^{(0)}$ para todo i.
2. Obtemos $\boldsymbol{\beta}^{(1)} = \left(\mathbf{X}^\top \mathbf{W}^{(0)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(0)} \mathbf{z}^{(0)}$.
3. Usamos $\boldsymbol{\beta}^{(1)}$ para calcular $\mathbf{W}^{(1)}$ e $\mathbf{z}^{(1)}$.
4. Repetimos os passos 2 e 3 até a convergência.

Mínimos quadrados reponderados iterativos

$$\boldsymbol{\beta}^{(m+1)} = \left(\mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(m)} \mathbf{z}^{(m)}, \mathbf{z} = \eta + \mathbf{G}(\mathbf{y} - \boldsymbol{\mu}), w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2.$$

A estimação de $\boldsymbol{\beta}$ nos MLGen é usualmente feita pelo método da máxima verossimilhança usando o seguinte algoritmo de mínimos quadrados reponderados iterativos.

1. Fornecemos um valor inicial para $\boldsymbol{\eta}$, usualmente $\eta_i = g(y_i)$ e assim calculamos $w_i^{(0)}$ e $z_i^{(0)}$ para todo i.
2. Obtemos $\boldsymbol{\beta}^{(1)} = \left(\mathbf{X}^\top \mathbf{W}^{(0)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}^{(0)} \mathbf{z}^{(0)}$.
3. Usamos $\boldsymbol{\beta}^{(1)}$ para calcular $\mathbf{W}^{(1)}$ e $\mathbf{z}^{(1)}$.
4. Repetimos os passos 2 e 3 até a convergência.

Em geral o algoritmo converge rapidamente (menos de 10 iterações).

Mínimos quadrados reponderados iterativos

Mínimos quadrados reponderados iterativos

Critérios de convergência

Mínimos quadrados reponderados iterativos

Critérios de convergência

Um possível critério de convergência é dado por

$$\sum_{r=0}^{k} \left(\frac{\beta_r^{(m+1)} - \beta_r^{(m)}}{\beta_r^{(m)}} \right)^2 < \zeta,$$

Mínimos quadrados reponderados iterativos

Critérios de convergência

Um possível critério de convergência é dado por

$$\sum_{r=0}^{k} \left(\frac{\beta_r^{(m+1)} - \beta_r^{(m)}}{\beta_r^{(m)}} \right)^2 < \zeta,$$

em que escolhemos um ζ positivo e suficientemente pequeno.

Mínimos quadrados reponderados iterativos

Critérios de convergência

Um possível critério de convergência é dado por

$$\sum_{r=0}^{k} \left(\frac{\beta_r^{(m+1)} - \beta_r^{(m)}}{\beta_r^{(m)}} \right)^2 < \zeta,$$

em que escolhemos um ζ positivo e suficientemente pequeno.

Um outro possível critério de convergência é dado por

Mínimos quadrados reponderados iterativos

Critérios de convergência

Um possível critério de convergência é dado por

$$\sum_{r=0}^{k} \left(\frac{\beta_r^{(m+1)} - \beta_r^{(m)}}{\beta_r^{(m)}} \right)^2 < \zeta,$$

em que escolhemos um ζ positivo e suficientemente pequeno.

Um outro possível critério de convergência é dado por

$$|D^{\star(m+1)}(\mathbf{y}; \hat{\boldsymbol{\mu}}) - D^{\star(m)}(\mathbf{y}; \hat{\boldsymbol{\mu}})| < \zeta,$$

em que $\mathrm{D}^{\star}(\mathbf{y}; \hat{\boldsymbol{\mu}}) = \phi^{-1} D(\mathbf{y}; \hat{\boldsymbol{\mu}})$.

Mínimos quadrados reponderados iterativos

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$,

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i}$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i)$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i}$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2,$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i}$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i}\mu_i^2$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i}\mu_i^2 = \mu_i$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i}\mu_i^2 = \mu_i \text{ ou } w_i = e^{\eta_i}.$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i}\mu_i^2 = \mu_i \text{ ou } w_i = e^{\eta_i}.$$

$$z_i = \eta_i + G_{ii}(y_i - \mu_i),$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i}\mu_i^2 = \mu_i \text{ ou } w_i = e^{\eta_i}.$$

$$z_i = \eta_i + G_{ii}(y_i - \mu_i), G_{ii} = 1/\mu_i$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i}\mu_i^2 = \mu_i \text{ ou } w_i = e^{\eta_i}.$$

$$z_i = \eta_i + G_{ii}(y_i - \mu_i), G_{ii} = 1/\mu_i \Rightarrow$$

$$z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i}$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Já vimos que $\theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$ e $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i}\mu_i^2 = \mu_i \text{ ou } w_i = e^{\eta_i}.$$

$$z_i = \eta_i + G_{ii}(y_i - \mu_i), G_{ii} = 1/\mu_i \Rightarrow$$

$$z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i} \text{ ou } z_i = \eta_i + \frac{y_i - e^{\eta_i}}{e^{\eta_i}}.$$

Mínimos quadrados reponderados iterativos

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

$$w_i = \mu_i, \quad z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i}.$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

$$w_i = \mu_i, \quad z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i}.$$

Note que nesse caso $w_i = V_i$.

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

$$w_i = \mu_i, \quad z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i}.$$

Note que nesse caso $w_i = V_i$. Isso ocorre sempre que usamos a função de ligação canônica, pois nesse caso $\eta_i = \theta_i$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

$$w_i = \mu_i, \quad z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i}.$$

Note que nesse caso $w_i = V_i$. Isso ocorre sempre que usamos a função de ligação canônica, pois nesse caso $\eta_i = \theta_i$ e assim,

$$w_i = \frac{1}{V_i} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

$$w_i = \mu_i, \quad z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i}.$$

Note que nesse caso $w_i = V_i$. Isso ocorre sempre que usamos a função de ligação canônica, pois nesse caso $\eta_i = \theta_i$ e assim,

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = \left(\frac{\partial \mu_i}{\partial \theta_i}\right)^{-1}$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

$$w_i = \mu_i, \quad z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i}.$$

Note que nesse caso $w_i = V_i$. Isso ocorre sempre que usamos a função de ligação canônica, pois nesse caso $\eta_i = \theta_i$ e assim,

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = \left(\frac{\partial \mu_i}{\partial \theta_i}\right)^{-1}\left(\frac{\partial \mu_i}{\partial \theta_i}\right)^2$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

$$w_i = \mu_i, \quad z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i}.$$

Note que nesse caso $w_i = V_i$. Isso ocorre sempre que usamos a função de ligação canônica, pois nesse caso $\eta_i = \theta_i$ e assim,

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = \left(\frac{\partial \mu_i}{\partial \theta_i}\right)^{-1}\left(\frac{\partial \mu_i}{\partial \theta_i}\right)^2 = \frac{\partial \mu_i}{\partial \theta_i}$$

Mínimos quadrados reponderados iterativos

Exemplo 1: Modelo Poisson com f. de ligação logarítmica (canônica)

$$w_i = \mu_i, \quad z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i}.$$

Note que nesse caso $w_i = V_i$. Isso ocorre sempre que usamos a função de ligação canônica, pois nesse caso $\eta_i = \theta_i$ e assim,

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = \left(\frac{\partial \mu_i}{\partial \theta_i}\right)^{-1}\left(\frac{\partial \mu_i}{\partial \theta_i}\right)^2 = \frac{\partial \mu_i}{\partial \theta_i} = V_i$$

Mínimos quadrados reponderados iterativos

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2,$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i}$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i^2}\mu_i^2$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i^2}\mu_i^2 = 1$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i^2}\mu_i^2 = 1 \Rightarrow \mathbf{W} \text{ é a matriz identidade.}$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i^2}\mu_i^2 = 1 \Rightarrow \mathbf{W} \text{ é a matriz identidade.}$$

$$z_i = \eta_i + G_{ii}(y_i - \mu_i),$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i^2}\mu_i^2 = 1 \Rightarrow \mathbf{W} \text{ é a matriz identidade.}$$

$$z_i = \eta_i + G_{ii}(y_i - \mu_i), G_{ii} = 1/\mu_i$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i^2}\mu_i^2 = 1 \Rightarrow \mathbf{W} \text{ é a matriz identidade.}$$

$$z_i = \eta_i + G_{ii}(y_i - \mu_i), G_{ii} = 1/\mu_i \Rightarrow$$

$$z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i}$$

Mínimos quadrados reponderados iterativos

Exemplo 2: Modelo Gama com função de ligação logarítmica

Já vimos que $V_i = \mu_i^2$.

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2, g(\mu_i) = \log \mu_i = \eta_i \Rightarrow \mu_i = e^{\eta_i} \Rightarrow$$

$$\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = (e^{\eta_i})^2 = \mu_i^2 \Rightarrow w_i = \frac{1}{\mu_i^2}\mu_i^2 = 1 \Rightarrow \mathbf{W} \text{ é a matriz identidade.}$$

$$z_i = \eta_i + G_{ii}(y_i - \mu_i), G_{ii} = 1/\mu_i \Rightarrow$$

$$z_i = \log \mu_i + \frac{y_i - \mu_i}{\mu_i} \text{ ou } z_i = \eta_i + \frac{y_i - e^{\eta_i}}{e^{\eta_i}}.$$

Estimação de ϕ por máxima verossimilhança

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido.

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido. Para as demais distribuições, temos que estimar ϕ.

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido. Para as demais distribuições, temos que estimar ϕ.

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido. Para as demais distribuições, temos que estimar ϕ. Vimos anteriormente que

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido. Para as demais distribuições, temos que estimar ϕ. Vimos anteriormente que

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi).$$

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido. Para as demais distribuições, temos que estimar ϕ. Vimos anteriormente que

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi).$$

Assim,

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi}$$

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido. Para as demais distribuições, temos que estimar ϕ. Vimos anteriormente que

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi).$$

Assim,

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi$$

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido. Para as demais distribuições, temos que estimar ϕ. Vimos anteriormente que

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi).$$

Assim,

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i\theta_i - b(\theta_i)]$$

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido. Para as demais distribuições, temos que estimar ϕ. Vimos anteriormente que

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi).$$

Assim,

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i\theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido. Para as demais distribuições, temos que estimar ϕ. Vimos anteriormente que

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi).$$

Assim,

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i\theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Para a normal e a gaussiana inversa, conseguimos resolver algebricamente $U_\phi = 0$.

Estimação de ϕ por máxima verossimilhança

Para a Poisson e a binomial, temos que ϕ é conhecido. Para as demais distribuições, temos que estimar ϕ. Vimos anteriormente que

$$l(\boldsymbol{\beta}, \phi) = \sum_{i=1}^{n} \{\phi[y_i\theta_i - b(\theta_i)]\} + \sum_{i=1}^{n} c(y_i, \phi).$$

Assim,

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i\theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Para a normal e a gaussiana inversa, conseguimos resolver algebricamente $U_\phi = 0$. Para a gama é necessário a utilização de métodos numéricos.

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2},$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\beta, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5}$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\beta, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i},$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}, c(y_i, \phi) = \frac{1}{2} \log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}.$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}, c(y_i, \phi) = \frac{1}{2} \log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}.$$

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}, c(y_i, \phi) = \frac{1}{2} \log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}.$$

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} \left(-\frac{y_i}{2\mu_i^2} + \right.$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}, c(y_i, \phi) = \frac{1}{2} \log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}.$$

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} \left(-\frac{y_i}{2\mu_i^2} + \frac{1}{\mu_i}\right)$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}, c(y_i, \phi) = \frac{1}{2} \log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}.$$

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} \left(-\frac{y_i}{2\mu_i^2} + \frac{1}{\mu_i}\right) + \sum_{i=1}^{n} \left(\frac{1}{2\phi}\right.$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\beta, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}, c(y_i, \phi) = \frac{1}{2} \log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}.$$

$$\frac{\partial l(\beta, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} \left(-\frac{y_i}{2\mu_i^2} + \frac{1}{\mu_i}\right) + \sum_{i=1}^{n} \left(\frac{1}{2\phi} - \frac{1}{2y_i}\right)$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\beta, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}, c(y_i, \phi) = \frac{1}{2} \log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}.$$

$$\frac{\partial l(\beta, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} \left(-\frac{y_i}{2\mu_i^2} + \frac{1}{\mu_i}\right) + \sum_{i=1}^{n} \left(\frac{1}{2\phi} - \frac{1}{2y_i}\right)$$

$$U_\phi = 0$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\beta,\phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n}[y_i\theta_i - b(\theta_i)] + \sum_{i=1}^{n}\frac{\partial c(y_i,\phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}, c(y_i,\phi) = \frac{1}{2}\log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}.$$

$$\frac{\partial l(\beta,\phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n}\left(-\frac{y_i}{2\mu_i^2} + \frac{1}{\mu_i}\right) + \sum_{i=1}^{n}\left(\frac{1}{2\phi} - \frac{1}{2y_i}\right)$$

$$U_\phi = 0 \Rightarrow \frac{n}{2\hat{\phi}}$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\beta,\phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n}[y_i\theta_i - b(\theta_i)] + \sum_{i=1}^{n}\frac{\partial c(y_i,\phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}, c(y_i,\phi) = \frac{1}{2}\log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}.$$

$$\frac{\partial l(\beta,\phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n}\left(-\frac{y_i}{2\mu_i^2} + \frac{1}{\mu_i}\right) + \sum_{i=1}^{n}\left(\frac{1}{2\phi} - \frac{1}{2y_i}\right)$$

$$U_\phi = 0 \Rightarrow \frac{n}{2\hat{\phi}} = \sum_{i=1}^{n}\left(\frac{y_i}{2\hat{\mu}_i^2} - \frac{1}{\hat{\mu}_i} + \frac{1}{2y_i}\right) \Rightarrow \hat{\phi}_{\text{MV}}$$

Estimação de ϕ por máxima verossimilhança

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} [y_i \theta_i - b(\theta_i)] + \sum_{i=1}^{n} \frac{\partial c(y_i, \phi)}{\partial \phi}.$$

Exemplo: Gaussiana inversa

$$\theta_i = -\frac{1}{2\mu_i^2}, b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}, c(y_i, \phi) = \frac{1}{2} \log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}.$$

$$\frac{\partial l(\boldsymbol{\beta}, \phi)}{\partial \phi} = U_\phi = \sum_{i=1}^{n} \left(-\frac{y_i}{2\mu_i^2} + \frac{1}{\mu_i}\right) + \sum_{i=1}^{n} \left(\frac{1}{2\phi} - \frac{1}{2y_i}\right)$$

$$U_\phi = 0 \Rightarrow \frac{n}{2\hat{\phi}} = \sum_{i=1}^{n} \left(\frac{y_i}{2\hat{\mu}_i^2} - \frac{1}{\hat{\mu}_i} + \frac{1}{2y_i}\right) \Rightarrow \hat{\phi}_{\text{MV}} = \frac{n}{\sum_{i=1}^{n} \frac{(y_i - \hat{\mu}_i)^2}{y_i \hat{\mu}_i^2}}$$

Estimação de ϕ por máxima verossimilhança

Exemplo: Gaussiana inversa

$$\hat{\phi}_{\text{MV}} = \frac{n}{\sum_{i=1}^{n} \frac{(y_i - \hat{\mu}_i)^2}{y_i \hat{\mu}_i^2}}$$

Estimação de ϕ por máxima verossimilhança

Exemplo: Gaussiana inversa

$$\hat{\phi}_{\text{MV}} = \frac{n}{\sum_{i=1}^{n} \frac{(y_i - \hat{\mu}_i)^2}{y_i \hat{\mu}_i^2}} = \frac{n}{D^{\star}(\mathbf{y}; \hat{\boldsymbol{\mu}})}.$$

Estimação de ϕ por máxima verossimilhança

Exemplo: Gaussiana inversa

$$\hat{\phi}_{\text{MV}} = \frac{n}{\sum_{i=1}^{n} \frac{(y_i - \hat{\mu}_i)^2}{y_i \hat{\mu}_i^2}} = \frac{n}{D^\star(\mathbf{y}; \hat{\boldsymbol{\mu}})}.$$

Pode-se mostrar que também no caso normal,

$$\hat{\phi}_{\text{MV}} = \frac{n}{D^\star(\mathbf{y}; \hat{\boldsymbol{\mu}})}.$$

Estimação de ϕ pelo método dos momentos

Estimação de ϕ pelo método dos momentos

Um outro estimador consistente para ϕ e que sempre tem forma fechada em função de $\hat{\mu}_i$ é obtido pelo método dos momentos.

Estimação de ϕ pelo método dos momentos

Um outro estimador consistente para ϕ e que sempre tem forma fechada em função de $\hat{\mu}_i$ é obtido pelo método dos momentos. Pode-se mostrar que a distribuição assintótica de

$$\phi \sum_{i=1}^{n} \left[\frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \right]$$

Estimação de ϕ pelo método dos momentos

Um outro estimador consistente para ϕ e que sempre tem forma fechada em função de $\hat{\mu}_i$ é obtido pelo método dos momentos. Pode-se mostrar que a distribuição assintótica de

$$\phi \sum_{i=1}^{n} \left[\frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \right]$$

é χ^2_{n-k-1}.

Estimação de ϕ pelo método dos momentos

Um outro estimador consistente para ϕ e que sempre tem forma fechada em função de $\hat{\mu}_i$ é obtido pelo método dos momentos. Pode-se mostrar que a distribuição assintótica de

$$\phi \sum_{i=1}^{n} \left[\frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \right]$$

é χ^2_{n-k-1}. Assim, como a esperança de uma qui-quadrado é igual ao seus graus de liberdade, então

Estimação de ϕ pelo método dos momentos

Um outro estimador consistente para ϕ e que sempre tem forma fechada em função de $\hat{\mu}_i$ é obtido pelo método dos momentos. Pode-se mostrar que a distribuição assintótica de

$$\phi \sum_{i=1}^{n} \left[\frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \right]$$

é χ^2_{n-k-1}. Assim, como a esperança de uma qui-quadrado é igual ao seus graus de liberdade, então

$$\hat{\phi} \sum_{i=1}^{n} \left[\frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \right] = n - k - 1$$

Estimação de ϕ pelo método dos momentos

Um outro estimador consistente para ϕ e que sempre tem forma fechada em função de $\hat{\mu}_i$ é obtido pelo método dos momentos. Pode-se mostrar que a distribuição assintótica de

$$\phi \sum_{i=1}^{n} \left[\frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \right]$$

é χ^2_{n-k-1}. Assim, como a esperança de uma qui-quadrado é igual ao seus graus de liberdade, então

$$\hat{\phi} \sum_{i=1}^{n} \left[\frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \right] = n - k - 1 \Rightarrow \hat{\phi}_{\text{MM}} = \frac{n - k - 1}{\sum_{i=1}^{n} \left[\frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \right]}.$$

Matriz de informação de Fisher do modelo

Sendo $\boldsymbol{\gamma} = (\boldsymbol{\beta}^\top, \phi)^\top$,

Matriz de informação de Fisher do modelo

Sendo $\gamma = (\beta^\top, \phi)^\top$, a matriz de informação de Fisher de um MLGen é dada por

$$\mathbf{K}(\gamma) = \begin{bmatrix} \mathbf{K}_{\beta\beta} & \mathbf{K}_{\beta\phi} \\ \mathbf{K}_{\phi\beta} & K_{\phi\phi} \end{bmatrix}.$$

Matriz de informação de Fisher do modelo

Sendo $\gamma = (\beta^\top, \phi)^\top$, a matriz de informação de Fisher de um MLGen é dada por

$$\mathbf{K}(\gamma) = \begin{bmatrix} \mathbf{K}_{\beta\beta} & \mathbf{K}_{\beta\phi} \\ \mathbf{K}_{\phi\beta} & K_{\phi\phi} \end{bmatrix}.$$

$$K_{\phi\phi} = -\mathrm{E}\left(\frac{\partial^2}{\partial\phi^2} l(\beta, \phi)\right),$$

Matriz de informação de Fisher do modelo

Sendo $\gamma = (\beta^\top, \phi)^\top$, a matriz de informação de Fisher de um MLGen é dada por

$$\mathbf{K}(\gamma) = \begin{bmatrix} \mathbf{K}_{\beta\beta} & \mathbf{K}_{\beta\phi} \\ \mathbf{K}_{\phi\beta} & K_{\phi\phi} \end{bmatrix}.$$

$$K_{\phi\phi} = -\mathrm{E}\left(\frac{\partial^2}{\partial\phi^2} l(\beta, \phi)\right), \frac{\partial l(\beta, \phi)}{\partial\phi} = \sum_{i=1}^{n} [y_i\theta_i - b(\theta_i)]$$

Matriz de informação de Fisher do modelo

Sendo $\gamma = (\beta^\top, \phi)^\top$, a matriz de informação de Fisher de um MLGen é dada por

$$\mathbf{K}(\gamma) = \begin{bmatrix} \mathbf{K}_{\beta\beta} & \mathbf{K}_{\beta\phi} \\ \mathbf{K}_{\phi\beta} & K_{\phi\phi} \end{bmatrix}.$$

$$K_{\phi\phi} = -\mathrm{E}\left(\frac{\partial^2}{\partial\phi^2} l(\beta,\phi)\right), \frac{\partial l(\beta,\phi)}{\partial\phi} = \sum_{i=1}^{n}[y_i\theta_i - b(\theta_i)] + \sum_{i=1}^{n}\frac{\partial c(y_i,\phi)}{\partial\phi}.$$

Matriz de informação de Fisher do modelo

Sendo $\gamma = (\beta^\top, \phi)^\top$, a matriz de informação de Fisher de um MLGen é dada por

$$\mathbf{K}(\gamma) = \begin{bmatrix} \mathbf{K}_{\beta\beta} & \mathbf{K}_{\beta\phi} \\ \mathbf{K}_{\phi\beta} & K_{\phi\phi} \end{bmatrix}.$$

$$K_{\phi\phi} = -\mathrm{E}\left(\frac{\partial^2}{\partial\phi^2} l(\beta,\phi)\right), \frac{\partial l(\beta,\phi)}{\partial\phi} = \sum_{i=1}^{n}[y_i\theta_i - b(\theta_i)] + \sum_{i=1}^{n}\frac{\partial c(y_i,\phi)}{\partial\phi}.$$

Assim,

$$K_{\phi\phi}$$

Matriz de informação de Fisher do modelo

Sendo $\gamma = (\beta^\top, \phi)^\top$, a matriz de informação de Fisher de um MLGen é dada por

$$\mathbf{K}(\gamma) = \begin{bmatrix} \mathbf{K}_{\beta\beta} & \mathbf{K}_{\beta\phi} \\ \mathbf{K}_{\phi\beta} & K_{\phi\phi} \end{bmatrix}.$$

$$K_{\phi\phi} = -\mathrm{E}\left(\frac{\partial^2}{\partial\phi^2} l(\beta,\phi)\right), \frac{\partial l(\beta,\phi)}{\partial\phi} = \sum_{i=1}^{n}[y_i\theta_i - b(\theta_i)] + \sum_{i=1}^{n}\frac{\partial c(y_i,\phi)}{\partial\phi}.$$

Assim,

$$K_{\phi\phi} = -\mathrm{E}\left(\sum_{i=1}^{n}\frac{\partial^2}{\partial\phi^2} c(y_i,\phi)\right).$$

Matriz de informação de Fisher do modelo

$$K_{\phi\phi}$$

Matriz de informação de Fisher do modelo

$$K_{\phi\phi} = -\mathrm{E}\left(\sum_{i=1}^{n} \frac{\partial^2}{\partial \phi^2} c(y_i, \phi)\right).$$

Matriz de informação de Fisher do modelo

$$K_{\phi\phi} = -\mathrm{E}\left(\sum_{i=1}^{n} \frac{\partial^2}{\partial \phi^2} c(y_i, \phi)\right).$$

Exemplo: gaussiana inversa

Matriz de informação de Fisher do modelo

$$K_{\phi\phi} = -\mathrm{E}\left(\sum_{i=1}^{n} \frac{\partial^2}{\partial \phi^2} c(y_i, \phi)\right).$$

Exemplo: gaussiana inversa

$$c(y_i, \phi) = \frac{1}{2}\log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i},$$

Matriz de informação de Fisher do modelo

$$K_{\phi\phi} = -\mathrm{E}\left(\sum_{i=1}^{n} \frac{\partial^2}{\partial \phi^2} c(y_i, \phi)\right).$$

Exemplo: gaussiana inversa

$$c(y_i, \phi) = \frac{1}{2}\log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}, \qquad \frac{\partial}{\partial \phi} c(y_i, \phi) = \frac{1}{2\phi} - \frac{1}{2y_i}.$$

Matriz de informação de Fisher do modelo

$$K_{\phi\phi} = -\mathrm{E}\left(\sum_{i=1}^{n} \frac{\partial^2}{\partial\phi^2} c(y_i, \phi)\right).$$

Exemplo: gaussiana inversa

$$c(y_i, \phi) = \frac{1}{2}\log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}, \qquad \frac{\partial}{\partial\phi} c(y_i, \phi) = \frac{1}{2\phi} - \frac{1}{2y_i}.$$

$$\frac{\partial^2}{\partial\phi^2} c(y_i, \phi) = -\frac{1}{2\phi^2},$$

Matriz de informação de Fisher do modelo

$$K_{\phi\phi} = -\mathrm{E}\left(\sum_{i=1}^{n} \frac{\partial^2}{\partial\phi^2} c(y_i, \phi)\right).$$

Exemplo: gaussiana inversa

$$c(y_i, \phi) = \frac{1}{2}\log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}, \qquad \frac{\partial}{\partial\phi} c(y_i, \phi) = \frac{1}{2\phi} - \frac{1}{2y_i}.$$

$$\frac{\partial^2}{\partial\phi^2} c(y_i, \phi) = -\frac{1}{2\phi^2}, \qquad K_{\phi\phi} = -\mathrm{E}\left(\sum_{i=1}^{n} -\frac{1}{2\phi^2}\right)$$

Matriz de informação de Fisher do modelo

$$K_{\phi\phi} = -\mathrm{E}\left(\sum_{i=1}^{n} \frac{\partial^2}{\partial\phi^2} c(y_i, \phi)\right).$$

Exemplo: gaussiana inversa

$$c(y_i, \phi) = \frac{1}{2}\log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}, \qquad \frac{\partial}{\partial\phi} c(y_i, \phi) = \frac{1}{2\phi} - \frac{1}{2y_i}.$$

$$\frac{\partial^2}{\partial\phi^2} c(y_i, \phi) = -\frac{1}{2\phi^2}, \qquad K_{\phi\phi} = -\mathrm{E}\left(\sum_{i=1}^{n} -\frac{1}{2\phi^2}\right) = \frac{n}{2\phi^2}$$

Matriz de informação de Fisher do modelo

Matriz de informação de Fisher do modelo

Temos ainda que $\mathbf{K}_{\boldsymbol{\beta}\phi} = \mathbf{K}_{\phi\boldsymbol{\beta}}^{\top}$

Matriz de informação de Fisher do modelo

Temos ainda que $\mathbf{K}_{\boldsymbol{\beta}\phi} = \mathbf{K}_{\phi\boldsymbol{\beta}}^{\top}$ é um vetor de $(k+1)$ posições, sendo uma associada a cada um dos β_j do modelo.

Matriz de informação de Fisher do modelo

Temos ainda que $\mathbf{K}_{\boldsymbol{\beta}\phi} = \mathbf{K}_{\phi\boldsymbol{\beta}}^{\top}$ é um vetor de $(k+1)$ posições, sendo uma associada a cada um dos β_j do modelo.

O termo associado a β_r é dado por

Matriz de informação de Fisher do modelo

Temos ainda que $\mathbf{K}_{\boldsymbol{\beta}\phi} = \mathbf{K}_{\phi\boldsymbol{\beta}}^{\top}$ é um vetor de $(k+1)$ posições, sendo uma associada a cada um dos β_j do modelo.

O termo associado a β_r é dado por

$$-\mathrm{E}\left(\frac{\partial U_{\beta_r}}{\partial \phi}\right),$$

Matriz de informação de Fisher do modelo

Temos ainda que $\mathbf{K}_{\boldsymbol{\beta}\phi} = \mathbf{K}_{\phi\boldsymbol{\beta}}^{\top}$ é um vetor de $(k+1)$ posições, sendo uma associada a cada um dos β_j do modelo.

O termo associado a β_r é dado por

$$-\mathrm{E}\left(\frac{\partial U_{\beta_r}}{\partial \phi}\right), \qquad U_{\beta_r} = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}.$$

Matriz de informação de Fisher do modelo

Temos ainda que $\mathbf{K}_{\boldsymbol{\beta}\phi} = \mathbf{K}_{\phi\boldsymbol{\beta}}^{\top}$ é um vetor de $(k+1)$ posições, sendo uma associada a cada um dos β_j do modelo.

O termo associado a β_r é dado por

$$-\mathrm{E}\left(\frac{\partial U_{\beta_r}}{\partial \phi}\right), \qquad U_{\beta_r} = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}.$$

Assim, esse termo da informação de Fisher é dado por

Matriz de informação de Fisher do modelo

Temos ainda que $\mathbf{K}_{\boldsymbol{\beta}\phi} = \mathbf{K}_{\phi\boldsymbol{\beta}}^{\top}$ é um vetor de $(k+1)$ posições, sendo uma associada a cada um dos β_j do modelo.

O termo associado a β_r é dado por

$$-\mathrm{E}\left(\frac{\partial U_{\beta_r}}{\partial \phi}\right), \qquad U_{\beta_r} = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}.$$

Assim, esse termo da informação de Fisher é dado por

$$-\mathrm{E}\left[\sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}\right]$$

Matriz de informação de Fisher do modelo

Temos ainda que $\mathbf{K}_{\boldsymbol{\beta}\phi} = \mathbf{K}_{\phi\boldsymbol{\beta}}^{\top}$ é um vetor de $(k+1)$ posições, sendo uma associada a cada um dos β_j do modelo.

O termo associado a β_r é dado por

$$-\mathrm{E}\left(\frac{\partial U_{\beta_r}}{\partial \phi}\right), \qquad U_{\beta_r} = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}.$$

Assim, esse termo da informação de Fisher é dado por

$$-\mathrm{E}\left[\sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}\right] = -\sum_{i=1}^{n} \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir} \mathrm{E}(y_i - \mu_i)$$

Matriz de informação de Fisher do modelo

Temos ainda que $\mathbf{K}_{\boldsymbol{\beta}\phi} = \mathbf{K}_{\phi\boldsymbol{\beta}}^{\top}$ é um vetor de $(k+1)$ posições, sendo uma associada a cada um dos β_j do modelo.

O termo associado a β_r é dado por

$$-\mathrm{E}\left(\frac{\partial U_{\beta_r}}{\partial \phi}\right), \qquad U_{\beta_r} = \phi \sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}.$$

Assim, esse termo da informação de Fisher é dado por

$$-\mathrm{E}\left[\sum_{i=1}^{n} (y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}\right] = -\sum_{i=1}^{n} \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir} \mathrm{E}(y_i - \mu_i) = 0$$

Matriz de informação de Fisher do modelo

Matriz de informação de Fisher do modelo

Logo, temos que

$$\mathbf{K}(\gamma) = \begin{bmatrix} \mathbf{K}_{\beta\beta} & 0 \\ 0 & K_{\phi\phi} \end{bmatrix},$$

Matriz de informação de Fisher do modelo

Logo, temos que

$$\mathbf{K}(\gamma) = \begin{bmatrix} \mathbf{K}_{\beta\beta} & 0 \\ 0 & K_{\phi\phi} \end{bmatrix},$$

ou seja $\mathbf{K}(\gamma)$ é uma matriz bloco diagonal, o que significa que β e ϕ são ortogonais

Matriz de informação de Fisher do modelo

Logo, temos que

$$\mathbf{K}(\gamma) = \begin{bmatrix} \mathbf{K}_{\beta\beta} & 0 \\ 0 & K_{\phi\phi} \end{bmatrix},$$

ou seja $\mathbf{K}(\gamma)$ é uma matriz bloco diagonal, o que significa que β e ϕ são ortogonais e portanto os estimadores de máxima verossimilhança de β e ϕ são assintoticamente independentes.

Simplificações com a função de ligação canônica

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, U_β e $\mathbf{K}_{\beta\beta}$ se simplificam.

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, U_{β} e $\mathbf{K}_{\beta\beta}$ se simplificam.

Vimos que nos MLgen, $U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \mu)$.

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, U_{β} e $\mathbf{K}_{\beta\beta}$ se simplificam.

Vimos que nos MLgen, $U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i$

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, $U_{\boldsymbol{\beta}}$ e $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ se simplificam.

Vimos que nos MLgen, $U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, $U_{\boldsymbol{\beta}}$ e $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ se simplificam.

Vimos que nos MLgen, $U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Além disso, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$.

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, $U_{\boldsymbol{\beta}}$ e $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ se simplificam.

Vimos que nos MLgen, $U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Além disso, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$. Mas se a função de ligação é a canônica,

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, U_{β} e $\mathbf{K}_{\beta\beta}$ se simplificam.

Vimos que nos MLgen, $U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Além disso, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$. Mas se a função de ligação é a canônica, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, U_{β} e $\mathbf{K}_{\beta\beta}$ se simplificam.

Vimos que nos MLgen, $U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Além disso, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$. Mas se a função de ligação é a canônica, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i} = \frac{\partial \theta_i}{\partial \mu_i}$.

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, U_{β} e $\mathbf{K}_{\beta\beta}$ se simplificam.

Vimos que nos MLgen, $U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Além disso, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$. Mas se a função de ligação é a canônica, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i} = \frac{\partial \theta_i}{\partial \mu_i}$.

Assim, se a f. de ligação é a canônica, $w_i G_{ii} = 1$

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, U_{β} e $\mathbf{K}_{\beta\beta}$ se simplificam.

Vimos que nos MLgen, $U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Além disso, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$. Mas se a função de ligação é a canônica, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i} = \frac{\partial \theta_i}{\partial \mu_i}$.

Assim, se a f. de ligação é a canônica, $w_i G_{ii} = 1$ e $U_{\beta} = \phi \mathbf{X}^{\top} (\mathbf{y} - \boldsymbol{\mu})$.

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, $U_{\boldsymbol{\beta}}$ e $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ se simplificam.

Vimos que nos MLgen, $U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Além disso, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$. Mas se a função de ligação é a canônica, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i} = \frac{\partial \theta_i}{\partial \mu_i}$.

Assim, se a f. de ligação é a canônica, $w_i G_{ii} = 1$ e $U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top (\mathbf{y} - \boldsymbol{\mu})$.

Vimos ainda que nos MLGen, $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$.

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, $U_{\boldsymbol{\beta}}$ e $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ se simplificam.

Vimos que nos MLgen, $U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Além disso, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$. Mas se a função de ligação é a canônica, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i} = \frac{\partial \theta_i}{\partial \mu_i}$.

Assim, se a f. de ligação é a canônica, $w_i G_{ii} = 1$ e $U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top (\mathbf{y} - \boldsymbol{\mu})$.

Vimos ainda que nos MLGen, $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$. Mas se a função de ligação é canônica, $w_i = V_i$.

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, U_{β} e $\mathbf{K}_{\beta\beta}$ se simplificam.

Vimos que nos MLgen, $U_{\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Além disso, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$. Mas se a função de ligação é a canônica, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i} = \frac{\partial \theta_i}{\partial \mu_i}$.

Assim, se a f. de ligação é a canônica, $w_i G_{ii} = 1$ e $U_{\beta} = \phi \mathbf{X}^{\top} (\mathbf{y} - \boldsymbol{\mu})$.

Vimos ainda que nos MLGen, $\mathbf{K}_{\beta\beta} = \phi \mathbf{X}^{\top} \mathbf{W} \mathbf{X}$. Mas se a função de ligação é canônica, $w_i = V_i$. Portanto, nesse caso, $\mathbf{K}_{\beta\beta} = \phi \mathbf{X}^{\top} \mathbf{V} \mathbf{X}$,

Simplificações com a função de ligação canônica

Temos que quando a função de ligação é a canônica, $U_{\boldsymbol{\beta}}$ e $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}}$ se simplificam.

Vimos que nos MLgen, $U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{G} (\mathbf{y} - \boldsymbol{\mu})$.

Se a função de ligação é canônica, $w_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$.

Além disso, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i}$. Mas se a função de ligação é a canônica, $G_{ii} = \frac{\partial \eta_i}{\partial \mu_i} = \frac{\partial \theta_i}{\partial \mu_i}$.

Assim, se a f. de ligação é a canônica, $w_i G_{ii} = 1$ e $U_{\boldsymbol{\beta}} = \phi \mathbf{X}^\top (\mathbf{y} - \boldsymbol{\mu})$.

Vimos ainda que nos MLGen, $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{W} \mathbf{X}$. Mas se a função de ligação é canônica, $w_i = V_i$. Portanto, nesse caso, $\mathbf{K}_{\boldsymbol{\beta}\boldsymbol{\beta}} = \phi \mathbf{X}^\top \mathbf{V} \mathbf{X}$, em que $\mathbf{V} = \text{diag}\{V_1, V_2, \ldots, V_n\}$.