Modelos lineares generalizados

Análise de diagnóstico

Introdução

Introdução

Assim como no MLGer, a análise de diagnóstico consiste na identificação de pontos alavanca, discrepantes e influentes e na verificação de possíveis afastamentos das suposições feitas para o modelo.

Introdução

Assim como no MLGer, a análise de diagnóstico consiste na identificação de pontos alavanca, discrepantes e influentes e na verificação de possíveis afastamentos das suposições feitas para o modelo.

Pontos alavanca

Introdução

Assim como no MLGer, a análise de diagnóstico consiste na identificação de pontos alavanca, discrepantes e influentes e na verificação de possíveis afastamentos das suposições feitas para o modelo.

Pontos alavanca

Nos MLGer, $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$ e $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$.

Introdução

Assim como no MLGer, a análise de diagnóstico consiste na identificação de pontos alavanca, discrepantes e influentes e na verificação de possíveis afastamentos das suposições feitas para o modelo.

Pontos alavanca

Nos MLGer, $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$ e $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$. Já no processo iterativo dos MLGen, $\hat{\boldsymbol{\beta}}^{(m+1)} = (\mathbf{X}^\top\mathbf{W}^{(m)}\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{W}^{(m)}\mathbf{z}^{(m)}$.

Introdução

Assim como no MLGer, a análise de diagnóstico consiste na identificação de pontos alavanca, discrepantes e influentes e na verificação de possíveis afastamentos das suposições feitas para o modelo.

Pontos alavanca

Nos MLGer, $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$ e $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$. Já no processo iterativo dos MLGen, $\hat{\boldsymbol{\beta}}^{(m+1)} = (\mathbf{X}^\top\mathbf{W}^{(m)}\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{W}^{(m)}\mathbf{z}^{(m)}$. Assim, $\mathbf{W}^{1/2}\mathbf{X}$ faz nos MLGen, o mesmo papel que $\mathbf{X}$ faz no MLGer.

Introdução

Assim como no MLGer, a análise de diagnóstico consiste na identificação de pontos alavanca, discrepantes e influentes e na verificação de possíveis afastamentos das suposições feitas para o modelo.

Pontos alavanca

Nos MLGer, $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$ e $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$. Já no processo iterativo dos MLGen, $\hat{\boldsymbol{\beta}}^{(m+1)} = (\mathbf{X}^\top\mathbf{W}^{(m)}\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{W}^{(m)}\mathbf{z}^{(m)}$. Assim, $\mathbf{W}^{1/2}\mathbf{X}$ faz nos MLGen, o mesmo papel que $\mathbf{X}$ faz no MLGer. Portanto, a matriz H nos MLGen é definida como

Introdução

Assim como no MLGer, a análise de diagnóstico consiste na identificação de pontos alavanca, discrepantes e influentes e na verificação de possíveis afastamentos das suposições feitas para o modelo.

Pontos alavanca

Nos MLGer, $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$ e $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$. Já no processo iterativo dos MLGen, $\hat{\boldsymbol{\beta}}^{(m+1)} = (\mathbf{X}^\top\mathbf{W}^{(m)}\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{W}^{(m)}\mathbf{z}^{(m)}$. Assim, $\mathbf{W}^{1/2}\mathbf{X}$ faz nos MLGen, o mesmo papel que $\mathbf{X}$ faz no MLGer. Portanto, a matriz H nos MLGen é definida como

$$\mathbf{H} = \widehat{\mathbf{W}}^{1/2}\mathbf{X}(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}\mathbf{X}^\top\widehat{\mathbf{W}}^{1/2}$$

Introdução

Assim como no MLGer, a análise de diagnóstico consiste na identificação de pontos alavanca, discrepantes e influentes e na verificação de possíveis afastamentos das suposições feitas para o modelo.

Pontos alavanca

Nos MLGer, $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$ e $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$. Já no processo iterativo dos MLGen, $\hat{\boldsymbol{\beta}}^{(m+1)} = (\mathbf{X}^\top\mathbf{W}^{(m)}\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{W}^{(m)}\mathbf{z}^{(m)}$. Assim, $\mathbf{W}^{1/2}\mathbf{X}$ faz nos MLGen, o mesmo papel que $\mathbf{X}$ faz no MLGer. Portanto, a matriz H nos MLGen é definida como

$$\mathbf{H} = \widehat{\mathbf{W}}^{1/2}\mathbf{X}(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}\mathbf{X}^\top\widehat{\mathbf{W}}^{1/2}$$

e os elementos da sua diagonal são usados como medidas do leverage da observação.

Introdução

Pontos alavanca

A matriz H nos MLGen é definida como

$$\mathbf{H} = \widehat{\mathbf{W}}^{1/2}\mathbf{X}(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}\mathbf{X}^\top\widehat{\mathbf{W}}^{1/2}$$

Introdução

Pontos alavanca

A matriz H nos MLGen é definida como

$$\mathbf{H} = \widehat{\mathbf{W}}^{1/2}\mathbf{X}(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}\mathbf{X}^\top\widehat{\mathbf{W}}^{1/2}$$

e os elementos da sua diagonal são usados como medidas do leverage da observação.

Introdução

Pontos alavanca

A matriz H nos MLGen é definida como

$$\mathbf{H} = \widehat{\mathbf{W}}^{1/2}\mathbf{X}(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}\mathbf{X}^\top\widehat{\mathbf{W}}^{1/2}$$

e os elementos da sua diagonal são usados como medidas do leverage da observação.

Observações:

Introdução

Pontos alavanca

A matriz H nos MLGen é definida como

$$\mathbf{H} = \widehat{\mathbf{W}}^{1/2}\mathbf{X}(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}\mathbf{X}^\top\widehat{\mathbf{W}}^{1/2}$$

e os elementos da sua diagonal são usados como medidas do leverage da observação.

Observações:

- Note que nos MLGen, **H** não é uma função apenas da matriz **X**.

Introdução

Pontos alavanca

A matriz H nos MLGen é definida como

$$\mathbf{H} = \widehat{\mathbf{W}}^{1/2}\mathbf{X}(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}\mathbf{X}^\top\widehat{\mathbf{W}}^{1/2}$$

e os elementos da sua diagonal são usados como medidas do leverage da observação.

Observações:

- Note que nos MLGen, **H** não é uma função apenas da matriz **X**.
- Note também que **H** é uma matriz aleatória.

Introdução

Pontos alavanca

A matriz H nos MLGen é definida como

$$\mathbf{H} = \widehat{\mathbf{W}}^{1/2}\mathbf{X}(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}\mathbf{X}^\top\widehat{\mathbf{W}}^{1/2}$$

e os elementos da sua diagonal são usados como medidas do leverage da observação.

Observações:

- Note que nos MLGen, **H** não é uma função apenas da matriz **X**.
- Note também que **H** é uma matriz aleatória.
- Como consequência das duas observações anteriores, a interpretação dos termos h_{ii} é bem mais complexa nos MLGen.

Pontos discrepantes

Pontos discrepantes

Nos MLGen não é possível obter resíduos que sejam identicamente distribuídos.

Pontos discrepantes

Nos MLGen não é possível obter resíduos que sejam identicamente distribuídos. Dessa forma, diversos resíduos foram propostos.

Pontos discrepantes

Nos MLGen não é possível obter resíduos que sejam identicamente distribuídos. Dessa forma, diversos resíduos foram propostos. Para facilitar sua interpretação, seria desejável que esses resíduos tivessem distribuição normal padrão (pelo menos aproximadamente).

Pontos discrepantes

Nos MLGen não é possível obter resíduos que sejam identicamente distribuídos. Dessa forma, diversos resíduos foram propostos. Para facilitar sua interpretação, seria desejável que esses resíduos tivessem distribuição normal padrão (pelo menos aproximadamente).

Nos MLGer, $\text{Var}(y_i) = \phi^{-1} V_i$.

Pontos discrepantes

Nos MLGen não é possível obter resíduos que sejam identicamente distribuídos. Dessa forma, diversos resíduos foram propostos. Para facilitar sua interpretação, seria desejável que esses resíduos tivessem distribuição normal padrão (pelo menos aproximadamente).

Nos MLGer, $\text{Var}(y_i) = \phi^{-1} V_i$. Assim, é razoável pensarmos como primeiro resíduo

Pontos discrepantes

Nos MLGen não é possível obter resíduos que sejam identicamente distribuídos. Dessa forma, diversos resíduos foram propostos. Para facilitar sua interpretação, seria desejável que esses resíduos tivessem distribuição normal padrão (pelo menos aproximadamente).

Nos MLGer, $\text{Var}(y_i) = \phi^{-1} V_i$. Assim, é razoável pensarmos como primeiro resíduo

$$r_i = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1} \hat{V}_i}}.$$

Pontos discrepantes

Nos MLGen não é possível obter resíduos que sejam identicamente distribuídos. Dessa forma, diversos resíduos foram propostos. Para facilitar sua interpretação, seria desejável que esses resíduos tivessem distribuição normal padrão (pelo menos aproximadamente).

Nos MLGer, $\text{Var}(y_i) = \phi^{-1} V_i$. Assim, é razoável pensarmos como primeiro resíduo

$$r_i = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1} \hat{V}_i}}.$$

Porém, pode-se provar que $\text{Var}(r_i) \approx 1 - h_{ii}$.

Pontos discrepantes

Nos MLGen não é possível obter resíduos que sejam identicamente distribuídos. Dessa forma, diversos resíduos foram propostos. Para facilitar sua interpretação, seria desejável que esses resíduos tivessem distribuição normal padrão (pelo menos aproximadamente).

Nos MLGer, $\text{Var}(y_i) = \phi^{-1} V_i$. Assim, é razoável pensarmos como primeiro resíduo

$$r_i = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1} \hat{V}_i}}.$$

Porém, pode-se provar que $\text{Var}(r_i) \approx 1 - h_{ii}$. Assim, o primeiro resíduo considerado denominado **resíduo de Pearson estudentizado** é dado por

Pontos discrepantes

Nos MLGen não é possível obter resíduos que sejam identicamente distribuídos. Dessa forma, diversos resíduos foram propostos. Para facilitar sua interpretação, seria desejável que esses resíduos tivessem distribuição normal padrão (pelo menos aproximadamente).

Nos MLGer, $\text{Var}(y_i) = \phi^{-1} V_i$. Assim, é razoável pensarmos como primeiro resíduo

$$r_i = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1} \hat{V}_i}}.$$

Porém, pode-se provar que $\text{Var}(r_i) \approx 1 - h_{ii}$. Assim, o primeiro resíduo considerado denominado **resíduo de Pearson estudentizado** é dado por

$$t_{S_i} = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1} \hat{V}_i (1 - h_{ii})}}$$

Pontos discrepantes

Nos MLGen não é possível obter resíduos que sejam identicamente distribuídos. Dessa forma, diversos resíduos foram propostos. Para facilitar sua interpretação, seria desejável que esses resíduos tivessem distribuição normal padrão (pelo menos aproximadamente).

Nos MLGer, $\text{Var}(y_i) = \phi^{-1} V_i$. Assim, é razoável pensarmos como primeiro resíduo

$$r_i = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1} \hat{V}_i}}.$$

Porém, pode-se provar que $\text{Var}(r_i) \approx 1 - h_{ii}$. Assim, o primeiro resíduo considerado denominado **resíduo de Pearson estudentizado** é dado por

$$t_{S_i} = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1} \hat{V}_i (1 - h_{ii})}} = \frac{\hat{\phi}^{1/2}(y_i - \hat{\mu}_i)}{\sqrt{\hat{V}_i (1 - h_{ii})}}.$$

Pontos discrepantes

Pontos discrepantes

O **resíduo de Pearson estudentizado** é dado por

Pontos discrepantes

O **resíduo de Pearson estudentizado** é dado por

$$t_{S_i} = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1}\hat{V}_i(1-h_{ii})}} = \frac{\hat{\phi}^{1/2}(y_i - \hat{\mu}_i)}{\sqrt{\hat{V}_i(1-h_{ii})}}.$$

Pontos discrepantes

O **resíduo de Pearson estudentizado** é dado por

$$t_{S_i} = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1}\hat{V}_i(1-h_{ii})}} = \frac{\hat{\phi}^{1/2}(y_i - \hat{\mu}_i)}{\sqrt{\hat{V}_i(1-h_{ii})}}.$$

Estudos de simulação mostram que o resíduo de Pearson estudentizado apresenta distribuição assimétrica mesmo em grandes amostras.

Pontos discrepantes

O **resíduo de Pearson estudentizado** é dado por

$$t_{S_i} = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1}\hat{V}_i(1-h_{ii})}} = \frac{\hat{\phi}^{1/2}(y_i - \hat{\mu}_i)}{\sqrt{\hat{V}_i(1-h_{ii})}}.$$

Estudos de simulação mostram que o resíduo de Pearson estudentizado apresenta distribuição assimétrica mesmo em grandes amostras.

Por esse motivo, diversos outros resíduos foram sugeridos com objetivo de obter resíduos com distribuição mais próxima da normal padrão.

Pontos discrepantes

O **resíduo de Pearson estudentizado** é dado por

$$t_{S_i} = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\phi}^{-1}\hat{V}_i(1-h_{ii})}} = \frac{\hat{\phi}^{1/2}(y_i - \hat{\mu}_i)}{\sqrt{\hat{V}_i(1-h_{ii})}}.$$

Estudos de simulação mostram que o resíduo de Pearson estudentizado apresenta distribuição assimétrica mesmo em grandes amostras.

Por esse motivo, diversos outros resíduos foram sugeridos com objetivo de obter resíduos com distribuição mais próxima da normal padrão.

Quatro outros resíduos utilizados nos MLGen são: resíduo deviance estudentizado, resíduo de Williams, resíduo Anscombe e resíduo quantílico (aleatorizado).

Pontos discrepantes

Pontos discrepantes

O resíduo mais conhecido em MLGen utiliza a função desvio.

Pontos discrepantes

O resíduo mais conhecido em MLGen utiliza a função desvio. Vimos que

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\} = \sum_{i=1}^{n} d^2(y_i, \hat{\mu}_i),$$

Pontos discrepantes

O resíduo mais conhecido em MLGen utiliza a função desvio. Vimos que

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\} = \sum_{i=1}^{n} d^2(y_i, \hat{\mu}_i),$$

em que $d(y_i, \hat{\mu}_i) = \pm\sqrt{2\phi} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right]^{1/2}$.

Pontos discrepantes

O resíduo mais conhecido em MLGen utiliza a função desvio. Vimos que

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\} = \sum_{i=1}^{n} d^2(y_i, \hat{\mu}_i),$$

em que $d(y_i, \hat{\mu}_i) = \pm\sqrt{2\phi} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right]^{1/2}$.

Pode-se mostrar que $\text{Var}(d(y_i, \hat{\mu}_i)) \approx 1 - h_{ii}$ e assim o **resíduo componente do desvio estudentizado (deviance estudentizado)** é dado por

Pontos discrepantes

O resíduo mais conhecido em MLGen utiliza a função desvio. Vimos que

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\} = \sum_{i=1}^{n} d^2(y_i, \hat{\mu}_i),$$

em que $d(y_i, \hat{\mu}_i) = \pm\sqrt{2\phi} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right]^{1/2}$.

Pode-se mostrar que $\text{Var}(d(y_i, \hat{\mu}_i)) \approx 1 - h_{ii}$ e assim o **resíduo componente do desvio estudentizado (deviance estudentizado)** é dado por

Pontos discrepantes

O resíduo mais conhecido em MLGen utiliza a função desvio. Vimos que

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\} = \sum_{i=1}^{n} d^2(y_i, \hat{\mu}_i),$$

em que $d(y_i, \hat{\mu}_i) = \pm\sqrt{2\phi} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right]^{1/2}$.

Pode-se mostrar que $\text{Var}(d(y_i, \hat{\mu}_i)) \approx 1 - h_{ii}$ e assim o **resíduo componente do desvio estudentizado (deviance estudentizado)** é dado por

$$t_{D_i} = \frac{\text{sinal}\{y_i - \hat{\mu}_i\}\hat{d}(y_i, \hat{\mu}_i)}{\sqrt{1 - h_{ii}}}.$$

Pontos discrepantes

O resíduo mais conhecido em MLGen utiliza a função desvio. Vimos que

$$D(\mathbf{y}, \hat{\boldsymbol{\mu}}) = 2\phi \left\{ \sum_{i=1}^{n} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right] \right\} = \sum_{i=1}^{n} d^2(y_i, \hat{\mu}_i),$$

em que $d(y_i, \hat{\mu}_i) = \pm\sqrt{2\phi} \left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \right]^{1/2}$.

Pode-se mostrar que $\text{Var}(d(y_i, \hat{\mu}_i)) \approx 1 - h_{ii}$ e assim o **resíduo componente do desvio estudentizado (deviance estudentizado)** é dado por

$$t_{D_i} = \frac{\text{sinal}\{y_i - \hat{\mu}_i\}\hat{d}(y_i, \hat{\mu}_i)}{\sqrt{1 - h_{ii}}}.$$

Estudos de simulação sugerem que t_{D_i} tem distribuição mais simétrica que t_{S_i}. Por outro lado, sua média é ligeiramente diferente de zero.

Pontos discrepantes

Pontos discrepantes

O **resíduo de Williams** é uma espécie de média ponderada entre t_{S_i} e t_{D_i} dada por

Pontos discrepantes

O **resíduo de Williams** é uma espécie de média ponderada entre t_{S_i} e t_{D_i} dada por

$$t_{G_i} = \text{sinal}\{y_i - \hat{\mu}_i\}[(1 - h_{ii})t_{D_i}^2 + (h_{ii})t_{S_i}^2]^{1/2}.$$

Pontos discrepantes

O **resíduo de Williams** é uma espécie de média ponderada entre t_{S_i} e t_{D_i} dada por

$$t_{G_i} = \text{sinal}\{y_i - \hat{\mu}_i\}[(1 - h_{ii})t_{D_i}^2 + (h_{ii})t_{S_i}^2]^{1/2}.$$

O **resíduo de Anscombe estudentizado** é dado por

$$t_{A_i} = \frac{\hat{\phi}^{1/2}[\psi(y_i) - \psi(\hat{\mu}_i)]}{\psi'(\hat{\mu}_i)\sqrt{\hat{V}_i(1 - h_{ii})}},$$

Pontos discrepantes

O **resíduo de Williams** é uma espécie de média ponderada entre t_{S_i} e t_{D_i} dada por

$$t_{G_i} = \text{sinal}\{y_i - \hat{\mu}_i\}[(1 - h_{ii})t_{D_i}^2 + (h_{ii})t_{S_i}^2]^{1/2}.$$

O **resíduo de Anscombe estudentizado** é dado por

$$t_{A_i} = \frac{\hat{\phi}^{1/2}[\psi(y_i) - \psi(\hat{\mu}_i)]}{\psi'(\hat{\mu}_i)\sqrt{\hat{V}_i(1 - h_{ii})}},$$

em que $\psi(.)$ é uma função que tem o objetivo de tornar a distribuição de t_{A_i} mais próxima da normal padrão.

Pontos discrepantes

O **resíduo de Williams** é uma espécie de média ponderada entre t_{S_i} e t_{D_i} dada por

$$t_{G_i} = \text{sinal}\{y_i - \hat{\mu}_i\}[(1 - h_{ii})t_{D_i}^2 + (h_{ii})t_{S_i}^2]^{1/2}.$$

O **resíduo de Anscombe estudentizado** é dado por

$$t_{A_i} = \frac{\hat{\phi}^{1/2}[\psi(y_i) - \psi(\hat{\mu}_i)]}{\psi'(\hat{\mu}_i)\sqrt{\hat{V}_i(1 - h_{ii})}},$$

em que $\psi(.)$ é uma função que tem o objetivo de tornar a distribuição de t_{A_i} mais próxima da normal padrão. No caso dos MLGen, essa função é dada por $\psi(\mu) = \int_o^\mu [V(t)]^{-1/3} dt$, em que $V(.)$ é a função de variância.

Pontos discrepantes

O **resíduo de Williams** é uma espécie de média ponderada entre t_{S_i} e t_{D_i} dada por

$$t_{G_i} = \text{sinal}\{y_i - \hat{\mu}_i\}[(1 - h_{ii})t_{D_i}^2 + (h_{ii})t_{S_i}^2]^{1/2}.$$

O **resíduo de Anscombe estudentizado** é dado por

$$t_{A_i} = \frac{\hat{\phi}^{1/2}[\psi(y_i) - \psi(\hat{\mu}_i)]}{\psi'(\hat{\mu}_i)\sqrt{\hat{V}_i(1 - h_{ii})}},$$

em que $\psi(.)$ é uma função que tem o objetivo de tornar a distribuição de t_{A_i} mais próxima da normal padrão. No caso dos MLGen, essa função é dada por $\psi(\mu) = \int_o^\mu [V(t)]^{-1/3} dt$, em que $V(.)$ é a função de variância. No caso dos modelos com resposta gama, por exemplo, $V(\mu_i) = \mu_i^2$

Pontos discrepantes

O **resíduo de Williams** é uma espécie de média ponderada entre t_{S_i} e t_{D_i} dada por

$$t_{G_i} = \text{sinal}\{y_i - \hat{\mu}_i\}[(1 - h_{ii})t_{D_i}^2 + (h_{ii})t_{S_i}^2]^{1/2}.$$

O **resíduo de Anscombe estudentizado** é dado por

$$t_{A_i} = \frac{\hat{\phi}^{1/2}[\psi(y_i) - \psi(\hat{\mu}_i)]}{\psi'(\hat{\mu}_i)\sqrt{\hat{V}_i(1 - h_{ii})}},$$

em que $\psi(.)$ é uma função que tem o objetivo de tornar a distribuição de t_{A_i} mais próxima da normal padrão. No caso dos MLGen, essa função é dada por $\psi(\mu) = \int_o^\mu [V(t)]^{-1/3} dt$, em que $V(.)$ é a função de variância. No caso dos modelos com resposta gama, por exemplo, $V(\mu_i) = \mu_i^2$ e $t_{A_i} = 3\hat{\phi}^{1/2}(y_i^{1/3} - \hat{\mu}_i^{1/3})/[(1 - h_{ii})^{1/2}\hat{\mu}_i^{1/3}]$.

Pontos discrepantes

Pontos discrepantes

Resíduo quantílico

Pontos discrepantes

Resíduo quantílico

- Discutido por Dunn & Smyth (1996).

Pontos discrepantes

Resíduo quantílico

- Discutido por Dunn & Smyth (1996).
- Para MLGen com resposta contínua é definido como

$$r_i^q = \Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\} \tag{1}$$

em que $\Phi(.)$ e $F(.)$ são a função distribuição acumulada da normal padrão e da variável resposta em estudo, respectivamente.

Resíduo quantílico

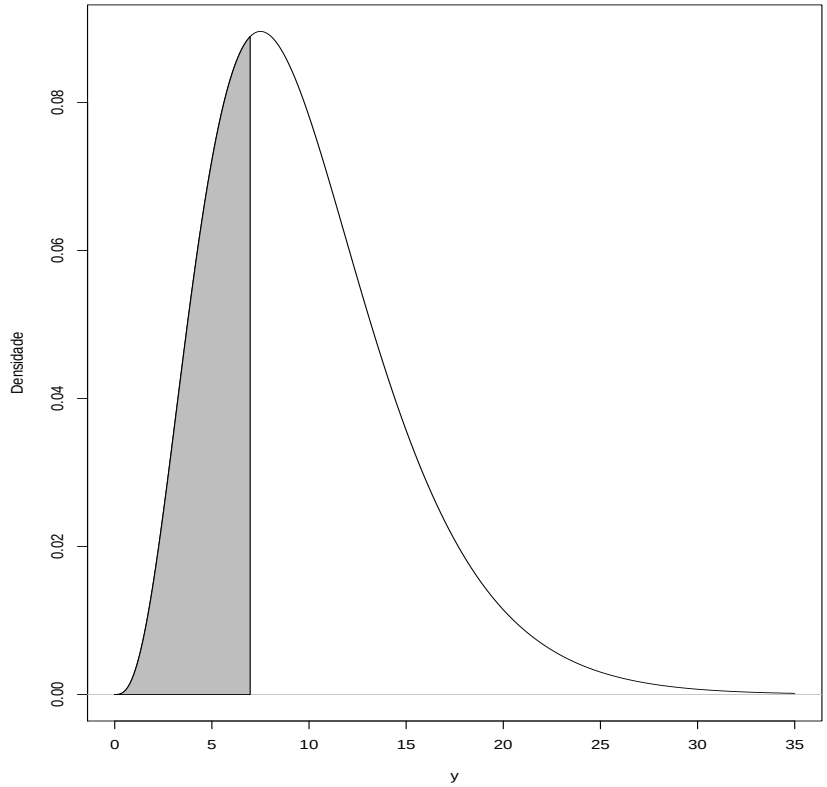


Figura: Distribuição gama com $\hat{\mu}_i = 10, \hat{\phi} = 4, y_i = 7$.

Resíduo quantílico

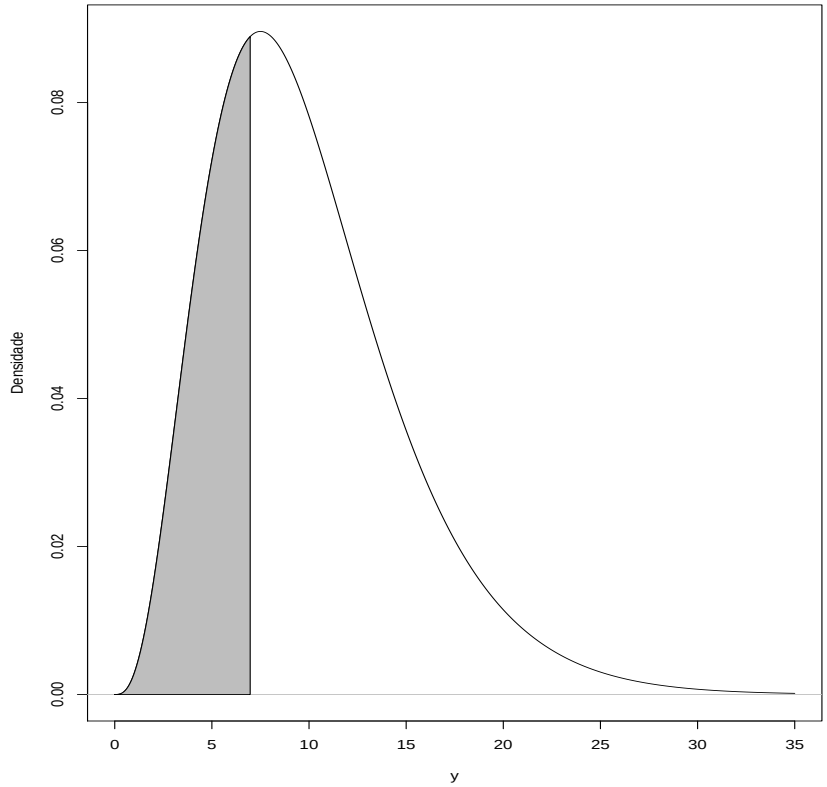


Figura: Distribuição gama com $\hat{\mu}_i = 10, \hat{\phi} = 4, y_i = 7$.

$$r_i^q = \Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\}$$

Resíduo quantílico

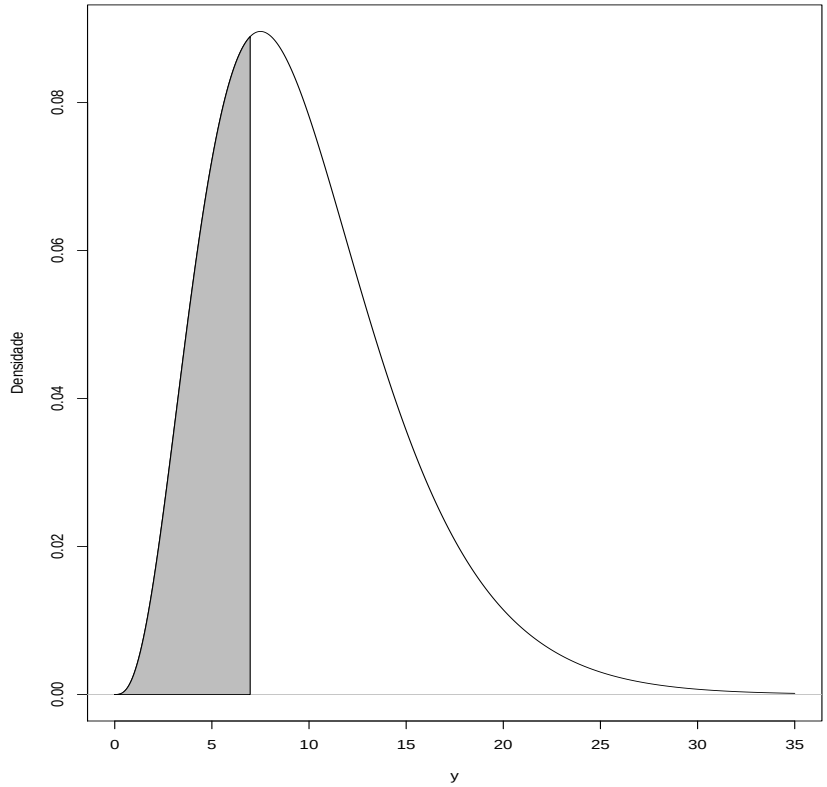


Figura: Distribuição gama com $\hat{\mu}_i = 10, \hat{\phi} = 4, y_i = 7$.

$$r_i^q = \Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\} = \Phi^{-1}\{F(7; 10, 4)\}$$

Resíduo quantílico

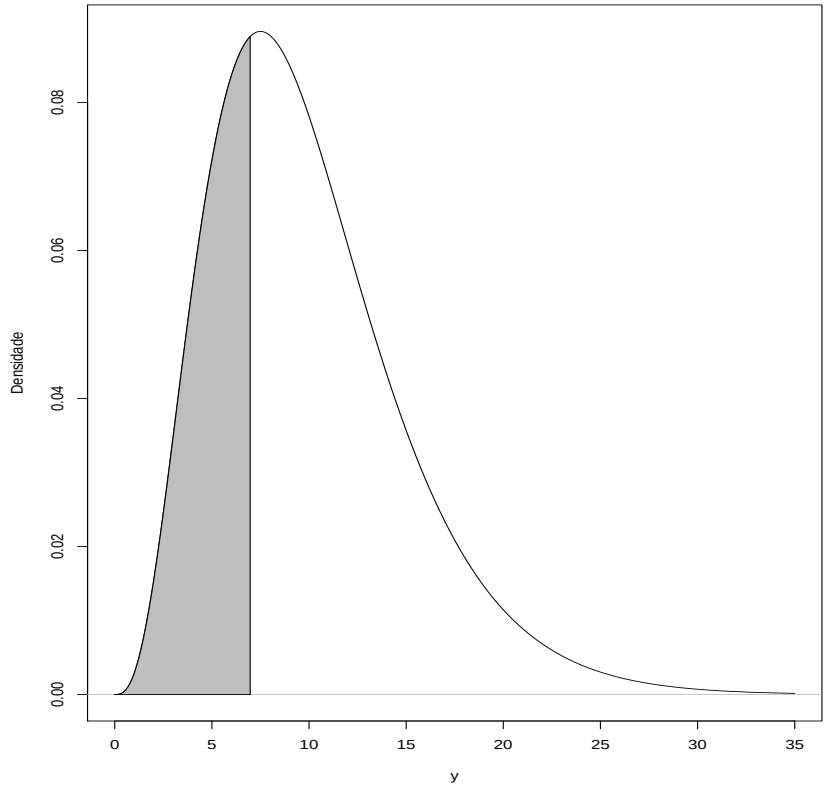


Figura: Distribuição gama com $\hat{\mu}_i = 10, \hat{\phi} = 4, y_i = 7$.

$$r_i^q = \Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\} = \Phi^{-1}\{F(7; 10, 4)\} = \Phi^{-1}\{0.3081\}$$

Resíduo quantílico

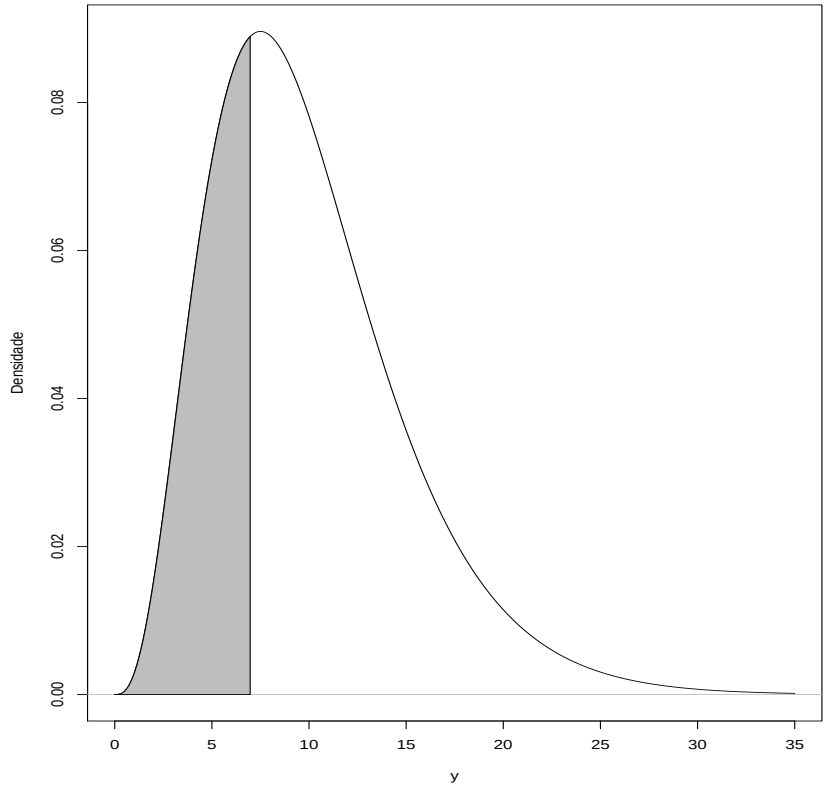


Figura: Distribuição gama com $\hat{\mu}_i = 10, \hat{\phi} = 4, y_i = 7$.

$$r_i^q = \Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\} = \Phi^{-1}\{F(7; 10, 4)\} = \Phi^{-1}\{0.3081\} = -0.5012$$

Resíduo quantílico

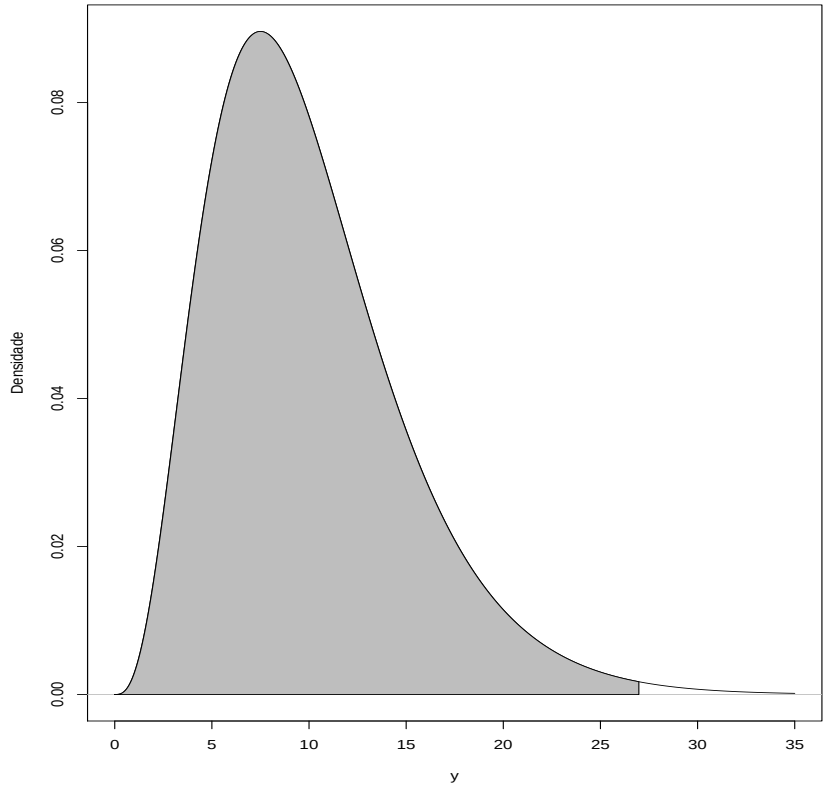


Figura: Distribuição gama com $\hat{\mu}_i = 10, \hat{\phi} = 4, y_i = 27$.

Resíduo quantílico

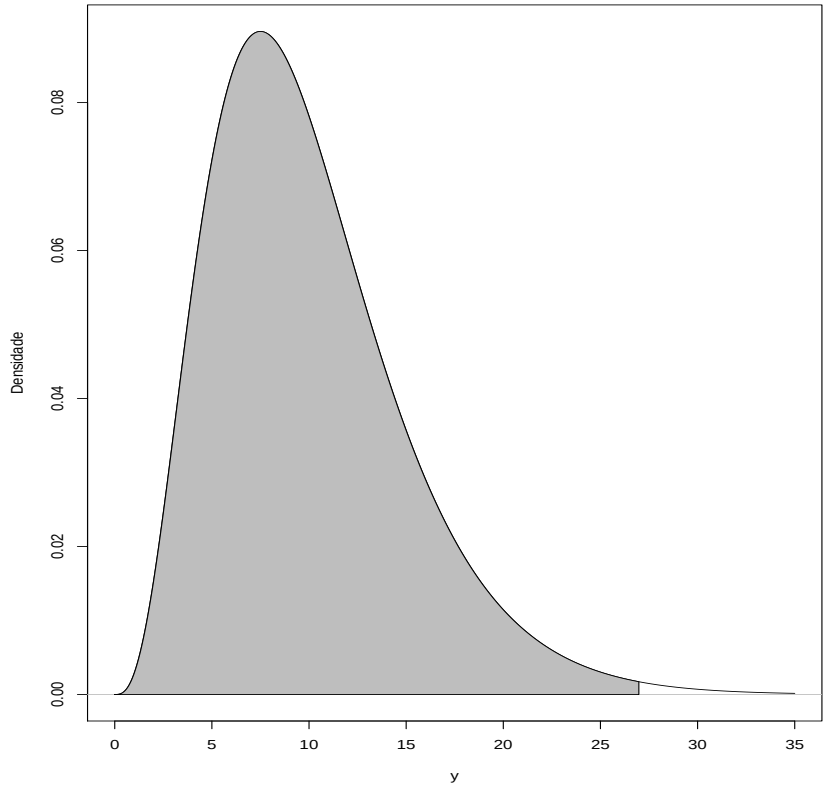


Figura: Distribuição gama com $\hat{\mu}_i = 10, \hat{\phi} = 4, y_i = 27$.

$$r_i^q = \Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\}$$

Resíduo quantílico

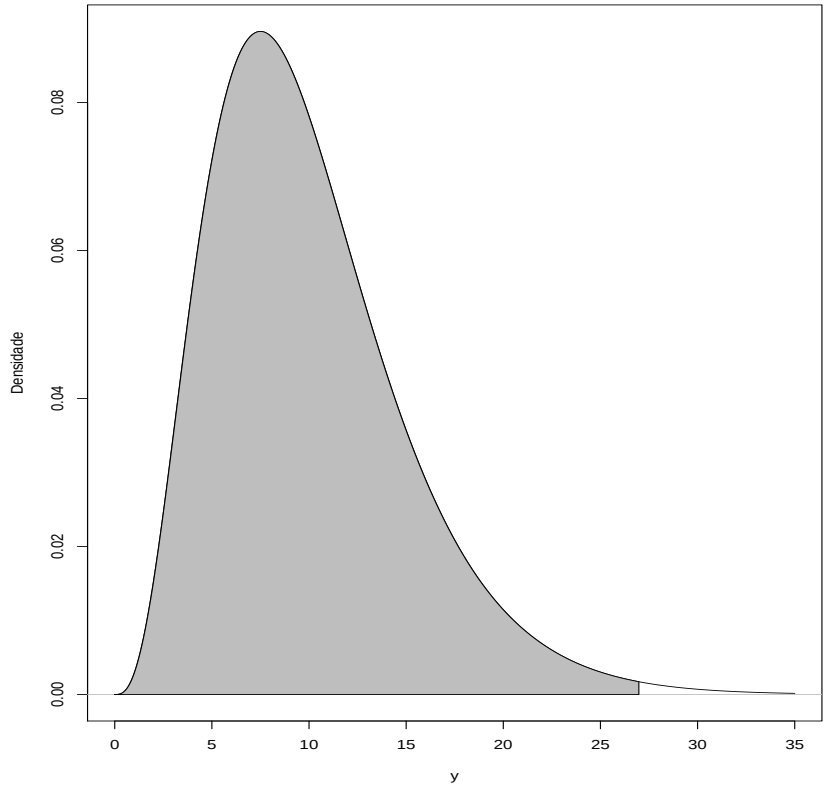


Figura: Distribuição gama com $\hat{\mu}_i = 10, \hat{\phi} = 4, y_i = 27$.

$$r_i^q = \Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\} = \Phi^{-1}\{F(27; 10, 4)\}$$

Resíduo quantílico

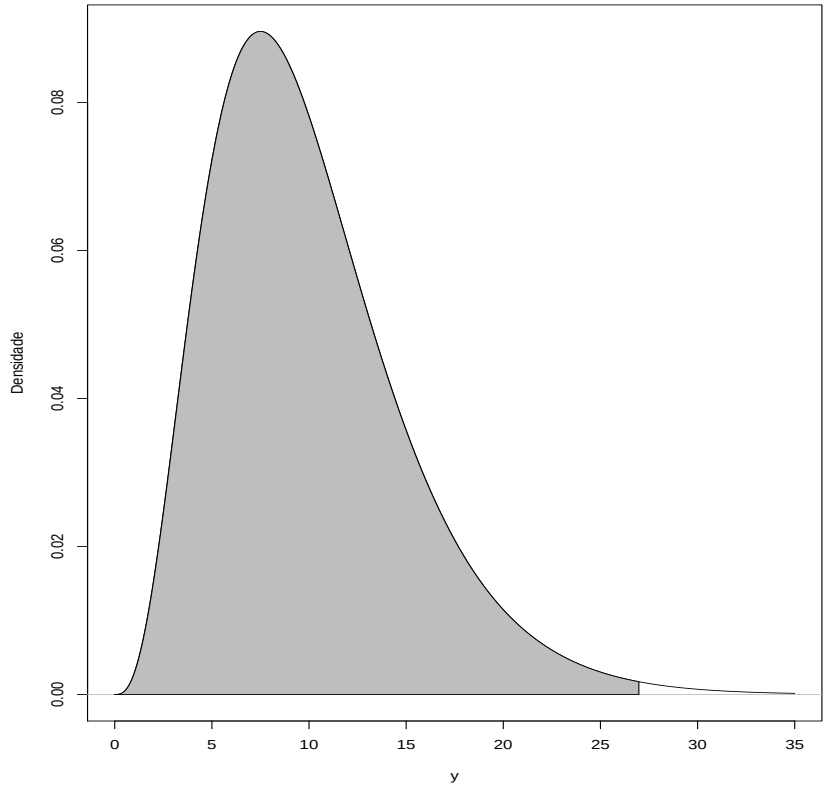


Figura: Distribuição gama com $\hat{\mu}_i = 10, \hat{\phi} = 4, y_i = 27$.

$$r_i^q = \Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\} = \Phi^{-1}\{F(27; 10, 4)\} = \Phi^{-1}\{0.9943\}$$

Resíduo quantílico

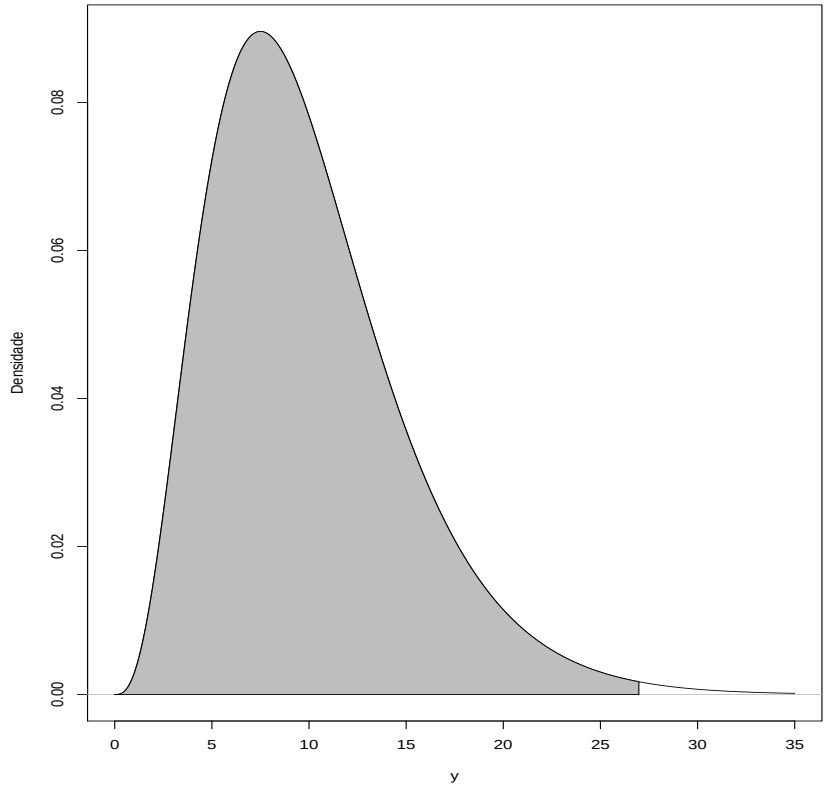


Figura: Distribuição gama com $\hat{\mu}_i = 10, \hat{\phi} = 4, y_i = 27$.

$$r_i^q = \Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\} = \Phi^{-1}\{F(27; 10, 4)\} = \Phi^{-1}\{0.9943\} = 2.5302$$

Vantagens do resíduo quantílico

Vantagens do resíduo quantílico

- Simples e intuitivo.

Vantagens do resíduo quantílico

- Simples e intuitivo.
- Expressão praticamente idêntica em diferentes modelos.

Vantagens do resíduo quantílico

- Simples e intuitivo.
- Expressão praticamente idêntica em diferentes modelos.
- Tem distribuição assintoticamente normal padrão.

Vantagens do resíduo quantílico

- Simples e intuitivo.
- Expressão praticamente idêntica em diferentes modelos.
- Tem distribuição assintoticamente normal padrão.
- Distribuição próxima da normal padrão em pequenas amostras.

Pontos discrepantes

Pontos discrepantes

Resíduo quantílico ajustado

Pontos discrepantes

Resíduo quantílico ajustado

- Proposto por Scudilio & Pereira (2020).

Pontos discrepantes

Resíduo quantílico ajustado

- Proposto por Scudilio & Pereira (2020).
- Para MLGen com resposta contínua é definido como

$$r_i^q = \frac{\Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\}}{\sqrt{1 - h_{ii}}} \tag{2}$$

em que $\Phi(.)$ e $F(.)$ são a função distribuição acumulada da normal padrão e da variável resposta em estudo, respectivamente.

Pontos discrepantes

Resíduo quantílico ajustado

- Proposto por Scudilio & Pereira (2020).
- Para MLGen com resposta contínua é definido como

$$r_i^q = \frac{\Phi^{-1}\{F(y_i; \hat{\mu}_i, \hat{\phi})\}}{\sqrt{1 - h_{ii}}} \tag{2}$$

em que $\Phi(.)$ e $F(.)$ são a função distribuição acumulada da normal padrão e da variável resposta em estudo, respectivamente.

- Tem distribuição mais próxima da normal padrão que os demais resíduos.

Resíduo quantílico aleatorizado

Resíduo quantílico aleatorizado

Resíduo quantílico aleatorizado

- Proposto por Dunn & Smyth (1996).

Resíduo quantílico aleatorizado

- Proposto por Dunn & Smyth (1996).
- Para MLGen com resposta discreta é definido como

$$r_i^q = \Phi^{-1}\{u_i\} \tag{3}$$

em que $u_i \sim U(a_i, b_i)$, sendo $a_i = \lim_{y \uparrow y_i} F(y, \hat{\mu}_i, \hat{\phi})$ e $b_i = F(y_i, \hat{\mu}_i, \hat{\phi})$.

Resíduo quantílico aleatorizado

- Proposto por Dunn & Smyth (1996).
- Para MLGen com resposta discreta é definido como

$$r_i^q = \Phi^{-1}\{u_i\} \tag{3}$$

em que $u_i \sim U(a_i, b_i)$, sendo $a_i = \lim_{y \uparrow y_i} F(y, \hat{\mu}_i, \hat{\phi})$ e $b_i = F(y_i, \hat{\mu}_i, \hat{\phi})$.

- Tem distribuição assintótica normal padrão.

Pontos influentes

Pontos influentes

A distância de Cook para os MLGen é definida como

Pontos influentes

A distância de Cook para os MLGen é definida como

$$LD_i = 2[(l(\hat{\beta}) - l(\hat{\beta}_{(i)})].$$

Pontos influentes

A distância de Cook para os MLGen é definida como

$$LD_i = 2[(l(\hat{\beta}) - l(\hat{\beta}_{(i)})].$$

No caso dos MLGen, não é possível obter uma forma analítica para $\hat{\beta}_{(i)}$ em função de $\hat{\beta}$.

Pontos influentes

A distância de Cook para os MLGen é definida como

$$LD_i = 2[(l(\hat{\beta}) - l(\hat{\beta}_{(i)})].$$

No caso dos MLGen, não é possível obter uma forma analítica para $\hat{\beta}_{(i)}$ em função de $\hat{\beta}$. Porém, fazendo-se uma expansão de Taylor de LD_i em torno de $\hat{\beta}$, obtém-se,

Pontos influentes

A distância de Cook para os MLGen é definida como

$$LD_i = 2[(l(\hat{\beta}) - l(\hat{\beta}_{(i)})].$$

No caso dos MLGen, não é possível obter uma forma analítica para $\hat{\beta}_{(i)}$ em função de $\hat{\beta}$. Porém, fazendo-se uma expansão de Taylor de LD_i em torno de $\hat{\beta}$, obtém-se, após algumas manipulações algébricas que

$$LD_i \approx \left[\frac{h_{ii}}{1 - h_{ii}}\right] t^2_{S_i}.$$

Pontos influentes

A distância de Cook para os MLGen é definida como

$$LD_i = 2[(l(\hat{\beta}) - l(\hat{\beta}_{(i)})].$$

No caso dos MLGen, não é possível obter uma forma analítica para $\hat{\beta}_{(i)}$ em função de $\hat{\beta}$. Porém, fazendo-se uma expansão de Taylor de LD_i em torno de $\hat{\beta}$, obtém-se, após algumas manipulações algébricas que

$$LD_i \approx \left[\frac{h_{ii}}{1 - h_{ii}}\right] t^2_{S_i}.$$

Portanto, de forma semelhante ao que ocorre nos MLGer, a influência de uma observação nos MLGen é função de seu leverage e de sua discrepância.

Gráficos de resíduos

Gráficos de resíduos

Gráficos que apresentam no eixo y, h_{ii}, algum dos resíduos ou LD_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos

Gráficos que apresentam no eixo y, h_{ii}, algum dos resíduos ou LD_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo.

Gráficos de resíduos

Gráficos que apresentam no eixo y, h_{ii}, algum dos resíduos ou LD_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo. As suposições dos MLGen são:

Gráficos de resíduos

Gráficos que apresentam no eixo y, h_{ii}, algum dos resíduos ou LD_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo. As suposições dos MLGen são:

- $y_i|x_i$ é independente de $y_j|x_j \; \forall \; i \neq j$.

Gráficos de resíduos

Gráficos que apresentam no eixo y, h_{ii}, algum dos resíduos ou LD_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo. As suposições dos MLGen são:

- $y_i|x_i$ é independente de $y_j|x_j \; \forall \; i \neq j$.
- ϕ não varia com as variáveis preditoras.

Gráficos de resíduos

Gráficos que apresentam no eixo y, h_{ii}, algum dos resíduos ou LD_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo. As suposições dos MLGen são:

- $y_i|x_i$ é independente de $y_j|x_j \; \forall \; i \neq j$.
- ϕ não varia com as variáveis preditoras.
- $y_i|x_i$ tem distribuição que pertence à FEL e a "correta" distribuição de probabilidade foi assumida para $y_i|x_i$.

Gráficos de resíduos

Gráficos que apresentam no eixo y, h_{ii}, algum dos resíduos ou LD_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo. As suposições dos MLGen são:

- $y_i|x_i$ é independente de $y_j|x_j \ \forall \ i \neq j$.
- ϕ não varia com as variáveis preditoras.
- $y_i|x_i$ tem distribuição que pertence à FEL e a "correta" distribuição de probabilidade foi assumida para $y_i|x_i$.
- A "correta" função de ligação foi escolhida.

Gráficos de resíduos

Gráficos que apresentam no eixo y, h_{ii}, algum dos resíduos ou LD_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo. As suposições dos MLGen são:

- $y_i|x_i$ é independente de $y_j|x_j \; \forall \; i \neq j$.
- ϕ não varia com as variáveis preditoras.
- $y_i|x_i$ tem distribuição que pertence à FEL e a "correta" distribuição de probabilidade foi assumida para $y_i|x_i$.
- A "correta" função de ligação foi escolhida.
- Todas as covariáveis foram incluídas "corretamente" no modelo.

Gráficos de resíduos

Gráficos de resíduos

Na sequência, falamos de 4 diferentes gráficos usualmente feitos para verificação das suposições do modelo.

Gráficos de resíduos

Na sequência, falamos de 4 diferentes gráficos usualmente feitos para verificação das suposições do modelo. Vamos descrevê-los considerando que será usado o resíduo t_{D_i}, mas qualquer outro resíduo pode ser usado.

Gráficos de resíduos

Na sequência, falamos de 4 diferentes gráficos usualmente feitos para verificação das suposições do modelo. Vamos descrevê-los considerando que será usado o resíduo t_{D_i}, mas qualquer outro resíduo pode ser usado.

- Gráfico de t_{D_i} contra o tempo, ordem das observações ou contra a ordem em que há suspeita de existência de dependência.

Gráficos de resíduos

Na sequência, falamos de 4 diferentes gráficos usualmente feitos para verificação das suposições do modelo. Vamos descrevê-los considerando que será usado o resíduo t_{D_i}, mas qualquer outro resíduo pode ser usado.

- Gráfico de t_{D_i} contra o tempo, ordem das observações ou contra a ordem em que há suspeita de existência de dependência.

Se a disposição dos pontos apresentar algum padrão, há suspeita de problemas com a suposição de independência entre diferentes observações da variável resposta dadas as variáveis preditoras.

Gráficos de resíduos

Gráficos de resíduos

- Gráfico de t_{D_i} contra o $\hat{\mu}_i$.

Gráficos de resíduos

- Gráfico de t_{D_i} contra o $\hat{\mu}_i$.

Se a disposição dos pontos apresentar algum padrão, vários resíduos forem bem grandes, ou a variabilidade de t_{D_i} parecer mudar a medida que variamos $\hat{\mu}_i$ pode haver problemas no ajuste do modelo em relação a um dos seguintes aspectos:

Gráficos de resíduos

- Gráfico de t_{D_i} contra o $\hat{\mu}_i$.

Se a disposição dos pontos apresentar algum padrão, vários resíduos forem bem grandes, ou a variabilidade de t_{D_i} parecer mudar a medida que variamos $\hat{\mu}_i$ pode haver problemas no ajuste do modelo em relação a um dos seguintes aspectos:

1. Escolha da função de ligação;

Gráficos de resíduos

- Gráfico de t_{D_i} contra o $\hat{\mu}_i$.

Se a disposição dos pontos apresentar algum padrão, vários resíduos forem bem grandes, ou a variabilidade de t_{D_i} parecer mudar a medida que variamos $\hat{\mu}_i$ pode haver problemas no ajuste do modelo em relação a um dos seguintes aspectos:

1. Escolha da função de ligação;
2. Forma de entrada de variáveis preditoras no modelo;

Gráficos de resíduos

- Gráfico de t_{D_i} contra o $\hat{\mu}_i$.

Se a disposição dos pontos apresentar algum padrão, vários resíduos forem bem grandes, ou a variabilidade de t_{D_i} parecer mudar a medida que variamos $\hat{\mu}_i$ pode haver problemas no ajuste do modelo em relação a um dos seguintes aspectos:

1. Escolha da função de ligação;
2. Forma de entrada de variáveis preditoras no modelo;
3. Escolha da distribuição da variável resposta;

Gráficos de resíduos

- Gráfico de t_{D_i} contra o $\hat{\mu}_i$.

Se a disposição dos pontos apresentar algum padrão, vários resíduos forem bem grandes, ou a variabilidade de t_{D_i} parecer mudar a medida que variamos $\hat{\mu}_i$ pode haver problemas no ajuste do modelo em relação a um dos seguintes aspectos:

1. Escolha da função de ligação;
2. Forma de entrada de variáveis preditoras no modelo;
3. Escolha da distribuição da variável resposta;
4. Suposição de ϕ constante pode não ser razoável.

Gráficos de resíduos

Gráficos de resíduos

- Gráfico de t_{D_i} contra variáveis preditoras presentes e ausentes do modelo.

Gráficos de resíduos

- Gráfico de t_{D_i} contra variáveis preditoras presentes e ausentes do modelo.

A observação de algum padrão sugere que a variável não foi incluída de forma adequada no modelo caso ela esteja presente ou que deveria ser incluída no modelo caso ela esteja ausente.

Gráficos de resíduos

Gráficos de resíduos

- Gráfico de probabilidade normal de t_{D_i} com envelope simulado.

Gráficos de resíduos

- Gráfico de probabilidade normal de t_{D_i} com envelope simulado.

Muitos pontos fora do envelope sugerem problemas do modelo em relação a um dos seguintes aspectos:

Gráficos de resíduos

- Gráfico de probabilidade normal de t_{D_i} com envelope simulado.

Muitos pontos fora do envelope sugerem problemas do modelo em relação a um dos seguintes aspectos:

1. Escolha da distribuição da variável resposta;

Gráficos de resíduos

- Gráfico de probabilidade normal de t_{D_i} com envelope simulado.

Muitos pontos fora do envelope sugerem problemas do modelo em relação a um dos seguintes aspectos:

1. Escolha da distribuição da variável resposta;
2. Escolha da função de ligação;

Gráficos de resíduos

- Gráfico de probabilidade normal de t_{D_i} com envelope simulado.

Muitos pontos fora do envelope sugerem problemas do modelo em relação a um dos seguintes aspectos:

1. Escolha da distribuição da variável resposta;
2. Escolha da função de ligação;
3. Forma de entrada de variáveis preditoras no modelo;

Gráficos de resíduos

- Gráfico de probabilidade normal de t_{D_i} com envelope simulado.

Muitos pontos fora do envelope sugerem problemas do modelo em relação a um dos seguintes aspectos:

1. Escolha da distribuição da variável resposta;
2. Escolha da função de ligação;
3. Forma de entrada de variáveis preditoras no modelo;
4. Suposição de ϕ constante pode não ser razoável.

Gráfico de probabilidade normal

Gráfico de probabilidade normal

- Para a obtenção do gráfico de probabilidade normal, considere t_i, para $i = 1, \ldots, n$, um resíduo qualquer. Colocamos no gráfico os pontos $(E(Z_{[i]}), t_{[i]})$, em que $[i]$ representa o i-ésimo menor valor e $E(Z_{[i]})$ se refere aos valores esperados das estatísticas de ordem da normal padrão. Temos que

$$E(Z_{[i]}) \cong \Phi^{-1}\left(\frac{i - 3/8}{n + 1/4}\right), \tag{4}$$

em que Φ é a função de distribuição acumulada da normal padrão.

Gráfico de probabilidade meio normal

Gráfico de probabilidade meio normal

- Para o gráfico meio normal probabilístico, tomamos o valor absoluto de t_i, como definido anteriormente, com $i = 1, \ldots, n$. Dispomos no gráfico os pontos $(E(|Z_{[i]}|), |t_{[i]}|)$, em que $[i]$ representa o i-ésimo menor valor e $E(|Z_{[i]}|)$ agora se refere aos valores esperados de $|Z_{[i]}|$, que obtemos fazendo

$$E(|Z_{[i]}|) \cong \Phi^{-1}\left(\frac{n+i+1/2}{2n+9/8}\right), \tag{5}$$

sendo também Φ a função de distribuição acumulada da normal padrão.

Gráficos de probabilidade

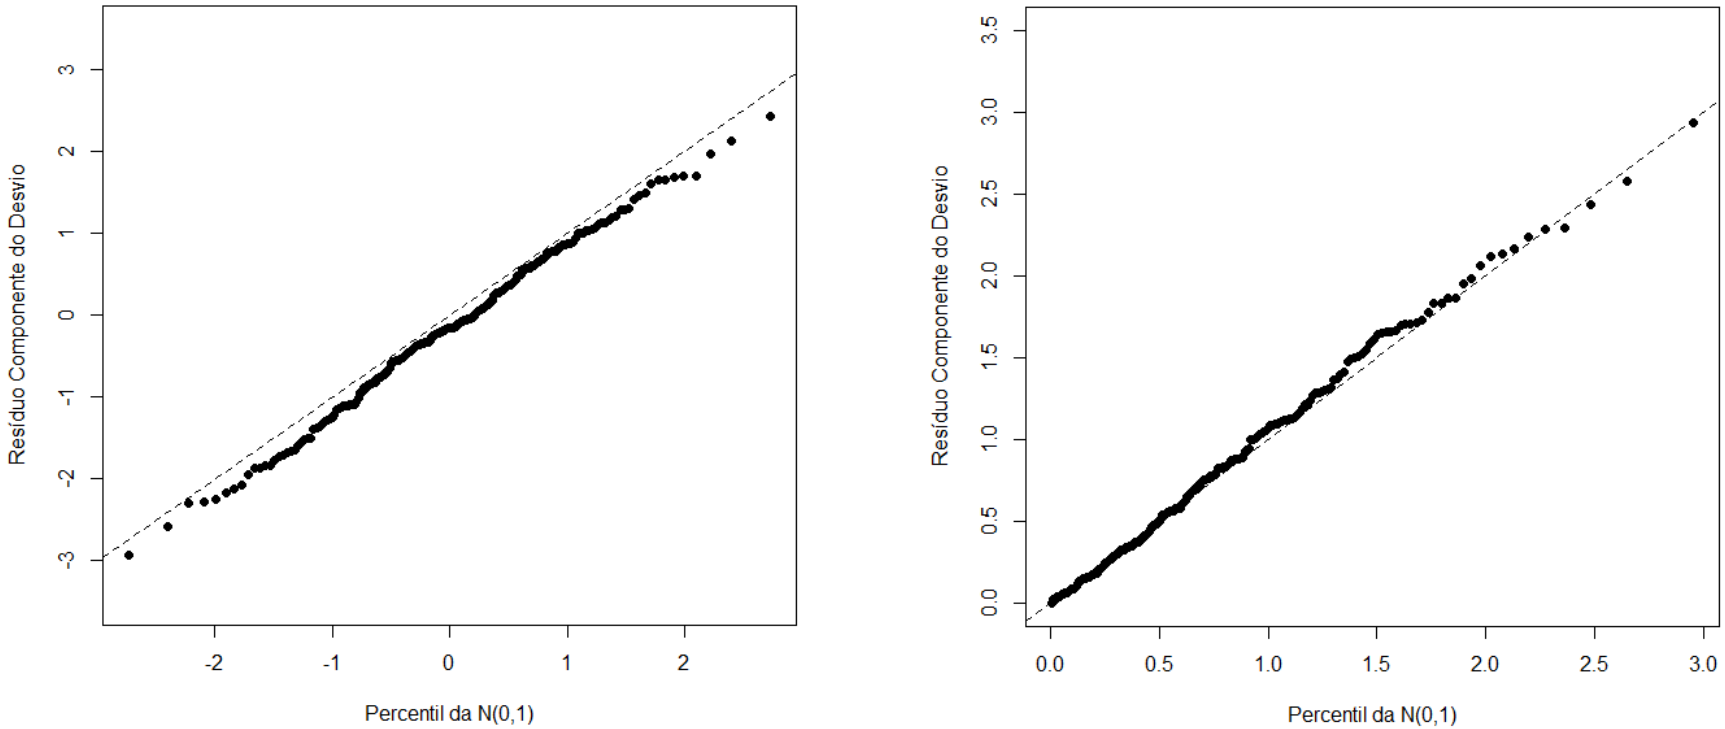


Figura: Gráficos de probabilidade normal (esquerda) e meio normal (direita) para dados gerados assumindo um modelo de regressão gama.

Métodos de construção do envelope

Métodos de construção do envelope

- Envelope simulado: Atkinson

Métodos de construção do envelope

- Envelope simulado: Atkinson

– Atkinson (1981) sugeriu a utilização de uma espécie de banda para a flutuação dos pontos, a qual denominou envelope.

Métodos de construção do envelope

- Envelope simulado: Atkinson

– Atkinson (1981) sugeriu a utilização de uma espécie de banda para a flutuação dos pontos, a qual denominou envelope. Este procedimento consiste em determinar os limites do envelope realizando os seguintes passos:

Métodos de construção do envelope

- Envelope simulado: Atkinson

– Atkinson (1981) sugeriu a utilização de uma espécie de banda para a flutuação dos pontos, a qual denominou envelope. Este procedimento consiste em determinar os limites do envelope realizando os seguintes passos:

1) Geramos n observações $y^*_{i,1}$ considerando que o modelo ajustado é verdadeiro e guardamos esses valores em $\mathbf{y}^*_1 = (y^*_{1,1}, \ldots, y^*_{n,1})^\top$.

Métodos de construção do envelope

- Envelope simulado: Atkinson

– Atkinson (1981) sugeriu a utilização de uma espécie de banda para a flutuação dos pontos, a qual denominou envelope. Este procedimento consiste em determinar os limites do envelope realizando os seguintes passos:

1) Geramos n observações $y^*_{i,1}$ considerando que o modelo ajustado é verdadeiro e guardamos esses valores em $\mathbf{y}^*_1 = (y^*_{1,1}, \ldots, y^*_{n,1})^\top$.

2) Ajustamos $\mathbf{y}^*_1$ contra a matriz de variáveis preditoras $\mathbf{X}$ e obtemos os resíduos $t_{i,1}$, para $i = 1, 2, \ldots, n$.

Envelope simulado: Atkinson

Envelope simulado: Atkinson

3) Repetimos os passos 1) e 2) m vezes.

Envelope simulado: Atkinson

3) Repetimos os passos 1) e 2) m vezes. Logo, teremos $t_{i,j}$, para $i = 1, 2, \ldots, n$ e $j = 1, 2, \ldots, m$, conforme apresentado na Tabela 1.

Tabela: Resíduos originais e simulados.

Resíduo original	Réplica 1	Réplica 2	⋯	Réplica $m-1$	Réplica m
t_1	$t_{1,1}$	$t_{1,2}$	$\cdots$	$t_{1,m-1}$	$t_{1,m}$
t_2	$t_{2,1}$	$t_{2,2}$	$\cdots$	$t_{2,m-1}$	$t_{2,m}$
t_3	$t_{3,1}$	$t_{3,2}$	$\cdots$	$t_{3,m-1}$	$t_{3,m}$
t_4	$t_{4,1}$	$t_{4,2}$	$\cdots$	$t_{4,m-1}$	$t_{4,m}$
t_5	$t_{5,1}$	$t_{5,2}$	$\cdots$	$t_{5,m-1}$	$t_{5,m}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
t_{n-1}	$t_{n-1,1}$	$t_{n-1,2}$	$\cdots$	$t_{n-1,m-1}$	$t_{n-1,m}$
t_n	$t_{n,1}$	$t_{n,2}$	$\cdots$	$t_{n,m-1}$	$t_{n,m}$

Envelope simulado: Atkinson

Envelope simulado: Atkinson

4) Colocamos cada grupo de n resíduos em ordem crescente, obtendo assim $t_{[i],j}$, para $i = 1, 2, \ldots, n$ e $j = 1, 2, \ldots, m$, conforme apresentamos na Tabela 2.

Envelope simulado: Atkinson

4) Colocamos cada grupo de n resíduos em ordem crescente, obtendo assim $t_{[i],j}$, para $i = 1, 2, \ldots, n$ e $j = 1, 2, \ldots, m$, conforme apresentamos na Tabela 2.

Tabela: Resíduos originais e simulados ordenados de forma crescente.

4) $\Downarrow$	$\Downarrow$	$\Downarrow$		$\Downarrow$	$\Downarrow$
Resíduo original	Réplica 1	Réplica 2	$\cdots$	Réplica $m-1$	Réplica m
$t_{[1]}$	$t_{[1],1}$	$t_{[1],2}$	$\cdots$	$t_{[1],m-1}$	$t_{[1],m}$
$t_{[2]}$	$t_{[2],1}$	$t_{[2],2}$	$\cdots$	$t_{[2],m-1}$	$t_{[2],m}$
$t_{[3]}$	$t_{[3],1}$	$t_{[3],2}$	$\cdots$	$t_{[3],m-1}$	$t_{[3],m}$
$t_{[4]}$	$t_{[4],1}$	$t_{[4],2}$	$\cdots$	$t_{[4],m-1}$	$t_{[4],m}$
$t_{[5]}$	$t_{[5],1}$	$t_{[5],2}$	$\cdots$	$t_{[5],m-1}$	$t_{[5],m}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
$t_{[n-1]}$	$t_{[n-1],1}$	$t_{[n-1],2}$	$\cdots$	$t_{[n-1],m-1}$	$t_{[n-1],m}$
$t_{[n]}$	$t_{[n],1}$	$t_{[n],2}$	$\cdots$	$t_{[n],m-1}$	$t_{[n],m}$

Envelope simulado: Atkinson

Envelope simulado: Atkinson

5) Obtemos os limites $t_{[i],[1]} = \min_j(t_{[i],j})$ e $t_{[i],[m]} = \max_j(t_{[i],j})$.

Envelope simulado: Atkinson

5) Obtemos os limites $t_{[i],[1]} = \min_j(t_{[i],j})$ e $t_{[i],[m]} = \max_j(t_{[i],j})$. Assim, os limites correspondentes a $t_{[i]}$ serão dados por $t_{[i],[1]}$ e $t_{[i],[m]}$, como presente na Tabela 3 (sugestão de Atkinson: m = 19).

Envelope simulado: Atkinson

5) Obtemos os limites $t_{[i],[1]} = \min_j(t_{[i],j})$ e $t_{[i],[m]} = \max_j(t_{[i],j})$. Assim, os limites correspondentes a $t_{[i]}$ serão dados por $t_{[i],[1]}$ e $t_{[i],[m]}$, como presente na Tabela 3 (sugestão de Atkinson: m = 19).

Tabela: Obtendo os limites correspondentes de cada resíduo.

	Réplica 1	Réplica 2	...	Réplica $m-1$	Réplica m	Mínimo	Resíduo Original	Máximo
5) $\Rightarrow$	$t_{[1],1}$	$t_{[1],2}$	$\cdots$	$t_{[1],m-1}$	$t_{[1],m}$	$t_{[1],[1]}$	$t_{[1]}$	$t_{[1],[m]}$
$\Rightarrow$	$t_{[2],1}$	$t_{[2],2}$	$\cdots$	$t_{[2],m-1}$	$t_{[2],m}$	$t_{[2],[1]}$	$t_{[2]}$	$t_{[2],[m]}$
$\Rightarrow$	$t_{[3],1}$	$t_{[3],2}$	$\cdots$	$t_{[3],m-1}$	$t_{[3],m}$	$t_{[3],[1]}$	$t_{[3]}$	$t_{[3],[m]}$
$\Rightarrow$	$t_{[4],1}$	$t_{[4],2}$	$\cdots$	$t_{[4],m-1}$	$t_{[4],m}$	$t_{[4],[1]}$	$t_{[4]}$	$t_{[4],[m]}$
$\Rightarrow$	$t_{[5],1}$	$t_{[5],2}$	$\cdots$	$t_{[5],m-1}$	$t_{[5],m}$	$t_{[5],[1]}$	$t_{[5]}$	$t_{[5],[m]}$
	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$\Rightarrow$	$t_{[n-1],1}$	$t_{[n-1],2}$	$\cdots$	$t_{[n-1],m-1}$	$t_{[n-1],m}$	$t_{[n-1],[1]}$	$t_{[n-1]}$	$t_{[n-1],[m]}$
$\Rightarrow$	$t_{[n],1}$	$t_{[n],2}$	$\cdots$	$t_{[n],m-1}$	$t_{[n],m}$	$t_{[n],[1]}$	$t_{[n]}$	$t_{[n],[m]}$

Envelope simulado: Everitt/Paula

Envelope simulado: Everitt/Paula

- Envelope simulado: Everitt/Paula

Envelope simulado: Everitt/Paula

- Envelope simulado: Everitt/Paula
  - Podemos gerar um m consideravelmente maior e usar como limites inferiores e superiores não o mínimo e o máximo, mas valores tais que produzam uma espécie de banda com $\gamma \times 100\%$ de confiança.

Envelope simulado: Everitt/Paula

- Envelope simulado: Everitt/Paula

– Podemos gerar um m consideravelmente maior e usar como limites inferiores e superiores não o mínimo e o máximo, mas valores tais que produzam uma espécie de banda com $\gamma \times 100\%$ de confiança.

– Everitt (1994) sugere utilizar $m = 100$ e determinar as bandas do envelope atribuindo ao limite inferior e ao limite superior os vetores $t_{[i],[5]}$ e $t_{[i],[95]}$, respectivamente, para $i = 1, \ldots, n$.

Envelope simulado: Everitt/Paula

- Envelope simulado: Everitt/Paula

– Podemos gerar um m consideravelmente maior e usar como limites inferiores e superiores não o mínimo e o máximo, mas valores tais que produzam uma espécie de banda com $\gamma \times 100\%$ de confiança.

– Everitt (1994) sugere utilizar $m = 100$ e determinar as bandas do envelope atribuindo ao limite inferior e ao limite superior os vetores $t_{[i],[5]}$ e $t_{[i],[95]}$, respectivamente, para $i = 1, \ldots, n$.

– Posteriormente, Paula (2013) propõe uma modificação, definindo o limite inferior como a média dos vetores $t_{[i],[2]}$ e $t_{[i],[3]}$, e o limite superior como a média dos vetores $t_{[i],[97]}$ e $t_{[i],[98]}$, para $i = 1, \ldots, n$.

Envelope simulado

Observações

Envelope simulado

Observações

- Se apenas a observação com maior valor de resíduo (em módulo) estiver fora do envelope, é um indício de que este ponto é um outlier.

Envelope simulado

Observações

- Se apenas a observação com maior valor de resíduo (em módulo) estiver fora do envelope, é um indício de que este ponto é um outlier. Muitos pontos fora do envelope sugerem problemas com alguma suposição do modelo.

Envelope simulado

Observações

- Se apenas a observação com maior valor de resíduo (em módulo) estiver fora do envelope, é um indício de que este ponto é um outlier. Muitos pontos fora do envelope sugerem problemas com alguma suposição do modelo.
- O procedimento aqui descrito pode ser usado em diversas diferentes classes de modelos de regressão.

Envelope simulado

Observações

- Se apenas a observação com maior valor de resíduo (em módulo) estiver fora do envelope, é um indício de que este ponto é um outlier. Muitos pontos fora do envelope sugerem problemas com alguma suposição do modelo.

- O procedimento aqui descrito pode ser usado em diversas diferentes classes de modelos de regressão. No caso do MLGer, com $y \sim N_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$, o envelope pode ser gerado de forma mais simples (ver Paula (2013)).

Exemplo de envelope

Exemplo de envelope

- Método de rejeição de modelo proposto por Fernandes (2019).

Exemplo de envelope

- Método de rejeição de modelo proposto por Fernandes (2019).

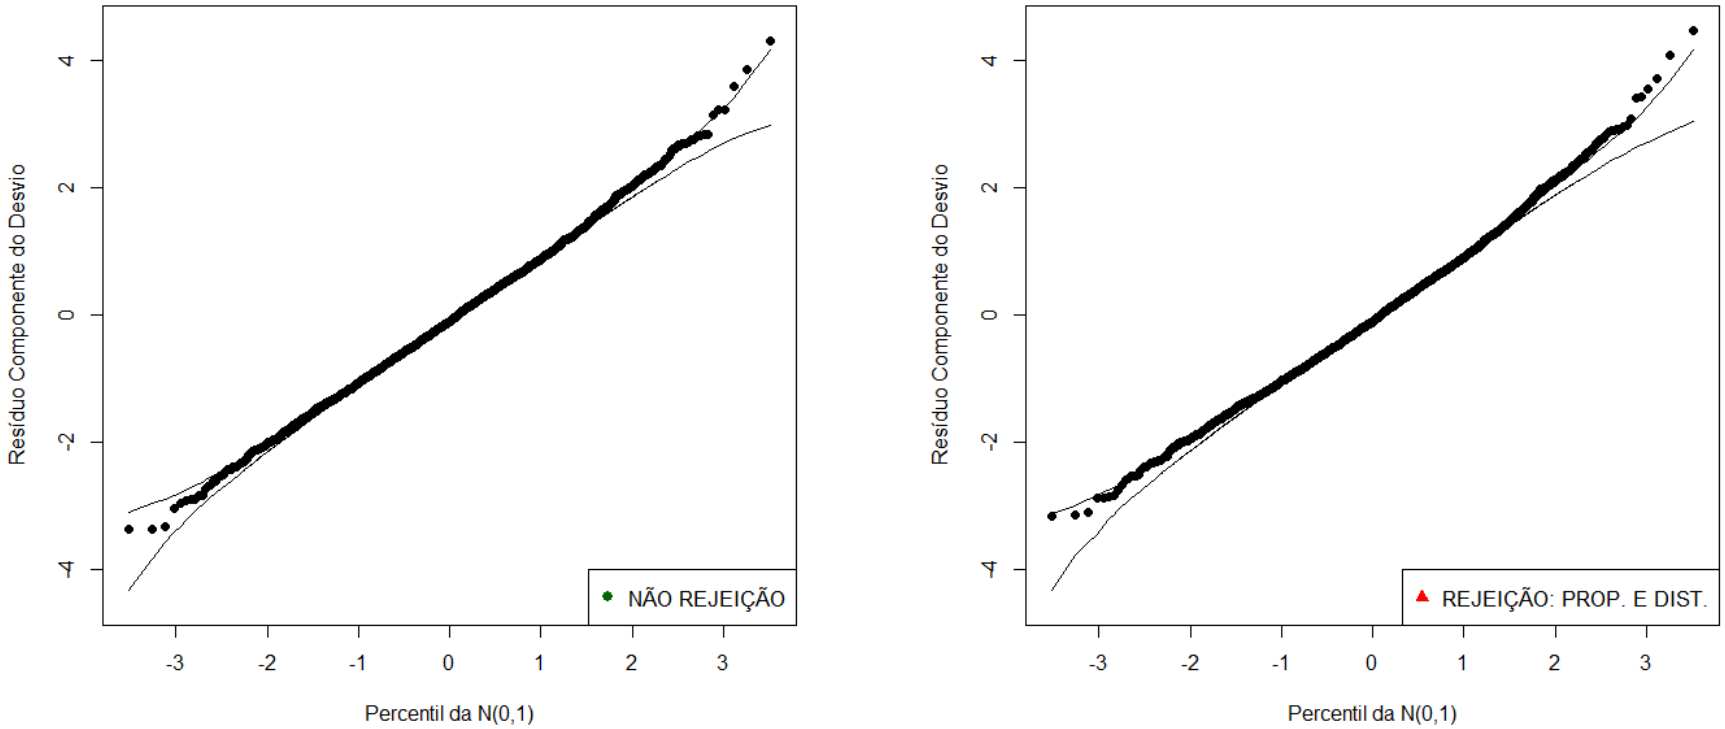


Figura: Método de rejeição proposto aplicado ao gráfico normal probabilístico utilizando a distribuição normal inversa (esquerda) e a distribuição gama (direita).

References

Dunn, P. K. & Smyth, G. K. (1996), 'Randomized quantile residuals', *Journal of Computational and Graphical Statistics* **5**(3), 236–244.

Scudilio, J. & Pereira, G. H. (2020), 'Adjusted quantile residual for generalized linear models', *Computational Statistics* **35**(1), 399–421.