Modelos lineares generalizados

Seleção de modelos

Introdução

Introdução

O objetivo da seleção de modelos é selecionar o modelo que produz o melhor ajuste dentro de um conjunto de modelos candidatos.

Introdução

O objetivo da seleção de modelos é selecionar o modelo que produz o melhor ajuste dentro de um conjunto de modelos candidatos. A seleção de modelos envolve dois diferentes aspectos:

Introdução

O objetivo da seleção de modelos é selecionar o modelo que produz o melhor ajuste dentro de um conjunto de modelos candidatos. A seleção de modelos envolve dois diferentes aspectos:

- Medidas para escolher um entre 2 ou mais modelos candidatos.

Introdução

O objetivo da seleção de modelos é selecionar o modelo que produz o melhor ajuste dentro de um conjunto de modelos candidatos. A seleção de modelos envolve dois diferentes aspectos:

- Medidas para escolher um entre 2 ou mais modelos candidatos.
- Métodos automatizados de selecionar um modelo.

Introdução

O objetivo da seleção de modelos é selecionar o modelo que produz o melhor ajuste dentro de um conjunto de modelos candidatos. A seleção de modelos envolve dois diferentes aspectos:

- Medidas para escolher um entre 2 ou mais modelos candidatos.
- Métodos automatizados de selecionar um modelo.

Os métodos e medidas discutidos nesta aula valem tanto para os MLGen quanto para o MLGer.

Medidas de comparação de modelos

Medidas de comparação de modelos

Se os 2 modelos são encaixados, ou seja, se um deles é um caso particular do outro,

Medidas de comparação de modelos

Se os 2 modelos são encaixados, ou seja, se um deles é um caso particular do outro, a forma mais simples de decidir por um desses modelos é realizar um teste de hipóteses:

Medidas de comparação de modelos

Se os 2 modelos são encaixados, ou seja, se um deles é um caso particular do outro, a forma mais simples de decidir por um desses modelos é realizar um teste de hipóteses: teste F no caso do MLGer

Medidas de comparação de modelos

Se os 2 modelos são encaixados, ou seja, se um deles é um caso particular do outro, a forma mais simples de decidir por um desses modelos é realizar um teste de hipóteses: teste F no caso do MLGer e teste da razão de verossilhanças, escore, Wald ou gradiente no caso dos MLgen.

Medidas de comparação de modelos

Se os 2 modelos são encaixados, ou seja, se um deles é um caso particular do outro, a forma mais simples de decidir por um desses modelos é realizar um teste de hipóteses: teste F no caso do MLGer e teste da razão de verossilhanças, escore, Wald ou gradiente no caso dos MLgen.

Se os 2 modelos não são encaixados, os testes mencionados não podem ser usados.

Medidas de comparação de modelos

Se os 2 modelos são encaixados, ou seja, se um deles é um caso particular do outro, a forma mais simples de decidir por um desses modelos é realizar um teste de hipóteses: teste F no caso do MLGer e teste da razão de verossilhanças, escore, Wald ou gradiente no caso dos MLgen.

Se os 2 modelos não são encaixados, os testes mencionados não podem ser usados. Assim, são utilizada medidas para comparação de modelos candidatos,

Medidas de comparação de modelos

Se os 2 modelos são encaixados, ou seja, se um deles é um caso particular do outro, a forma mais simples de decidir por um desses modelos é realizar um teste de hipóteses: teste F no caso do MLGer e teste da razão de verossilhanças, escore, Wald ou gradiente no caso dos MLgen.

Se os 2 modelos não são encaixados, os testes mencionados não podem ser usados. Assim, são utilizada medidas para comparação de modelos candidatos, sendo bem comum o uso do critério da informação de Akaike (AIC) e suas variações.

Critério da informação de Akaike (AIC)

Critério da informação de Akaike (AIC)

Akaike mostrou que o logaritmo da função de verossimilhança aplicado no EMV é um estimador viesado da esperança do logaritmo da função de verossimilhança.

Critério da informação de Akaike (AIC)

Akaike mostrou que o logaritmo da função de verossimilhança aplicado no EMV é um estimador viesado da esperança do logaritmo da função de verossimilhança. Assim, o autor derivou o AIC como uma correção aproximada assintótica do logaritmo da função de verossimilhança (multiplicado por -2).

Critério da informação de Akaike (AIC)

Akaike mostrou que o logaritmo da função de verossimilhança aplicado no EMV é um estimador viesado da esperança do logaritmo da função de verossimilhança. Assim, o autor derivou o AIC como uma correção aproximada assintótica do logaritmo da função de verossimilhança (multiplicado por -2). O AIC é dado por

$$\text{AIC} = -2l(\hat{\gamma}) + 2k^{\star},$$

Critério da informação de Akaike (AIC)

Akaike mostrou que o logaritmo da função de verossimilhança aplicado no EMV é um estimador viesado da esperança do logaritmo da função de verossimilhança. Assim, o autor derivou o AIC como uma correção aproximada assintótica do logaritmo da função de verossimilhança (multiplicado por -2). O AIC é dado por

$$\text{AIC} = -2l(\hat{\gamma}) + 2k^{\star},$$

em que $k^{\star}$ é número de parâmetros do modelo.

Critério da informação de Akaike (AIC)

Akaike mostrou que o logaritmo da função de verossimilhança aplicado no EMV é um estimador viesado da esperança do logaritmo da função de verossimilhança. Assim, o autor derivou o AIC como uma correção aproximada assintótica do logaritmo da função de verossimilhança (multiplicado por -2). O AIC é dado por

$$\text{AIC} = -2l(\hat{\gamma}) + 2k^{\star},$$

em que $k^{\star}$ é número de parâmetros do modelo. Na notação que estamos usando $k^{\star} = k + 2$.

Critério da informação de Akaike (AIC)

Akaike mostrou que o logaritmo da função de verossimilhança aplicado no EMV é um estimador viesado da esperança do logaritmo da função de verossimilhança. Assim, o autor derivou o AIC como uma correção aproximada assintótica do logaritmo da função de verossimilhança (multiplicado por -2). O AIC é dado por

$$\text{AIC} = -2l(\hat{\gamma}) + 2k^{\star},$$

em que $k^{\star}$ é número de parâmetros do modelo. Na notação que estamos usando $k^{\star} = k + 2$.

O melhor modelo segundo esse critério é aquele que tem o menor AIC e $2k^{\star}$ é um fator de penalização pela inclusão de mais variáveis preditoras.

Relação entre Q_{RV} e AIC

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis,

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3)$$

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}}$$

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$$

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})] - 2$$

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})] - 2 = Q_{RV} - 2.$$

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})] - 2 = Q_{RV} - 2.$$

Logo, escolho o modelo reduzido se $Q_{RV} - 2 < 0$

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})] - 2 = Q_{RV} - 2.$$

Logo, escolho o modelo reduzido se $Q_{RV} - 2 < 0 \Rightarrow Q_{RV} < 2$.

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})] - 2 = Q_{RV} - 2.$$

Logo, escolho o modelo reduzido se $Q_{RV} - 2 < 0 \Rightarrow Q_{RV} < 2$.

Como nesse caso, sob H_0 e assintoticamente, $Q_{RV} \sim \chi^2_1$,

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})] - 2 = Q_{RV} - 2.$$

Logo, escolho o modelo reduzido se $Q_{RV} - 2 < 0 \Rightarrow Q_{RV} < 2$.

Como nesse caso, sob H_0 e assintoticamente, $Q_{RV} \sim \chi^2_1$, então no caso de uma única variável de diferença, usar o AIC é equivalente a fazer um TH com estatística Q_{RV} e nível de significância de

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})] - 2 = Q_{RV} - 2.$$

Logo, escolho o modelo reduzido se $Q_{RV} - 2 < 0 \Rightarrow Q_{RV} < 2$.

Como nesse caso, sob H_0 e assintoticamente, $Q_{RV} \sim \chi^2_1$, então no caso de uma única variável de diferença, usar o AIC é equivalente a fazer um TH com estatística Q_{RV} e nível de significância de

$$P(\chi^2_1 \geq 2)$$

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})] - 2 = Q_{RV} - 2.$$

Logo, escolho o modelo reduzido se $Q_{RV} - 2 < 0 \Rightarrow Q_{RV} < 2$.

Como nesse caso, sob H_0 e assintoticamente, $Q_{RV} \sim \chi^2_1$, então no caso de uma única variável de diferença, usar o AIC é equivalente a fazer um TH com estatística Q_{RV} e nível de significância de

$$P(\chi^2_1 \geq 2) = 0{,}157.$$

Relação entre Q_{RV} e AIC

Vimos que $Q_{RV} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})]$.

Supondo que um modelo completo tem uma variável a mais que um reduzido, que por sua vez tem k variáveis, então

$$\text{AIC}_{\text{COMP}} = -2l_C(\hat{\gamma}) + 2(k+3) \text{ e } \text{AIC}_{\text{RED}} = -2l_R(\tilde{\gamma}) + 2(k+2),$$

$$\text{AIC}_{\text{RED}} - \text{AIC}_{\text{COMP}} = 2[l_C(\hat{\gamma}) - l_R(\tilde{\gamma})] - 2 = Q_{RV} - 2.$$

Logo, escolho o modelo reduzido se $Q_{RV} - 2 < 0 \Rightarrow Q_{RV} < 2$.

Como nesse caso, sob H_0 e assintoticamente, $Q_{RV} \sim \chi^2_1$, então no caso de uma única variável de diferença, usar o AIC é equivalente a fazer um TH com estatística Q_{RV} e nível de significância de

$$P(\chi^2_1 \geq 2) = 0{,}157.$$

Outras medidas

Outras medidas

Diversas variações do AIC foram propostas com o objetivo de, supondo que o modelo correto está entre os modelos candidatos, aumentar a proporção de vezes em que o modelo correto é escolhido.

Outras medidas

Diversas variações do AIC foram propostas com o objetivo de, supondo que o modelo correto está entre os modelos candidatos, aumentar a proporção de vezes em que o modelo correto é escolhido. Algumas delas são citadas a seguir.

Outras medidas

Diversas variações do AIC foram propostas com o objetivo de, supondo que o modelo correto está entre os modelos candidatos, aumentar a proporção de vezes em que o modelo correto é escolhido. Algumas delas são citadas a seguir.

O BIC (Bayesian Information Criterion) ou SIC (Schwarz Information Criterion)

Outras medidas

Diversas variações do AIC foram propostas com o objetivo de, supondo que o modelo correto está entre os modelos candidatos, aumentar a proporção de vezes em que o modelo correto é escolhido. Algumas delas são citadas a seguir.

O BIC (Bayesian Information Criterion) ou SIC (Schwarz Information Criterion) é dado por

$$\text{BIC} = -2l(\hat{\gamma}) + k^{\star} \log(n).$$

Outras medidas

Diversas variações do AIC foram propostas com o objetivo de, supondo que o modelo correto está entre os modelos candidatos, aumentar a proporção de vezes em que o modelo correto é escolhido. Algumas delas são citadas a seguir.

O BIC (Bayesian Information Criterion) ou SIC (Schwarz Information Criterion) é dado por

$$\text{BIC} = -2l(\hat{\gamma}) + k^{\star} \log(n).$$

O HQC (Hannan-Quinn Information Criterion)

Outras medidas

Diversas variações do AIC foram propostas com o objetivo de, supondo que o modelo correto está entre os modelos candidatos, aumentar a proporção de vezes em que o modelo correto é escolhido. Algumas delas são citadas a seguir.

O BIC (Bayesian Information Criterion) ou SIC (Schwarz Information Criterion) é dado por

$$\text{BIC} = -2l(\hat{\gamma}) + k^{\star}\log(n).$$

O HQC (Hannan-Quinn Information Criterion) é dado por

$$\text{HQC} = -2l(\hat{\gamma}) + 2k^{\star}\log[\log(n)].$$

Outras medidas

Outras medidas

Todos os critérios mencionados tem melhor performance em grandes amostras.

Outras medidas

Todos os critérios mencionados tem melhor performance em grandes amostras. Assim, há critérios desenvolvidos especificamente para pequenas amostras como, por exemplo, o AICc que é dado por

$$\text{AICc} = -2l(\hat{\gamma}) + 2k^{\star}\left(\frac{n}{n-k^{\star}-1}\right).$$

Outras medidas

Todos os critérios mencionados tem melhor performance em grandes amostras. Assim, há critérios desenvolvidos especificamente para pequenas amostras como, por exemplo, o AICc que é dado por

$$\text{AICc} = -2l(\hat{\gamma}) + 2k^{\star}\left(\frac{n}{n-k^{\star}-1}\right).$$

Para pequenas amostras, também já foram propostos diversos métodos baseados em bootstrap.

Outras medidas

Todos os critérios mencionados tem melhor performance em grandes amostras. Assim, há critérios desenvolvidos especificamente para pequenas amostras como, por exemplo, o AICc que é dado por

$$\text{AICc} = -2l(\hat{\gamma}) + 2k^{\star}\left(\frac{n}{n-k^{\star}-1}\right).$$

Para pequenas amostras, também já foram propostos diversos métodos baseados em bootstrap.

Estudos de simulação sugerem que nenhum critério é sempre o melhor e assim os critérios mais simples são os mais utilizados.

Métodos automatizados de selecionar um modelo

Métodos automatizados de selecionar um modelo

Considerando que temos m variáveis preditoras disponíveis,

Métodos automatizados de selecionar um modelo

Considerando que temos m variáveis preditoras disponíveis, o número de modelos possíveis

Métodos automatizados de selecionar um modelo

Considerando que temos m variáveis preditoras disponíveis, o número de modelos possíveis (fixada a forma de entrada de cada covariável, a distribuição de probabilidade da resposta e a função de ligação)

Métodos automatizados de selecionar um modelo

Considerando que temos m variáveis preditoras disponíveis, o número de modelos possíveis (fixada a forma de entrada de cada covariável, a distribuição de probabilidade da resposta e a função de ligação) é 2^m.

Métodos automatizados de selecionar um modelo

Considerando que temos m variáveis preditoras disponíveis, o número de modelos possíveis (fixada a forma de entrada de cada covariável, a distribuição de probabilidade da resposta e a função de ligação) é 2^m.

Métodos automatizados de selecionar um modelo

Considerando que temos m variáveis preditoras disponíveis, o número de modelos possíveis (fixada a forma de entrada de cada covariável, a distribuição de probabilidade da resposta e a função de ligação) é 2^m.

Se $m = 30$, por exemplo, isso significa que temos mais de 1 bilhão de possíveis modelos.

Métodos automatizados de selecionar um modelo

Considerando que temos m variáveis preditoras disponíveis, o número de modelos possíveis (fixada a forma de entrada de cada covariável, a distribuição de probabilidade da resposta e a função de ligação) é 2^m.

Se $m = 30$, por exemplo, isso significa que temos mais de 1 bilhão de possíveis modelos.

Dessa forma, é inviável ajustar todos os possíveis modelos para escolher o melhor segundo alguma medida.

Métodos automatizados de selecionar um modelo

Considerando que temos m variáveis preditoras disponíveis, o número de modelos possíveis (fixada a forma de entrada de cada covariável, a distribuição de probabilidade da resposta e a função de ligação) é 2^m.

Se $m = 30$, por exemplo, isso significa que temos mais de 1 bilhão de possíveis modelos.

Dessa forma, é inviável ajustar todos os possíveis modelos para escolher o melhor segundo alguma medida.

Assim, uma possível solução é utilizar algum método em que apenas parte dos 2^m modelos são ajustados,

Métodos automatizados de selecionar um modelo

Considerando que temos m variáveis preditoras disponíveis, o número de modelos possíveis (fixada a forma de entrada de cada covariável, a distribuição de probabilidade da resposta e a função de ligação) é 2^m.

Se $m = 30$, por exemplo, isso significa que temos mais de 1 bilhão de possíveis modelos.

Dessa forma, é inviável ajustar todos os possíveis modelos para escolher o melhor segundo alguma medida.

Assim, uma possível solução é utilizar algum método em que apenas parte dos 2^m modelos são ajustados, preferencialmente sem grande prejuízo do processo de seleção de variáveis.

Métodos automatizados de selecionar um modelo

Métodos automatizados de selecionar um modelo

Os métodos automatizados mais tradicionais de selecionar um modelo são o stepwise e suas variações.

Métodos automatizados de selecionar um modelo

Os métodos automatizados mais tradicionais de selecionar um modelo são o stepwise e suas variações.

Nestes métodos, iniciamos ou um modelo com um intercepto ou com um modelo contendo todas as variáveis preditoras disponíveis.

Métodos automatizados de selecionar um modelo

Os métodos automatizados mais tradicionais de selecionar um modelo são o stepwise e suas variações.

Nestes métodos, iniciamos ou um modelo com um intercepto ou com um modelo contendo todas as variáveis preditoras disponíveis. Em seguida, variáveis são incluídas ou excluídas, uma de cada vez, no modelo.

Métodos automatizados de selecionar um modelo

Os métodos automatizados mais tradicionais de selecionar um modelo são o stepwise e suas variações.

Nestes métodos, iniciamos ou um modelo com um intercepto ou com um modelo contendo todas as variáveis preditoras disponíveis. Em seguida, variáveis são incluídas ou excluídas, uma de cada vez, no modelo. O procedimento finaliza quando, segundo o critério que está sendo considerado, a inclusão ou exclusão de uma variável não melhora o modelo.

Métodos automatizados de selecionar um modelo

Os métodos automatizados mais tradicionais de selecionar um modelo são o stepwise e suas variações.

Nestes métodos, iniciamos ou um modelo com um intercepto ou com um modelo contendo todas as variáveis preditoras disponíveis. Em seguida, variáveis são incluídas ou excluídas, uma de cada vez, no modelo. O procedimento finaliza quando, segundo o critério que está sendo considerado, a inclusão ou exclusão de uma variável não melhora o modelo.

As principais variações do método são:

- Forward;

Métodos automatizados de selecionar um modelo

Os métodos automatizados mais tradicionais de selecionar um modelo são o stepwise e suas variações.

Nestes métodos, iniciamos ou um modelo com um intercepto ou com um modelo contendo todas as variáveis preditoras disponíveis. Em seguida, variáveis são incluídas ou excluídas, uma de cada vez, no modelo. O procedimento finaliza quando, segundo o critério que está sendo considerado, a inclusão ou exclusão de uma variável não melhora o modelo.

As principais variações do método são:

- Forward;
- Backward;

Métodos automatizados de selecionar um modelo

Os métodos automatizados mais tradicionais de selecionar um modelo são o stepwise e suas variações.

Nestes métodos, iniciamos ou um modelo com um intercepto ou com um modelo contendo todas as variáveis preditoras disponíveis. Em seguida, variáveis são incluídas ou excluídas, uma de cada vez, no modelo. O procedimento finaliza quando, segundo o critério que está sendo considerado, a inclusão ou exclusão de uma variável não melhora o modelo.

As principais variações do método são:

- Forward;
- Backward;
- Forward stpewise;

Métodos automatizados de selecionar um modelo

Os métodos automatizados mais tradicionais de selecionar um modelo são o stepwise e suas variações.

Nestes métodos, iniciamos ou um modelo com um intercepto ou com um modelo contendo todas as variáveis preditoras disponíveis. Em seguida, variáveis são incluídas ou excluídas, uma de cada vez, no modelo. O procedimento finaliza quando, segundo o critério que está sendo considerado, a inclusão ou exclusão de uma variável não melhora o modelo.

As principais variações do método são:

- Forward;
- Backward;
- Forward stpewise;
- Backward stepwise.

Métodos automatizados de selecionar um modelo

Os métodos automatizados mais tradicionais de selecionar um modelo são o stepwise e suas variações.

Nestes métodos, iniciamos ou um modelo com um intercepto ou com um modelo contendo todas as variáveis preditoras disponíveis. Em seguida, variáveis são incluídas ou excluídas, uma de cada vez, no modelo. O procedimento finaliza quando, segundo o critério que está sendo considerado, a inclusão ou exclusão de uma variável não melhora o modelo.

As principais variações do método são:

- Forward;
- Backward;
- Forward stpewise;
- Backward stepwise.

Métodos automatizados de selecionar um modelo

Métodos automatizados de selecionar um modelo

Os métodos automatizados tradicionais de selecionar um modelo não são consistentes, ou seja, eles não selecionam o modelo correto com probabilidade 1 mesmo em amostras grandes.

Métodos automatizados de selecionar um modelo

Os métodos automatizados tradicionais de selecionar um modelo não são consistentes, ou seja, eles não selecionam o modelo correto com probabilidade 1 mesmo em amostras grandes.

Quando o foco é preditivo, o método lasso e suas variações apresentam geralmente poder preditivo superior que os métodos tradicionais.

Métodos automatizados de selecionar um modelo

Os métodos automatizados tradicionais de selecionar um modelo não são consistentes, ou seja, eles não selecionam o modelo correto com probabilidade 1 mesmo em amostras grandes.

Quando o foco é preditivo, o método lasso e suas variações apresentam geralmente poder preditivo superior que os métodos tradicionais.

Em MLGen, o lasso seleciona covariáveis e estima os parâmetros do modelo minimizando

$$-l(\hat{\boldsymbol{\beta}}, \hat{\phi}) + \lambda \sum_{j=1}^{k} |\hat{\beta}_j|.$$