Modelos lineares generalizados

Modelos para dados de contagem

Introdução

Introdução

Na classe dos MLGen, a distribuição utilizada quando a variável resposta é uma contagem é a distribuição de Poisson.

Introdução

Na classe dos MLGen, a distribuição utilizada quando a variável resposta é uma contagem é a distribuição de Poisson.

Se supormos que um dos parâmetros da binomial negativa é conhecido, então a binomial negativa pertence à família exponencial linear.

Introdução

Na classe dos MLGen, a distribuição utilizada quando a variável resposta é uma contagem é a distribuição de Poisson.

Se supormos que um dos parâmetros da binomial negativa é conhecido, então a binomial negativa pertence à família exponencial linear.

Porém, a distribuição binomial negativa, em geral, é útil em modelos de regressão quando assumimos que os 2 parâmetros são desconhecidos.

Distribuição de Poisson

Distribuição de Poisson

Função de probabilidade da Poisson no formato da FEL:

$$f(y;\mu) = exp\{y \log \mu - \mu - \log y!\},$$

Distribuição de Poisson

Função de probabilidade da Poisson no formato da FEL:

$$f(y;\mu) = exp\{y \log \mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log \mu$, $b(\theta) = e^{\theta}$ e $c(y, \phi) = -\log y!$.

Distribuição de Poisson

Função de probabilidade da Poisson no formato da FEL:

$$f(y;\mu) = exp\{y \log \mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log \mu$, $b(\theta) = e^{\theta}$ e $c(y, \phi) = -\log y!$. Assim, $E(y) = \mu$ e

Distribuição de Poisson

Função de probabilidade da Poisson no formato da FEL:

$$f(y;\mu) = exp\{y \log \mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log \mu$, $b(\theta) = e^{\theta}$ e $c(y, \phi) = -\log y!$. Assim, $E(y) = \mu$ e $Var(y) = \mu$.

Distribuição de Poisson

Função de probabilidade da Poisson no formato da FEL:

$$f(y;\mu) = exp\{y \log \mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log \mu$, $b(\theta) = e^{\theta}$ e $c(y, \phi) = -\log y!$. Assim, $E(y) = \mu$ e $Var(y) = \mu$.

Pode-se provar ainda que $ASSIM(y) = \mu^{-1/2}$ e $CURT(y) = 3 + \mu^{-1}$.

Distribuição de Poisson

Função de probabilidade da Poisson no formato da FEL:

$$f(y;\mu) = exp\{y \log \mu - \mu - \log y!\},$$

que está na forma da FEL, com $\phi = 1$, $\theta = \log \mu$, $b(\theta) = e^{\theta}$ e $c(y, \phi) = -\log y!$. Assim, $E(y) = \mu$ e $Var(y) = \mu$.

Pode-se provar ainda que $ASSIM(y) = \mu^{-1/2}$ e $CURT(y) = 3 + \mu^{-1}$.

Desta forma, para μ grande, a distribuição de Poisson pode ser aproximada pela normal com média e variância igual a μ.

MLGen com resposta Poisson

MLGen com resposta Poisson

Se a distribuição de Poisson for adequada para a variável resposta, o MLGer não deve ser usado mesmo que as médias sejam altas.

MLGen com resposta Poisson

Se a distribuição de Poisson for adequada para a variável resposta, o MLGer não deve ser usado mesmo que as médias sejam altas. O motivo é que na Poisson a variância é igual a média, enquanto no MLGer, a variância é constante.

MLGen com resposta Poisson

Se a distribuição de Poisson for adequada para a variável resposta, o MLGer não deve ser usado mesmo que as médias sejam altas. O motivo é que na Poisson a variância é igual a média, enquanto no MLGer, a variância é constante.

A função de ligação canônica para o modelo com a resposta Poisson é a função de ligação logarítmica.

MLGen com resposta Poisson

Se a distribuição de Poisson for adequada para a variável resposta, o MLGer não deve ser usado mesmo que as médias sejam altas. O motivo é que na Poisson a variância é igual a média, enquanto no MLGer, a variância é constante.

A função de ligação canônica para o modelo com a resposta Poisson é a função de ligação logarítmica. Ela é interessante também por produzir valores ajustados positivos

MLGen com resposta Poisson

Se a distribuição de Poisson for adequada para a variável resposta, o MLGer não deve ser usado mesmo que as médias sejam altas. O motivo é que na Poisson a variância é igual a média, enquanto no MLGer, a variância é constante.

A função de ligação canônica para o modelo com a resposta Poisson é a função de ligação logarítmica. Ela é interessante também por produzir valores ajustados positivos e por levar a parâmetros facilmente interpretáveis.

MLGen com resposta Poisson

Se a distribuição de Poisson for adequada para a variável resposta, o MLGer não deve ser usado mesmo que as médias sejam altas. O motivo é que na Poisson a variância é igual a média, enquanto no MLGer, a variância é constante.

A função de ligação canônica para o modelo com a resposta Poisson é a função de ligação logarítmica. Ela é interessante também por produzir valores ajustados positivos e por levar a parâmetros facilmente interpretáveis.

Outras funções de ligação que são usualmente utilizadas são a identidade e a raiz quadrada.

Offset

Offset

Em muitas situações as unidades experimentais

Offset

Em muitas situações as unidades experimentais ou conjunto de unidades experimentais

Offset

Em muitas situações as unidades experimentais ou conjunto de unidades experimentais não são acompanhadas ao longo do mesmo tempo.

Offset

Em muitas situações as unidades experimentais ou conjunto de unidades experimentais não são acompanhadas ao longo do mesmo tempo. Nesse caso, não é razoável admitir que $y_i \sim Poisson(\mu_i)$,

Offset

Em muitas situações as unidades experimentais ou conjunto de unidades experimentais não são acompanhadas ao longo do mesmo tempo. Nesse caso, não é razoável admitir que $y_i \sim Poisson(\mu_i)$, sendo μ_i uma função que não leva em consideração o tempo de acompanhamento t_i.

Offset

Em muitas situações as unidades experimentais ou conjunto de unidades experimentais não são acompanhadas ao longo do mesmo tempo. Nesse caso, não é razoável admitir que $y_i \sim Poisson(\mu_i)$, sendo μ_i uma função que não leva em consideração o tempo de acompanhamento t_i.

Assim, é mais razoável assumir que $y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a $E(y_i)$ por unidade de tempo.

Offset

Em muitas situações as unidades experimentais ou conjunto de unidades experimentais não são acompanhadas ao longo do mesmo tempo. Nesse caso, não é razoável admitir que $y_i \sim Poisson(\mu_i)$, sendo μ_i uma função que não leva em consideração o tempo de acompanhamento t_i.

Assim, é mais razoável assumir que $y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a $E(y_i)$ por unidade de tempo. Obviamente que é λ_i que varia em função das variáveis preditoras e não $E(y_i) = \lambda_i t_i$.

Offset

Em muitas situações as unidades experimentais ou conjunto de unidades experimentais não são acompanhadas ao longo do mesmo tempo. Nesse caso, não é razoável admitir que $y_i \sim Poisson(\mu_i)$, sendo μ_i uma função que não leva em consideração o tempo de acompanhamento t_i.

Assim, é mais razoável assumir que $y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a $E(y_i)$ por unidade de tempo. Obviamente que é λ_i que varia em função das variáveis preditoras e não $E(y_i) = \lambda_i t_i$.

Logo, podemos considerar por exemplo

Offset

Em muitas situações as unidades experimentais ou conjunto de unidades experimentais não são acompanhadas ao longo do mesmo tempo. Nesse caso, não é razoável admitir que $y_i \sim Poisson(\mu_i)$, sendo μ_i uma função que não leva em consideração o tempo de acompanhamento t_i.

Assim, é mais razoável assumir que $y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a $E(y_i)$ por unidade de tempo. Obviamente que é λ_i que varia em função das variáveis preditoras e não $E(y_i) = \lambda_i t_i$.

Logo, podemos considerar por exemplo

$$\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Offset

$y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a $E(y_i)$ por unidade de tempo e t_i é o tempo de acompanhamento da unidade experimental i. Nesse caso podemos considerar por exemplo

$$\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Offset

$y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a E(y_i) por unidade de tempo e t_i é o tempo de acompanhamento da unidade experimental i. Nesse caso podemos considerar por exemplo

$$\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Porém, estamos observando os y_i que são estimadores dos μ_i.

Offset

$y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a E(y_i) por unidade de tempo e t_i é o tempo de acompanhamento da unidade experimental i. Nesse caso podemos considerar por exemplo

$$\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Porém, estamos observando os y_i que são estimadores dos μ_i. Então fazemos

$$\log(\lambda_i) + log(t_i) = log(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta}$$

Offset

$y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a E(y_i) por unidade de tempo e t_i é o tempo de acompanhamento da unidade experimental i. Nesse caso podemos considerar por exemplo

$$\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Porém, estamos observando os y_i que são estimadores dos μ_i. Então fazemos

$$\log(\lambda_i) + log(t_i) = log(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta} \Rightarrow \log(\lambda_i t_i)$$

Offset

$y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a E(y_i) por unidade de tempo e t_i é o tempo de acompanhamento da unidade experimental i. Nesse caso podemos considerar por exemplo

$$\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Porém, estamos observando os y_i que são estimadores dos μ_i. Então fazemos

$$\log(\lambda_i) + log(t_i) = log(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta} \Rightarrow \log(\lambda_i t_i) = \log(\mu_i)$$

Offset

$y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a E(y_i) por unidade de tempo e t_i é o tempo de acompanhamento da unidade experimental i. Nesse caso podemos considerar por exemplo

$$\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Porém, estamos observando os y_i que são estimadores dos μ_i. Então fazemos

$$\log(\lambda_i) + log(t_i) = log(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta} \Rightarrow \log(\lambda_i t_i) = \log(\mu_i) = log(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Offset

$y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a E(y_i) por unidade de tempo e t_i é o tempo de acompanhamento da unidade experimental i. Nesse caso podemos considerar por exemplo

$$\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Porém, estamos observando os y_i que são estimadores dos μ_i. Então fazemos

$$\log(\lambda_i) + log(t_i) = log(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta} \Rightarrow \log(\lambda_i t_i) = \log(\mu_i) = log(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Assim, $log(t_i)$ é um offset,

Offset

$y_i \sim Poisson(\lambda_i t_i)$, em que λ_i é a E(y_i) por unidade de tempo e t_i é o tempo de acompanhamento da unidade experimental i. Nesse caso podemos considerar por exemplo

$$\log(\lambda_i) = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Porém, estamos observando os y_i que são estimadores dos μ_i. Então fazemos

$$\log(\lambda_i) + log(t_i) = log(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta} \Rightarrow \log(\lambda_i t_i) = \log(\mu_i) = log(t_i) + \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Assim, $log(t_i)$ é um offset, ou seja, funciona como uma variável preditora com parâmetro associado conhecido (no caso igual a 1).

Distribuição binomial negativa

Distribuição binomial negativa

No uso da binomial negativa como alternativa a Poisson para a distribuição da variável resposta, consideramos ambos os parâmetros da binomial negativa desconhecidos.

Distribuição binomial negativa

No uso da binomial negativa como alternativa a Poisson para a distribuição da variável resposta, consideramos ambos os parâmetros da binomial negativa desconhecidos.

Nesse caso, fazendo uma reparametrização da binomial negativa, conveniente para o uso em modelos de regressão,

Distribuição binomial negativa

No uso da binomial negativa como alternativa a Poisson para a distribuição da variável resposta, consideramos ambos os parâmetros da binomial negativa desconhecidos.

Nesse caso, fazendo uma reparametrização da binomial negativa, conveniente para o uso em modelos de regressão, obtemos

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

Distribuição binomial negativa

No uso da binomial negativa como alternativa a Poisson para a distribuição da variável resposta, consideramos ambos os parâmetros da binomial negativa desconhecidos.

Nesse caso, fazendo uma reparametrização da binomial negativa, conveniente para o uso em modelos de regressão, obtemos

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e

Distribuição binomial negativa

No uso da binomial negativa como alternativa a Poisson para a distribuição da variável resposta, consideramos ambos os parâmetros da binomial negativa desconhecidos.

Nesse caso, fazendo uma reparametrização da binomial negativa, conveniente para o uso em modelos de regressão, obtemos

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

Distribuição binomial negativa

No uso da binomial negativa como alternativa a Poisson para a distribuição da variável resposta, consideramos ambos os parâmetros da binomial negativa desconhecidos.

Nesse caso, fazendo uma reparametrização da binomial negativa, conveniente para o uso em modelos de regressão, obtemos

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

Note que $f(y;\mu,\phi)$ não pode ser escrito na forma da família exponencial linear.

Distribuição binomial negativa

No uso da binomial negativa como alternativa a Poisson para a distribuição da variável resposta, consideramos ambos os parâmetros da binomial negativa desconhecidos.

Nesse caso, fazendo uma reparametrização da binomial negativa, conveniente para o uso em modelos de regressão, obtemos

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

Note que $f(y;\mu,\phi)$ não pode ser escrito na forma da família exponencial linear. Assim, o modelo com resposta binomial negativa considerando ϕ desconhecido, não pertence à classe dos MLGen.

Distribuição binomial negativa

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

Distribuição binomial negativa

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e

Distribuição binomial negativa

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

Distribuição binomial negativa

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

O modelo de regressão com resposta binomial negativa não é um MLGen,

Distribuição binomial negativa

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

O modelo de regressão com resposta binomial negativa não é um MLGen, mas é uma interessante alternativa ao MLGen com resposta Poisson quando há sobredispersão,

Distribuição binomial negativa

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

O modelo de regressão com resposta binomial negativa não é um MLGen, mas é uma interessante alternativa ao MLGen com resposta Poisson quando há sobredispersão, ou seja, quando $\mathrm{Var}(y_i) > \mu_i$.

Distribuição binomial negativa

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

O modelo de regressão com resposta binomial negativa não é um MLGen, mas é uma interessante alternativa ao MLGen com resposta Poisson quando há sobredispersão, ou seja, quando $\mathrm{Var}(y_i) > \mu_i$.

Enquanto no último modelo assumimos que $\mathrm{Var}(y_i) = \mu_i$,

Distribuição binomial negativa

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

O modelo de regressão com resposta binomial negativa não é um MLGen, mas é uma interessante alternativa ao MLGen com resposta Poisson quando há sobredispersão, ou seja, quando $\mathrm{Var}(y_i) > \mu_i$. Enquanto no último modelo assumimos que $\mathrm{Var}(y_i) = \mu_i$, no modelo de regressão com resposta binomial negativa, assumimos que $\mathrm{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Distribuição binomial negativa

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

O modelo de regressão com resposta binomial negativa não é um MLGen, mas é uma interessante alternativa ao MLGen com resposta Poisson quando há sobredispersão, ou seja, quando $\mathrm{Var}(y_i) > \mu_i$. Enquanto no último modelo assumimos que $\mathrm{Var}(y_i) = \mu_i$, no modelo de regressão com resposta binomial negativa, assumimos que $\mathrm{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assumimos não somente variância maior no modelo com resposta binomial negativa,

Distribuição binomial negativa

$$f(y;\mu,\phi) = \frac{\Gamma(\phi+y)}{\Gamma(y+1)\Gamma(\phi)}\left(\frac{\mu}{\mu+\phi}\right)^{y}\left(\frac{\phi}{\mu+\phi}\right)^{\phi}.$$

em que $\mathrm{E}(y) = \mu$ e $\mathrm{Var}(y) = \mu + \mu^2/\phi$.

O modelo de regressão com resposta binomial negativa não é um MLGen, mas é uma interessante alternativa ao MLGen com resposta Poisson quando há sobredispersão, ou seja, quando $\mathrm{Var}(y_i) > \mu_i$. Enquanto no último modelo assumimos que $\mathrm{Var}(y_i) = \mu_i$, no modelo de regressão com resposta binomial negativa, assumimos que $\mathrm{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assumimos não somente variância maior no modelo com resposta binomial negativa, como temos também maior flexibilidade, pois é possível controlar a relação entre a variância e a média a partir do parâmetro ϕ.

Comparação dos coeficientes de variação

Vimos que na Poisson $\text{Var}(y_i) = \mu_i$ e na binomial negativa $\text{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Comparação dos coeficientes de variação

Vimos que na Poisson $\text{Var}(y_i) = \mu_i$ e na binomial negativa $\text{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assim, para a Poisson

$$\text{CV}(y_i)$$

Comparação dos coeficientes de variação

Vimos que na Poisson $\text{Var}(y_i) = \mu_i$ e na binomial negativa $\text{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assim, para a Poisson

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i}}{\mu_i}$$

Comparação dos coeficientes de variação

Vimos que na Poisson $\text{Var}(y_i) = \mu_i$ e na binomial negativa $\text{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assim, para a Poisson

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i}}{\mu_i} = \frac{1}{\sqrt{\mu_i}},$$

Comparação dos coeficientes de variação

Vimos que na Poisson $\text{Var}(y_i) = \mu_i$ e na binomial negativa $\text{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assim, para a Poisson

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i}}{\mu_i} = \frac{1}{\sqrt{\mu_i}},$$

que é próximo de 0 para valores grandes de μ_i.

Comparação dos coeficientes de variação

Vimos que na Poisson $\text{Var}(y_i) = \mu_i$ e na binomial negativa $\text{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assim, para a Poisson

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i}}{\mu_i} = \frac{1}{\sqrt{\mu_i}},$$

que é próximo de 0 para valores grandes de μ_i.

Para a distribuição binomial negativa,

$$\text{CV}(y_i)$$

Comparação dos coeficientes de variação

Vimos que na Poisson $\text{Var}(y_i) = \mu_i$ e na binomial negativa $\text{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assim, para a Poisson

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i}}{\mu_i} = \frac{1}{\sqrt{\mu_i}},$$

que é próximo de 0 para valores grandes de μ_i.

Para a distribuição binomial negativa,

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i + \mu_i^2/\phi}}{\mu_i}$$

Comparação dos coeficientes de variação

Vimos que na Poisson $\text{Var}(y_i) = \mu_i$ e na binomial negativa $\text{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assim, para a Poisson

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i}}{\mu_i} = \frac{1}{\sqrt{\mu_i}},$$

que é próximo de 0 para valores grandes de μ_i.

Para a distribuição binomial negativa,

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i + \mu_i^2/\phi}}{\mu_i} = \sqrt{\frac{\mu_i + \mu_i^2/\phi}{\mu_i^2}}$$

Comparação dos coeficientes de variação

Vimos que na Poisson $\text{Var}(y_i) = \mu_i$ e na binomial negativa $\text{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assim, para a Poisson

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i}}{\mu_i} = \frac{1}{\sqrt{\mu_i}},$$

que é próximo de 0 para valores grandes de μ_i.

Para a distribuição binomial negativa,

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i + \mu_i^2/\phi}}{\mu_i} = \sqrt{\frac{\mu_i + \mu_i^2/\phi}{\mu_i^2}} = \sqrt{\frac{1}{\mu_i} + \frac{1}{\phi}},$$

Comparação dos coeficientes de variação

Vimos que na Poisson $\text{Var}(y_i) = \mu_i$ e na binomial negativa $\text{Var}(y_i) = \mu_i + \mu_i^2/\phi$.

Assim, para a Poisson

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i}}{\mu_i} = \frac{1}{\sqrt{\mu_i}},$$

que é próximo de 0 para valores grandes de μ_i.

Para a distribuição binomial negativa,

$$\text{CV}(y_i) = \frac{\sqrt{\mu_i + \mu_i^2/\phi}}{\mu_i} = \sqrt{\frac{\mu_i + \mu_i^2/\phi}{\mu_i^2}} = \sqrt{\frac{1}{\mu_i} + \frac{1}{\phi}},$$

que é sempre superior a $\sqrt{1/\phi}$.

Modelos de regressão com resposta binomial negativa

Apesar dos modelos de regressão com resposta binomial negativa não ser um MLGen, ele é muito semelhante a ele,

Modelos de regressão com resposta binomial negativa

Apesar dos modelos de regressão com resposta binomial negativa não ser um MLGen, ele é muito semelhante a ele, pois

- A distribuição da variável resposta também tem como um dos parâmetros a média que varia em função de variáveis preditoras

Modelos de regressão com resposta binomial negativa

Apesar dos modelos de regressão com resposta binomial negativa não ser um MLGen, ele é muito semelhante a ele, pois

- A distribuição da variável resposta também tem como um dos parâmetros a média que varia em função de variáveis preditoras e um parâmetro de dispersão ϕ^{-1} que é assumido constante;

Modelos de regressão com resposta binomial negativa

Apesar dos modelos de regressão com resposta binomial negativa não ser um MLGen, ele é muito semelhante a ele, pois

- A distribuição da variável resposta também tem como um dos parâmetros a média que varia em função de variáveis preditoras e um parâmetro de dispersão ϕ^{-1} que é assumido constante;
- O vetor de parâmetros $\boldsymbol{\beta}$ do modelo também é geralmente estimado por máxima verossimilhança usando métodos numéricos;

Modelos de regressão com resposta binomial negativa

Apesar dos modelos de regressão com resposta binomial negativa não ser um MLGen, ele é muito semelhante a ele, pois

- A distribuição da variável resposta também tem como um dos parâmetros a média que varia em função de variáveis preditoras e um parâmetro de dispersão ϕ^{-1} que é assumido constante;
- O vetor de parâmetros $\boldsymbol{\beta}$ do modelo também é geralmente estimado por máxima verossimilhança usando métodos numéricos;
- Testes de hipóteses podem ser feitos usando as estatísticas de Wald, escore, razão de verossimilhanças e gradiente;

Modelos de regressão com resposta binomial negativa

Apesar dos modelos de regressão com resposta binomial negativa não ser um MLGen, ele é muito semelhante a ele, pois

- A distribuição da variável resposta também tem como um dos parâmetros a média que varia em função de variáveis preditoras e um parâmetro de dispersão ϕ^{-1} que é assumido constante;
- O vetor de parâmetros $\boldsymbol{\beta}$ do modelo também é geralmente estimado por máxima verossimilhança usando métodos numéricos;
- Testes de hipóteses podem ser feitos usando as estatísticas de Wald, escore, razão de verossimilhanças e gradiente;
- Resíduos semelhantes aos definidos para os MLGen são utilizados para análise de diagnóstico nos modelos com resposta binomial negativa.