EST507 Modelos de Regressão

Modelo linear geral - Análise de diagnóstico

Parte 1

Análise de diagnóstico

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos:

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos:

identificação de pontos discrepantes e/ou influentes

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos: identificação de pontos discrepantes e/ou influentes e verificação de possíveis afastamentos das suposições feitas para o modelo.

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos: identificação de pontos discrepantes e/ou influentes e verificação de possíveis afastamentos das suposições feitas para o modelo.

Na análise de diagnóstico é necessário o uso de resíduos.

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos: identificação de pontos discrepantes e/ou influentes e verificação de possíveis afastamentos das suposições feitas para o modelo.

Na análise de diagnóstico é necessário o uso de resíduos. O resíduo para i-ésima pode ser definido como uma função do tipo $r_i = r(y_i, \hat{y}_i)$ que procura medir a discrepância entre o valor observado e o valor ajustado para a i-ésima observação.

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos: identificação de pontos discrepantes e/ou influentes e verificação de possíveis afastamentos das suposições feitas para o modelo.

Na análise de diagnóstico é necessário o uso de resíduos. O resíduo para i-ésima pode ser definido como uma função do tipo $r_i = r(y_i, \hat{y}_i)$ que procura medir a discrepância entre o valor observado e o valor ajustado para a i-ésima observação.

Resíduo ordinário:

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos: identificação de pontos discrepantes e/ou influentes e verificação de possíveis afastamentos das suposições feitas para o modelo.

Na análise de diagnóstico é necessário o uso de resíduos. O resíduo para i-ésima pode ser definido como uma função do tipo $r_i = r(y_i, \hat{y}_i)$ que procura medir a discrepância entre o valor observado e o valor ajustado para a i-ésima observação.

Resíduo ordinário: $\hat{\epsilon}_i = y_i - \hat{y}_i$

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos: identificação de pontos discrepantes e/ou influentes e verificação de possíveis afastamentos das suposições feitas para o modelo.

Na análise de diagnóstico é necessário o uso de resíduos. O resíduo para i-ésima pode ser definido como uma função do tipo $r_i = r(y_i, \hat{y}_i)$ que procura medir a discrepância entre o valor observado e o valor ajustado para a i-ésima observação.

Resíduo ordinário: $\hat{\epsilon}_i = y_i - \hat{y}_i = y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$.

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos: identificação de pontos discrepantes e/ou influentes e verificação de possíveis afastamentos das suposições feitas para o modelo.

Na análise de diagnóstico é necessário o uso de resíduos. O resíduo para i-ésima pode ser definido como uma função do tipo $r_i = r(y_i, \hat{y}_i)$ que procura medir a discrepância entre o valor observado e o valor ajustado para a i-ésima observação.

Resíduo ordinário: $\hat{\epsilon}_i = y_i - \hat{y}_i = y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$.

Forma vetorial:

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos: identificação de pontos discrepantes e/ou influentes e verificação de possíveis afastamentos das suposições feitas para o modelo.

Na análise de diagnóstico é necessário o uso de resíduos. O resíduo para i-ésima pode ser definido como uma função do tipo $r_i = r(y_i, \hat{y}_i)$ que procura medir a discrepância entre o valor observado e o valor ajustado para a i-ésima observação.

Resíduo ordinário: $\hat{\epsilon}_i = y_i - \hat{y}_i = y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$.

Forma vetorial: $\hat{\boldsymbol{\epsilon}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}$

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos: identificação de pontos discrepantes e/ou influentes e verificação de possíveis afastamentos das suposições feitas para o modelo.

Na análise de diagnóstico é necessário o uso de resíduos. O resíduo para i-ésima pode ser definido como uma função do tipo $r_i = r(y_i, \hat{y}_i)$ que procura medir a discrepância entre o valor observado e o valor ajustado para a i-ésima observação.

Resíduo ordinário: $\hat{\epsilon}_i = y_i - \hat{y}_i = y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$.

Forma vetorial: $\hat{\boldsymbol{\epsilon}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{y} - \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$

Análise de diagnóstico

Análise de diagnóstico consiste em dois conjuntos de procedimentos: identificação de pontos discrepantes e/ou influentes e verificação de possíveis afastamentos das suposições feitas para o modelo.

Na análise de diagnóstico é necessário o uso de resíduos. O resíduo para i-ésima pode ser definido como uma função do tipo $r_i = r(y_i, \hat{y}_i)$ que procura medir a discrepância entre o valor observado e o valor ajustado para a i-ésima observação.

Resíduo ordinário: $\hat{\epsilon}_i = y_i - \hat{y}_i = y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}$.

Forma vetorial: $\hat{\boldsymbol{\epsilon}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{y} - \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}]$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}]$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}]$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})^\top$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})^\top =$$

$\sigma^2(\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H})$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})^\top =$$

$$\sigma^2(\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H}) = \sigma^2(\mathbf{I} - \mathbf{H})$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})^\top =$$

$$\sigma^2(\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H}) = \sigma^2(\mathbf{I} - \mathbf{H})$$

$\mathrm{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j)$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})^\top =$$

$$\sigma^2(\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H}) = \sigma^2(\mathbf{I} - \mathbf{H})$$

$$\mathrm{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})^\top =$$

$$\sigma^2(\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H}) = \sigma^2(\mathbf{I} - \mathbf{H})$$

$$\mathrm{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$$

$$\mathrm{Var}(\hat{\epsilon}_i)$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})^\top =$$

$$\sigma^2(\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H}) = \sigma^2(\mathbf{I} - \mathbf{H})$$

$$\mathrm{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$$

$$\mathrm{Var}(\hat{\epsilon}_i) = \sigma^2(1 - h_{ii})$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})^\top =$$

$$\sigma^2(\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H}) = \sigma^2(\mathbf{I} - \mathbf{H})$$

$$\mathrm{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$$

$$\mathrm{Var}(\hat{\epsilon}_i) = \sigma^2(1 - h_{ii})$$

$$\mathrm{Corr}(\hat{\epsilon}_i, \hat{\epsilon}_j)$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})^\top =$$

$$\sigma^2(\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H}) = \sigma^2(\mathbf{I} - \mathbf{H})$$

$$\mathrm{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$$

$$\mathrm{Var}(\hat{\epsilon}_i) = \sigma^2(1 - h_{ii})$$

$$\mathrm{Corr}(\hat{\epsilon}_i, \hat{\epsilon}_j) = \frac{-h_{ij}\sigma^2}{\sigma\sqrt{1 - h_{ii}}\sigma\sqrt{1 - h_{jj}}}$$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$$\mathrm{E}(\hat{\epsilon}) = \mathrm{E}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{E}[\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{H}\mathbf{X}\beta =$$

$\mathbf{X}\beta$- $\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\beta = \mathbf{X}\beta - \mathbf{X}\beta = 0$

$$\mathrm{Cov}(\hat{\epsilon}) = \mathrm{Cov}[(\mathbf{I} - \mathbf{H})\mathbf{y}] = (\mathbf{I} - \mathbf{H})\mathrm{Cov}[\mathbf{y}](\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H})\sigma^2\mathbf{I}(\mathbf{I} - \mathbf{H})^\top =$$

$\sigma^2(\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H}) = \sigma^2(\mathbf{I} - \mathbf{H})$

$$\mathrm{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$$

$$\mathrm{Var}(\hat{\epsilon}_i) = \sigma^2(1 - h_{ii})$$

$$\mathrm{Corr}(\hat{\epsilon}_i, \hat{\epsilon}_j) = \frac{-h_{ij}\sigma^2}{\sigma\sqrt{1 - h_{ii}}\sigma\sqrt{1 - h_{jj}}} = -\frac{h_{ij}}{\sqrt{1 - h_{ii}}\sqrt{1 - h_{jj}}},$$

em que h_{ij} é o termo (i, j) de $\mathbf{H}$.

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$\text{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$\text{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$

$\text{Var}(\hat{\epsilon}_i)\sigma^2(1 - h_{ii})$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$\text{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$

$\text{Var}(\hat{\epsilon}_i)\sigma^2(1 - h_{ii})$

$$\text{Corr}(\hat{\epsilon}_i, \hat{\epsilon}_j) = \frac{-h_{ij}\sigma^2}{\sigma\sqrt{1 - h_{ii}}\sigma\sqrt{1 - h_{ii}}} = -\frac{h_{ij}}{\sqrt{1 - h_{ii}}\sqrt{1 - h_{ii}}},$$

em que h_{ij} é o termo (ij) de $\mathbf{H}$.

Propriedades de h_{ij}

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$\text{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$

$\text{Var}(\hat{\epsilon}_i)\sigma^2(1 - h_{ii})$

$$\text{Corr}(\hat{\epsilon}_i, \hat{\epsilon}_j) = \frac{-h_{ij}\sigma^2}{\sigma\sqrt{1 - h_{ii}}\sigma\sqrt{1 - h_{ii}}} = -\frac{h_{ij}}{\sqrt{1 - h_{ii}}\sqrt{1 - h_{ii}}},$$

em que h_{ij} é o termo (ij) de $\mathbf{H}$.

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$\text{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$

$\text{Var}(\hat{\epsilon}_i)\sigma^2(1 - h_{ii})$

$$\text{Corr}(\hat{\epsilon}_i, \hat{\epsilon}_j) = \frac{-h_{ij}\sigma^2}{\sigma\sqrt{1 - h_{ii}}\sigma\sqrt{1 - h_{ii}}} = -\frac{h_{ij}}{\sqrt{1 - h_{ii}}\sqrt{1 - h_{ii}}},$$

em que h_{ij} é o termo (ij) de $\mathbf{H}$.

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0,5$

Resíduo ordinário

Resíduo ordinário: $\hat{\epsilon} = (\mathbf{I} - \mathbf{H})\mathbf{y}$.

$\text{Cov}(\hat{\epsilon}_i, \hat{\epsilon}_j) = -h_{ij}\sigma^2$

$\text{Var}(\hat{\epsilon}_i)\sigma^2(1 - h_{ii})$

$$\text{Corr}(\hat{\epsilon}_i, \hat{\epsilon}_j) = \frac{-h_{ij}\sigma^2}{\sigma\sqrt{1 - h_{ii}}\sigma\sqrt{1 - h_{ii}}} = -\frac{h_{ij}}{\sqrt{1 - h_{ii}}\sqrt{1 - h_{ii}}},$$

em que h_{ij} é o termo (ij) de $\mathbf{H}$.

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0,5$
- iii) $\sum_{j \neq i} h_{ij}^2 = h_{ii}(1 - h_{ii})$

Leverage de uma observação

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0{,}5$
- iii) $\sum_{j \neq i} h_{ij}^2 = h_{ii}(1 - h_{ii})$

Temos que $\hat{\mathbf{y}} = \mathbf{Hy}$

Leverage de uma observação

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0{,}5$
- iii) $\sum_{j \neq i} h_{ij}^2 = h_{ii}(1 - h_{ii})$

Temos que $\hat{\mathbf{y}} = \mathbf{Hy}$ e portanto $\hat{y}_i = h_{ii} y_i + \sum_{j \neq i} h_{ij} y_j$.

Leverage de uma observação

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0{,}5$
- iii) $\sum_{j \neq i} h_{ij}^2 = h_{ii}(1 - h_{ii})$

Temos que $\hat{\mathbf{y}} = \mathbf{Hy}$ e portanto $\hat{y}_i = h_{ii} y_i + \sum_{j \neq i} h_{ij} y_j$.

Se $h_{ii} = 1$, pela propriedade iii, temos que $h_{ij} = 0$ para todo $j \neq i$

Leverage de uma observação

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0{,}5$
- iii) $\sum_{j \neq i} h_{ij}^2 = h_{ii}(1 - h_{ii})$

Temos que $\hat{\mathbf{y}} = \mathbf{Hy}$ e portanto $\hat{y}_i = h_{ii} y_i + \sum_{j \neq i} h_{ij} y_j$.

Se $h_{ii} = 1$, pela propriedade iii, temos que $h_{ij} = 0$ para todo $j \neq i$ e $\hat{y}_i = y_i$.

Leverage de uma observação

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0{,}5$
- iii) $\sum_{j \neq i} h_{ij}^2 = h_{ii}(1 - h_{ii})$

Temos que $\hat{\mathbf{y}} = \mathbf{Hy}$ e portanto $\hat{y}_i = h_{ii} y_i + \sum_{j \neq i} h_{ij} y_j$.

Se $h_{ii} = 1$, pela propriedade iii, temos que $h_{ij} = 0$ para todo $j \neq i$ e $\hat{y}_i = y_i$.

Se h_{ii} é próximo de 1,

Leverage de uma observação

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0{,}5$
- iii) $\sum_{j \neq i} h_{ij}^2 = h_{ii}(1 - h_{ii})$

Temos que $\hat{\mathbf{y}} = \mathbf{Hy}$ e portanto $\hat{y}_i = h_{ii} y_i + \sum_{j \neq i} h_{ij} y_j$.

Se $h_{ii} = 1$, pela propriedade iii, temos que $h_{ij} = 0$ para todo $j \neq i$ e $\hat{y}_i = y_i$.

Se h_{ii} é próximo de 1, os h_{ij} serão pequenos

Leverage de uma observação

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0{,}5$
- iii) $\sum_{j \neq i} h_{ij}^2 = h_{ii}(1 - h_{ii})$

Temos que $\hat{\mathbf{y}} = \mathbf{Hy}$ e portanto $\hat{y}_i = h_{ii} y_i + \sum_{j \neq i} h_{ij} y_j$.

Se $h_{ii} = 1$, pela propriedade iii, temos que $h_{ij} = 0$ para todo $j \neq i$ e $\hat{y}_i = y_i$.

Se h_{ii} é próximo de 1, os h_{ij} serão pequenos e $\hat{y}_i$ será próximo de y_i.

Leverage de uma observação

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0{,}5$
- iii) $\sum_{j \neq i} h_{ij}^2 = h_{ii}(1 - h_{ii})$

Temos que $\hat{\mathbf{y}} = \mathbf{Hy}$ e portanto $\hat{y}_i = h_{ii} y_i + \sum_{j \neq i} h_{ij} y_j$.

Se $h_{ii} = 1$, pela propriedade iii, temos que $h_{ij} = 0$ para todo $j \neq i$ e $\hat{y}_i = y_i$.

Se h_{ii} é próximo de 1, os h_{ij} serão pequenos e $\hat{y}_i$ será próximo de y_i.

Portanto, h_{ii} é uma medida da influência da i-ésima observação sobre o próprio valor ajustado.

Leverage de uma observação

Propriedades de h_{ij}

- i) $\frac{1}{n} \leq h_{ii} \leq 1$
- ii) $-0,5 \leq h_{ij} \leq 0{,}5$
- iii) $\sum_{j \neq i} h_{ij}^2 = h_{ii}(1 - h_{ii})$

Temos que $\hat{\mathbf{y}} = \mathbf{Hy}$ e portanto $\hat{y}_i = h_{ii} y_i + \sum_{j \neq i} h_{ij} y_j$.

Se $h_{ii} = 1$, pela propriedade iii, temos que $h_{ij} = 0$ para todo $j \neq i$ e $\hat{y}_i = y_i$.

Se h_{ii} é próximo de 1, os h_{ij} serão pequenos e $\hat{y}_i$ será próximo de y_i.

Portanto, h_{ii} é uma medida da influência da i-ésima observação sobre o próprio valor ajustado.
O valor h_{ii} é denominado leverage da observação.

Pontos alavanca

$\sum_{i=1}^{n} h_{ii}$

Pontos alavanca

$\sum_{i=1}^{n} h_{ii} = \text{tr}(\mathbf{H})$

Pontos alavanca

$\sum_{i=1}^{n} h_{ii} = \text{tr}(\mathbf{H}) = k + 1,$

Pontos alavanca

$\sum_{i=1}^{n} h_{ii} = \text{tr}(\mathbf{H}) = k + 1$, pois $\mathbf{H}$ é idempotente de posto $k + 1$.

Pontos alavanca

$\sum_{i=1}^{n} h_{ii} = \text{tr}(\mathbf{H}) = k + 1$, pois $\mathbf{H}$ é idempotente de posto $k + 1$.

Todos os pontos tem igual influência sobre seus proprios valores ajustados:

Pontos alavanca

$\sum_{i=1}^{n} h_{ii} = \text{tr}(\mathbf{H}) = k + 1$, pois $\mathbf{H}$ é idempotente de posto $k + 1$.

Todos os pontos tem igual influência sobre seus proprios valores ajustados: $h_{ii} = (k + 1)/n$.

Pontos alavanca

$\sum_{i=1}^{n} h_{ii} = \text{tr}(\mathbf{H}) = k + 1$, pois $\mathbf{H}$ é idempotente de posto $k + 1$.

Todos os pontos tem igual influência sobre seus proprios valores ajustados: $h_{ii} = (k + 1)/n$.
Um procedimento sugerido é examinar os pontos tais que

$$h_{ii} > \frac{2(k + 1)}{n}.$$

Pontos alavanca

$\sum_{i=1}^{n} h_{ii} = \text{tr}(\mathbf{H}) = k + 1$, pois $\mathbf{H}$ é idempotente de posto $k + 1$.

Todos os pontos tem igual influência sobre seus proprios valores ajustados: $h_{ii} = (k + 1)/n$.
Um procedimento sugerido é examinar os pontos tais que

$$h_{ii} > \frac{2(k + 1)}{n}.$$

Pontos que atendem a esse critério são denominados pontos alavanca ou de alto leverage

Pontos alavanca

$\sum_{i=1}^{n} h_{ii} = \text{tr}(\mathbf{H}) = k + 1$, pois $\mathbf{H}$ é idempotente de posto $k + 1$.

Todos os pontos tem igual influência sobre seus proprios valores ajustados: $h_{ii} = (k + 1)/n$.
Um procedimento sugerido é examinar os pontos tais que

$$h_{ii} > \frac{2(k + 1)}{n}.$$

Pontos que atendem a esse critério são denominados pontos alavanca ou de alto leverage e estão localizados em regiões remotas no subespaço gerado pelas colunas da matriz X.

Pontos discrepantes

Pontos discrepantes

Pontos discrepantes são pontos mal ajustados pelo modelo.

Pontos discrepantes

Pontos discrepantes são pontos mal ajustados pelo modelo. Os pontos dicrepantes são assim valores que apresentam alto resíduo, em módulo.

Pontos discrepantes

Pontos discrepantes são pontos mal ajustados pelo modelo. Os pontos dicrepantes são assim valores que apresentam alto resíduo, em módulo.

Um resíduo mais adequado

Pontos discrepantes

Pontos discrepantes são pontos mal ajustados pelo modelo. Os pontos dicrepantes são assim valores que apresentam alto resíduo, em módulo.

Um resíduo mais adequado

Vimos que $\text{Var}(\hat{\epsilon}_i) = \sigma^2(1 - h_{ii})$.

Pontos discrepantes

Pontos discrepantes são pontos mal ajustados pelo modelo. Os pontos dicrepantes são assim valores que apresentam alto resíduo, em módulo.

Um resíduo mais adequado

Vimos que $\text{Var}(\hat{\epsilon}_i) = \sigma^2(1 - h_{ii})$. Assim um resíduo razoável é dado por

$$r_i = \frac{\hat{\epsilon}_i}{\sqrt{s^2(1 - h_{ii})}},$$

sendo conhecido como resíduo estudentizado (internamente).

Pontos discrepantes

Pontos discrepantes são pontos mal ajustados pelo modelo. Os pontos dicrepantes são assim valores que apresentam alto resíduo, em módulo.

Um resíduo mais adequado

Vimos que $\text{Var}(\hat{\epsilon}_i) = \sigma^2(1 - h_{ii})$. Assim um resíduo razoável é dado por

$$r_i = \frac{\hat{\epsilon}_i}{\sqrt{s^2(1 - h_{ii})}},$$

sendo conhecido como resíduo estudentizado (internamente).

Problemas

Pontos discrepantes

Pontos discrepantes são pontos mal ajustados pelo modelo. Os pontos dicrepantes são assim valores que apresentam alto resíduo, em módulo.

Um resíduo mais adequado

Vimos que $\text{Var}(\hat{\epsilon}_i) = \sigma^2(1 - h_{ii})$. Assim um resíduo razoável é dado por

$$r_i = \frac{\hat{\epsilon}_i}{\sqrt{s^2(1 - h_{ii})}},$$

sendo conhecido como resíduo estudentizado (internamente).

Problemas

- Não tem distribuição t pois $\hat{\epsilon}_i$ e QMRES não são independentes.

Pontos discrepantes

Pontos discrepantes são pontos mal ajustados pelo modelo. Os pontos dicrepantes são assim valores que apresentam alto resíduo, em módulo.

Um resíduo mais adequado

Vimos que $\text{Var}(\hat{\epsilon}_i) = \sigma^2(1 - h_{ii})$. Assim um resíduo razoável é dado por

$$r_i = \frac{\hat{\epsilon}_i}{\sqrt{s^2(1 - h_{ii})}},$$

sendo conhecido como resíduo estudentizado (internamente).

Problemas

- Não tem distribuição t pois $\hat{\epsilon}_i$ e QMRES não são independentes.
- Observações discrepantes podem "puxar" a função de regressão para ela reduzindo o valor do resíduo.

Pontos discrepantes

Pontos discrepantes

Um resíduo mais adequado

Solução:

Pontos discrepantes

Um resíduo mais adequado

Solução:

Considerar no numerador do resíduo

$$l_i = y_i - \hat{y}_{i(i)},$$

em que $\hat{y}_{i(i)}$ é o valor ajustado para a i-ésima observação quando o modelo utilizado não usa a observação i.

Pontos discrepantes

Um resíduo mais adequado

Solução:

Considerar no numerador do resíduo

$$l_i = y_i - \hat{y}_{i(i)},$$

em que $\hat{y}_{i(i)}$ é o valor ajustado para a i-ésima observação quando o modelo utilizado não usa a observação i.

Pode-se provar que

$$l_i = \frac{\hat{\epsilon}_i}{1 - h_{ii}}$$

e assim não é necessário ajustar n modelos de regressão.

Pontos discrepantes

Pontos discrepantes

Um resíduo mais adequado

Pontos discrepantes

Um resíduo mais adequado

Pode-se provar ainda que um estimador não viesado da $\text{Var}(l_i)$ é dado por

$$\widehat{\text{Var}(l_i)} = \frac{s^2_{(i)}}{1 - h_{ii}},$$

em que $s^2_{(i)}$ é o QMRes no modelo ajustado sem a observação i.

Pontos discrepantes

Um resíduo mais adequado

Pode-se provar ainda que um estimador não viesado da $\text{Var}(l_i)$ é dado por

$$\widehat{\text{Var}(l_i)} = \frac{s^2_{(i)}}{1 - h_{ii}},$$

em que $s^2_{(i)}$ é o QMRes no modelo ajustado sem a observação i.

Assim, um resíduo mais adequado é dado por

$$t_i = \frac{l_i}{\sqrt{\widehat{\text{Var}(l_i)}}}$$

Pontos discrepantes

Um resíduo mais adequado

Pode-se provar ainda que um estimador não viesado da $\text{Var}(l_i)$ é dado por

$$\widehat{\text{Var}(l_i)} = \frac{s^2_{(i)}}{1 - h_{ii}},$$

em que $s^2_{(i)}$ é o QMRes no modelo ajustado sem a observação i.

Assim, um resíduo mais adequado é dado por

$$t_i = \frac{l_i}{\sqrt{\widehat{\text{Var}(l_i)}}} = \frac{\hat{\epsilon}_i/(1 - h_{ii})}{\sqrt{s^2_{(i)}/(1 - h_{ii})}}$$

Pontos discrepantes

Um resíduo mais adequado

Pode-se provar ainda que um estimador não viesado da $\text{Var}(l_i)$ é dado por

$$\widehat{\text{Var}(l_i)} = \frac{s^2_{(i)}}{1 - h_{ii}},$$

em que $s^2_{(i)}$ é o QMRes no modelo ajustado sem a observação i.

Assim, um resíduo mais adequado é dado por

$$t_i = \frac{l_i}{\sqrt{\widehat{\text{Var}(l_i)}}} = \frac{\hat{\epsilon}_i/(1 - h_{ii})}{\sqrt{s^2_{(i)}/(1 - h_{ii})}} = \frac{\hat{\epsilon}_i}{\sqrt{s^2_{(i)}(1 - h_{ii})}},$$

Pontos discrepantes

Um resíduo mais adequado

Pode-se provar ainda que um estimador não viesado da $\text{Var}(l_i)$ é dado por

$$\widehat{\text{Var}(l_i)} = \frac{s^2_{(i)}}{1 - h_{ii}},$$

em que $s^2_{(i)}$ é o QMRes no modelo ajustado sem a observação i.

Assim, um resíduo mais adequado é dado por

$$t_i = \frac{l_i}{\sqrt{\widehat{\text{Var}(l_i)}}} = \frac{\hat{\epsilon}_i/(1 - h_{ii})}{\sqrt{s^2_{(i)}/(1 - h_{ii})}} = \frac{\hat{\epsilon}_i}{\sqrt{s^2_{(i)}(1 - h_{ii})}},$$

sendo denominado resíduo estudentizado externamente (deletado).

Pontos discrepantes

Pontos discrepantes

Um resíduo mais adequado

Pontos discrepantes

Um resíduo mais adequado

- $\hat{\epsilon}_i$ e $s^2_{(i)}$ são independentes.

Pontos discrepantes

Um resíduo mais adequado

- $\hat{\epsilon}_i$ e $s^2_{(i)}$ são independentes.
- t_i tem distribuição t com $(n-k)$ graus de liberdade.

Pontos discrepantes

Um resíduo mais adequado

- $\hat{\epsilon}_i$ e $s^2_{(i)}$ são independentes.
- t_i tem distribuição t com $(n-k)$ graus de liberdade.
- $$t_i = r_i \left(\frac{n-k-2}{n-k-1-r_i^2} \right)^{1/2}.$$

Pontos discrepantes

Um resíduo mais adequado

- $\hat{\epsilon}_i$ e $s^2_{(i)}$ são independentes.
- t_i tem distribuição t com $(n-k)$ graus de liberdade.
- $$t_i = r_i \left(\frac{n-k-2}{n-k-1-r_i^2} \right)^{1/2}.$$
- Observações com valores grandes (em módulo) de t_i são possíveis observações discrepantes (aberrantes ou outliers).

Pontos discrepantes

Um resíduo mais adequado

- $\hat{\epsilon}_i$ e $s^2_{(i)}$ são independentes.
- t_i tem distribuição t com $(n-k)$ graus de liberdade.
- $$t_i = r_i \left(\frac{n-k-2}{n-k-1-r_i^2} \right)^{1/2}.$$
- Observações com valores grandes (em módulo) de t_i são possíveis observações discrepantes (aberrantes ou outliers).
- Os resíduos t_i não são independentes.