EST507 Modelos de Regressão

Modelo linear geral - Análise de diagnóstico

Parte 2

A parte dos slides de aula referente
aos envelopes simulados foi preparada
por Victor Fernandes

Pontos influentes

Pontos influentes

Um observação é influente se sua exclusão causa uma mudança significativa do modelo ajustado.

Pontos influentes

Um observação é influente se sua exclusão causa uma mudança significativa do modelo ajustado.

DFFITS

Pontos influentes

Um observação é influente se sua exclusão causa uma mudança significativa do modelo ajustado.

DFFITS

Mede a influência de cada observação sobre seu prório valor ajustado sendo dada por

Pontos influentes

Um observação é influente se sua exclusão causa uma mudança significativa do modelo ajustado.

DFFITS

Mede a influência de cada observação sobre seu prório valor ajustado sendo dada por

$$(DFFITS)_i = \frac{|\hat{y}_i - \hat{y}_{i(i)}|}{\sqrt{s^2_{(i)}(1 - h_{ii})}}.$$

Pontos influentes

Um observação é influente se sua exclusão causa uma mudança significativa do modelo ajustado.

DFFITS

Mede a influência de cada observação sobre seu prório valor ajustado sendo dada por

$$(DFFITS)_i = \frac{|\hat{y}_i - \hat{y}_{i(i)}|}{\sqrt{s^2_{(i)}(1 - h_{ii})}}.$$

Pode-se provar que

$$(DFFITS)_i = |t_i| \left(\frac{h_{ii}}{1 - h_{ii}} \right)^{1/2}.$$

Pontos influentes

Pontos influentes

Distância de Cook

Pontos influentes

Distância de Cook

Mede a influência de cada observação sobre os n valores ajustados sendo dada por

Pontos influentes

Distância de Cook

Mede a influência de cada observação sobre os n valores ajustados sendo dada por

$$d_i = \frac{\sum_{j=1}^{n}(\hat{y}_j - \hat{y}_{j(i)})^2}{(k-1)s^2}.$$

Pontos influentes

Distância de Cook

Mede a influência de cada observação sobre os n valores ajustados sendo dada por

$$d_i = \frac{\sum_{j=1}^{n} (\hat{y}_j - \hat{y}_{j(i)})^2}{(k-1)s^2}.$$

Pode-se provar que

$$d_i = \frac{r_i^2 h_{ii}}{(1-h_{ii})(k+1)}.$$

Pontos influentes

Distância de Cook

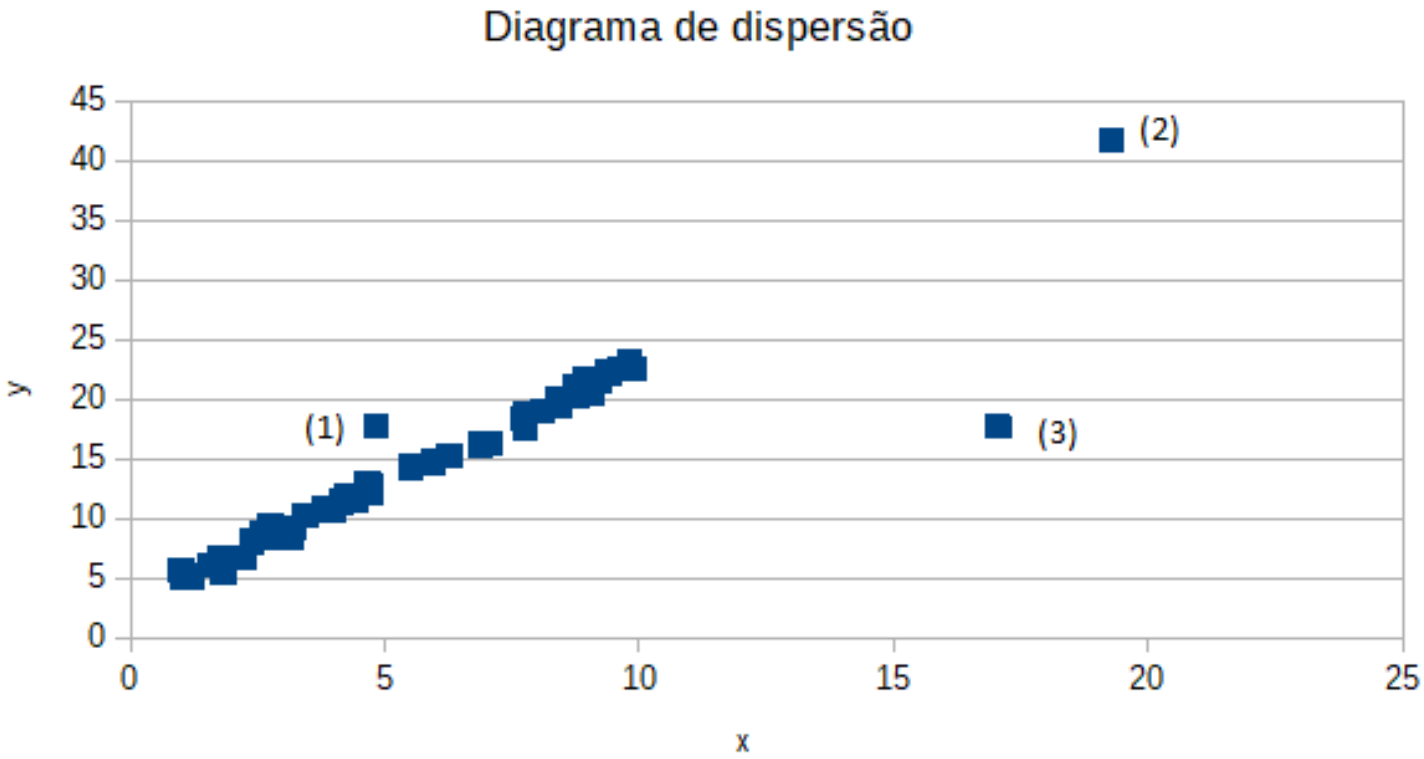
Mede a influência de cada observação sobre os n valores ajustados sendo dada por

$$d_i = \frac{\sum_{j=1}^{n} (\hat{y}_j - \hat{y}_{j(i)})^2}{(k-1)s^2}.$$

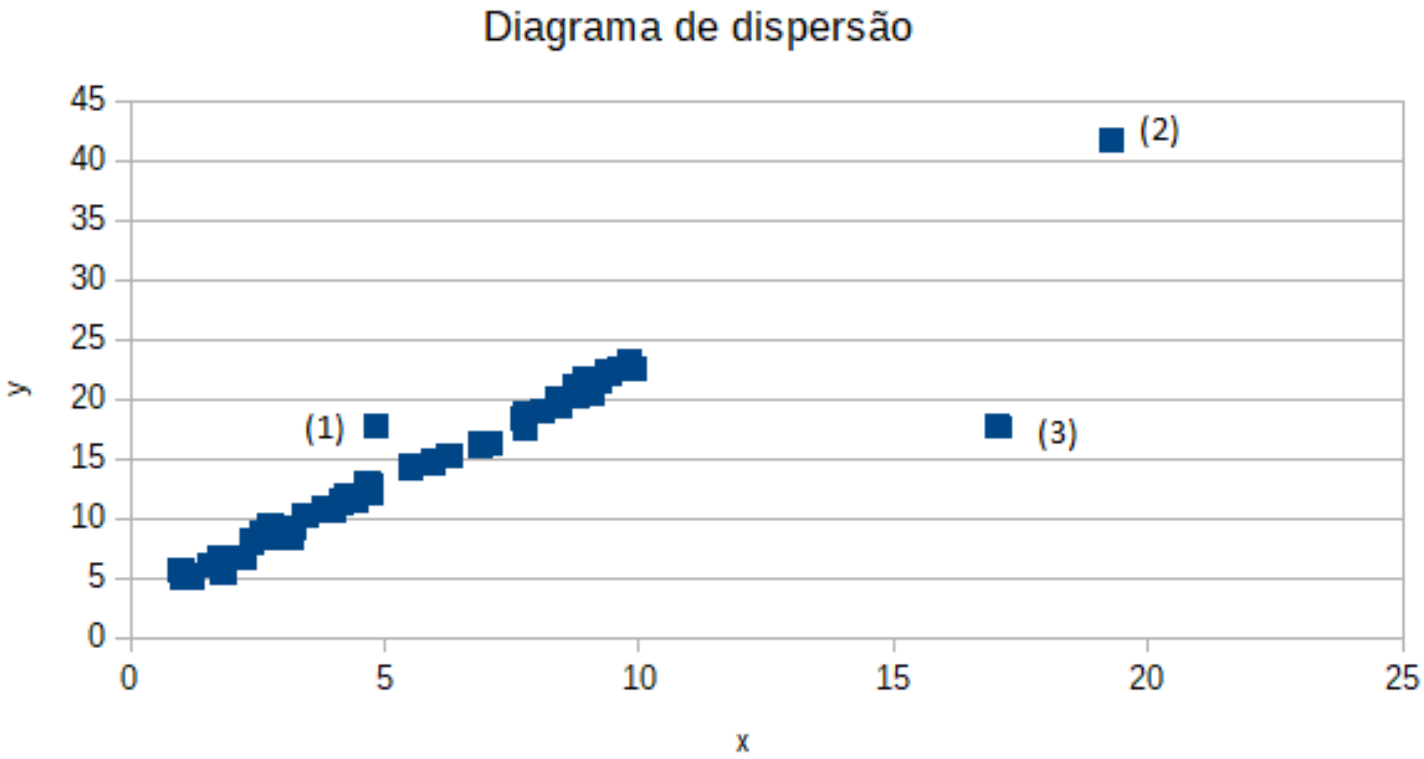
Pode-se provar que

$$d_i = \frac{r_i^2 h_{ii}}{(1-h_{ii})(k+1)}.$$

Diferenciando os pontos

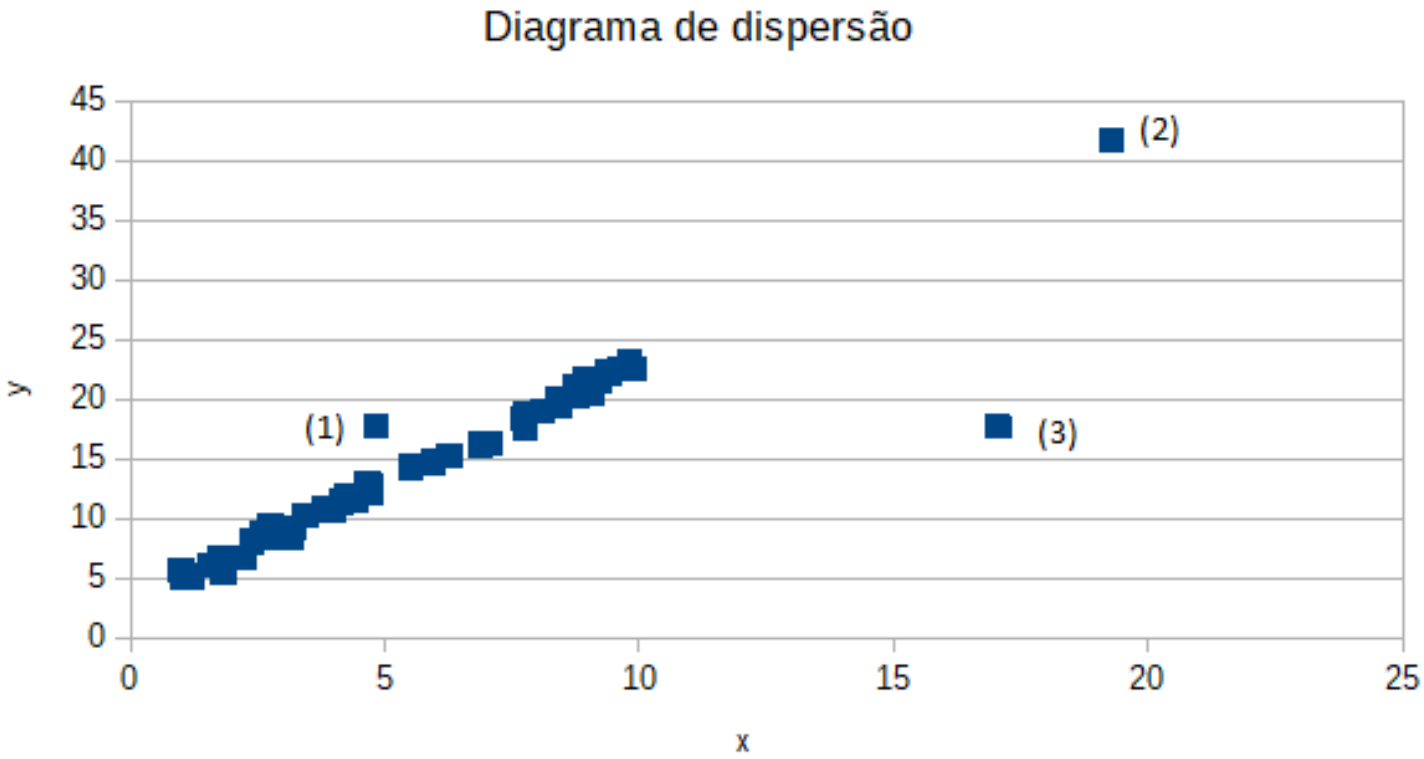


Diferenciando os pontos



(1) Observação discrepante, mas pouco influente por possuir h_{ii} baixo.

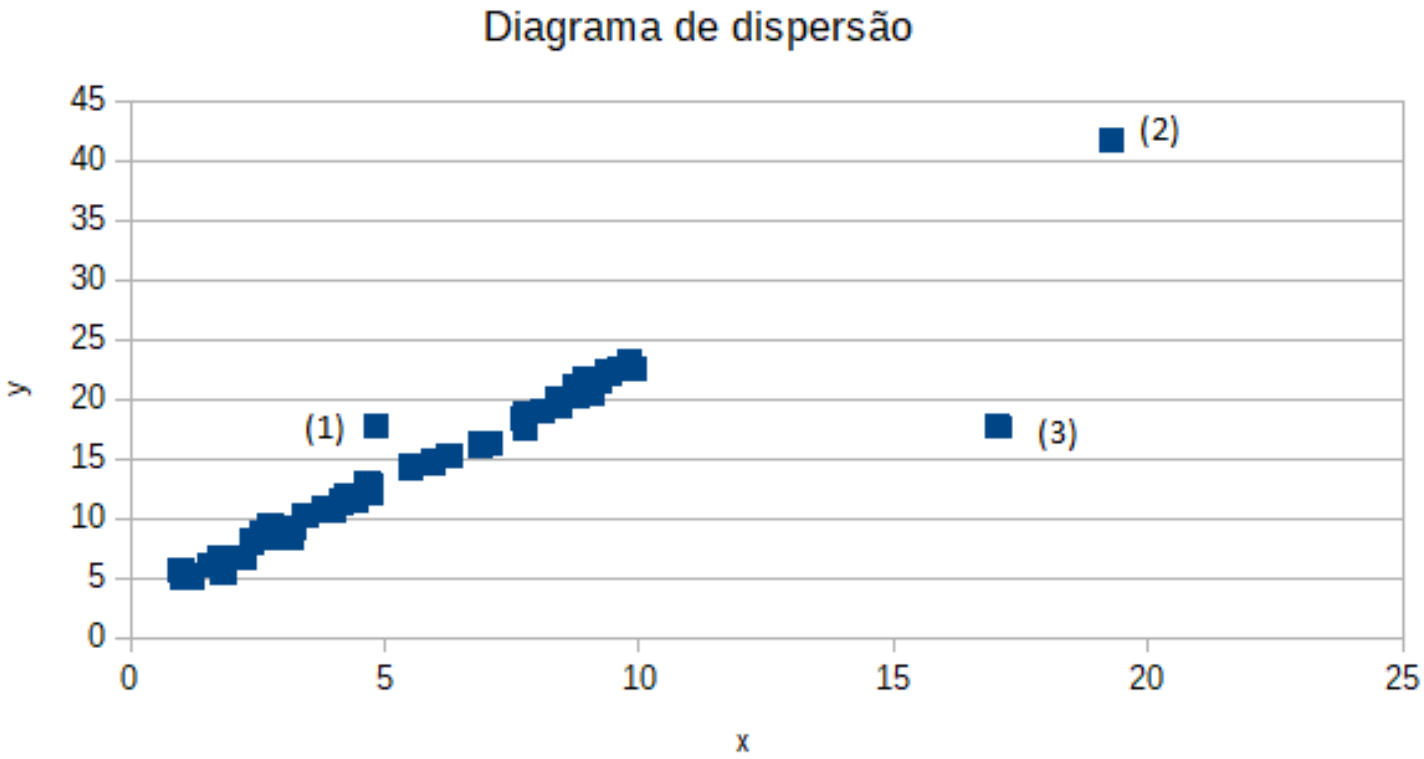
Diferenciando os pontos



(1) Observação discrepante, mas pouco influente por possuir h_{ii} baixo.

(2) Observação de alto leverage, mas pouco influente por não ser discrepante.

Diferenciando os pontos



(1) Observação discrepante, mas pouco influente por possuir h_{ii} baixo.

(2) Observação de alto leverage, mas pouco influente por não ser discrepante.

(3) Observação de alto leverage, discrepante e influente.

Gráficos de resíduos

Gráficos de resíduos

Gráficos que apresentam no eixo y o levarage h_{ii}, o resíduo t_i ou medidas de influência como $(DFFITS)_i$ e d_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos

Gráficos que apresentam no eixo y o levarage h_{ii}, o resíduo t_i ou medidas de influência como $(DFFITS)_i$ e d_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo.

Gráficos de resíduos

Gráficos que apresentam no eixo y o levarage h_{ii}, o resíduo t_i ou medidas de influência como $(DFFITS)_i$ e d_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo.

O MLGer possui basicamente três suposições:

Gráficos de resíduos

Gráficos que apresentam no eixo y o levarage h_{ii}, o resíduo t_i ou medidas de influência como $(DFFITS)_i$ e d_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo.

O MLGer possui basicamente três suposições:

- independência dos erros;

Gráficos de resíduos

Gráficos que apresentam no eixo y o levarage h_{ii}, o resíduo t_i ou medidas de influência como $(DFFITS)_i$ e d_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo.

O MLGer possui basicamente três suposições:

- independência dos erros;
- homocedasticidade dos erros;

Gráficos de resíduos

Gráficos que apresentam no eixo y o levarage h_{ii}, o resíduo t_i ou medidas de influência como $(DFFITS)_i$ e d_i e no eixo x o número da observação (ordem da observação) ou $\hat{y}_i$ são úteis para identificação de pontos de alavanca, discrepantes e influentes.

Gráficos de resíduos também são úteis para a verificação das suposições do modelo.

O MLGer possui basicamente três suposições:

- independência dos erros;
- homocedasticidade dos erros;
- normalidade dos erros.

Verificação da independência dos erros

Verificação da independência dos erros

É realizada fazendo-se gráficos de t_i contra o tempo, ordem das observações ou contra a ordem em que há suspeita de existência de dependência.

Verificação da independência dos erros

É realizada fazendo-se gráficos de t_i contra o tempo, ordem das observações ou contra a ordem em que há suspeita de existência de dependência.

Se a disposição dos pontos apresentar algum padrão, há suspeita de problemas com a suposição de independência dos erros.

Gráfico que sugere dependência dos erros

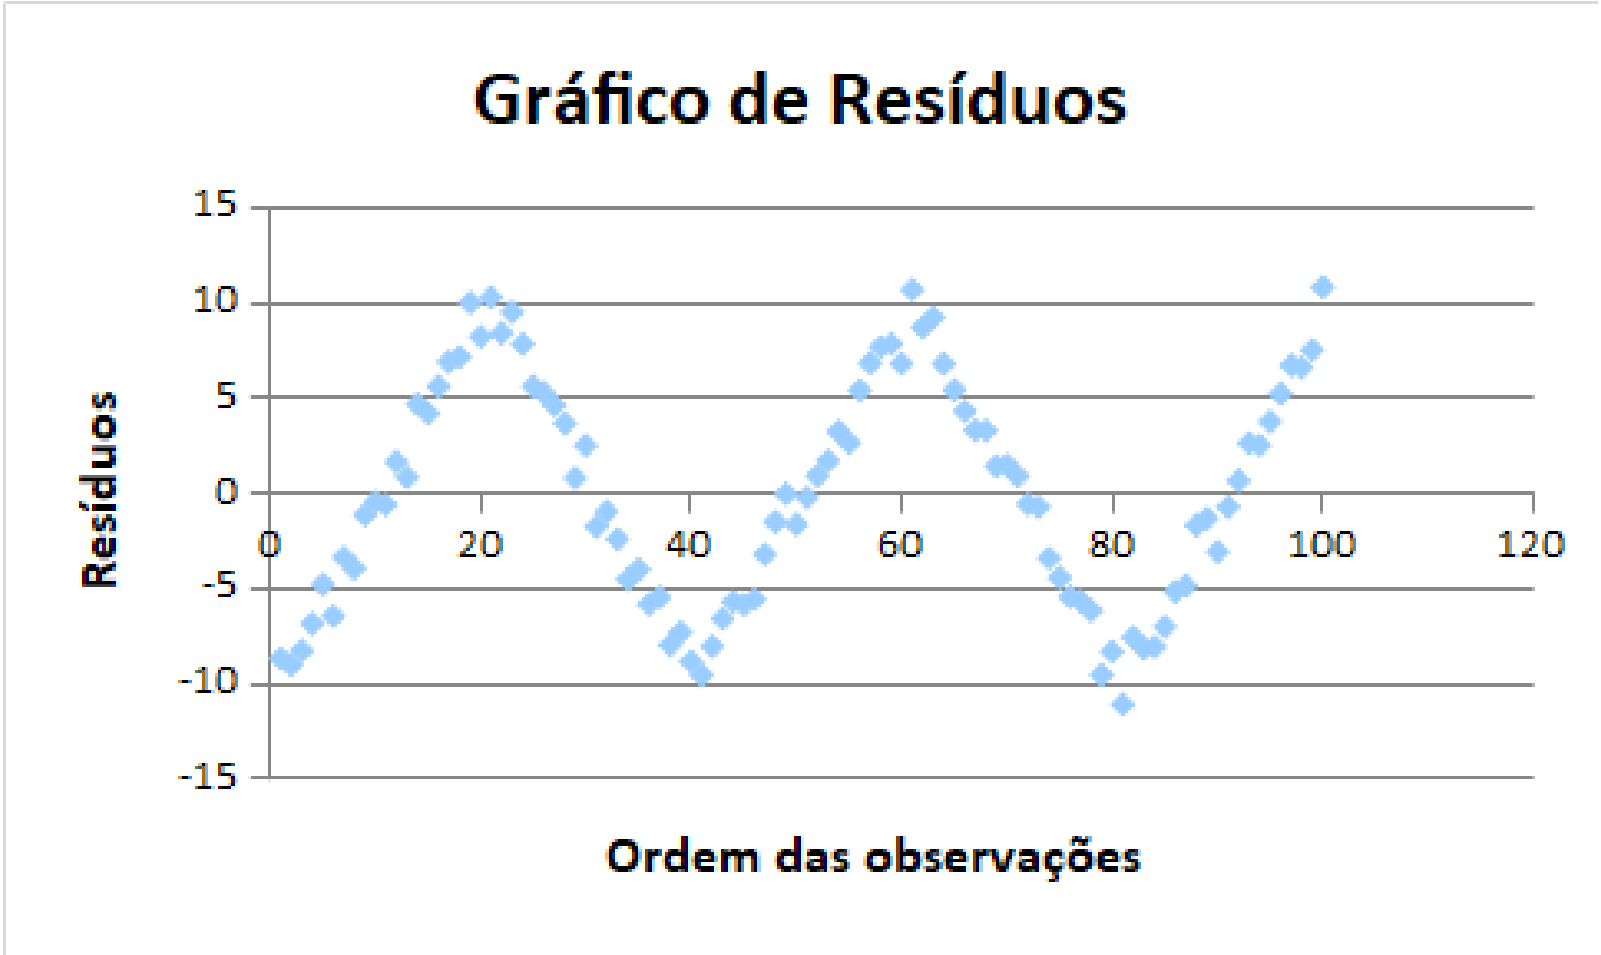
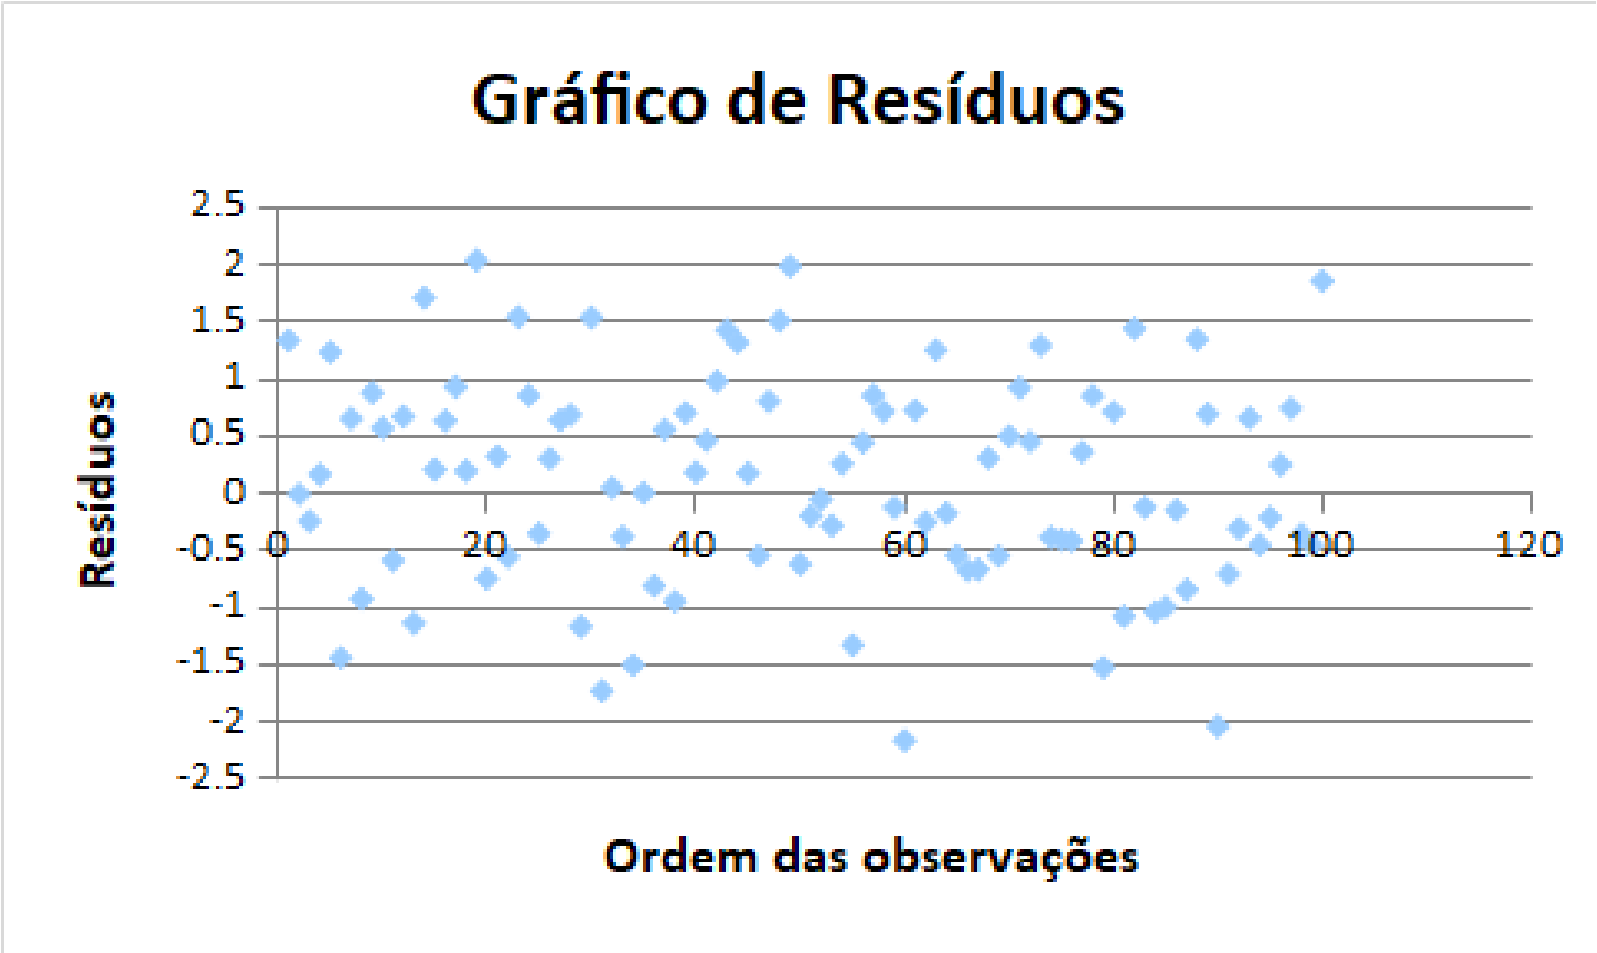


Gráfico que não sugere dependência dos erros



Verificação da homocedasticidade dos erros

Verificação da homocedasticidade dos erros

É realizada fazendo-se gráficos de t_i contra $\hat{y}_i$.

Verificação da homocedasticidade dos erros

É realizada fazendo-se gráficos de t_i contra $\hat{y}_i$.

Se a variância de t_i não parecer ser constante a medida que aumenta-se $\hat{y}_i$, há suspeita de heterocedasticidade dos erros.

Gráfico que sugere heterocedasticidade dos erros

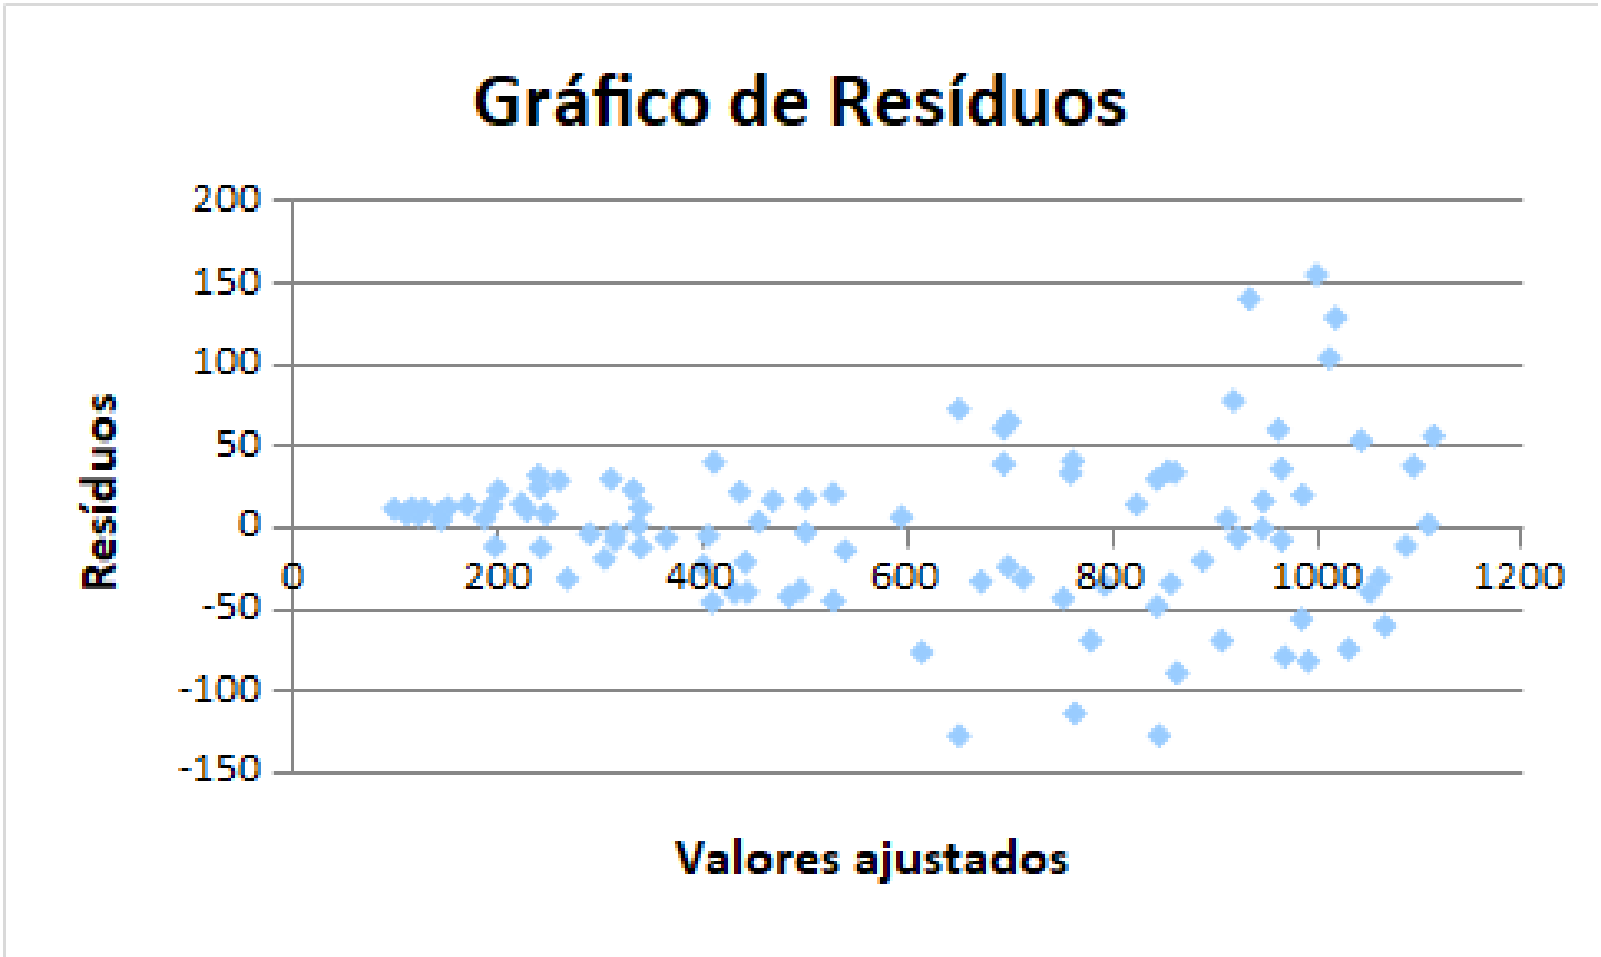
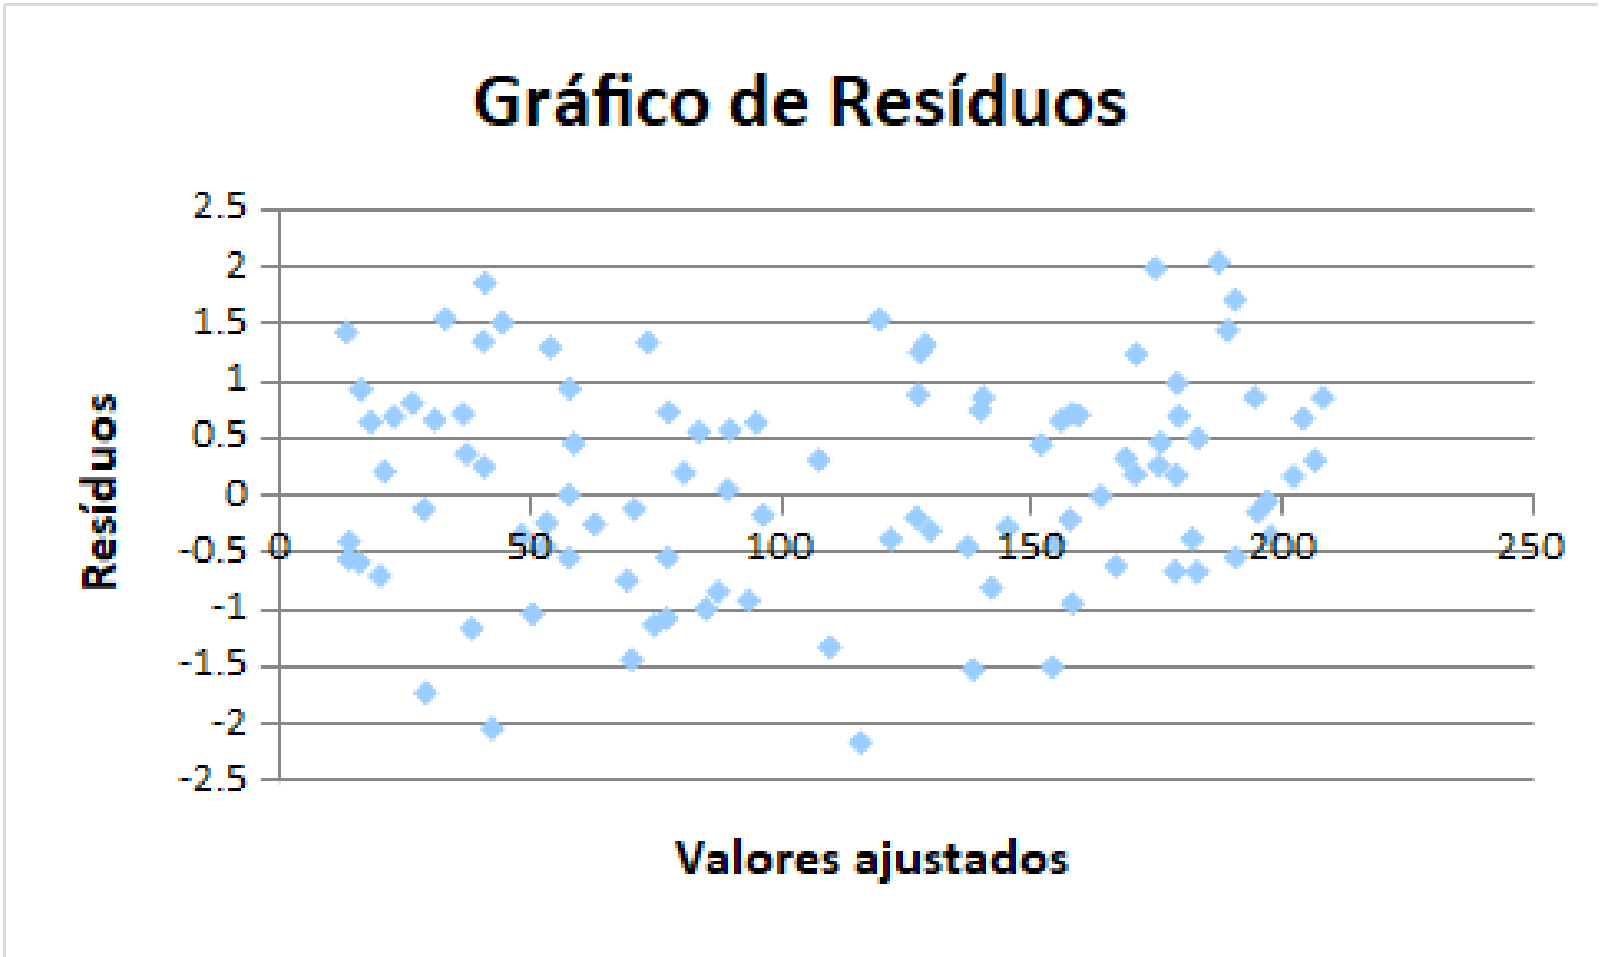


Gráfico que não sugere heterocedasticidade dos erros



Verificação da normalidade dos erros

Verificação da normalidade dos erros

É a suposição mais difícil de ser verificada pelos seguintes motivos:

Verificação da normalidade dos erros

É a suposição mais difícil de ser verificada pelos seguintes motivos:

- Os erros tem distribuição normal, mas t_i tem distribuição t de Student e $\hat{\epsilon}_i$ não tem variância constante.

Verificação da normalidade dos erros

É a suposição mais difícil de ser verificada pelos seguintes motivos:

- Os erros tem distribuição normal, mas t_i tem distribuição t de Student e $\hat{\epsilon}_i$ não tem variância constante.
- Os resíduos t_i são correlacionados.

Verificação da normalidade dos erros

É a suposição mais difícil de ser verificada pelos seguintes motivos:

- Os erros tem distribuição normal, mas t_i tem distribuição t de Student e $\hat{\epsilon}_i$ não tem variância constante.
- Os resíduos t_i são correlacionados.
- Problemas nas outras suposições podem nos levar a pensar que os erros não tem distribuição normal.

Verificação da normalidade dos erros

É a suposição mais difícil de ser verificada pelos seguintes motivos:

- Os erros tem distribuição normal, mas t_i tem distribuição t de Student e $\hat{\epsilon}_i$ não tem variância constante.
- Os resíduos t_i são correlacionados.
- Problemas nas outras suposições podem nos levar a pensar que os erros não tem distribuição normal.

Verificação da normalidade dos erros

É a suposição mais difícil de ser verificada pelos seguintes motivos:

- Os erros tem distribuição normal, mas t_i tem distribuição t de Student e $\hat{\epsilon}_i$ não tem variância constante.
- Os resíduos t_i são correlacionados.
- Problemas nas outras suposições podem nos levar a pensar que os erros não tem distribuição normal.

Uma forma muito utilizada de se verificar a suposição de normalidade é fazer um gráfico de probabilidade normal para t_i com envelope simulado.

Verificação da normalidade dos erros

É a suposição mais difícil de ser verificada pelos seguintes motivos:

- Os erros tem distribuição normal, mas t_i tem distribuição t de Student e $\hat{\epsilon}_i$ não tem variância constante.
- Os resíduos t_i são correlacionados.
- Problemas nas outras suposições podem nos levar a pensar que os erros não tem distribuição normal.

Uma forma muito utilizada de se verificar a suposição de normalidade é fazer um gráfico de probabilidade normal para t_i com envelope simulado.

Equivalentemente, pode-se fazer um gráfico de probabilidade meio normal para $|t_i|$ com envelope simulado.

Gráfico de probabilidade normal

Gráfico de probabilidade normal

- Para a obtenção do gráfico de probabilidade normal, considere t_i, para $i = 1, \ldots, n$, um resíduo qualquer. Colocamos no gráfico os pontos $(E(Z_{[i]}), t_{[i]})$, em que $[i]$ representa o i-ésimo menor valor e $E(Z_{[i]})$ se refere aos valores esperados das estatísticas de ordem da normal padrão. Temos que

$$E(Z_{[i]}) \cong \Phi^{-1}\left(\frac{i - 3/8}{n + 1/4}\right), \tag{1}$$

em que Φ é a função de distribuição acumulada da normal padrão.

Gráfico de probabilidade meio normal

Gráfico de probabilidade meio normal

- Para o gráfico meio normal probabilístico, tomamos o valor absoluto de t_i, como definido anteriormente, com $i = 1, \ldots, n$. Dispomos no gráfico os pontos $(E(|Z_{[i]}|), |t_{[i]}|)$, em que $[i]$ representa o i-ésimo menor valor e $E(|Z_{[i]}|)$ agora se refere aos valores esperados de $|Z_{[i]}|$, que obtemos fazendo

$$E(|Z_{[i]}|) \cong \Phi^{-1}\left(\frac{n+i+1/2}{2n+9/8}\right), \tag{2}$$

sendo também Φ a função de distribuição acumulada da normal padrão.

Gráficos de probabilidade

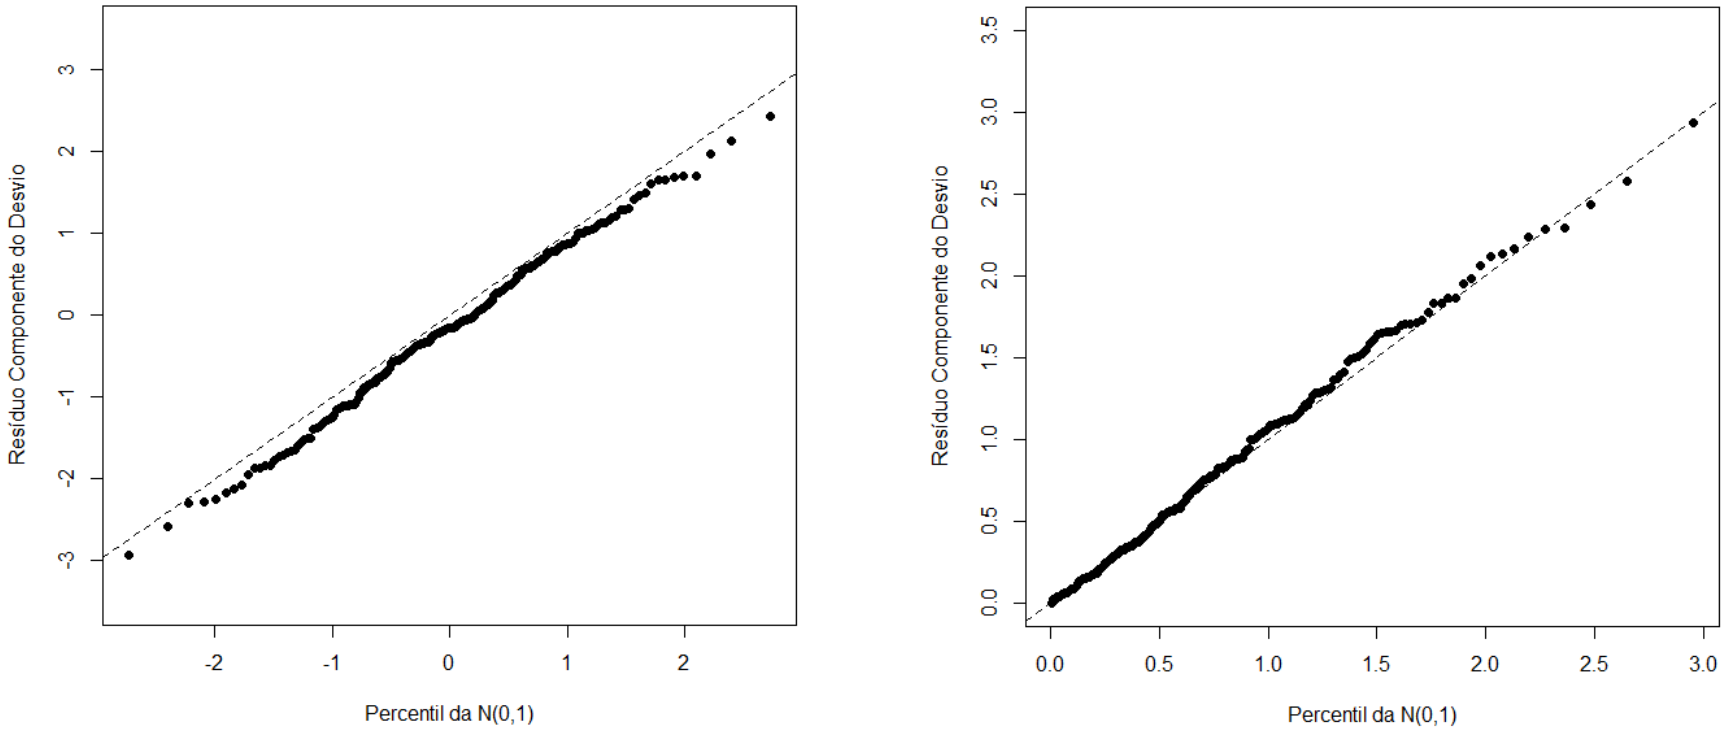


Figura: Gráficos de probabilidade normal (esquerda) e meio normal (direita) para dados gerados assumindo um modelo de regressão gama.

Métodos de construção do envelope

Métodos de construção do envelope

- Envelope simulado: Atkinson

Métodos de construção do envelope

- Envelope simulado: Atkinson

– Atkinson (1981) sugeriu a utilização de uma espécie de banda para a flutuação dos pontos, a qual denominou envelope.

Métodos de construção do envelope

- Envelope simulado: Atkinson

– Atkinson (1981) sugeriu a utilização de uma espécie de banda para a flutuação dos pontos, a qual denominou envelope. Este procedimento consiste em determinar os limites do envelope realizando os seguintes passos:

Métodos de construção do envelope

- Envelope simulado: Atkinson

– Atkinson (1981) sugeriu a utilização de uma espécie de banda para a flutuação dos pontos, a qual denominou envelope. Este procedimento consiste em determinar os limites do envelope realizando os seguintes passos:

1) Geramos n observações $y^*_{i,1}$ considerando que o modelo ajustado é verdadeiro e guardamos esses valores em $\mathbf{y}^*_1 = (y^*_{1,1}, \ldots, y^*_{n,1})^\top$.

Métodos de construção do envelope

- Envelope simulado: Atkinson

– Atkinson (1981) sugeriu a utilização de uma espécie de banda para a flutuação dos pontos, a qual denominou envelope. Este procedimento consiste em determinar os limites do envelope realizando os seguintes passos:

1) Geramos n observações $y^*_{i,1}$ considerando que o modelo ajustado é verdadeiro e guardamos esses valores em $\mathbf{y}^*_1 = (y^*_{1,1}, \ldots, y^*_{n,1})^\top$.

2) Ajustamos $\mathbf{y}^*_1$ contra a matriz de variáveis preditoras $\mathbf{X}$ e obtemos os resíduos $t_{i,1}$, para $i = 1, 2, \ldots, n$.

Envelope simulado: Atkinson

Envelope simulado: Atkinson

3) Repetimos os passos 1) e 2) m vezes.

Envelope simulado: Atkinson

3) Repetimos os passos 1) e 2) m vezes. Logo, teremos $t_{i,j}$, para $i = 1, 2, \ldots, n$ e $j = 1, 2, \ldots, m$, conforme apresentado na Tabela 1.

Tabela: Resíduos originais e simulados.

Resíduo original	Réplica 1	Réplica 2	...	Réplica $m-1$	Réplica m
t_1	$t_{1,1}$	$t_{1,2}$	$\cdots$	$t_{1,m-1}$	$t_{1,m}$
t_2	$t_{2,1}$	$t_{2,2}$	$\cdots$	$t_{2,m-1}$	$t_{2,m}$
t_3	$t_{3,1}$	$t_{3,2}$	$\cdots$	$t_{3,m-1}$	$t_{3,m}$
t_4	$t_{4,1}$	$t_{4,2}$	$\cdots$	$t_{4,m-1}$	$t_{4,m}$
t_5	$t_{5,1}$	$t_{5,2}$	$\cdots$	$t_{5,m-1}$	$t_{5,m}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
t_{n-1}	$t_{n-1,1}$	$t_{n-1,2}$	$\cdots$	$t_{n-1,m-1}$	$t_{n-1,m}$
t_n	$t_{n,1}$	$t_{n,2}$	$\cdots$	$t_{n,m-1}$	$t_{n,m}$

Envelope simulado: Atkinson

Envelope simulado: Atkinson

4) Colocamos cada grupo de n resíduos em ordem crescente, obtendo assim $t_{[i],j}$, para $i = 1, 2, \ldots, n$ e $j = 1, 2, \ldots, m$, conforme apresentamos na Tabela 2.

Envelope simulado: Atkinson

4) Colocamos cada grupo de n resíduos em ordem crescente, obtendo assim $t_{[i],j}$, para $i = 1, 2, \ldots, n$ e $j = 1, 2, \ldots, m$, conforme apresentamos na Tabela 2.

Tabela: Resíduos originais e simulados ordenados de forma crescente.

4) $\Downarrow$	$\Downarrow$	$\Downarrow$		$\Downarrow$	$\Downarrow$
Resíduo original	Réplica 1	Réplica 2	$\cdots$	Réplica $m-1$	Réplica m
$t_{[1]}$	$t_{[1],1}$	$t_{[1],2}$	$\cdots$	$t_{[1],m-1}$	$t_{[1],m}$
$t_{[2]}$	$t_{[2],1}$	$t_{[2],2}$	$\cdots$	$t_{[2],m-1}$	$t_{[2],m}$
$t_{[3]}$	$t_{[3],1}$	$t_{[3],2}$	$\cdots$	$t_{[3],m-1}$	$t_{[3],m}$
$t_{[4]}$	$t_{[4],1}$	$t_{[4],2}$	$\cdots$	$t_{[4],m-1}$	$t_{[4],m}$
$t_{[5]}$	$t_{[5],1}$	$t_{[5],2}$	$\cdots$	$t_{[5],m-1}$	$t_{[5],m}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
$t_{[n-1]}$	$t_{[n-1],1}$	$t_{[n-1],2}$	$\cdots$	$t_{[n-1],m-1}$	$t_{[n-1],m}$
$t_{[n]}$	$t_{[n],1}$	$t_{[n],2}$	$\cdots$	$t_{[n],m-1}$	$t_{[n],m}$

Envelope simulado: Atkinson

Envelope simulado: Atkinson

5) Obtemos os limites $t_{[i],[1]} = \min_j(t_{[i],j})$ e $t_{[i],[m]} = \max_j(t_{[i],j})$.

Envelope simulado: Atkinson

5) Obtemos os limites $t_{[i],[1]} = \min_j(t_{[i],j})$ e $t_{[i],[m]} = \max_j(t_{[i],j})$. Assim, os limites correspondentes a $t_{[i]}$ serão dados por $t_{[i],[1]}$ e $t_{[i],[m]}$, como presente na Tabela 3 (sugestão de Atkinson: m = 19).

Envelope simulado: Atkinson

5) Obtemos os limites $t_{[i],[1]} = \min_j(t_{[i],j})$ e $t_{[i],[m]} = \max_j(t_{[i],j})$. Assim, os limites correspondentes a $t_{[i]}$ serão dados por $t_{[i],[1]}$ e $t_{[i],[m]}$, como presente na Tabela 3 (sugestão de Atkinson: m = 19).

Tabela: Obtendo os limites correspondentes de cada resíduo.

	Réplica 1	Réplica 2	...	Réplica $m-1$	Réplica m	Mínimo	Resíduo Original	Máximo
5) $\Rightarrow$	$t_{[1],1}$	$t_{[1],2}$	$\cdots$	$t_{[1],m-1}$	$t_{[1],m}$	$t_{[1],[1]}$	$t_{[1]}$	$t_{[1],[m]}$
$\Rightarrow$	$t_{[2],1}$	$t_{[2],2}$	$\cdots$	$t_{[2],m-1}$	$t_{[2],m}$	$t_{[2],[1]}$	$t_{[2]}$	$t_{[2],[m]}$
$\Rightarrow$	$t_{[3],1}$	$t_{[3],2}$	$\cdots$	$t_{[3],m-1}$	$t_{[3],m}$	$t_{[3],[1]}$	$t_{[3]}$	$t_{[3],[m]}$
$\Rightarrow$	$t_{[4],1}$	$t_{[4],2}$	$\cdots$	$t_{[4],m-1}$	$t_{[4],m}$	$t_{[4],[1]}$	$t_{[4]}$	$t_{[4],[m]}$
$\Rightarrow$	$t_{[5],1}$	$t_{[5],2}$	$\cdots$	$t_{[5],m-1}$	$t_{[5],m}$	$t_{[5],[1]}$	$t_{[5]}$	$t_{[5],[m]}$
	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$\Rightarrow$	$t_{[n-1],1}$	$t_{[n-1],2}$	$\cdots$	$t_{[n-1],m-1}$	$t_{[n-1],m}$	$t_{[n-1],[1]}$	$t_{[n-1]}$	$t_{[n-1],[m]}$
$\Rightarrow$	$t_{[n],1}$	$t_{[n],2}$	$\cdots$	$t_{[n],m-1}$	$t_{[n],m}$	$t_{[n],[1]}$	$t_{[n]}$	$t_{[n],[m]}$

Envelope simulado: Everitt/Paula

Envelope simulado: Everitt/Paula

- Envelope simulado: Everitt/Paula

Envelope simulado: Everitt/Paula

- Envelope simulado: Everitt/Paula
  - Podemos gerar um m consideravelmente maior e usar como limites inferiores e superiores não o mínimo e o máximo, mas valores tais que produzam uma espécie de banda com $\gamma \times 100\%$ de confiança.

Envelope simulado: Everitt/Paula

- Envelope simulado: Everitt/Paula

– Podemos gerar um m consideravelmente maior e usar como limites inferiores e superiores não o mínimo e o máximo, mas valores tais que produzam uma espécie de banda com $\gamma \times 100\%$ de confiança.

– Everitt (1994) sugere utilizar $m = 100$ e determinar as bandas do envelope atribuindo ao limite inferior e ao limite superior os vetores $t_{[i],[5]}$ e $t_{[i],[95]}$, respectivamente, para $i = 1, \ldots, n$.

Envelope simulado: Everitt/Paula

- Envelope simulado: Everitt/Paula

– Podemos gerar um m consideravelmente maior e usar como limites inferiores e superiores não o mínimo e o máximo, mas valores tais que produzam uma espécie de banda com $\gamma \times 100\%$ de confiança.

– Everitt (1994) sugere utilizar $m = 100$ e determinar as bandas do envelope atribuindo ao limite inferior e ao limite superior os vetores $t_{[i],[5]}$ e $t_{[i],[95]}$, respectivamente, para $i = 1, \ldots, n$.

– Posteriormente, Paula (2013) propõe uma modificação, definindo o limite inferior como a média dos vetores $t_{[i],[2]}$ e $t_{[i],[3]}$, e o limite superior como a média dos vetores $t_{[i],[97]}$ e $t_{[i],[98]}$, para $i = 1, \ldots, n$.

Envelope simulado

Observações

Envelope simulado

Observações

- Se apenas a observação com maior valor de resíduo (em módulo) estiver fora do envelope, é um indício de que este ponto é um outlier.

Envelope simulado

Observações

- Se apenas a observação com maior valor de resíduo (em módulo) estiver fora do envelope, é um indício de que este ponto é um outlier. Muitos pontos fora do envelope sugerem problemas com a suposição de normalidade ou alguma outra suposição do modelo.

Envelope simulado

Observações

- Se apenas a observação com maior valor de resíduo (em módulo) estiver fora do envelope, é um indício de que este ponto é um outlier. Muitos pontos fora do envelope sugerem problemas com a suposição de normalidade ou alguma outra suposição do modelo.
- O procedimento aqui descrito pode ser usado em diversas diferentes classes de modelos de regressão.

Envelope simulado

Observações

- Se apenas a observação com maior valor de resíduo (em módulo) estiver fora do envelope, é um indício de que este ponto é um outlier. Muitos pontos fora do envelope sugerem problemas com a suposição de normalidade ou alguma outra suposição do modelo.

- O procedimento aqui descrito pode ser usado em diversas diferentes classes de modelos de regressão. No caso do MLGer, com $y \sim N_n(\mathbf{X}\beta, \sigma^2\mathbf{I})$, o envelope pode ser gerado de forma mais simples (ver Paula (2013)).

Exemplo de envelope

Exemplo de envelope

- Método de rejeição de modelo proposto por Fernandes (2019).

Exemplo de envelope

- Método de rejeição de modelo proposto por Fernandes (2019).

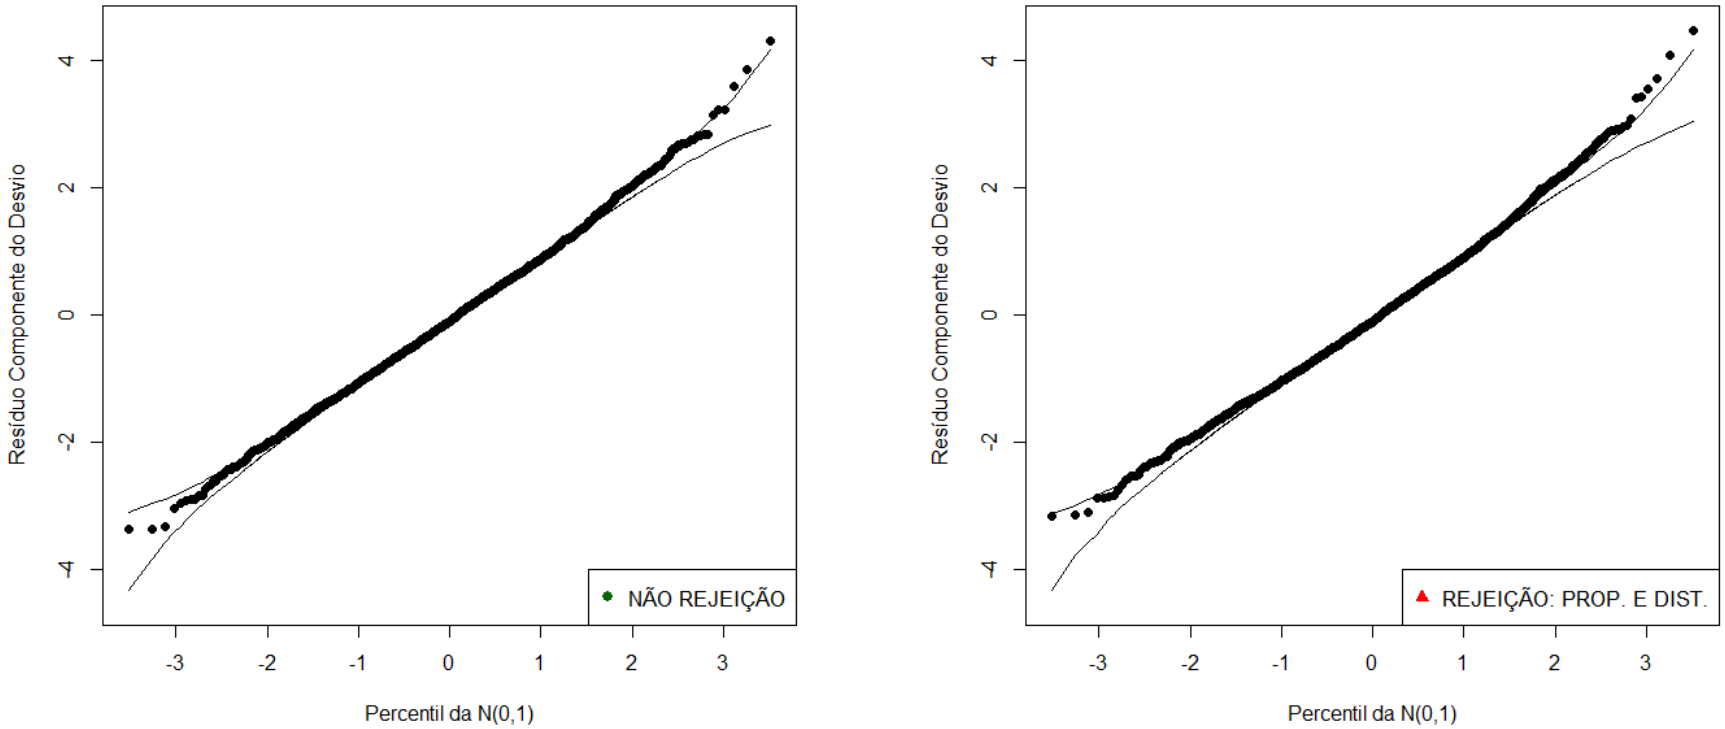


Figura: Método de rejeição proposto aplicado ao gráfico normal probabilístico utilizando a distribuição normal inversa (esquerda) e a distribuição gama (direita).

Verificações adicionais

Verificações adicionais

Também é interessante fazer gráficos de t_i em função de variáveis presentes e ausentes no modelo.

Verificações adicionais

Também é interessante fazer gráficos de t_i em função de variáveis presentes e ausentes no modelo.

A observação de algum padrão sugere que a variável não foi incluída de forma adequada no modelo caso ela esteja presente ou que deveria ser incluída no modelo caso ela esteja ausente.

Gráfico que sugere inclusão inadequada de variável preditora no modelo

