26 08 18 1ª aula

MLGen : classe de modelos

Modelos Lineares Generalizados

Ref: Paula. G.A – "MLG com apoio computacional"

P1: 15/10/26 P2: 10/12/26

TR: 26/11/26 1/12/26 3/12/26

Prova: Pode trazer folha A4

Relembrando que MLGeral tem as seguintes limitações:

MLGeral assume $\underset{\sim}{y}|X \sim N_n(X\underset{\sim}{\beta}, \sigma^2 I)$

Mas muitas vezes não é razoável supor isso acima.

Família Exponencial na forma canônica

$$f(y;\theta) = h(y) \cdot \exp\{\theta y - b(\theta)\}$$

* Parametro de pertubação: ϕ

Família exp. Linear (FEL):

$$f(y;\theta,\phi) = \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}$$

FGM da FEL

Note:

$$\int_{-\infty}^{\infty} \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\}\, dy = 1$$

$$= \exp[-\phi b(\theta)] \cdot \int \exp\{\phi\theta y + c(y,\phi)\} dy = 1$$

$$\Rightarrow \int \exp\{\phi\theta y + c(y,\phi)\} dy = \exp[\phi b(\theta)] \quad (I)$$

Note:

$$M_y(t) = E(\exp(ty)) = \int \exp(ty) \cdot \exp\{\phi[\theta y - b(\theta)] + c(y,\phi)\} d$$

$$= \exp(-\phi b(\theta)) \cdot \int \exp\{\phi\theta y + c(y,\phi) + ty\} dy$$

$$= \exp(-\phi b(\theta)) \cdot \int \exp\{y(\phi\theta + t) + c(y,\theta)\}\, dy$$

$$= \exp(-\phi b(\theta)) \cdot \underbrace{\int \exp\{ y\phi(\theta + t\phi^{-1}) + c(y,\theta)\}\, dy}_{\text{semelhante a (I)}}$$

$$= \exp(-\phi b(\theta)) \cdot \exp(\phi\, b(\theta + t\phi^{-1}))$$

$$= \exp\{-\phi\, b(\theta) + \phi b(\theta + t\phi^{-1})\} = \exp\{\phi[b(\theta + t\phi^{-1}) - b(\theta)]\}$$

Obtendo os momentos:

1º: $\left.\dfrac{\partial M_y(t)}{\partial t}\right|_{t=0} = \exp\{\phi[b(\theta + t\phi^{-1}) - b(\theta)]\} \cdot \cancel{\phi}\, b'(\theta + t\phi^{-1}) \cdot \cancel{\phi^{-1}}$

* $t=0$

$$= \exp\{\cancel{\phi[b(\theta) - b(\theta)]}\} \cdot b'(\theta) = b'(\theta)$$

↑ Deriva em θ

26 de 20 — 2ª aula

$$\frac{\partial M_y(t)}{\partial t} = \exp\{\phi[b(\phi^{-1}t + \theta) - b(\theta)]\} \cdot b'(\theta + t\phi^{-1})$$

$$\Rightarrow \frac{\partial^2 M_y(t)}{\partial t^2} = \exp\{\phi[b(\phi^{-1}t+\theta)-b(\theta)]\}\cdot(b'(\theta+t\phi^{-1}))^2 + \exp\{\phi[b(\phi^{-1}t+\theta)-b(\theta)]\}\cdot b''(\theta+t\phi^{-1})\cdot\phi^{-1}$$

$$= \exp\{\phi[b(\phi^{-1}t+\theta)-b(\theta)]\}\cdot\left(b'(\theta+t\phi^{-1})^2 + b''(\theta+t\phi^{-1})\cdot\phi^{-1}\right)$$

$$\Rightarrow \left.\frac{\partial^2 M_y(t)}{\partial t^2}\right|_{t=0} = 1\cdot b'(\theta)^2 + b''(\theta)\cdot\phi^{-1} = E(Y^2)$$

* $Var(Y) = E(Y^2) - E^2(Y) = b'(\theta)^2 + b''(\theta)\cdot\phi^{-1} - b'(\theta)^2$

$$\Rightarrow Var(Y) = b''(\theta)\,\phi^{-1}$$

* $b''(\theta) = V(\mu)$ é denominada função de variância

Exemplo 1: Poisson: $f(y,\mu) = \frac{e^{-\mu}\mu^y}{y!}$ mostre que é exp

Relembrando que FEL: $\exp\{\phi[y\theta - b(\theta)] + c(y,\theta)\}$

$$\Rightarrow f(y,\mu) = \frac{e^{-\mu}\cdot\mu^{y}}{y!} = \exp(-\mu)\cdot\exp(\log\mu^{y})\cdot\exp(-\log y!)$$

$$= \exp\{-\mu + y\log\mu - \log y!\}$$

$$= \exp\{y\log\mu - \mu - \log y!\}$$

* $\phi = 1 \quad \theta = \log\mu$

$b(\theta) = \mu = \exp(\theta) \quad c(y,\theta) = -\log y!$

Sabemos que $E(y) = b'(\theta) = e^{\theta} = \mu \quad b''(\theta) = e^{\theta} = \mu = Var(y)$

Gamma: $f(y,\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}}\cdot y^{\alpha-1}\cdot\exp\left\{-\frac{y}{\beta}\right\}$

$E(Y) = \alpha\cdot\beta \qquad Var(y) = \alpha\beta^{2}$

(Reparametrização, serve p/ facilitar)

Sejam $\mu = \alpha\cdot\beta$ e $\lambda = \alpha \quad \Rightarrow \beta = \frac{\mu}{\lambda}$ e $\alpha = \lambda$

$$\Rightarrow f(y,\mu,\lambda) = \frac{1}{\Gamma(\lambda)\cdot(\mu/\lambda)^{\lambda}}\cdot y^{\lambda-1}\cdot\exp\left\{-\frac{\lambda y}{\mu}\right\}$$

$E(y) = \mu \qquad Var(y) = \frac{\mu^{2}}{\lambda}$

Mostrando que é da fam. exp. lin

$$f(y;\mu,\lambda) = \exp\left\{-\log\Gamma(\lambda) - \lambda\log\mu + \lambda\log\lambda + (\lambda-1)\log y - \frac{\lambda y}{\mu}\right\}$$

Note: $\phi = \lambda \quad \theta = \frac{-1}{\mu} \Rightarrow \lambda = \phi$ e $\mu = \frac{-1}{\theta}$

$$\Rightarrow \exp\left\{\lambda\left[\frac{-y}{\mu} - \log\mu\right] - \log\Gamma(\lambda) + \lambda\log\lambda + \lambda - 1\log y\right\}$$

$$\Rightarrow b(\theta) = \log\mu = \log\left(\frac{-1}{\theta}\right) = \log\left(\frac{1}{-\theta}\right) = -\log(-\theta)$$

$$\Rightarrow c(y,\lambda) = 0 \text{ que sobrou}$$

$$E(Y) = b'(\theta) = -\frac{1}{-\theta} + 1) = \frac{1}{-\theta} = \frac{1}{\frac{-1}{\mu}} = \mu$$

$$Var(Y) = b''(\theta)\cdot\phi^{-1} = \frac{1}{\lambda}\cdot\left(\frac{0+1}{\theta^2}\right) = \frac{1}{\lambda\cdot\theta^2} = \frac{1}{\lambda\left(\frac{-1}{\mu}\right)^2} = \frac{\mu^2}{\lambda}$$

Def: MLG.

Sejam $Y_1, Y_2, \dots Y_n$ v.a's indep. cada uma com dist. que pertencem FEL com parâmetros θ_i e ϕ.

↑ não é igual p/ todos necessariamente

Os MLGs são definidos pela eq. mostrada acima ($\exp\{\phi \dots\}$) e pelo componente sistemático:

$$g(\mu_i) = \underset{\sim}{x}_i^T \underset{\sim}{\beta}$$

em que

$\mu_i = E(Y_i) = b'(\theta_i)$

$\underset{\sim}{\beta} = (\beta_0 \ \beta_1 \ \cdots \ \beta_k)^T$

$\underset{\sim}{x}_i = (1 \ x_{i1} \ x_{i2} \ \cdots \ x_{ik})^T$

e g é função de ligação estritamente monótona e pelo menos duplamente diferenciável

MLG possui seguintes componentes:

Variável resposta

Componente sistemático: representado pelo $\underset{\sim}{x}_i^T \underset{\sim}{\beta} = \eta_i$.

Função de ligação $g(\cdot)$

* Se um parâmetro possui valor conhecido, é dito offset.

Para ajustar um MLGen, precisa escolher uma dist. ADEQUADA p/ variável resposta, escolher as covoriáveis do modelo e uma função de ligação $g(\cdot)$

* MLGeral é um caso particular de MLGen quando $g(\cdot)$ = identidade

*
MLGen não requer normalidade

* Não é necessário fazer transformação

* A variância não precisa ser igual p/ todas pois em FEL $Var(y_i) = \phi^{-1} \cdot b''(\theta_i)$

Função de ligação $g(\cdot)$ é dita Canônica quando $g(\mu_i) = \theta_i$

no caso da poisson $g(\mu_i) = \log \mu_i \Rightarrow \log \mu_i = \underset{\sim}{x_i}^T \underset{\sim}{\beta}$

ou $\mu_i = \exp^{\underset{\sim}{x_i}^T \underset{\sim}{\beta}}$

* Vantagens da função de ligação canônica

- garante a unicidade do EMV
- facilita a obtenção da estat. suf p/ $\underset{\sim}{\beta}$
- simplifica a estimação de $\underset{\sim}{\beta}$

* as vezes a função de ligação canônica não é a mais conveniente

26 08 25 3ª aula

Função de Ligação Canônica

Gama: se: $\frac{1}{\mu_i} = x_i^T\beta \Rightarrow \hat{\mu}_i = \frac{1}{x_i^T\beta}$

agora: $\log \mu_i = x_i^T\beta \Rightarrow \mu_i = \exp^{x_i^T\beta}$

Funções de ligações do Box-Cox:

$$g(\mu_i) = \begin{cases} \frac{\mu_i^{\lambda} - 1}{\lambda}, & \text{se } \lambda \neq 0 \\ \log \mu_i, & \text{se } \lambda = 0 \end{cases}$$

*p/ respostas binárias, além da f de ligação canônica

Probito: $g(\mu_i) = \Phi^{-1}(\mu_i)$, em que Φ é f.d.a da $N(0,1)$

e

Complemento log-log: $g(\mu_i) = \log[-\log(1-\mu_i)]$

Função de desvio

seja $l(\mu, y) = \sum_{i=1}^{n} l(\mu_i, y_i)$ a função de Verossimilhança

em que

$\mu_i = g^{-1}(\eta_i)$ e $\eta_i = x_i^T \beta$

Se $k+1 = n$, o modelo é denomido saturado

e $\tilde{\mu}_i = y_i$

$$\hat{l}(\mu, y) = \sum_{i=1}^{n} l(y_i, y_i) = l(y, y)$$

pois nesse caso $\hat{\mu}_i = y_i$

Quando $n > k+1$, $\hat{l}(\mu, y) = l(\hat{\mu}, y)$

Medida absduta da capacidade preditiva ↙ Função Desvio

$$D(y, \hat{\mu}) = 2[l(y, y) - l(\hat{\mu}, y)]$$

Uma função desvio pequena indica que, para um número menor de parâmetro ....

Pode-se mostrar que a função desvio pode ser reescrita como

$$D(y, \hat{\mu}) = 2\phi\{\Sigma[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i)\}$$

Exemplo: Normal: $\theta_i = \mu_i$ $b(\theta_i) = \sigma_i^2/2$ e $\phi = 1/\sigma^2$

$$l(\underset{\sim}{y}, \hat{\mu}) = \frac{2}{\sigma^2}\left\{\sum\left[y_i(y_i - \hat{\mu}_i) + \frac{\hat{\mu}_i^2}{2} - \frac{y_i^2}{2}\right]\right\}$$

$$= l(\underset{\sim}{y}, \hat{\mu}) = \frac{2}{\sigma^2}\left\{\sum_{i=1}^{n}\left[\frac{y_i^2}{2} - y_i\hat{\mu}_i + \frac{\hat{\mu}_i^2}{2}\right]\right\}$$

$$\Rightarrow l(\underset{\sim}{y}, \hat{\mu}) = \frac{1}{\sigma^2}\sum_{i=1}^{n}(y_i - \hat{\mu}_i)^2 = \frac{(n-1)S^2}{\sigma^2} = \frac{SQRes}{\sigma^2}$$

Gama: $\theta_i = -1/\mu_i$ $b(\theta_i) = -\log(-\theta_i)$ e $\phi = \lambda$

$$\Rightarrow D(y, \hat{\mu}) = 2\cdot\lambda\left\{\sum\left[y_i\left(\frac{-1}{y_i} + \frac{1}{\hat{\mu}_i}\right) - \log\left(\frac{1}{\hat{\mu}_i}\right) + \log\left(\frac{1}{y_i}\right)\right]\right\}$$

$$= 2\lambda\left\{\sum\left[\left(\frac{y_i}{\hat{\mu}_i} - 1\right) + \log(\hat{\mu}_i) - \log y_i\right]\right\}$$

$$= 2\lambda\left\{\sum\left[\log\frac{\hat{\mu}_i}{y_i} + \frac{y_i - \hat{\mu}_i}{\hat{\mu}_i}\right]\right\}$$

Estimação Pontual ($\underset{\sim}{\beta}$ e ϕ)

Use estimação por máxima verossimilhança

$$f(y_i;\theta_i,\phi) = \exp\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i,\phi)\}$$

$$\Rightarrow L(\underset{\sim}{\beta},\phi) = \exp\{\phi \sum[(\theta_i y_i - b(\theta_i)) + c(y_i,\phi)]\}$$

$$\Rightarrow l(\underset{\sim}{\beta},\phi) = \sum_{i=1}^{n}\{\phi[\theta_i y_i - b(\theta_i)] + c(y_i,\phi)\}$$

$$= \left\{\phi \sum_{i=1}^{n}[\theta_i y_i - b(\theta_i)]\right\} + \sum_{i=1}^{n} c(y_i,\phi)$$

Note que $\underset{\sim}{\beta}$ e ϕ são $K+2$ parâmetros no total

Vetor de derivadas de 1ª ordem de $l(\underset{\sim}{\beta},\phi)$ é $U(\underset{\sim}{\gamma})$
$= U(\underset{\sim}{\beta},\phi)$ de dimensão $K+2$

$$\Rightarrow U(\underset{\sim}{\gamma}) = U(\underset{\sim}{\beta},\phi) = \begin{bmatrix} U(\underset{\sim}{\beta}) \\ U(\phi) \end{bmatrix}$$

$$\ell\left(\underset{\sim}{\beta}, \phi\right) = \sum_{i=1}^{n} \phi\left[y_i \theta_i - b(\theta_i)\right] + \sum_{i=1}^{n} c(y_i, \phi) = \sum_{i=1}^{n} \ell_i(\underset{\sim}{\beta}, \phi)$$

Temos que $\theta_i = q(\mu_i)$ $\quad \mu_i = g^{-1}(\eta_i) = h(\eta_i)$ e $\quad \eta_i = \sum_{j=0}^{k} x_j \beta_j$

$$\Rightarrow U_{\beta r} = \frac{\partial \ell(\underset{\sim}{\beta}, \phi)}{\partial \beta_r} = \frac{\partial \sum \ell_i(\underset{\sim}{\beta}, \phi)}{\partial \beta_r} = \sum_{i=1}^{n} \frac{\partial \ell_i(\underset{\sim}{\beta}, \phi)}{\partial \beta_r}$$

$$= \Sigma \left\{ \frac{\partial\, \ell_i(\beta_i, \phi)}{\partial \theta_i} \cdot \frac{\partial \theta_i}{\partial \mu_i} \cdot \frac{\partial \mu_i}{\partial \eta_i} \cdot \frac{\partial \eta_i}{\partial \beta_r} \right\}$$

* note então:

$$\frac{\partial \ell_i(\underset{\sim}{\beta}, \phi)}{\partial \theta_i} = \phi\left[y_i - b'(\theta_i)\right] = \phi\left[y_i - \mu_i\right]$$

$$\frac{\partial \theta_i}{\partial \mu_i} : \frac{\partial \mu_i}{\partial \theta_i} = \frac{\partial\, b'(\theta_i)}{\partial \theta_i} = b''(\theta_i) = V_i \Rightarrow \frac{\partial \theta_i}{\partial \mu_i} = V_i^{-1}$$

$$\frac{\partial \mu_i}{\partial \eta_i} = \frac{\partial g^{-1}(\eta_i)}{\partial \eta_i}$$, melhor deixar $\frac{\partial \mu_i}{\partial \eta_i}$

$$\frac{\partial \eta_i}{\partial \beta_r} = x_{ir}$$

$$\Rightarrow U_r = \phi \sum_{i=1}^{n} (y_i - \mu_i) \cdot \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}$$

EMV de β é obtido igualando U_r a zero mas U_r são não lineares. tem que resolver numericamente. com processes iterativos>

---

26 08 27 4ª aula

Métodos p/ resolver:

Ideias: Newton - Raphson e Scoring de Fisher.

Newton - Raphson.

Exp de Taylor de 1ª ordem de $f(x)$ em x_0

$$f(x) = f(x_0) + f'(x_0)(x - x_0) = 0$$

$$\Rightarrow x = \frac{f'(x_0)\, x_0 - f(x_0)}{f'(x_0)} = x_0 - \frac{f(x_0)}{f'(x_0)}$$

Generalizando: $x^{(m+1)} = x^m - \frac{f(x^m)}{f'(x^m)}$

Se quisermos estimar um único parâmetro λ

$\Rightarrow \lambda^{(m+1)} = \lambda^{(m)} - \frac{\partial l(\lambda)}{\partial \lambda} \cdot \left(\frac{\partial^2 l(\lambda)}{\partial \lambda^2} \right)^{-1}$

$\underset{\sim}{\beta}^{(m+1)} = \underset{\sim}{\beta}^{(m)} + \left[J_{\beta\beta}^{(m)} \right]^{-1} U_\beta^m$

* J é o matriz Negativo da 2ª derivada

* Note que $J_{\beta\beta}^{(m)}$ precisa ser positiva-definida as vezes não podemos prosseguir.

Scoring de Fisher: usa info de Fisher.

substitua $J_{\beta\beta}^m$ por $E(J_{\beta\beta}) = K_{\beta\beta}$, $K_{rs} = -E\left[\frac{\partial^2 l(\beta, \phi)}{\partial \beta_r \partial \beta_s} \right]$

Relembre que:

sob condições de regularidade $-E\left(\frac{\partial^2 l(\beta,\phi)}{\partial \beta_r \partial \beta_s} \right) = E\left(\frac{\partial l(\beta,\phi)}{\partial \beta_r} \frac{\partial l(\beta,\phi)}{\partial \beta_s} \right)$

Pode mostrar que

$$K_{rs} = \phi \sum_{i=1}^{n} w_i x_{ir} x_{is} \quad , \text{ onde } w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2$$

$\Rightarrow$ $K_{\beta\beta}$ pode ser reescrita como:

$$K_{\beta\beta} = \phi X^T W X$$

e

$$W = \text{diag}\{w_1, \dots w_n\} = \begin{bmatrix} w_1 & & 0 \\ & \ddots & \\ 0 & & w_n \end{bmatrix}$$

Podemos reescrever U_β correspondente a βr como

$$U_r = \phi \sum (y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir} \cdot \frac{\partial \mu_i}{\partial \eta_i} \left(\frac{\partial \mu_i}{\partial \eta_i}\right)^{-1}$$

$$= \phi \sum (y_i - \mu_i) \cdot w_i \cdot \frac{\partial \eta_i}{\partial \mu_i} \cdot x_{ir}$$

Assim podemos reescrever U_β como

* lembrete $\eta_i = g(\mu_i)$

$$U_\beta = \phi X^T W G (\underset{\sim}{y} - \underset{\sim}{\mu})$$

onde $G = \text{diag}\{g'(\mu_1), \dots g'(\mu_n)\} = \begin{bmatrix} g'(\mu_1) & & 0 \\ & \ddots & \\ 0 & & g'(\mu_n) \end{bmatrix}$

* método de min. quads ponderado interativo é apenas uma versão particular de scoring de Fisher.

Vamos Premultiplicar com $K_{\beta\beta}$ no passo m.

$$K_{\beta\beta}^{(m)} \underset{\sim}{\beta}^{(m+1)} = K_{\beta\beta}^{(m)} \underset{\sim}{\beta}^{(m)} + I \cdot U_\beta^{(m)}$$

$$\Rightarrow \cancel{\phi} X^T W^m X \cdot \beta^{(m+1)} = \cancel{\phi} X^T W^m X \beta^{(m)} + \cancel{\phi} X^T W^m G^m (y - \mu^m)$$

$$\Rightarrow X^T W^m X \beta^{(m+1)} = X^T W^{(m)} \left(X\beta^{(m)} + G^m (y - \mu^{(m)}) \right)$$

$$\Rightarrow X^T W^m X \beta^{(m+1)} = X^T W^{(m)} \cdot \underbrace{\left[\eta^{(m)} + G^m (y - \mu^{(m)}) \right]}_{z^{(m)}}$$

$$\Rightarrow X^T W^{(m)} X \beta^{m+1} = X^T W^{(m)} \cdot z^{(m)}$$

$$\Rightarrow \beta^{(m+1)} = (X^T W^{(m)} X)^{-1} X^T W^{(m)} z^{(m)}$$

* MLGer é quando $W^{(m)} = I$

repare que $\eta_i = g(\mu_i) \Rightarrow \hat{\eta}_i = g(y_i)$

algoritmo: ① use $\eta_i = g(y_i)$ p/ calcular $w^{(0)}$ e $z^{(0)}$.

② calcule $\beta^{(1)} = \ldots$ ③ ④ ... repetir até convergir

Critério de convergência:

Exemplo: modelo Poisson com f. de ligação logarítmica (canônica)

Já sabemos que $\eta_i = \theta_i = \log(\mu_i)$, $b(\theta_i) = e^{\theta_i} = \mu_i$

$g(\mu_i)$ $V_i = b''(\theta_i) = e^{\theta_i} = \mu_i$ $\mu_i = e^{\eta_i} \Rightarrow \frac{\partial \mu_i}{\partial \eta_i} = \mu_i$

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = \frac{1}{\mu_i}\mu_i^2 = \mu_i$$

z_i: $z_i = \eta_i + G_{ii}(y_i - \mu_i)$ $\quad G_{ii} = g'(\mu_i) = \frac{d\log(\mu_i)}{d\mu_i}$

$\Rightarrow z_i = \log \mu_i + \frac{1}{\mu_i}(y_i - \mu_i)$ $\quad = 1/\mu_i$

ou

$= \eta_i + \left(\frac{y_i - e^{\eta_i}}{e^{\eta_i}}\right)$

* Note que nesse caso $w_i = V_i$. Isso ocorre com função de ligação canônica. pois $\eta_i = \theta_i$

$$w_i = \frac{1}{V_i}\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2 = \frac{1}{V_i} V_i^2 = V_i$$

Exemplo 2: Gama com f. de ligação logaritmica.

$V_i = \mu_i^2$

$\Rightarrow w_i = \frac{1}{\mu^2} \cdot \mu_i^2 = 1$ pois $g(\mu_i) = \log(\mu_i)$

$\Rightarrow$ a mesma expressão p/ z_i

26/09/01 5ª aula

Relembrando que

$$\beta^{(m+1)} = (X^T W^{(m)} X)^{-1} X^T W^{(m)} z^{(m)}$$

Exemplo 2 com dados.

x	y
1	4
2	6
3	9
4	15

* $g(\mu_i) = \log \mu_i = \eta_i \quad \eta_i^0 = \log y_i$

e $z_i = \frac{1}{\mu_i}$

$$\Rightarrow \eta^{(0)} = \begin{bmatrix} \log 4 \\ \log 6 \\ \log 9 \\ \log 15 \end{bmatrix} \qquad W^{(0)} = I_{4\times 4} \qquad z_i^{(0)} = \log y_i + \frac{y_i - y_i}{y_i} = 0$$

$$\Rightarrow z^{(0)} = \eta^{(0)}$$

$$\Rightarrow \beta^{(1)} = (X^T W^{(0)} X)^{-1} X^T W^{(0)} z^{(0)} = \left(\begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{bmatrix} \right)^{-1} X^T I z^{(0)}$$

$$= \begin{bmatrix} 4 & 10 \\ 10 & 30 \end{bmatrix}^{-1} \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 \end{bmatrix} z^{(0)}$$

$$\underset{2\times 2}{\begin{bmatrix} 30 & -10 \\ -10 & 4 \end{bmatrix}} \cdot \left(\frac{1}{120-100}\right) \cdot \underset{2\times 4}{\begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 \end{bmatrix}} \underset{4\times 1}{\begin{bmatrix} \log 4 \\ \log 6 \\ \log 9 \\ \log 15 \end{bmatrix}} = \begin{bmatrix} \beta_0^{(1)} \\ \beta_1^{(1)} \end{bmatrix}$$

Note que $W = I$ p/ todos os passos nesse caso

$$\eta^{(1)} = X \cdot \underset{\sim}{\beta}^{(1)} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 \end{bmatrix}^T \begin{bmatrix} \beta_0^{(1)} \\ \beta_1^{(1)} \end{bmatrix} = \begin{bmatrix} \beta_0^{(1)} + \beta_1^{(1)} \cdot 1 \\ \vdots \\ \beta_0^{(1)} + \beta_1^{(1)} \cdot 4 \end{bmatrix}$$

e $\mu_i = e^{\eta_i} \Rightarrow \underset{\sim}{\mu}^{(1)} = e^{\eta^{(1)}} =$

$$\underset{\sim}{\mu}^{(1)} = \begin{bmatrix} e^{\beta_0^{(1)} + \beta_1^{(1)} \cdot 1} \\ \vdots \\ e^{\beta_0^{(1)} + \beta_1^{(1)} \cdot 4} \end{bmatrix}$$

Repetir até convergir

//

Estimação de ϕ por max. verossilhança

$$l(\beta, \phi) = \sum \{\phi[y_i \theta_i - b(\theta_i)]\} + \sum c(y_i, \phi)$$

$$\Rightarrow \frac{\partial \ell(\beta,\phi)}{\partial \phi} = \sum [y_i\theta_i - b(\theta_i)] + \sum \frac{\partial c(y_i,\phi)}{\partial \phi} = U_\phi$$

Exemplo: Gaussiana Inversa $\Rightarrow \theta_i = -\frac{1}{2\mu_i^2}$, $b(\theta_i) = -(-2\theta_i)^{0,5} = -\frac{1}{\mu_i}$.

* $U_\phi = \sum y_i\theta_i - b(\theta_i) + \sum \frac{\partial c(y_i,\phi)}{\partial \phi}$.

$$c(y_i,\phi) = \frac{1}{2}\log\left(\frac{\phi}{2\pi y_i^3}\right) - \frac{\phi}{2y_i}$$

$$\Rightarrow U_\phi = \sum \left\{\frac{-y_i}{2\mu_i^2} + \frac{1}{\mu_i}\right\} + \sum \left\{\frac{1}{2\hat{\phi}} - \frac{1}{2y_i}\right\} = 0$$

$$\Rightarrow \frac{n}{2\hat{\phi}} = \sum \frac{y_i}{2\mu_i^2} - \sum \frac{1}{\mu_i} + \sum \frac{1}{2y_i}$$

$$\Rightarrow \hat{\phi} = \frac{n}{2\left(\sum \frac{y_i}{2\mu_i^2} - \sum \frac{1}{\mu_i} + \sum \frac{1}{2y_i}\right)} = \frac{n}{\left\{\sum \left(\frac{y_i}{\mu_i^2} - \frac{2}{\mu_i} + \frac{1}{y_i}\right)\right\}}$$

$$= \frac{n}{\sum \left(\frac{y_i^2 - 2\mu_i y_i + \mu_i^2}{\mu_i^2 \cdot y_i} \right)} = \frac{n}{\sum \frac{(y_i - \mu_i)^2}{\hat{\mu}_i^2 y_i}} = \frac{n}{D^*(y, \hat{\mu})}$$

$$\Rightarrow \hat{\phi}^*_{MV} = \frac{n}{D^*(y, \hat{\mu})}$$

Estimação por método dos momentos

Pode-se mostrar que $\phi \sum \left(\frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \right) \overset{\cdot}{\sim} \chi^2_{n-k-1}$

Como $\hat{\phi} \sum \left[\frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \right] = n - k - 1$

$$\Rightarrow \hat{\phi}_{MM} = \frac{n-k-1}{\sum \left[\left(\frac{y_i - \hat{\mu}_i}{V\hat{\mu}_i} \right) \right]}$$

Matriz de informação de Fisher

sendo $\gamma = (\beta^T, \phi)^T$, a matriz de informação de Fisher de um MLGen é dada por

$$K(\gamma) = \begin{bmatrix} K_{\beta\beta} & K_{\beta\phi} \\ K_{\phi\beta} & K_{\phi\phi} \end{bmatrix}$$

$$K_{\phi\phi} = -E\left(\frac{\partial^2}{\partial\phi^2} l(\beta,\phi)\right) \cdot \frac{\partial l(\beta,\phi)}{\partial\phi} = -E\left(\sum_{i=1} \frac{\partial^2}{\partial\phi^2} c(y_i,\phi)\right)$$

$$* \quad \frac{\partial l(\beta,\phi)}{\partial\phi^2} = \sum \frac{\partial^2}{\partial\phi^2} c(y_i,\phi)$$

Ex. Gaussiana Inversa:

$$K_{\phi\phi} = -\sum E\left(\frac{-1}{2\phi^2}\right) = \frac{n}{2\phi^2}$$

Temos ainda $K_{\beta\phi} = K_{\phi\beta}^T$ (vetor $(k+1) \times 1$) sendo uma associada a cada um dos β_j do modelo

O termo associado a β_r é dado por

$$-E\left(\frac{\partial U_{\beta r}}{\partial \phi}\right), \quad U_{\beta r} = \phi \sum (y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}.$$

onde

$$\Rightarrow -E\left(\frac{\partial U_{\beta r}}{\partial \phi}\right) = \sum E\left[(y_i - \mu_i) \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir}\right]$$

$$= -\sum \frac{1}{V_i} \frac{\partial \mu_i}{\partial \eta_i} x_{ir} \cdot E(y_i - \mu_i) = 0$$

$\uparrow$

$E(y_i) = \mu_i$

$$\Rightarrow K(\gamma) = \begin{bmatrix} K_{\beta\beta} & 0 \\ 0 & K_{\phi\phi} \end{bmatrix}$$

$\uparrow$

é matriz bloco diagonal

Simplificação com a função de ligação canônica

Temos que quando a função de ligação é canônica, U_β e $K_{\beta\beta}$ simplificam

Sabendo que $W_i = V_i = \frac{\partial \mu_i}{\partial \theta_i}$ $\quad g_i = g'(\mu_i) = \frac{\partial \eta_i}{\partial \mu_i} = \frac{\partial \theta_i}{\partial \mu_i}$

$$\Rightarrow W_i g_i = \frac{\partial \mu_i}{\partial \theta_i} \cdot \frac{\partial \theta_i}{\partial \mu_i} = I \Rightarrow WG = 1$$

$\Rightarrow$ Nesse caso $K_{\beta\beta} = \phi X^T V X$

260903 6ª aula

Testes hipóteses e Intervalos de Confiança

Distribuição assintótica de $\hat{\gamma}$ = EMV de γ

pode se mostrar que $E(U(\gamma)) = 0$ e $Var(U(\gamma)) = K(\gamma)$

↑ sob condições de regularidade.

$\Rightarrow U(\gamma) \sim N_{k+2}(0, K(\gamma))$

$\Rightarrow \hat{\gamma} \overset{assin}{\sim} N_{k+2}(\gamma, K(\gamma)^{-1})$

podemos repartir $\hat{\gamma}$: $\hat{\beta} \sim N_{k+1}(\beta, K_{\beta\beta}^{-1})$ e $\hat{\phi} \sim N(\phi, K_{\phi\phi}^{-1})$

Teste de hipótese para um subconjunto de β

$\beta = (\beta_a^T, \beta_b^T)^T$.

↑ rearranjar para testar β's das ultimas posições

$H_0: \beta_b = \beta_b^{(0)}$ vs $H_1: \beta_b \neq \beta_b^{(0)}$. $\beta_b^{(0)} : k_2 \times 1$

* a hipótese nula gera as seguintes partições de $U(\gamma)$ e $K(\gamma)$

$$U(\gamma) = \begin{bmatrix} U_{\beta_a} \\ U_{\beta_b} \\ U_\phi \end{bmatrix} , K(\gamma) = \begin{bmatrix} K_{\beta_a \beta_a} & K_{\beta_a \beta_b} & K_{\beta_a \phi} \\ & \ddots & \vdots \\ & & \end{bmatrix}$$

$$K(\gamma)^{-1} = \begin{bmatrix} K^{\beta_a \beta_a} & K^{\beta_a \beta_b} & K^{\beta_a \phi} \\ K^{\beta_b \beta_a} & K^{\beta_b \beta_b} & K^{\beta_b \phi} \\ & \ddots & \end{bmatrix}$$

A partir dessa matriz $K(\gamma)^{-1}$, definem-se 4 diferentes testes de hipóteses

- razão de verossilhança, escore, wald, Gradiente

Sob H_0, todas tem dist assintotica qui-quadrado com k_2 gl.

Estatística do teste da razão de verossimilhança é dada por

$$\Omega_{RV} = 2[\ell(\hat{\beta}_a, \hat{\beta}_b, \hat{\phi}) - \ell(\tilde{\beta}_a, \tilde{\beta}_b, \tilde{\phi})$$

Estatística do teste escore é dada por

$$\Omega_E = (\bar{U}_{\beta_b})^T \bar{K}^{\beta_b \beta_b} \bar{U}_{\beta_b}, \text{ note: } \bar{K}^{\beta_b \beta_b} \neq \left[\bar{K}_{\beta_b \beta_b}\right]^{-1}$$

Exemplo: Teste de razão de verossim p/ testar $H_0: \beta_1 = 0$ vs $H_1: \beta_1 \neq 0$

no modelo de reg com Poisson de resposta:

$$\Rightarrow L(\beta_0, \beta_1) = \frac{\prod e^{-\mu_i} \mu_i^{y_i}}{y_i!} \Rightarrow \ell(\beta_0, \beta_1) = \sum \log\left\{\frac{e^{-\mu_i} \mu_i^{y_i}}{y_i!}\right\}$$

$$= \sum \log\left\{\frac{e^{-\beta_0 - \beta_1 x_i} (\beta_0 + \beta_1 x_i)^{y_i}}{y_i}\right\}$$

caso $g(\mu_i) = \log \mu_i = x_i^T \beta \Rightarrow \mu_i = e^{x_i^T \beta}$, ℓ seria diferente

Nesse caso é a identidade $g(\mu_i) = \mu_i$

$$= \sum \{ (-\beta_0 - \beta_1 x_i) + y_i \log(\beta_0 + \beta_1 x_i) - \log y_i! \}$$

$$\Rightarrow Q_{RV} = 2 \left[\sum \{ -\hat{\beta}_0 - \hat{\beta}_1 x_i + y_i \log(\hat{\beta}_0 + \hat{\beta}_1 x_i) - \cancel{\log y_i!} \} - \right.$$
$$\left. \sum \{ \tilde{\beta}_0 - y_i \log(\tilde{\beta}_0) + \cancel{\log y_i!} \} \right]$$

* $\tilde{\beta}_1 \overset{H_0}{=} 0$ e $\tilde{\beta}_0 = \bar{y}$

$$= 2 \cdot \sum \left\{ \tilde{\beta}_0 - \hat{\beta}_0 - \hat{\beta}_1 x_i + y_i \log \left(\frac{\hat{\beta}_0 + \hat{\beta}_1 x_i}{\tilde{\beta}_0} \right) \right\}$$

260908 7ª aula

Novo exemplo:

Teste de Wald: testar $H_0: \beta_1 = 0$ vs $H_1: \beta_1 \neq 0$ no modelo poisson com ligação logaritmica e 1 única covariável

$\Rightarrow \phi = 1$, $K_{\beta\beta} = X^T V X$

$$X = \begin{bmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{bmatrix}^T \Rightarrow K_{\beta\beta} = \begin{bmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{bmatrix} \begin{bmatrix} \mu_1 & & 0 \\ & \ddots & \\ 0 & & \mu_n \end{bmatrix} \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

* $V(\mu) = \mu = \lambda$, $\log \mu_i = \beta_0 + \beta_1 x$

$$\Rightarrow \mu_i = \exp\{\beta_0 + \beta_1 x_i\}$$

$$\Rightarrow X^T V = \begin{bmatrix} e^{\beta_0+\beta_1 x_1} & e^{\beta_0+\beta_1 x_2} & \cdots & e^{\beta_0+\beta_1 x_n} \\ x_1 e^{\beta_0+\beta_1 x_1} & x_2 e^{\beta_0+\beta_1 x_2} & \cdots & x_2 e^{\beta_0+\beta_1 x_2} \end{bmatrix}$$

$$\Rightarrow X^T V X = \begin{bmatrix} \sum_{i=1}^{n} e^{\beta_0+\beta_1 x_i} & \sum_{i=1}^{n} x_i e^{\beta_0+\beta_1 x_i} \\ \sum_{i=1}^{n} x_i e^{\beta_0+\beta_1 x_i} & \sum_{i=1}^{n} x_i^2 e^{\beta_0+\beta_1 x_i} \end{bmatrix}$$

$$\Rightarrow (X^T V X)^{-1} = (K_{\beta\beta})^{-1} = K^{\beta\beta}$$

$$= \underbrace{\frac{1}{\sum x_i^2 e^{\beta_0+\beta_1 x_i} \cdot \sum e^{\beta_0+\beta_1 x_i} - \left(\sum x_i e^{\beta_0+\beta_1 x_i}\right)^2}}_{(I)} \begin{bmatrix} \sum x^2 e^{\beta_0+\beta_1 x_i} & -\sum x_i e^{\beta_0+\beta_1 x_i} \\ -\sum x_i e^{\beta_0+\beta_1 x_i} & \sum e^{\beta_0+\beta_1 x_i} \end{bmatrix} \quad (1)$$

$K^{\beta_0\beta_0} = ?$

$H_0: \beta_1 = 0 \quad \Rightarrow \quad K^{\beta_1\beta_1} = \frac{\sum e^{\beta_0+\beta_1 x_i}}{(I)}$

$\hat{K}^{\beta_0\beta_0} = ? \qquad \hat{K}^{\beta_0\beta_0} = \frac{\sum e^{\hat{\beta}_0+\beta_1 x_i}}{\hat{(I)}}$

$$\underset{\sim}{\beta} = \begin{bmatrix} \beta_a \\ \beta_b \end{bmatrix}^{H_0}_{H_1} = \hat{\underset{\sim}{\beta}} = \begin{bmatrix} \hat{\beta}_a \\ \tilde{\beta}_b \end{bmatrix}, \quad \hat{\beta}_b = \hat{\beta}_1, \quad \beta_b^{(0)} = 0$$

$$\Rightarrow Q_W = \hat{\beta}_1^2 \cdot \left[\underbrace{\sum e^{\hat{\beta}_0 + \hat{\beta}_1 x_i}}_{\text{(I)}} \right]$$

Exemplo: Estatística escore no MLGeral

função de ligação Identidade, resposta normal e 1

$$g(\mu_i) = \mu_i = \eta_i = \beta_0 + \beta_1 x_i \qquad g'(\mu_i) = 1 = V_i = w_i$$

$$\Rightarrow H_0: \beta_1 = 0 \text{ vs } H_1: \beta_1 \neq 0 \qquad \phi = 1/\sigma^2$$

$$X = \begin{bmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{bmatrix}^T \qquad V = \begin{bmatrix} 1 & & 0 \\ & \ddots & \\ 0 & & 1 \end{bmatrix} \Rightarrow V = \begin{bmatrix} 1 & & 0 \\ & \ddots & \\ 0 & & 1 \end{bmatrix}$$

$$\Rightarrow K_{\beta\beta} = \begin{bmatrix} n & n\bar{x} \\ n\bar{x} & \sum x_i^2 \end{bmatrix} \frac{1}{\sigma^2}$$

$$\Rightarrow K^{\beta\beta} = \sigma^2 \frac{1}{n\sum x_i^2 - n\bar{x}^2} \begin{bmatrix} \sum x_i^2 - n\bar{x} \\ -n\bar{x} \quad n \end{bmatrix} = \frac{\sigma^2}{n \cdot \sum (x_i - \bar{x})^2} \begin{bmatrix} \sum x_i^2 & -\sum x_i \\ -\sum x_i & n \end{bmatrix}$$

$$U_\beta = \phi \cdot X^T (y-\mu) = \frac{1}{\sigma^2} \cdot \begin{bmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{bmatrix} \cdot \begin{bmatrix} y_1 - \mu_1 \\ \vdots \\ y_n - \mu_n \end{bmatrix}$$

$$\Rightarrow U_\beta = \frac{1}{\sigma^2} \begin{bmatrix} \sum (y_i - \mu_i) \\ \sum x_i (y_i - \mu_i) \end{bmatrix} = \frac{1}{\sigma^2} \cdot \begin{bmatrix} \sum (y_i - \mu_i) \\ \sum x_i (y_i - \mu_i) \end{bmatrix}$$

* $\mu_i = \beta_0 + \beta_1 x_i$

$$\tilde{K}^{\beta_1 \beta_1} = \frac{n \, \tilde{\sigma}^2}{n \sum (x_i - \bar{x})^2} = \frac{\tilde{\sigma}^2}{\sum (x_i - \bar{x})^2}$$

$$\tilde{U}_{\beta_1} = \frac{1}{\tilde{\sigma}^2} \sum x_i (y_i - \bar{y})$$

$$\Rightarrow Q_E = \left[\frac{1}{\tilde{\sigma}^2} \right]^2 \frac{\tilde{\sigma}^2}{\sum (x_i - \bar{x})^2} \left[\sum x_i (y_i - \bar{y}) \right]^2$$

$$= \frac{\left[\sum x_i (y_i - \bar{y}) \right]^2}{\sum (x_i - \bar{x})^2} \cdot \frac{1}{\tilde{\sigma}^2}$$

* $\sum x_i^2 - n\bar{x}^2 = \sum (x_i - \bar{x})^2$

2609 10 8ª aula

Obs: sempre que queremos testar 1 único $\beta_k = 0$, Qui é mais usada

Quando no teste tem mais de 1 parametro, teste de razão .V.

Amostras pequenas, usa-se preferencialmente versões corrigidas

Teste de hipóteses lineares gerais

Podemos ter interesse em $H_0: C\beta = t$ vs $H_1: C\beta \neq t$

Exemplo: $X = \begin{cases} \text{Sup} \\ \text{med} \\ \text{Escol + baix} \end{cases}$

$X_{i1} = \begin{cases} 1, & \text{se med} \\ 0, & \text{c.c} \end{cases}$

$X_{i2} = \begin{cases} 1, & \text{se baixa} \\ 0, & \text{c.c} \end{cases}$

Sup x med: $\beta_1 = 0$, Sup x baixa: $\beta_2 = 0$

med x baixa: $\beta_1 = \beta_2$

Relembre que Q_{RV} segue assintoticamente χ^2_q

Exemplo: $g(\mu_i) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3}$

$H_0: \beta_1 = \beta_2 = \beta_3 \Rightarrow C = \begin{bmatrix} 0 & 1 & -1 & 0 \\ 0 & 0 & 1 & -1 \end{bmatrix}$

$\Rightarrow$ modelo reduzido:

$$g(\mu_i) = \beta_0 + \beta_1 (x_{i1} + x_{i2} + x_{i3})$$

tem-se $\hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3$ Completo

e $\hat{\beta}_1^*$ reduzido

calcule Q_{RV}

Intervalos de Confiança p/ β_j

Sabemos que $\hat{\beta}$ é $N_{K+1}(\beta, (K_{\beta\beta})^{-1}) \Rightarrow \beta_j \sim N(\beta_j, k^{\beta_j \beta_j})$

$$\Rightarrow IC[\beta_j, 100(1-\alpha)\%] = \beta_j \mp z_{\frac{1-\alpha}{2}} \cdot \sqrt{\hat{k}^{\beta_j \beta_j}}$$

e

Contraste: $a^T\hat{\beta} \sim N(a^T\beta;\ a^T(\hat{k}_{\beta\beta})^{-1}a)$

IC p/ E(y)

Exemplo: $g(\mu_i) = x_i^T\beta = \eta_i$

Seja $x_0 = (1, x_{01}, \dots, x_{0(c)})$

$g(\mu_i) = x_i^T\beta = \eta_i \Rightarrow IC[\eta_i;\ 100(1-\alpha)] = \left[x_0^T\beta \mp z\sqrt{x_0^T \cdot k^{\beta_i\beta_i} \cdot x_0}\right]$

$\Rightarrow I(\mu_i = E(y);\ 100(1-\alpha)) = \left[g^{-1}(x_0^T\beta) \mp g^{-1}(\dots)\right]$

Analise de Diagnostico

- identificação de pontos discrepantes / influentes e afastamento de supos-
- usa os resíduos) - mede a discrepância.

Relembrando que: resíduos ordinários: $\hat{e} = (I-H)Y$ e $E(\hat{e}) = 0$

$Cov(\hat{e}_i, \hat{e}_j) = -h_{ij}\sigma^2$

$Var(\hat{e}_i) = \sigma^2(1-h_{ii})$

Propriedades de Hii: i) $\frac{1}{n} \leq h_{ii} \leq 1$ ii) $-0{,}5 \leq h_{ij} \leq 0{,}5$

iii) $\sum h_{ij}^2 = h_{ii}(1-h_{jj})$

Tipos de resíduos : r_i, $\hat{e}_i$, t_i ...

26 09 15 9ª aula

Pontos Influentes em MLGer

DFFits

mede a influência de cada observação sobre seu próprio valor ajustado sendo dada por

$$DFFits = \frac{|\hat{y}_i - \hat{y}_{(i)}|}{\sqrt{s_{(i)}^2 (1-h_{ii})}}$$

pode-se mostrar que:

$$DFFits = |t_i| \left(\frac{h_{ii}}{1-h_{ii}}\right)^{\frac{1}{2}}$$

Distância de Cook

Mede a influência de cada observação sobre os n valores ajustados sendo dada por.

$$d_i = \frac{\sum (\quad)}{(1-h_{ii})}$$

Exemplo

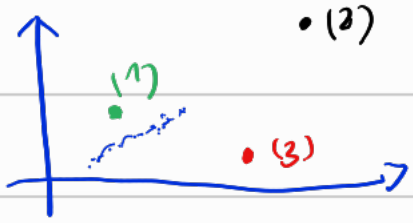

1) discrepante, pouco influente por ter h_{ii} baixo

2) alta leverage (alavancagem), mas pouco influente por ser não discrepante

3) discrepante, alta leverage, influente.

Relembre que

em MLGer: $\hat{\beta} = (X^T X)^{-1}(X^T y)$ $\qquad H = (X^T X)^{-1} X^T$

e

em MLGen: $\hat{\beta}_{m+1} = (X^T W^{(m)} X)^{-1} X^T W^{(m)} z^{(m)}$

$\Rightarrow \hat{W}^{\frac{1}{2}} X$ em MLGen seria o X de MLGer

$\Rightarrow$ em MLGen: $H = \hat{W}^{\frac{1}{2}} X (X^T \hat{W} X)^{-1} X^T \hat{W}^{1/2}$

Pontos discrepantes em MLGen

em MLGen não é possível obter que sejam identicamente distribuídos. Dessa forma, diversas formas foram propostas.

sabendo $Var(y_i) = \phi^{-1} V_i$ $\Rightarrow$ 1º resíduo: $r_i = \dfrac{y_i - \hat{y}_i}{\sqrt{\hat{\phi}^{-1} V_i}}$

Mas, pode se provar que $Var(r_i) \cong 1 - h_{ii}$

$\Rightarrow$ 2º resíduo: $t_{Si} = \dfrac{y_i - \hat{y}_i}{\sqrt{\hat{\phi}^{-1}\hat{V}_i\,(1-h_{ii})}}$ = resíduo de Pearson estudentizado

Porém, estudos: a dist de t_{Si} é assimétrica, mesmo em grandes amostras.

Probelema: intervalor de confiança assimétrica.

O resíduo mais conhecido em MLGen: usa função desvio.

Vimos que

$$D(\underset{\sim}{y}, \hat{\underset{\sim}{\mu}}) = 2\phi\left\{\sum y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i)\right\} = \sum d^2(y_i, \hat{\mu}_i)$$

em que $d(y_i, \hat{\mu}_i) = \pm\sqrt{2\phi}\left[y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i)\right]^{\frac{1}{2}}$ *

$Var(d(y_i, \hat{\mu}_i)) \cong 1 - h_{ii}$

$$\Rightarrow t_{Di} = \frac{\text{sinal}(y_i - \hat{\mu}_i)\cdot \hat{d}(y_i, \hat{\mu}_i)}{\sqrt{1 - h_{ii}}}$$

* = componente do desvio estudentizado (devionce studentizado)

é simétrico; problema: média ligeiramente diferente de zero.

Resíduo de Williams (uma espécie de média ponderada entre t_{Si} e t_{Di})

$$t_{Gi} = \text{sinal}\{y_i - \hat{\mu}_i\}\{(1-h_{ii})\, t_{Di}^2 + (h_{ii})\, t_{Si}^2\}^{1/2}$$

Resíduo de Anscombe estudentizado

$$t_{Ai} = \frac{\hat{\phi}^{1/2}[\psi(y_i) - \psi(\hat{\mu}_i)]}{\psi'(\hat{\mu}_i)\sqrt{\hat{V}_i(1-h_{ii})}}, \text{ onde } \psi(\mu) = \int_0^{\mu} [V(t)]^{-\frac{1}{3}}\, dt$$

Exemplo: Gama: $V(\mu_i) = \mu_i \Rightarrow \psi(\mu_i) = \int_0^{\mu_i} t^{-\frac{2}{3}}\, dt = \left[\frac{t^{\frac{1}{3}}}{1/3}\right]_0^{\mu} = 3\mu^{1/3}$

$$\psi'(\mu_i) = \mu_i^{-\frac{2}{3}}$$

$$\Rightarrow t_{Ai} = \frac{\hat{\phi}^{\frac{1}{2}}\,(3y_i^{\frac{1}{3}} - 3\hat{\mu}_i^{\frac{1}{3}})}{\hat{\mu}_i^{-\frac{2}{3}}\sqrt{\hat{\mu}_i^2(1-h_{ii})}} = \frac{3\hat{\phi}^{1/2}(y_i^{1/3} - \hat{\mu}_i^{1/3})}{\hat{\mu}_i^{\frac{1}{3}}\cdot\sqrt{1-h_{ii}}}$$

✡

Resíduo Quantílico Dunn e Smyth (1996)

$$r_i^q = \phi^{-1}\cdot F(y_i; \phi, \mu_i)$$

Vantagens:

- Simples e intuitivo (?)
- Expressão praticamente idêntica em diferentes distribuições
- assintoticamente $r_i^q \to N(0,1)$
- também é proximo da $N(0,1)$ em amostras pequenas

Resíduo Quantílico ajustado

Scudilio e Pereira 2020

↑ guglis! ö

$$r_i^q = \frac{\hat{\Phi}^{-1}\{F(y_i;\hat{\mu}_i,\hat{\phi})\}}{\sqrt{1-h_{ii}}}$$

26 09 17 10ª aula

Supondo um exemplo:

V. Resposta é poisson e função de ligação identidade

$\hat{\beta}_0 = -0,5$ e $\hat{\beta}_1 = 4$; obs i: $x_i = 0,5$ e $y_i = 1$

Calcule $\hat{\Phi}^{-1}\{F(y_i;\hat{\mu}_i,\hat{\phi})$

Poisson: $\Phi^{-1}[F(1;\hat{\mu}_i,\hat{\phi})]$ fLI $\Rightarrow \eta_i = g(\mu_i) = \mu_i = x_i^T\beta$

$\Rightarrow \hat{\mu}_i = -0{,}5 + 0{,}5 \cdot 4 = 1{,}5$

* $\hat{\phi} = 1$

* $P(Y=y) = \frac{e^{-\lambda} \lambda^y}{y!}$

$\Rightarrow F(1; 1{,}5, \hat{\phi}) = \sum_{i=0}^{1} \frac{e^{-1{,}5}\, 1{,}5^i}{i!}$

$= \frac{e^{-1{,}5} \cdot 1}{0!} + \frac{e^{-1{,}5} \cdot 1{,}5}{1!} = e^{-1{,}5} \cdot (1{,}5) = 2{,}5\, e^{-1{,}5}$

$\Rightarrow \phi^{-1}(2{,}5\, e^{-1{,}5}) = \phi^{-1}(2{,}5 \cdot 0{,}223) = \phi^{-1}(0{,}5578)$

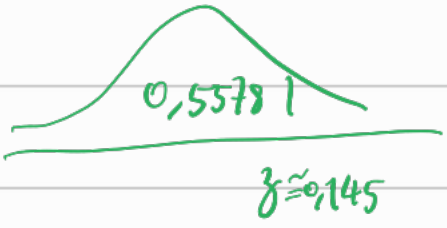

$\Rightarrow r_i^q \simeq 0{,}145$

como é Normal(0,1), será considerado valores discrepante se $|r_i^q| > 2$ ou $|r_i^q| > 3$ a depender da vontade do pesquisador. (tamanho da amostra também?)

* Novo resíduo! :

Resíduo quantílico aleatorizado (Dunn e Smyth 1996)

$r_i^q = \phi^{-1}(u_i)$, $u_i \sim U(a_i, b_i)$, sendo

$a_i = \lim_{y \to y_i} F(y; \hat{\mu}_i, \hat{\phi})$ e $b = F(y_i, \hat{\mu}_i, \hat{\phi})$

* Tem distribuição assintótica normal padrão.

* Problema!: não serve p/ identificar observações discrepantes pois depende do sorteio da uniforme.

* Serve p/ ver se ajuste do modelo adequado.

Pontos influentes em MLGen

$$LD_i = 2 \cdot \left(\ell(\hat{\beta}) - \ell(\hat{\beta}_{(i)}) \right)$$

* Não tem forma analítica de obter $\ell(\hat{\beta}_{(i)})$ em função de $\hat{\beta}$ em MLGen.

Mas: expansão de Taylor de LD_i em torno de $\hat{\beta}$ + manipulação algébrica

$$LD_i \approx \left(\frac{h_i}{1 - h_{ii}} \right) t_{Si}^2$$

Gráficos de resíduos.

eixo y: h_{ii}, resíduos ou LDi

eixo x: ordem da obs ou $\hat{y}_i$.

são uteis pl ver alavanca, discrepantes e influentes.

5 suposições pl verificar de MLGen

1. independência ($y_i|x_i \perp y_j|x_j$, $i \neq j$)

2. Homocedasticidade (ϕ é constante)

3. $y_i|x_i$ tem dist que pertence a FEL

4. função de ligação "corretamente" escolhida

5. todas as covariáveis "corretamente" escolhidas

* Nenhum modelo é correto, alguns são úteis.

p/ Independencia : resíduo x ordem

* raramente temos a ordem de coleta.

Grafico de t_{Di} contra $\hat{\mu}_i$ serve p/ verificar o resto das suposições.

Gráfico de

Gráfico de probabilidade Normal de t_{Di} com envelope simulado :
serve p/ suposições exceto independência.

- p/ obter o gráfico de probabilidade normal, considere t_i, $i=1,\dots,n$ um resíduo qualquer. e no grafico colocamos $(E(Z_{(i)}); t_{(i)})$

$$E(Z_{(i)}) \cong \Phi^{-1}\left(\quad\right)$$

26 09 22 11ª aula

Envelope

método de construção de envelope

- Envelope simulado: Atkinson

passos: 1. gerar n observações de y_i^* e guardar em $\underset{\sim}{y}^*$
2. calcula os resíduos ($y_i - y^* = t_i$)
3. repetir 1 e 2 m vezes.
4. ...
5. ...

Exemplo:

(Supondo que temos apenas 1 covariável
Supondo: $\log \mu_i = \beta_0 + \beta_1 x_i$, $y_i \sim \Gamma(\mu_i, \phi)$)

$\Rightarrow \mu_i = e^{\beta_0 + \beta_1 x_i}$ $\quad \hat{\beta}_0 = 1$ e $\hat{\beta}_1 = 0{,}2$

$\Rightarrow$

x_i	2	5	9	4
y_i	4	7	10	6
$\hat{\mu}_i$	$e^{1,4}$	e^{2}	$e^{2,8}$	$e^{1,8}$
y_i^*	$\Gamma(e^{1,4}; 100)$	$\Gamma(e^{2}; 100)$	$\Gamma(e^{2,8}, 100)$	$\Gamma(e^{1,8}, 100)$
t_i^*	t_1^*	t_2^*	t_3^*	t_4^*

resíduos $\rightarrow$ repetir os passo 1 e 2.

4.

5. obter os limites $t_{[i],[1]} = \min_j(t_{[i],j})$ e $t_{[i],[m]} = \max_j(t_{[i],j})$ para ser os limites da banda de confiança.

obs: se apenas a obs com maior valor estiver fora do envelope,
⇒ indício de outlier.

se muitos pontos fora do envelope: problema no modelo.

Seleção de Modelo

objetivo: selecionar o modelo que produz melhor ajuste dentro de um conjunto de modelos candidatos. A seleção de modelos envolve dois diferentes aspectos.

- critério p/ comparar dois modelo
- método automático de escolher

Critério de Informação de Akaike (AIC)

$AIC = -2\ell(\hat{\gamma}) + 2K^*$ (a formula é desse jeito pois

log da função de verossimilhança aplicado no EMV é viesado. os termos são para corrigir o viés.

Relação entre Q_{RV} e AIC

Vimos que $2\left[\ell_C(\hat{\gamma}) - \ell_R(\tilde{\gamma})\right]$

supondo que o modelo completo tem uma variável a mais que o reduzido. que por sua vez tem K variáveis.

↳ caso específico de modelo encaixado

nesse caso $K^* = K+3$, $AIC_{completo} = -2\ell_C(\hat{\gamma}) + 2(K+3)$

$AIC_{Red} = -2\ell_R(\tilde{\gamma}) + 2(K+2)$

$\Rightarrow AIC_{Red} - AIC_C = 2\left[\ell_C(\hat{\gamma}) - \ell_R(\hat{\gamma})\right] - 2$

$= Q_{RV} - 2$

Escolhe o modelo reduzido se $Q_{RV} - 2 < 0$

$\Rightarrow Q_{RV} < 2$

Note $Q_{RV} \sim \chi^2_1$ nesse caso pois a diferença dos modelos é 1 parâmetro.

valor-p $= Pr(\chi^2_1 > 2_{RV})$

note que $Pr(\chi^2_1 > 2) = 0{,}157$

então escolher modelo com AIC equivale fazer um teste de hipótese com nível de 15,7% de significância

Outras medidas:

$$BIC = -2\ell(\hat{\gamma}) + K^* \log(n)$$

$$H2C = -2\ell(\hat{\gamma}) + K^* \log\log(n)$$

Hannah-Quinn

$$AIC_c = -2\ell(\hat{\gamma}) + 2K^* \left(\frac{n}{n-K^*-1}\right)$$

métodos automatizados:

Forward; Backward; Stepwise; (Tradicionais, o Michel não gosta)

Lasso (Michel gosta)

método Lasso apresenta poder preditivo superior que métodos tradicionais.

em MLGen, o Lasso seleciona covariáveis e estima já os parâmetros do modelo minimizando

$$-\ell(\hat{\beta}, \hat{\phi}) + \lambda \Sigma |\hat{\beta}_i|$$

26 09 24 12ª aula

Medidas de resumo do ajuste de MLGen

- Função desvio em algumas situações tem dist. assintótica Qui-Quad.

$$D(y, \hat{\mu}) \xrightarrow{d} \chi^2_{n-k-1}.$$

Mas apenas em situações bem específicas

Exemplo: se poisson, isso ocorre só quando $\mu_i \to \infty$ $\forall i$.

ou

se ϕ desconhecido, a aproximação só fica boa com $\phi \to \infty$

$\Rightarrow$ Em geral, não é interessante comparar $D(y, \hat{\mu})$ com a média ou outras estatísticas.

- Pseudo R^2 (Baseado no artigo do Nagelkerke, 1991)

pseudos R^2 são generalizações do R^2 usual para os modelos mais gerais de regressão.

* Cox e Snell e Magee:

$$R^2_{CSM} = 1 - \exp\left\{\frac{-2}{n}(l(\hat{y}) - l(0))\right\}$$

Propriedades de R^2_{CSM}:

- em MLGer, R^2_{CSM} é o R^2 usual
- não depende de unidade de medida
- em caso de resposta discreta o R^2_{CSM} não atinge 1.

mas descobriram que (Caso discreto) $\max R^2_{CSM} = 1 - \exp\left(\frac{n}{2} l(0)\right)$

(N de Nagelkerke)

$$\Rightarrow R^2_N = \frac{R^2_{CSM}}{\max R^2_{CSM}}$$

$\Rightarrow$ R^2_N pode atingir 1 para qualquer dist.

- R^2_N tem boas propriedades
- em Regressão Logistica $\max R^2_{CSM} = 0{,}75$ se há mesma proporção de sucesso e fracasso"

Dem de: "em Reg. Logística $\max R^2_{csm} = 0{,}75$ se $p = 1-p = 0{,}5$"

sabendo que $\max R^2_{csm} = 1 - \exp\left\{\frac{2}{n}\hat{l}(0)\right\}$

então a proposição diz que $\exp\left\{\frac{2}{n}\hat{l}(0)\right\} = 0{,}25 \Leftrightarrow \frac{2}{n}\hat{l}(0) = \log 0{,}25$

$\Leftrightarrow \frac{\hat{l}(0)}{n} = \frac{\log 0{,}25}{2}$; $\pi_i = \frac{e^{\eta_i}}{1+e^{\eta_i}}$ e $\eta_i = x_i^T\beta$

$\mu_i =$ "$\log\left(\frac{p_i}{1-p_i}\right)$"

$\Leftrightarrow \hat{l}(0) = n \cdot \log 0{,}5$

note que em regressão logística a função de ligação associada é logito

$\log\left(\frac{p_i}{1-p_i}\right) = x^T\beta = \eta_i = g(\mu_i)$

$\Rightarrow \log(\pi_i) = \eta_i - \log(1+e^{\eta_i})$

$Y_i \sim Bern(p_i)$

$l(\beta) = \sum_{i=1} \phi(y_i\theta_i - b(\theta_i)) - \sum c(y_i, \phi)$ $\Rightarrow l(p_i) = \sum y_i \log p_i - \sum(1-y_i)\log 1-p_i$

$\Rightarrow l(\beta) = \sum y_i x_i'\beta - \log(1+\exp(x_i'\beta))$ $\hat{\beta}_0 = \log\left(\frac{\bar{y}}{1-\bar{y}}\right)$

$\hat{l}(0) = \sum[y_i \cdot \hat{\beta}_0 - \log(1+\exp(\hat{\beta}_0))]$ * fracasso = sucesso

$= [\sum y_i \cdot 0 - \log 1 + \exp(0)]$ $= \sum_1 = \frac{n}{2}$

$= \sum(-\log 2) = n \cdot (-\log 2)$

$$\Rightarrow l(0) = n(-\log 2) = n \log 2^{-1} = n \log 0{,}5$$

Resolução do Gustavo: * Y é Bernoulli

$$L(\beta_0) = \prod_{i=1}^{n} \mu_i^{y_i} \cdot (1-\mu_i)^{1-y_i} \Rightarrow l(\beta_0) = \sum \{ y_i \log \mu_i - (1-y_i) \log(1-\mu_i) \}$$

$$= \sum y_i \left(\log \frac{\mu_i}{1-\mu_i} + \log(1-\mu_i) \right) \quad \text{e} \quad \eta_i = \underset{\sim}{x}_i^{\top} \underset{\sim}{\beta} = \log\left(\frac{\mu_i}{1-\mu_i}\right)$$

$$\mu_i = \frac{e^{\beta_0}}{1+e^{\beta_0}}$$

* estamos fazendo $l(\beta_0)$

$$\Rightarrow l(\beta_0) = \sum \left[y_i \beta_0 + \log\left(1 - \frac{e^{\beta_0}}{1+e^{\beta_0}}\right) \right]$$

$$= \sum \left[y_i \beta_0 + \log\left(\frac{1}{1+e^{\beta_0}}\right) \right]$$

agora seja $\hat{\beta}_0 = o$ de max ver.

$$= \sum \left[y_i \beta_0 - \log(1+e^{\beta_0}) \right]$$

$$\Rightarrow \hat{\beta}_0 = \log\left(\frac{\bar{y}}{1-\bar{y}}\right)$$

amostra: $\bar{y} = 0{,}5$

$$\Rightarrow \hat{l}(0) = \sum \left\{ y_i \log\left(\frac{\bar{y}}{1-\bar{y}}\right) - \log\left(1 + \left(\frac{\bar{y}}{1-\bar{y}}\right)\right) \right\} \qquad 1 = \frac{1-\bar{y}}{1-\bar{y}}$$

$$\hat{l}(0) = \sum y_i \log(1) - \log 2$$

$$\hat{l}(0) = \sum \log\left(\frac{1}{2}\right) \Rightarrow \hat{l}(0) = n \cdot \log \frac{1}{2}$$

$$\Rightarrow \max R^2_{CSM} = 1 - \exp\left\{\frac{2}{n} \cdot n \log 0{,}5\right\} = 1 - \exp\{2 \cdot \log 0{,}5\}$$

$= 1 - \exp\{\log 0{,}25\} = 0{,}75$

arquivo 6 acaba aqui

arquivo 7:

Modelos para respostas positivas, contínuas e assimétricas

* as dist da FEL são Γ e N inversa.

Gama: sabemos que: $E(Y) = \mu$ e $Var(Y) = \phi^{-1}\mu^2 \Rightarrow$

coeficiente de variação é $CV(Y) = \frac{DP(Y)}{E(Y)} = \frac{\phi^{-\frac{1}{2}} \cdot \mu}{\mu} = \phi^{-\frac{1}{2}}$

e note $Assimetria(Y) = 2\phi^{-\frac{1}{2}}$ e $Curtose = 3 + 6\phi^{-1}$ e se $\phi \to \infty$,

a gama se aproxima de Normal.

Gaussiana Inversa:

$E(Y) = \mu$ $Var(Y) = \phi^{-1}\mu^3$, $Assim(Y) = 3\mu^{1/2}\phi^{-1/2}$ $Curt(Y) = 3 + 15\mu\phi^{-1}$

$\Rightarrow CV(Y) = \frac{\phi^{-\frac{1}{2}}\mu^{3/2}}{\mu} = \phi^{-\frac{1}{2}} \cdot \mu^{1/2}$

e note $N_{Inv} \xrightarrow{\phi \to \infty} N(\mu, \phi^{-1}\mu^3)$

26/09/29 13ª aula

Comparação da assimetria

considere que $E(Y)=\mu$ e $Var(y)=m$,

para Gama: $Var(y)=\phi^{-1}\mu^2$ e $Assim(y)=2\phi^{-1/2}$

$\Rightarrow \phi^{-1}\mu^2=m \Rightarrow \phi^{-1}=\frac{m}{\mu^2}$, $Assim(y)=2\phi^{-1/2}=2\left(\frac{m}{\mu^2}\right)^{1/2}=2\cdot\frac{\sqrt{m}}{\mu}$

$\Rightarrow \phi=\frac{\mu^2}{m}$ $\Rightarrow$ Assim(y) da gama é 2·CV

GI:

$\phi^{-1}\mu^3=m \Rightarrow \phi^{-1}=\frac{m}{\mu^3} \Rightarrow \phi=\frac{\mu^3}{m}$

e $Assim(y)=3\mu^{1/2}\cdot\phi^{-1/2}=3\cdot\mu^{1/2}\cdot\left(\frac{m}{\mu^3}\right)^{1/2}=3\cdot\frac{\sqrt{m}}{\mu}=3\cdot CV$

Função de ligação

Gama: $g(\mu_i)=\frac{1}{\mu_i} \Rightarrow \hat{\mu}_i=\frac{1}{\hat{\eta}_i}$ (canônica) (não é a mais usada, pois talvez dê negativo)

(a mais usada): $g(\mu_i)=\log(\mu_i)=\eta_i \Rightarrow \hat{\mu}_i=e^{\hat{\eta}_i}$ (parâmetros mais interpretáveis)

>>>

Em MLGer, β_j:

$$\beta_j = E(Y_i | X_{ij} = l+1) - E(Y_i | X_{ij} = l)$$

>>>

em MLGen com $g(\mu_i) = \log \mu_i$

$$\log \mu_i = x_i^T \beta \Rightarrow \mu_i = e^{x_i^T \beta} \Rightarrow (1)\ E(Y_i | X_{ij} = l) = \mu_i = e^{x_i^T \beta} = \exp\{\beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}\}$$

$$(2)\ E(Y_i | X_{ij} = l+1) = \exp\{\beta_0 + \dots + \beta_j (x_{ij}+1) + \dots \beta_k x_{ik}\}$$

(mantendo outros)

$$\Rightarrow \frac{(2)}{(1)} = \exp\{\beta_j\}$$

para cada aumento unitário de x_j, é esperado que haja um multiplicativo de $\exp\{\beta_j\}$.

* (supondo que temos uma amostra)
mesmo que o histograma da resposta y seja assimetrica, não necessariamente precisamos supor uma distribuição assimétrica. pois p/ cada x_i dos dados pode representar uma mesma dist só que com parametro diferente

(ñ sei se é exatamente isso que o gustavo quis dizer)

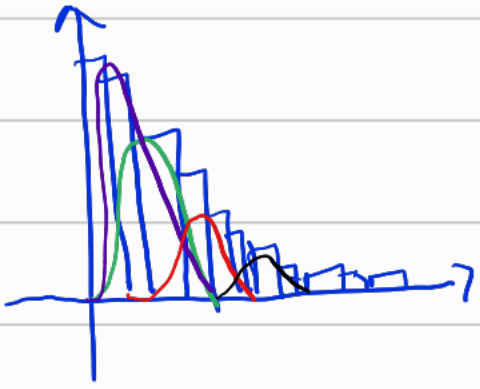

exemplos em R ..... se pontos influentes, testa combinações tirando eles de fora.

2026 10 01 14ª aula

em R ...

Sempre verificar se as suposições estão satisfeitas

Exemplo de resistência de vidro

4 voltagens → 3 dummies

e 2 temperaturas → 1 dummy

modelo usual de planejamento (com interação)

$$g(\mu_i) = \mu_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \beta_5 x_{i1} x_{i4} + \beta_6 x_{i2} x_{i4} + \beta_7 x_{i1} x_{i4}$$

⇒ $g(\mu_i) =$

		Temp 170	Temp 180
VOLTAGEM	200	β_0	$\beta_0 + \beta_4$
	250	$\beta_0 + \beta_1$	$\beta_0 + \beta_1 + \beta_4 + \beta_5$
	300	$\beta_0 + \beta_2$	$\beta_0 + \beta_2 + \beta_4 + \beta_6$
	350	$\beta_0 + \beta_3$	$\beta_0 + \beta_3 + \beta_4 + \beta_7$

Interpretação dos β's é a mesma em planejamento

se função de ligação é log : $g(\mu_i) = \log(\mu_i)$

1) $\exp(\beta_4)$: é o valor pelo qual é multiplicada a resistência média do vidro quando passamos a temp de 170 p/ 180 e mantemos a voltagem em 200.

2) $\exp(\beta_5)$: é o valor pelo qual é multiplicada a resistência média do vidro quando passamos a temp de 170 p/ 180 e a voltagem de 200 p/ 250.

Note que com modelo completo (com interação), como temos 8 parâmetros ($\beta_0 \cdots \beta_7$) e 8 tratamentos, o AIC será mesmo ñ importa a função de ligação. (se a distribuição mudar; se dist muda, AIC muda junto)

Vamos usar $g(\mu_i) = \log \mu_i$

26 to 06 15ª aula

Dados

Volt	Temp	$g(\mu_i)$	$\bar{y}$
200	170	β_0	885
300	170	$\beta_0 + \beta_1$	814
200	180	$\beta_0 + \beta_4$	424

300	180	$\beta_0 + \beta_2 + \beta_4 + \beta_6$	362
250	170	$\beta_0 + \beta_1$	1044
350	170	$\beta_0 + \beta_3$	364
250	180	$\beta_0 + \beta_1 + \beta_4 + \beta_5$	319
350	180	$\beta_0 + \beta_3 + \beta_4 + \beta_7$	343

O que é pl fazer: Testes de Hipotese, Comparações multiplas.

26 to 08 16ª aula

Note que geralmente usa-se Poisson em MLG quando envolve contagens.

Mas note que Se um dos parâmetros conhecido então Binomial Negativa pertence à familia exponencial linear

Poisson:

Já sabemos que $f(y;\mu) = \exp\{y \log \mu - \mu - \log y!\}$

$\phi = 1, \quad \theta = \log \mu$

$b(\theta) = e^{\theta}$

$$Assim(\mu) = e^{-\frac{1}{2}} \quad e \quad Curt(\mu) = 3 + \mu^{-1}$$

então se μ é alto, poisson converge pl normal

Note

Se Poisson é adequada p/ resposta do modelo, o MLGer não deve ser usado mesmo que as médias são altas. pois a homescedasticidade fica violado. Var = μ_i em MLGer a variância deve ser constante.

função de ligação p/ Poisson canônica é $g(\mu_i) = \log \mu_i$ que é adequado.

motivos do log ser bom: fácil de interpretar e produz valores positivos. ($\mu_i = e^{\eta_i}$)

outras ligações usadas p/ Poisson mas não tão boa quanto log:
identidade $g(\mu_i) = \mu_i$ e raiz quadrada $g(\mu_i) = \sqrt{\mu_i}$

Códigos em R .....

Se pontos influentes: o que fazer se cair na prova?

Não discutir de AIC ou BIC.

Menciona se muda ou não as estimativas

e se conclusões dos testes de hipótese mudam!

Offset

as vezes em certas situações as unidades amostrais fogem do experimento ou morrem de acidentes inesperados, daí não são acompanhadas ao longo do mesmo tempo. Assim não fica razoável usar $y_i \sim Poisson(\mu_i)$

é mais razoável fazer $y_i \sim Poisson(\lambda_i t_i)$ em que t_i é a $E(y_i)$ por unidade de tempo

(se função de ligação é log)

nesse caso a gente considera $\log \lambda_i = x_i^T \beta$

mas $\mu_i = \lambda_i t_i$

então $\log \lambda_i + \log t_i = x_i^T \beta + \log t_i$

$= \log(\lambda_i t_i)$

$= \log(\mu_i)$

$= g(\mu_i) = x_i^T \beta + \log t_i$

o termo chamado de "offset"