Seguindo a ordem do livro "Modelos de regressão com apoio computacional".

Nelder e Wedderburn propuseram os MLGs em 1972.

* Mais distribuições disponíveis p/ variável resposta.

Wedderburn: modelos de quase-verossimilhança (1974)

Jørgensen: modelos de dispersão (1987.

etc etc ...

2.2 Def FEL

$Y_1, \dots, Y_n$ indep

$$f(y_i; \theta_i, \phi) = \exp\{\phi\{y_i\theta_i - b(\theta_i)\} + c(y_i, \phi)\}$$

Y pertence a FEL.

θ parte aleatória

* Sob regularidade: $E\left(\frac{\partial \log f(Y_i; \theta_i, \phi}{\partial \theta_i}\right) = 0$

e $E\left[\frac{\partial^2 \log f(Y_i; \theta_i, \phi)}{\partial \theta^2}\right] = -E\left[\frac{\partial \log f(Y_i; \theta_i, \phi)}{\partial \theta}\right]^2$

* $E(Y) = \mu_i = b'(\theta)$. $Var(Y_i) = \phi^{-1} V(\mu_i)$

$V_i = V(\mu_i) = \frac{d\mu_i}{d\theta_i}$ = função de variância.

ϕ^{-1} / ou ϕ é o parâmetro de dispersão / precisão

* a função de variância caracteriza a dist.

Exemplo: $V(\mu) = \mu(1-\mu)$, $0 < \mu < 1$ caracteriza binomial com prob de sucesso μ.

Propriedade envolvendo Y e $V(\mu)$ é:

$$\sqrt{\phi}(Y-\mu) \xrightarrow[\phi \to \infty]{d} N(0, V(\mu))$$

ou seja

$$Y \xrightarrow{d} N(\mu, \phi^{-1} V(\mu))$$

outra parte que define MLG:

Parte sistemática

$\eta_i = x_i^T \beta$ = preditor linear

Função de ligação

$g(\mu_i) = \eta_i$

* g é função monótona diferenciável.

Tabela 2.1:

Dist. pertencentes à FEL:

Dist	$b(\theta)$	θ	ϕ	$V(\mu)$
Norm	$\theta^2/2$	μ	σ^2	1
Pois	e^θ	$\log(\mu)$	1	μ
Bin	$\log(1+e^\theta)$	$\log(\mu/1-\mu)$	n	$\mu(1-\mu)$
Γ	$-\log(-\theta)$	$-1/\mu$	$1/CV(y)^2$	μ^2
Norm Inv	$-\sqrt{-2\theta}$	$-1/2\mu^2$	ϕ	μ^3

2.2.1 Casos particulares

$Y \sim N(\mu, \sigma^2)$

$$\Rightarrow f(y) = \frac{1}{\sigma\sqrt{2\pi}} \cdot \exp\left\{\frac{-1}{2\sigma^2}(y-\mu)^2\right\} = \exp\left\{\frac{1}{\sigma^2}\left(\mu y - \frac{\mu^2}{2}\right) - \frac{1}{2}\log(2\pi\sigma^2) + \frac{y^2}{\sigma^2}\right\}$$

$\Rightarrow \phi = 1/\sigma^2, \quad \theta = \mu \quad b(\theta) = \mu^2, \quad c(y,\phi) = \frac{1}{2}\log\left(\frac{2\pi}{\phi}\right) - y^2\cdot\phi$

* $V(\mu) = 1$

$Y \sim \text{Poisson}(\mu) \Rightarrow f(y) = \frac{e^{-\mu}\cdot\mu^y}{y!} = \exp\{y\cdot\log\mu - \mu - \log y!\}$

$\Rightarrow \phi = 1 \quad \theta = \log(\mu), \; b(\theta) = e^\theta = \mu \quad c(y,\phi) = \log y! \Rightarrow V(\mu) = \mu$

$ny^* \sim Bin(n, \mu)$ $\quad$ *: Seja y^* a proporção de sucesso em n ensaios indep.

$$\Rightarrow f(ny^*) = \binom{n}{ny^*} \mu^{ny^*} (1-\mu)^{n-ny^*} = \exp\left\{\log\binom{n}{ny^*} + ny^* \log\mu + (n-ny^*)\log(1-\mu)\right\}$$

$$= \exp\left\{\log\binom{n}{ny^*} + ny^* \log\left(\frac{\mu}{1-\mu}\right) + n\log(1-\mu)\right\}$$

$\Rightarrow \phi = n$, $\theta = \log\frac{\mu}{1-\mu} \Rightarrow \mu = b(\theta) = \log(1+e^\theta)$ $\quad$ $c(y^*, \phi) = \log\binom{\phi}{\phi y^*}$

* $V(\mu) = \mu(1-\mu)$

Gama

$Y \sim \Gamma(\alpha, \theta)$. $\quad$ Reparametrização: $E(Y) = \alpha\theta = \mu$

e $CV(Y) = \frac{\sqrt{Var}}{E} = \frac{\sqrt{\sigma}}{\mu} = \frac{\sqrt{\alpha\theta^2}}{\alpha\theta} = \frac{1}{\sqrt{\alpha}}$

$$= \phi^{-\frac{1}{2}}$$

$$\Rightarrow Y \sim \Gamma(\mu, \phi) \Rightarrow f(y) = \frac{1}{\Gamma(\phi)} \cdot \left(\frac{\phi y}{\mu}\right)^\phi \exp\left(-\frac{\phi y}{\mu}\right) d(\log(y))$$

$$= \exp\left\{\phi\left[\left(\frac{-y}{\mu}\right) - \log(\mu)\right] - \log(\Gamma(\phi)) + \phi\log(\phi y) - \log(y)\right\}$$

$\Rightarrow \phi = \phi = CV(Y)^{-2}$. $\theta = \frac{-1}{\mu} \Rightarrow \mu = \frac{-1}{\theta} \Rightarrow -\log(\mu) = -\log\left(\frac{-1}{\theta}\right) = \log(-\theta)$

$\Rightarrow b(\theta) = -\log(-\theta)$, $c(y, \phi) = -\log(\Gamma(\phi)) + \phi(\log(\phi y) - \log(y))$.

* p/ $0 < \phi < 1$, a gama tem polo em origem e decresce monotonicamente.

* exponencial é um caso especial quando $\phi = 1$.

* $\phi > 1$: $f(0) = 0$ e maximo em $y = \frac{\mu - \mu}{\phi}$.

* χ^2_k é outro caso especial quando $\phi = k/2$ e $\mu = k$

* Normal é caso especial quando $\phi \to \infty$. $\Rightarrow Y \sim N(\mu, \phi^{-1} V(\mu))$ com ϕ grande.

* Note que $\phi = CV(Y)^{-2} = \frac{E^2(Y)}{Var(Y)}$. e $V(\mu) = \mu^2$

$Y \sim NIn(\mu, \phi)$ $\mu = E[Y]$. ϕ: parâmetro de precisão

$$f(y) = \sqrt{\frac{\phi}{2\pi y^3}} \exp\left\{-\frac{\phi(y-\mu)^2}{2\mu^2 y}\right\} = \exp\left[\phi\left\{\frac{-y}{2\mu^2} + \frac{1}{\mu}\right\} - \frac{1}{2}\left\{\log\frac{2\pi y^3}{\phi} + \frac{\phi}{y}\right\}\right]$$

$\Rightarrow \phi = \phi$. $\theta = \frac{-1}{2\mu^2}$ $b(\theta) = (-2\theta)^{\frac{1}{2}}$ e $c(y;\phi) = \frac{-1}{2}\left\{\log 2\pi y^3 + \frac{\phi}{y}\right\}$

$= \frac{1}{2}\cdot\log\left(\frac{\phi}{2\pi y^3}\right) - \frac{\phi}{2y}$

Note $V(\mu) = \mu^3$

Função de Ligação

as ligações canônicas mais comuns são:

Normal: $g(\mu) = \eta = \mu$

Gama: $g(\mu) = \eta = 1/\mu$

Bin: $g(\mu) = \eta = \log\left(\frac{\mu}{1-\mu}\right)$

N Inv: $g(\mu) = \eta = \frac{1}{\mu^2}$

Poisson: $g(\mu) = \eta = \log \mu$

Vantagens de usar g canônica

- garantem a concavidade de $L(\beta)$ $\Rightarrow$ fácil de obter resultados assintóticos.

exemplo: unicidade da estimativa da max. verossimilhança

Outras ligações:

Probito $\Phi^{-1}(\mu) = \eta = g(\mu)$

Ligação complemento log-log

modelo binomial.

$$\eta = g(\mu) = \log\left[-\log(1-\mu)\right] \quad \Leftrightarrow \mu = 1 - \exp\{-\exp(\eta)\}$$

* origem: dist do valor extremo: $f(y) = \exp\{y - \exp(y)\}$

...

Logito:

$$g(\mu) = \eta = \log\left(\frac{\mu}{1-\mu}\right)$$

Ligação de Box-Cox (Importe, pelo menos p/ obs positivas)

$$g(\mu) = \eta = \begin{cases} \dfrac{(\mu^{\lambda}-1)}{\lambda}, & \lambda \neq 0 \\ \log \mu, & \lambda = 0 \end{cases}$$

Função Desvio

Relembre: $\ell(\underset{\sim}{\mu}, \underset{\sim}{y}) = \sum \ell(\mu_i, y_i)$ onde $\mu_i = g^{-1}(\eta_i)$, e $\eta_i = x_i^T \beta$

log vero

estima-se $\ell(\underset{\sim}{\mu}, \underset{\sim}{y})$ com $\ell(\underset{\sim}{y}, \underset{\sim}{y}) = \sum \ell(y_i, y_i)$

por max. vero.: $\hat{\mu}_i = g^{-1}(\hat{\eta}_i)$, $\hat{\eta}_i = x_i^T \hat{\beta}$.

⇒ função desvio avalia qualidade do MLG:

$$D^*(\underset{\sim}{y}, \underset{\sim}{\hat{\mu}}) = \phi D(\underset{\sim}{y}, \underset{\sim}{\hat{\mu}}) = 2 \cdot \{ L(\underset{\sim}{y}, \underset{\sim}{y}) - L(\underset{\sim}{\hat{\mu}}, \underset{\sim}{y}) \}$$

$$\Rightarrow D(\underset{\sim}{y}, \underset{\sim}{\hat{\mu}}) = 2 \sum \{ y_i(\tilde{\theta}_i - \hat{\theta}_i) + b(\hat{\theta}_i) - b(\tilde{\theta}_i) \}$$

$\hat{\theta}$: estimativa por max. vero.

$\tilde{\theta}$: estimativa saturado.

Exemplos:

Normal:

$\theta_i = \mu_i \Rightarrow \tilde{\theta}_i = y_i$ e $\hat{\theta}_i = \hat{\mu}_i$ e $b(\theta) = \theta^2/2$

$$\Rightarrow D(\underset{\sim}{y}, \underset{\sim}{\hat{\mu}}) = 2 \sum \{ y_i(y_i - \hat{\mu}_i) + \frac{\hat{\mu}_i^2}{2} - \frac{y_i^2}{2} \} = \sum (y_i - \hat{\mu}_i)^2$$

= Soma de quadrados de resíduos.

Poisson.

$\theta_i = \log \mu_i \Rightarrow \tilde{\theta}_i = \log y_i$; $\hat{\theta}_i = \log \hat{\mu}_i$

$$\Rightarrow D(\underset{\sim}{y}, \underset{\sim}{\hat{\mu}}) = 2 \cdot \sum \{ y_i \cdot \log \frac{y_i}{\hat{\mu}_i} - (y_i - \hat{\mu}_i) \}$$

* se $y_i = 0$ i^{th} é $2\hat{\mu}_i$

Binomial $Y_i \sim Bin(n_i, \mu_i)$ $\quad i = 1, \dots, k$

$\Rightarrow \theta = \log\left(\frac{\mu}{1-\mu}\right)$

$\Rightarrow \tilde{\theta}_i = \log\left(\frac{y_i}{n_i - y_i}\right)$; $\hat{\theta}_i = \log\left(\frac{\hat{\mu}_i}{1-\hat{\mu}_i}\right)$

$$\Rightarrow D(y, \hat{\mu}) = 2 \cdot \sum \left\{ y_i \left(\log \frac{y_i}{(n_i - y_i)} \frac{(1-\hat{\mu}_i)}{(\hat{\mu}_i)} \right) + (n_i - y_i) \log\left(\frac{1 - y_i/n_i}{1 - \hat{\mu}_i} \right) \right\}$$

se $y_i = 0$: i^{th} é $-2 n_i \log(1 - \hat{\mu}_i)$

se $y_i = n_i$: i^{th} é $-2 n_i \log \hat{\mu}_i$

Gama: $\theta = -1/\mu$ $\qquad b(\theta) = -\log(-\theta)$

$\Rightarrow \tilde{\theta}_i = \frac{-1}{y_i}$ e $\hat{\theta}_i = \frac{-1}{\hat{\mu}_i}$ $\qquad b(\hat{\theta}) - b(\tilde{\theta})$

$$\Rightarrow D(y, \hat{\mu}) = 2 \cdot \sum \left\{ y_i \left(\frac{-1}{y_i} + \frac{1}{\hat{\mu}_i} \right) + \left(-\log\left(\frac{-1}{\hat{\mu}_i}\right) + \log\left(\frac{-1}{y_i}\right) \right) \right\}$$

$$= 2 \cdot \sum \left\{ \left(\frac{y_i - \hat{\mu}_i}{\hat{\mu}_i} \right) - \log\left(\frac{y_i}{\hat{\mu}_i} \right) \right\}$$

* se $y_i = 0$, o desvio fica indeterminado.

Sugestão de Cullagh e Nelder (1989):

$$D^*(y,\hat{\mu}) = 2\phi C(y) + 2\phi \Sigma \log(\hat{\mu}_i) + 2\phi \Sigma (y_i/\hat{\mu}_i)$$

C: arbitraria e limitada.

Bem, geralmente os programas não aceitam dist Γ com $y=0$

Normal Inversa:

$$\theta = \frac{-1}{2\mu^2} \Rightarrow \quad \text{e} \quad b(\theta) = -\sqrt{-2\theta}$$

$$\tilde{\theta}_i = \frac{-1}{2y_i^2} \quad \text{e} \quad \hat{\theta}_i = \frac{-1}{2\hat{\mu}_i^2}$$

$$\Rightarrow D(y,\hat{\mu}) = 2\Sigma\, y_i \left(\frac{-1}{2y_i^2} + \frac{1}{2\hat{\mu}_i^2}\right) + \left(-\sqrt{-\frac{2(-1)}{2\hat{\mu}_i^2}} + \sqrt{\frac{1}{y_i^2}}\right)$$

$$= 2\Sigma \left\{ \frac{-1}{2y_i} + \frac{y_i}{2\hat{\mu}_i^2} + \left(\frac{1}{y_i} - \frac{1}{\hat{\mu}_i}\right) \right\}$$

$$= 2\cdot\Sigma\left(\frac{1}{2y_i} + \frac{y_i}{2\hat{\mu}_i^2} - \frac{1}{\hat{\mu}_i}\right) = \Sigma \frac{1}{y_i} + \frac{y_i}{\hat{\mu}_i^2} - \frac{2}{\hat{\mu}_i}$$

$$= \Sigma \frac{\hat{\mu}_i^2 + y_i^2 - 2y_i\hat{\mu}_i}{y_i\hat{\mu}_i^2} = \Sigma \frac{(y_i - \hat{\mu}_i)^2}{y_i\hat{\mu}_i^2}$$

Medida R^2

Relembre que em MLGeral: $R^2 = 1 - \frac{SQRes}{SQT} = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$

e R^2 ajustado $= \bar{R}^2 = 1 - \frac{SQRes/(n-p)}{SQT/n-1}$

extensão de R^2 p/ MLG:

$$R^2 = 1 - \frac{D(\underset{\sim}{y}, \hat{\mu})}{D(\underset{\sim}{y}, \bar{y})}$$

Usual fazer $D(y; \hat{\mu}) \to \chi^2_{n-p}$.

Caso binomial: $D(y; \hat{\mu}) \to \chi^2_{n-p}$, mas não vale com $n_i \to \infty$ e $n_i\mu_i(1-\mu_i)$ permanence limitado

Poisson: $D(y, \hat{\mu}) \to \chi^2_{n-p}$, vale quando $\mu_i \to \infty$

Normal: $D(y, \hat{\mu}) \to \chi^2_{n-p}\,\sigma^2$ com σ^2 fixo e conhecido.

Geral, com $\phi \to \infty$, caso D^* dependa de ϕ:

$$D^*(y, \hat{\mu}) \to \chi^2_{n-p}, \quad \phi \to \infty$$

Resumindo, dispersão (ϕ^{-1}) pequena $\Rightarrow$ razoável comparar os valores dos com χ^2_{n-p}

Análise de Desvio

vetor de parâmetros $\underset{\sim}{\beta}$ particionado: $\underset{\sim}{\beta} = (\underset{\sim}{\beta}_1^T, \underset{\sim}{\beta}_2^T)^T$

$\underset{\sim}{\beta}_1$: $q \times 1$, e $\underset{\sim}{\beta}_2$: $p-q$.

Podemos ter interesse em testar as hipótese $H_0: \underset{\sim}{\beta}_1 = \underset{\sim}{0}$ vs $H_1: \underset{\sim}{\beta}_1 \neq \underset{\sim}{0}$

função desvio correspondentes aos modelos sob H_0 e H_1: $D(y, \hat{\mu}^0)$ e $D(y, \hat{\mu})$

($\hat{\mu}^0$: estimativa por MV)

A estatística do teste da RV:

$$\xi_{RV} = \phi \{ D(y, \hat{\mu}^0) - D(y; \hat{\mu}) \}$$

sob H_0, $\xi_{RV} = \chi^2_q$, com $n \to \infty$.

Note: $$F = \frac{\{ D(y, \hat{\mu}^0) - D(y, \hat{\mu}) \} / q}{D(y, \hat{\mu}) / n-p} \sim F_{q, n-p}$$

* $D(y, \hat{\mu})/n-p$ é estimativa consistente de ϕ^{-1}

vantagem de F: não depende de ϕ.

...

2.5 Função escore e informação de Fisher

$\underset{\sim}{\theta} = (\underset{\sim}{\beta}^T, \phi)^T$ e f de ver.: $L(\underset{\sim}{\theta})$.

Para função escore para parâmetro $\underset{\sim}{\beta}$ deriva-se inicialmente $L(\theta)$

$$\Rightarrow \partial L(\theta)/\partial \beta_j = \sum \phi \left\{ y \frac{d\theta_i}{d\mu_i}\frac{d\mu_i}{d\eta_i}\frac{\partial \eta_i}{\beta_j} - \frac{db(\theta_i)}{d\theta_i}\frac{d\theta_i}{d\mu_i}\frac{d\mu_i}{d\eta_i}\frac{\partial \eta_i}{\partial \beta_j} \right\}$$

$$= \sum \phi \left\{ y_i \frac{(d\mu_i/d\eta_i)}{V_i} x_{ij} - \mu_i \frac{(d\mu_i/d\eta_i)}{V_i} x_{ij} \right\}$$

$$= \sum \phi \left\{ \sqrt{\frac{w_i}{V_i}} (y_i - \mu_i) x_{ij} \right\}$$

em que $w_i = \left(\frac{d\mu_i}{d\eta_i}\right)^2 / V_i$.

$\Rightarrow$ é p

$$U_\beta(\theta) = \frac{\partial L(\underset{\sim}{\theta})}{\partial \underset{\sim}{\beta}} = \phi X^T W^{\frac{1}{2}} V^{-\frac{1}{2}} (y - \underset{\sim}{\mu})$$

X é $N^{(R)}_{n \times p}$ de posto completo. W: matriz de pesos

V: $\text{diag}\{V_1, \ldots, V_n\}$ $\underset{\sim}{y} = (y_1, \ldots, y_n)^T$ e $\underset{\sim}{\mu} = (\mu_1, \ldots, \mu_n)^T$

Submatriz de info de Fisher p/ β :

$$K_{\beta\beta}(\theta) = E\left\{-\frac{\partial^2 L(\theta)}{\partial\beta\partial\beta^T}\right\} = \phi X^T W X$$

Quando função de ligação canonica $\theta_i = \eta_i$

temos a versão simplificada:

$$U_\beta = \phi X^T(y-\mu) \quad \text{e} \quad K_{\beta\beta} = \phi X^T V X.$$

Particionado: $U_{\beta_1} = \phi X_1^T W^{\frac{1}{2}} V^{-\frac{1}{2}}(y-\mu)$ e

$$K_{\beta_1\beta_1} = \phi X_1^T W X_1$$

Score de Fisher p/ ϕ

$$U_\phi(\theta) = \frac{\partial L(\theta)}{\partial\phi} = \sum\{y_i\theta_i - b(\theta_i)\} + \sum c'(y_i;\phi)$$

* precisa de $\frac{\partial^2 L(\theta)}{\partial\phi^2} = \sum c''(y_i;\phi)$, onde $c''(y_i,\phi) = \frac{d^2 c(y,\phi)}{d\phi^2}$

$$\Rightarrow K_{\phi\phi}(\theta) = -\sum_{i=1}^{n} E\{c''(y_i;\phi)\}$$

Ortogonalidade

Tem-se: $\frac{\partial^2 L(\theta)}{\partial \beta \partial \phi} = \sum \left[w_i V_i^{-1} \right] (y_i - \mu_i) x_i \Rightarrow \underset{\sim}{\beta}$ e ϕ são ortogonais.

$$\Rightarrow K_{\beta\phi}(\theta) = E\left[-\frac{\partial^2 L(\theta)}{\partial \beta \partial \phi} \right] = \underset{\sim}{0} \Rightarrow K_{\theta\theta} = \begin{bmatrix} K_{\beta\beta} & 0 \\ 0 & K_{\phi\phi} \end{bmatrix}$$

matriz bloco diagonal

$$U_\theta = (U_\beta^T \quad U_\phi)^T$$

Casos particulares.

Normal:

$V(\mu) = 1 \Rightarrow \left(\frac{d\theta}{d\eta}\right)^2$. com $\theta = \eta$ temos $w = 1 \Rightarrow$

$$U_\beta = \sigma^2 X^T (y - \mu) \quad \text{e} \quad K_{\beta\beta} = \sigma^2 X^T X$$

$$U_\phi = \sum \left(y_i \mu_i - \frac{\mu_i^2}{2} \right) + \sum c'(y_i, \phi)$$

onde $c(y, \phi) = \frac{1}{2\phi} - \frac{y_i^2}{2}$. $\Rightarrow c''(y_i, \phi) = \frac{-1}{2\phi^2}$

portanto $K_{\phi\phi} = -\sum E(c''(Y_i, \phi)) = \frac{n}{2\phi^2}$

Poisson:

$$V(\mu) = \mu \quad \Rightarrow \quad w = \mu \left(\frac{d\theta}{d\eta}\right)^2$$

p/ ligação canônica: $\log(\mu) = \eta = g(\mu)$

e $\theta = \log \mu = \eta \Rightarrow \frac{d\theta}{d\eta} = 1$

$\Rightarrow w_i = \mu_i \quad \Rightarrow U_\beta = X^T V^{\frac{-1}{2}} (y-\mu)$ e $K_{\beta\beta} = X^T X$

* Se ligação raiz quad. $\eta = \sqrt{\mu} \Rightarrow U_\beta = 2X^T V^{-\frac{1}{2}}(y-\mu)$, $K_{\beta\beta} = 4X^T X$

Binomial:

$$V(\mu) = \mu(1-\mu) \qquad * w_i = \frac{1}{V_i\, g'(\mu_i)^2} \quad \Rightarrow w = \frac{1}{\mu_i(1-\mu_i)} \cdot \left(\frac{d\mu_i}{d\eta_i}\right)^2$$

* $\theta_i = \log\left(\frac{\mu_i}{1-\mu_i}\right) \Rightarrow \frac{d\theta_i}{d\mu_i} = \frac{1}{\mu_i(1-\mu_i)}$ e $\frac{d\theta_i}{d\eta_i} = \frac{1}{\mu_i(1-\mu_i)} \cdot \frac{d\mu_i}{d\theta_i}$

* na canônica $\theta_i = \eta_i \Rightarrow \frac{d\theta_i}{d\eta_i} = 1$ * $w_i = \frac{1}{V_i g'(\mu_i)^2}$ ou $w_i = V_i \left(\frac{d\theta}{d\eta}\right)^2$

$\Rightarrow w = \mu(1-\mu)\left(\frac{d\theta}{d\eta}\right)^2$. convenção: $w = n\mu(1-\mu)\left(\frac{d\theta}{d\eta}\right)^2$, $\phi = 1$

com η canonica: $\eta = \log\left(\frac{\mu}{1-\mu}\right)$, $w = n\mu(1-\mu) \Rightarrow$

$U_\beta = X^T(y-\mu)$ e $K_{\beta\beta} = X^T V X$.

Gama:

Temos $V(\mu)=\mu^2 \Rightarrow w=\mu^2\cdot\left(\frac{d\theta}{d\mu}\right)^2$. se $\eta=\log\mu$, $\frac{d\mu}{d\eta}=\mu$

$\Rightarrow w=1$ pois $w=\frac{1}{\mu^2}\cdot\left(\frac{d\mu}{d\eta}\right)^2=\frac{\mu^2}{\mu^2}=1$.

$\Rightarrow U_\beta=\phi X^T V^{-\frac{1}{2}}(y-\mu)$ e $K_{\beta\beta}=\phi X^T X$.

pl ligação canônica, $w=\mu^2$, $U_\phi=-\sum_{i=1}^{n}\left(\frac{y_i}{\mu_i}+\log(\mu_i)+\sum c'(y_i;\phi)\right)$

$c'(y_i;\phi)=\log(y_i)+\log(\phi)+1-\psi(\phi)$, onde $\psi(\phi)=\Gamma'(\phi)/\Gamma(\phi)$
↳ digama.

e $c''(y;\phi)=1/\phi-\psi'(\phi)$

* Trigama $=\psi'(\phi)=\frac{d\psi(\phi)}{d\phi}$

$\Rightarrow K_{\phi\phi}=-\sum E[c''(Y_i;\phi)]=n\{\phi\psi'(\phi)-1\}/\phi$

Normal inversa:

$V(\mu)=\mu^3 \Rightarrow w_i=\mu^3\left(\frac{d\theta}{d\eta}\right)^2$. se modelo log-linear $(\eta=\log\mu)$
$\Rightarrow w=\mu^{-1}$.

pl ligações canônica: $w=\mu^3$ $(\eta=\frac{1}{\mu^2})$ $\Rightarrow U_\beta=\phi X^T(y-\mu)$ e $K_{\beta\beta}=\phi X^T V X$

e $U_\phi=\sum\left(\frac{1}{\mu_i}-\frac{y_i}{2\mu_i^2}\right)+\sum c'(y_i;\phi)$. com $c'(y_i;\phi)=\frac{1}{2\phi}-\frac{1}{2}y_i$.

e $c''(y_i;\phi) = -1/2\phi^2 \Rightarrow K_{\phi\phi} = -\sum E[c''(y_i;\phi)] = \frac{+n}{2\phi^2}$

Estimação de parametros

de β:

Newton Raphson: $U_\beta \cong U_\beta^{(0)} + U_\beta'^{(0)}(\beta - \beta^{(0)})$

$\Rightarrow$ Processo iterativo: $\beta^{(m+1)} = \beta^{(m)} + \left\{(-U_\beta')^{-1}\right\}^{(m)} U_\beta^{(m)}$

método de score de fisher: substitui $-U_\beta'$ por $K_{\beta\beta}$ que é o seu valor esperado.

$\Rightarrow$

$\beta^{(m+1)} = (X^T W^{(m)} X)^{-1} X^T W^{(m)} z^{(m)}$, $m = 0, \ldots$ até convergir

$z = \eta + W^{\frac{1}{2}} V^{-\frac{1}{2}} (y - \mu)$. W: matriz de pesos que muda em cada passo.

* É comum iniciar $\eta^{(0)} = [g(y_1) \cdots g(y_n)]^T$

Caso logístico Binomial: $w = n\mu(1-\mu)$ e $z = \eta + \frac{(y - n\mu)}{n\mu(1-\mu)}$

Note: no modelo normal linear tem forma fechada de MV:

$\hat{\beta} = (X^T X)^{-1} X^T y$

Estimação de ϕ.

vamos igualar a função escore U_ϕ a zero, temos:

$$U_\phi = \frac{\partial L(\theta)}{\partial \phi}\Big|_{\phi=\hat{\phi}} = \sum_{i=1}^{n} [y_i\theta_i - b(\theta_i)] + \sum_{i=1}^{n} c'(y_i,\hat{\phi}) = 0$$

solução é que

$$\Rightarrow \sum c'(y_i,\hat{\phi}) = \frac{1}{2} D(y,\hat{\mu}) - \sum [y_i\tilde{\theta}_i - b(\tilde{\theta}_i)]$$

$D(y,\hat{\mu})$: desvio do modelo sob investigação

Caso normal e normal inversa, EMV de ϕ é:

$$\hat{\phi} = \frac{n}{D(y,\hat{\mu})}$$

Caso gama: a EMV de $\hat{\phi}$ sai da eq:

$$2n\{\log\hat{\phi} - \psi(\hat{\phi})\} = D(y,\mu)$$

Estimador consistente p/ ϕ (de momentos) (baseado na estatística de pearson)

$$\hat{\phi} = \frac{n-p}{\sum\left\{\frac{(y_i-\hat{\mu}_i)^2}{V(\mu_i)}\right\}}$$

suposição: $\hat{\beta}$ consistentemente estimado.

* R faz $\hat{\phi} = \frac{n-p}{D(y,\hat{\mu})}$, não é consistente

Dist assintótica do $\hat{\beta}$ e $\hat{\phi}$

temos $\hat{\beta} \perp \hat{\phi}$.

considere $E(U_\theta) = 0$, $Var(U_\theta) = K_{\theta\theta}$, com as funções escore de β e ϕ expressas na forma:

$U_\beta = \phi \sqrt{w_i V_i^{-1}} (y_i - \mu_i) x_i$, e $U_\phi = \sum U_{i\phi}$

onde $U_{i\phi} = \{y_i \theta_i - b(\theta_i)\} + c'(y_i; \phi)$

$\Rightarrow$ TCL: $U_\theta \sim N_{p+1}(0, K_{\theta\theta})$

então $U_\beta \sim N_p(0, K_{\beta\beta})$

e $U_\phi \sim N_1(0, K_{\phi\phi})$

Teste de hipótese para os $\underset{\sim}{\beta}$ e ϕ

caso 1

Generalização p/ MLG's:

$H_0: \beta = \beta^0$ vs $H_1: \beta \neq \beta^0$. * supondo ϕ conhecido

Teste da Razão de Verossimilhança

def: $\xi_{RV} = 2\{L(\hat{\beta}) - L(\beta^0)\}$. mas também pode ser expressa

como: $\xi_{RV} = \phi\{D(y, \hat{\mu}^0) - D(y, \hat{\mu})\}$

onde $\hat{\mu}^0 = g^{-1}(\hat{\eta}^0)$ e $\hat{\eta}^0 = X^T\beta^0$

caso particular em MLGer: $\xi_{RV} = \sum_{i=1}^{n}(y_i - \hat{\mu}_i^0)^2 - \sum_{i=1}^{n}(y_i - \hat{\mu}_i)^2/\sigma^2$

Teste de Wald

def: $\xi_W = [\hat{\beta} - \beta^0]^T \hat{Var}^{-1}(\hat{\beta})(\hat{\beta} - \beta^0)$ onde $\hat{Var}(\beta)$ é a matriz de var-cov assintótica de $\hat{\beta}$ estimada em $\hat{\beta}$

Para os MLGs, $\hat{Var}(\hat{\beta}) = \hat{K}^{-1}(\hat{\beta})$ e $K_\beta = \phi X^T W X$

$\Rightarrow$ nova forma de expressar $\xi_W = \phi[\hat{\beta} - \beta^0](X^T\hat{W}X)[\hat{\beta} - \beta^0]$

* caso particular com $p=1$: $\xi_W = \dfrac{(\hat{\beta} - \beta^0)^2}{\hat{Var}(\hat{\beta})}$

* Problema com a estatística de Wald: ξ_W depende da parametrização usada. — formas diferentes e equivalentes para $\eta(\beta)$ podem levar a diferentes valores de ξ_W.

Gradiente:

$$Q_G = [\tilde{U}_{\beta_b}]^T[\hat{\beta}_b - \beta_b^{(0)}]$$

Teste de escore conhecido também como teste de Rao

definido quando $U_\beta(\hat{\beta}) = 0$ por

$$\xi_{SR} = U_\beta(\beta^\circ)^T \hat{V}ar_0(\hat{\beta})\, U_\beta(\beta^\circ)$$

em que $\hat{V}ar(\hat{\beta})$ denota variância assintotica de $\hat{\beta}$ está sendo estimada sob H_0. e sabendo que $\hat{V}ar(\hat{\beta}) = K^{-1}(\hat{\beta})$

e $K(\beta) = \phi X^T W X$

podemos reescrever da forma:

$$\xi_{SR} = \phi^{-1} U_\beta(\beta^\circ) (X^T \hat{W}_0 X)^{-1} U_\beta(\beta^\circ)$$

, $\hat{W}_0$ é W estimado sob H_0.

* ξ_{SR} é conveniente quando é H_1 mais complexa que H_0.

Caso de normal linear, temos:

$$\xi_{SR} = (y - X\beta^\circ)^T X (X^T X)^{-1} X^T (y - X\beta^\circ) / \sigma^2$$

e ξ_W e ξ_{RV} coincidem com ξ_{SR}

Teste F

como definida em 2.4: $F = \dfrac{\{D(y,\hat{\mu}^\circ) - D(y,\hat{\mu})\}/p}{D(y,\hat{\mu})/(n-p)} \overset{H_0}{\underset{\phi \to 0}{\sim}} F_{p,n-p}$

* Propriedades sobre ξ_{RV}, ξ_{SR} e F: são invariantes com reparametrização $\Rightarrow$ útil pl construir intervalo/região de confiança pl os parâmetros

* Note que sob H_0, assintoticamente $\xi_{RV}, \xi_{SR}, \xi_W \longrightarrow \chi^2_p$

* Por Wald:

$$IC(\beta, (1-\alpha)\%) = \left\{\beta; (\hat{\beta}-\beta)^T (X^T \hat{W} X)(\hat{\beta}-\beta) \leq \phi^{-1} \chi^2_p (1-\alpha)\right\}$$

* Por RV:

$$IC(\beta, (1-\alpha)\%) = \left\{\beta; 2\cdot(L(\hat{\beta}) - L(\beta)) \leq \chi^2_p (1-\alpha)\right\}$$

- se o interesse é subconjunto β_1 q-dimensional, a região de confiança assintótica é:

Wald: $IC(\beta, (1-\alpha)\%) = \left[\beta; (\hat{\beta}_1-\beta)^T \hat{V}_{ar}^{-1}(\hat{\beta}_1)(\hat{\beta}_1-\beta) \leq \phi^{-1} \chi^2_q (1-\alpha)\right\}$

RV: $IC(\beta; (1-\alpha)\%) = \left[\beta; 2\left(L(\hat{\beta}) - L(\beta, \beta_2(\hat{\beta}))\right) \leq \chi^2_p (1-\alpha)\right\}$

nesse caso β é q-dim, $\hat{\beta}_2(\beta)$ é EMV de β_2 dado β.

Modelos encaixados

Supondo que temos uma partição de $\beta = (\beta_1^T \ \beta_2^T)^T$,

$H_0: \beta_1 = \beta_1^0$ vs $H_1: \beta_1 \neq \beta_1^0$

então $\xi_{RV} = \phi\{D(y,\mu^0) - D(y,\hat{\mu})\}$, em que $\hat{\mu}^0$ é EMV do

MLG com parte sistemática $\eta = \hat{\eta}_1^0 + \eta_2$, onde $\hat{\eta}_1^0 = \sum_{j=1}^{q} x_j \beta_j^0$

e $\eta_2 = \sum_{j=q+1}^{p} x_j \beta_j$

* $\hat{\eta}_1^0$ tem papel de um offset (parte conhecida no preditor linear)

Se Poisson e g é log linear, uma resp e 2 covs (cov1 e cov2) e offset dado como logto, então:

em R:

```
fit1.poisson = glm(resp ~ cov1 + cov2 + offset(logto), family = poisson)
```

Wald: $\xi_W = (\hat{\beta}_1 - \beta_1^0)\, \hat{Var}^{-1}(\hat{\beta}_1)\, (\hat{\beta}_1 - \beta_1^0)$

onde $\hat{Var}^{-1}(\hat{\beta}_1) = \phi^{-1}(X_1^T W^{\frac{1}{2}} M_2 W^{\frac{1}{2}} X_1)^{-1}$ onde X_1 vem da partição $X = [X_1 \ X_2]$

e M_2 vem de $M_2 = I_n - H_2$, onde

$H_2 = W^{\frac{1}{2}} X_2 (X_2^T W X_2)^{-1} X_2^T W^{\frac{1}{2}}$ = matriz de projeção ortogonal de vetores de $\mathbb{R}^n$ no subespaço gerado pelas colunas da matriz $W^{\frac{1}{2}} X_2$.

Caso particular de normal linear: $H_2 = X_2 (X_2^T X_2)^{-1} X_2^T$ e

$$Var(\hat{\beta}_1) = \sigma^2 [X_1^T (I_n - H_2) X_1]^{-1}$$

Teste de escore

$U_\beta = \phi^{r/2} X^T W^{1/2} \cdot r_p$, onde $r_p = \phi^{\frac{1}{2}} V^{-\frac{1}{2}} (y - \mu)$ é conhecido como resíduo de Pearson. Note que $E(r_p) = 0$ e $Var(r_p) = I_n$ →

$$\xi_{SR} = U_{\beta_1}(\hat{\beta}_1^0) \hat{Var}_0(\hat{\beta}_1) U_{\beta_1}(\hat{\beta}^0).$$

onde $U_{\beta_1}(\beta) = \frac{\partial L(\beta)}{\partial \beta_1} = \phi X_1^T W^{\frac{1}{2}} V^{-\frac{1}{2}} (y - \mu)$, $\hat{\beta}^0 = (\beta_1^{0T}, \hat{\beta}_2^{0T})^T$

e $\hat{\beta}_2^0$ é EMV de β_2