1ª Prova - Modelos lineares generalizados - 23/10/2018

Exercício 1. (2,0 pontos) Seja y uma variável aleatória com distribuição cuja função de probabilidade é dada por

$$f(y;\mu) = \frac{\mu^y}{(\mu+1)^{y+1}},$$

$\mu > 0$ e $y = 0, 1, 2, \ldots$.

(a) (1,0 ponto) Mostre que a distribuição de y pertence à família exponencial linear, apresentando cada um dos termos de sua função de probabilidade no formato da família exponencial linear.

(b) (1,0 ponto) Encontre $E(y)$ e $Var(y)$ em função de μ.

Exercício 2. (2,50 pontos) Um pesquisador está interessado em comparar o número médio de filhos em determinada região em função do grau de escolaridade da mãe observada em apenas 2 níveis: superior/pós graduação e outros. Inicialmente ele pegou uma amostra piloto de 6 mulheres com idade entre 40 e 45 anos. Entre as 3 mulheres da amostra com grau de escolaridade superior/pós graduação o número de filhos observado na amostra foi 1, 2, 1. Já entre as 3 mulheres com outro grau de escolaridade o número de filhos observado na amostra foi 3, 1, 2. O pesquisador irá considerar um modelo linear generalizado dado por $g(\mu_i) = \beta_0 + \beta_1 x_i$, em que $x_i = 1$ se a mulher i tem grau de escolaridade superior/pós graduação e $x_i = 0$ caso contrário.

(a) (0,25 ponto) Entre as distribuições normal, gama, gaussiana inversa, poisson e binomial, qual delas você escolheria para a distribuição da variável resposta. Justifique sua resposta.

(b) (1,50 ponto) Considere o modelo mencionado, sendo que distribuição da variável resposta é a mais adequada dentre as apresentadas no item (a) e a função de ligação é a canônica. Utilizando o método de mínimos quadrados ponderados iterativos para a estimação de β_0 e β_1 a partir da amostra piloto, obtém-se no passo 1 da processo iterativo. $\hat{\beta}_0 = 0,7805$ e $\hat{\beta}_1 = -0,4339$. A partir desses valores, apresente a matriz W e o vetor z que são usados para obter $\hat{\beta}_0$ e $\hat{\beta}_1$ no passo e do processo iterativo. **Para economizar tempo, se quiser, apresente a matriz W e o vetor z apenas como o produto de outros vetores e matrizes e apresente os valores em cada posição desses vetores e matrizes usados para obter W e z.**

(c) (0,75 ponto) Para os dados da amostra piloto, para qual valor aproximadamente deverá convergir $\hat{\beta}_0$ e $\hat{\beta}_1$? Justifique sua resposta (**não é necessário fazer o processo iterativo até a convergência para responder a essa questão**).

Exercício 3. (1,50 ponto) Suponha que y_i tem distribuição Bernoulli com parâmetro μ_i. Considere o modelo $\log(\mu_i/(1-\mu_i)) = \beta_0 + \beta_1 x_i$, em que x_i é o valor para a observação i de uma determinada variável preditora quantitativa. Considere que será retirada uma amostra de tamanho n e considere $\bar{y}$ e $\bar{x}$, respectivamente, a média amostral da variável resposta e da variável preditora. Considerando-se o teste $H_0 : \beta_1 = 0 \times H_1 : \beta_1 \neq 0$, pode-se mostrar que, sob $H_0 : \beta_1 = 0$, o estimador de máxima verossimilhança de β_0 é

$$\tilde{\beta}_0 = \log\left(\frac{\bar{y}}{1-\bar{y}}\right).$$

Sabe-se ainda que a estatística escore para testar $H_0 : \beta_1 = 0 \times H_1 : \beta_1 \neq 0$ é dada pelo produto de 3 termos. Mostre que o primeiro desses termos é dado por

$$\sum_{i=1}^{n} x_i(y_i - \bar{y}).$$

Exercício 4. (4,0 pontos) Um pesquisador está estudadando a média da distância percorrida em um teste físico de 12 minutos entre sedentários homens com idade entre 30 e 34 anos em função de duas variáveis: imc e grupo de sedentarimo: A (trabalha predominantemente em pé), B (trabalha entre 25% e 50% do tempo em pé) e C (trabalha menos de 25% do tempo em pé). Para realização do estudo ele coletou uma amostra de 60 indivíduos, sendo 20 de cada grupo de sedentarismo. Considere que será ajustado um modelo assumindo distribuição gama para a variável resposta e função de ligação logarítmica.

(a) (0,5 ponto) Apresente o modelo para este problema considerando interação entre as variáveis preditoras disponíveis. Quais seriam as hipóteses em termos dos parâmetros do modelo para testar se há ou não interação entre as variáveis preditoras?

Para fazer os demais itens, considere que testou-se inicialmente se havia ou não interação e concluiu-se não haver evidências de que haja interação. Ajustou-se assim um modelo sem interação. Gráficos de diagnóstico para o modelo sem interação são apresentados em anexo, bem como resultados do modelo com todas as variáveis preditoras e do modelo sem a variável qualitativa.

(b) (0,75 ponto) Parece haver pontos de alavanca? Justifique sua resposta. Parece haver observações discrepantes? Justifique sua resposta. Parece haver observações influentes? Justifique sua resposta. Caso tenha respondido sim em pelo menos um das perguntas desse item, o que você faria em relação a esses pontos?

(c) (0,4 ponto) Baseado nos gráficos apresentados, parece haver algum problema com as suposições do modelo? Justifique sua resposta.

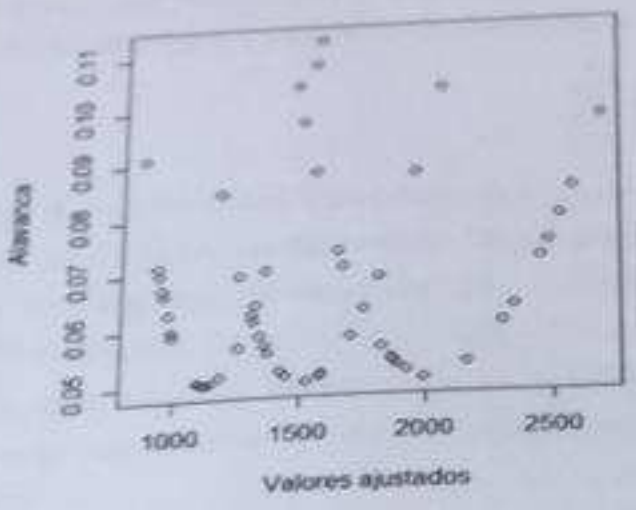
(d) (0,35 ponto) Interprete em termos do problema em questão o exponencial da estimativa que foi igual a -0,52 no problema em questão.

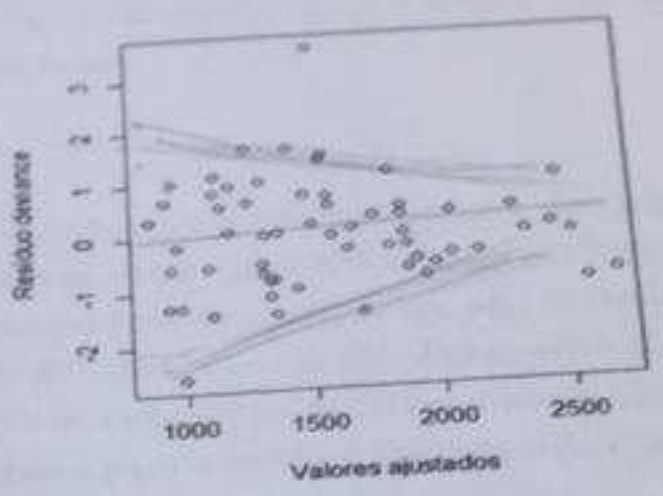
(e) (0,9 ponto) Teste a hipótese de que a média variável distância percorrida no teste de 12 minutos varia em função do grupo de sedentarismo considerando um nível de significância de 1%.

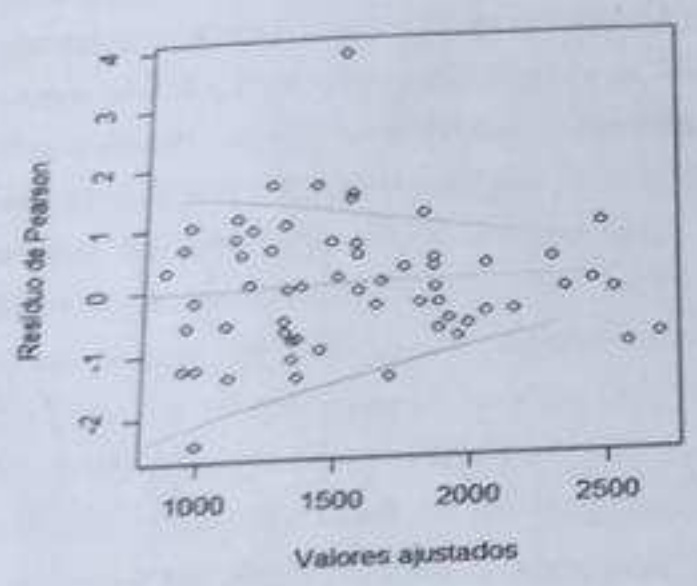
(f) (0,75 ponto) Construa um intervalo de confiança com 90% de confiança para a exponencial do parâmetro cuja estimativa foi igual a -0,06 e interprete o intervalo obtido em temos de problema em questão.

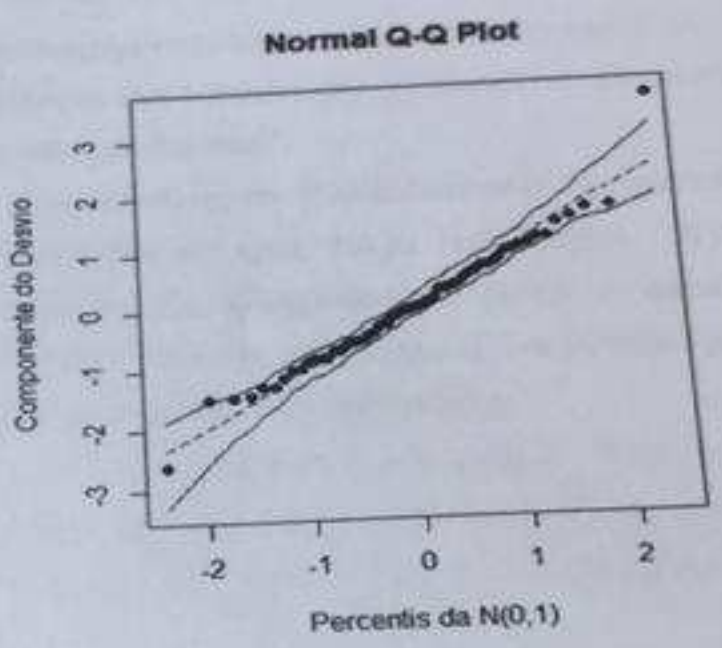
(g) (0,35 ponto) De forma geral (não apenas para esse conjunto de dados), suponha que você já identificou que uma das distribuições da família exponencial é adequada para a variável resposta que você está trabalhando. Para decidir entre algumas possíveis funções de ligação, você decide usar o AIC. A função de ligação que você escolher baseada no AIC é a mesma que você escolheria caso usasse o BIC? Justifique sua resposta.

1,6










```
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    9.280626   0.093663   99.08  < 2e-16 ***
imc           -0.062597   0.003456  -18.11  < 2e-16 ***
grupoB        -0.251589   0.023247  -10.82 2.41e-15 ***
grupoC        -0.523534   0.023374  -22.40  < 2e-16 ***
---
(Dispersion parameter for Gamma family taken to be 0.005363563)
    Null deviance: 5.33990  on 59  degrees of freedom
Residual deviance: 0.29304  on 56  degrees of freedom
AIC: 739.19
```

```
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    9.29380    0.28687  32.398  < 2e-16 ***
imc           -0.07176    0.01050  -6.836 5.53e-09 ***
---
(Dispersion parameter for Gamma family taken to be 0.05044265)

    Null deviance: 5.3399  on 59  degrees of freedom
Residual deviance: 2.9726  on 58  degrees of freedom
AIC: 874.65
```