Motivações

Estatística Multivariada 2 - 2025/2

Victor Coscrato

Parte I: Estatística multivariada

Problema 1

O ingresso de alunos na UFSCar é realizado a partir das provas do Exame Nacional do Ensino Médio (ENEM). O ENEM é composto de quatro provas: Linguagens e Códigos, Ciências da Natureza, Ciências Humanas e Matemática. Além disso ao inscrever-se no ENEM os candidatos preenchem um questionário socioeconômico com uma série de informações relativas a dados pessoais.

Uma base de dados esta disponível para estudo com informações dos alunos ingressos na UFSCar em 2017 com as seguintes informações:

1. Nota em cada uma das quatro provas;
2. Curso, Período e Campus que o aluno ingressou;
3. Sexo, Faixa Etária, Optante ou não por ações afirmativas, Período que cursou ensino médio, Exercia atividade remunerada ou não

Problema 1

Algumas possíveis questões a serem estudadas:

1. Os alunos do sexo masculino e feminino apresentam a mesma nota média em todas as provas?
2. Os alunos dos diferentes campi apresentam a mesma nota média em todas as provas?
3. Um determinado aluno não apresenta as informações do questionário socioeconômico, como podemos atribuir seu possível campi a partir das notas de suas provas?
4. Podemos identificar alguma estrutura conjunta entre as 4 diferentes provas?
5. Podemos identificar grandes grupos ou subgrupos homogêneos de alunos a partir das suas notas?
6. Existe alguma estrutura de relações entre as informações do bloco 3?

Porque realizar análises multivariadas?

- A realidade é multivariada



- É muito raro que fenômenos possam ser estudados de maneira isolada. No geral, existem diversas covariáveis relacionadas a qualquer grandeza de interesse.
- Todas essas covariáveis possuem uma estrutura de relações.
- Estudar grandezas de maneira isolada, ignora uma tal relação, que é uma fonte importantíssima de informação.

Objetivos de análises multivariadas?

- **Simplificação Estrutural:** Reduzir a dimensionalidade dos dados, identificando as principais fontes de variação e eliminando redundâncias. Isso facilita a visualização e a interpretação de dados complexos, revelando a estrutura subjacente de forma mais clara.
- **Agrupamento e Classificação:** Organizar as observações em grupos homogêneos (agrupamento) ou atribuir observações a categorias predefinidas (classificação). O objetivo é identificar padrões que permitam segmentar os dados de maneira significativa.
- **Investigação de Estruturas de Dependência:** Explorar e quantificar as relações entre variáveis. Isso inclui desde a análise de correlações simples até a modelagem de interações complexas entre múltiplos conjuntos de variáveis.
- **Predição:** Construir modelos para prever o valor de uma ou mais variáveis com base em outras.
- **Inferência:** Realizar testes de hipóteses e inferências estatísticas sobre as relações em um contexto multivariado.

Técnicas Multivariadas

Podemos classificar as técnicas multivariadas em dois grandes blocos:

- **Técnicas de Dependência:** Analisam a relação entre uma ou mais variáveis dependentes e um conjunto de variáveis independentes. O objetivo é prever ou explicar o valor das variáveis dependentes.
- **Técnicas de Interdependência:** Exploram as relações entre todas as variáveis de um conjunto, sem fazer distinção entre dependentes e independentes. O foco é entender a estrutura geral dos dados.

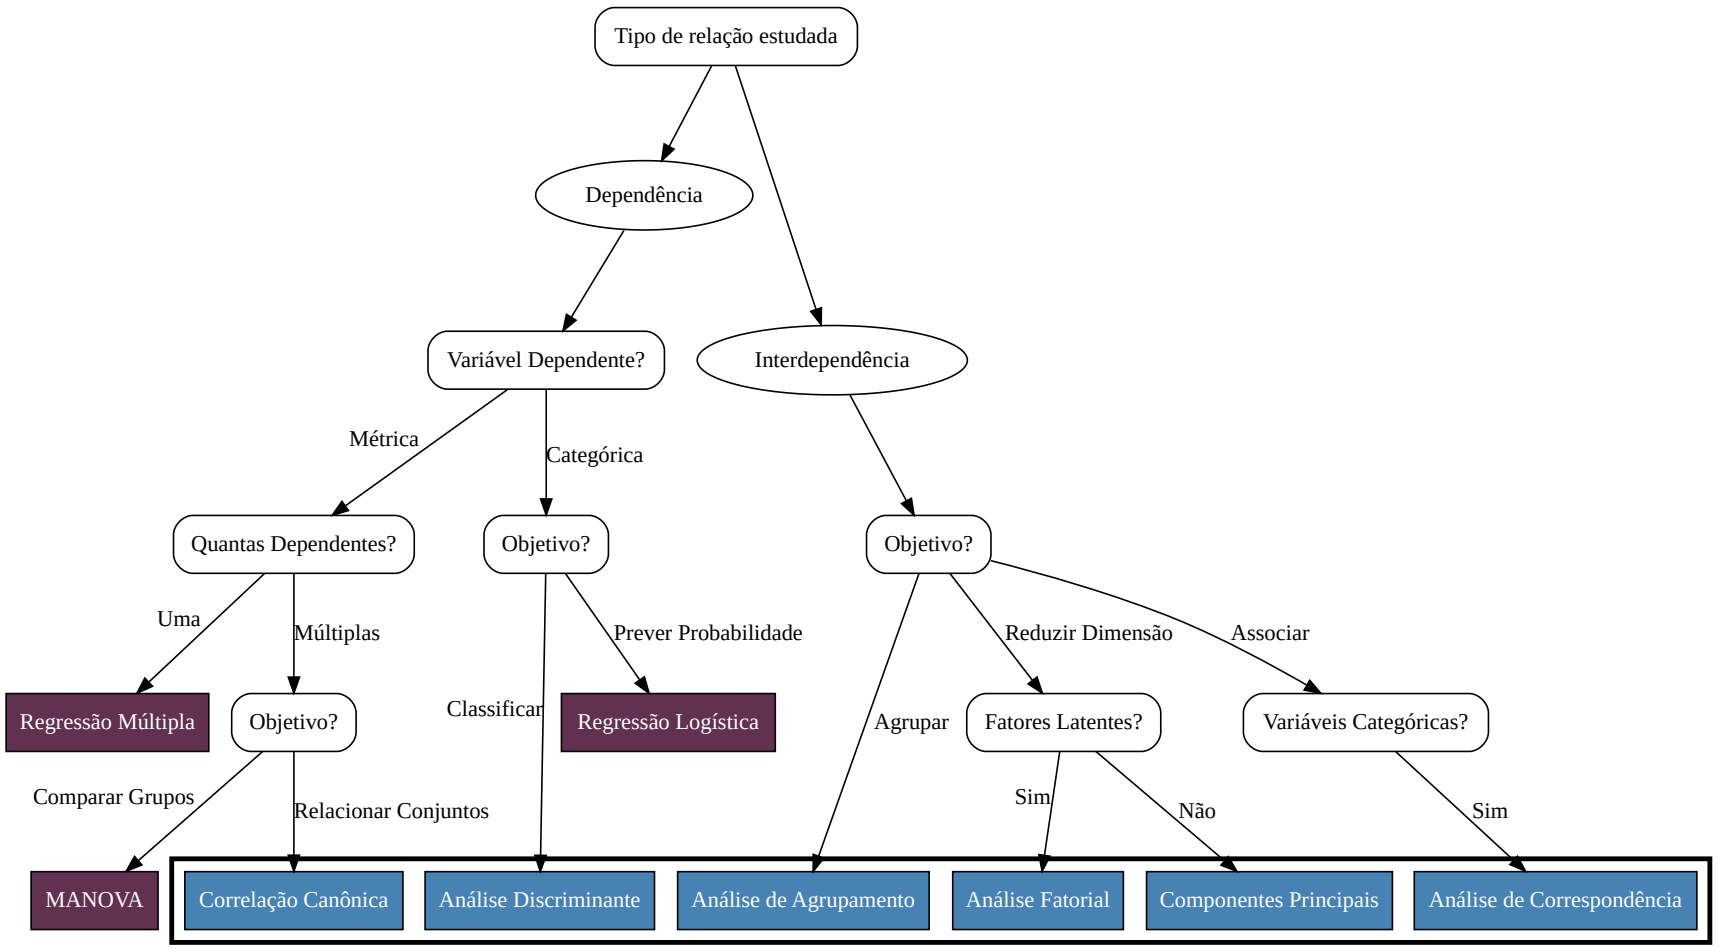
Além disso a escolha de uma determinada técnica depende também dos tipos de variáveis em questão:

- **Variáveis Categóricas (Qualitativas):** Representam categorias ou grupos (e.g., gênero, tipo de produto).
- **Variáveis Métricas (Quantitativas):** Representam quantidades numéricas (e.g., idade, altura, renda, temperatura).

Técnicas Multivariadas

Técnica	Objetivo Principal	Tipo de Variável	Tipo de Análise
Componentes Principais (PCA)	Redução de dimensionalidade	Quantitativas	Interdependência
Análise Fatorial (FA)	Identificação de fatores latentes	Quantitativas	Interdependência
Análise de Agrupamento	Formação de grupos homogêneos	Quantitativas/Qualitativas	Interdependência
Análise Discriminante	Classificação de observações	Mista (Quali/Quanti)	Dependência
Correlação Canônica	Relação entre conjuntos de variáveis	Quantitativas	Dependência
Análise de Correspondência	Relação entre variáveis categóricas	Qualitativas	Interdependência

Técnicas Multivariadas



Problema 2

O petróleo tanto pode ter origem em carbonatos (C) e folhelhos (F) de origem marinha, como em ambientes deltaicos (D) e para explicar a sua gênese são utilizadas diversas variáveis em conjunto. Foram coletados dados referentes a 63 amostras de petróleo (21 para cada uma das possíveis origens) nas quais foram obtidas as seguintes variáveis:

- API: densidade em unidades API
- S: porcentagem de enxofre
- Pr/Ph: razão pristâneo/fitâneo
- S/A: razão entre hidrocarbonetos saturados e aromáticos
- PCIR: razão isotópica de carbono(12C/13C) no petróleo
- GCIR: razão isotópica de carbono na fração gasolina
- G-R: diferença entre as razoes isotópicas na fração gasolina e no resíduo

Parte II: Recursos computacionais

Recursos computacionais

- É possível considerar o uso de métodos estatísticos multivariados sem recursos computacionais?

Recursos computacionais



Recursos computacionais







Recursos computacionais

- Python

```python
from sklearn.decomposition import PCA
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

acp = make_pipeline(StandardScaler(), PCA()).fit(X)
```

O elefante na sala

O elefante na sala







ChatGPT



Falácias da IA

- Revolução na educação



Youtube: Perimeter Institute for Theoretical Physics (clickme)

O processo de aprendizagem

O que não importa

- Forma de apresentação
- Acúmulo de material ou informação

O que importa

- Esforço
- Motivação
- Feedback
- Ambiente

O esforço

