26 08 17 1ª aula (0ª?)

26 08 19 2ª aula

Relembrando que:

Def: vetor aleatório

$$\underset{\sim}{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix}_{p\times 1}$$

Operadores em um vetor aleatório:

$$E(X) = \mu = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{bmatrix} \qquad Var(X) = Cov(X) = \Sigma = E\left((X-\mu)(X-\mu)^T\right)$$

$$Corr(X) = \rho = \begin{bmatrix} 1 & \rho_{12} & \cdots & \vdots \\ \rho_{21} & 1 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 1 \end{bmatrix} \qquad \rho_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}\,\sigma_{jj}}}$$

Propriedades:

- $E(Ax+b) = AE(x) + b$, com $A \in M_{q\times p}(\mathbb{R})$, $b \in \mathbb{R}_{q\times 1}$

- $Cov(Ax + c) = A\,Cov(x)\,A^T$, com $A \in M_{q\times p}(\mathbb{R})$, $c \in \mathbb{R}_{q\times 1}$

Vamos denotar a matriz de dados por

$$X = \begin{bmatrix} X_1^T \\ X_2^T \\ \vdots \\ X_n^T \end{bmatrix}_{n\times p} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ \vdots & \vdots & & \vdots \\ X_{n1} & \cdots & & X_{np} \end{bmatrix}$$

o estimador de $E(X) = \mu$ a partir de X é

$$\bar{x} = \hat{\mu} = \begin{pmatrix} \bar{x}_1 \\ \vdots \\ \bar{x}_p \end{pmatrix} = \left(\frac{1^T X}{n}\right)^T$$

Def. Formas Quadráticas.

$$x_{p\times 1} \text{ e } A \in M_{p\times p}(\mathbb{R}) \Rightarrow Q(x) = x^T A x = \sum_{i=1}^{p}\sum_{j=1}^{p} a_{ij} x_i x_j$$

Def. Uma matriz simétrica A é dita positiva definida se e somente $x^T A x > 0 \quad \forall x, x \neq 0$.

* semi-pos. def: $x^T A x \geq 0$

Propriedades: Se A é pos. def então:

- os autovalores de $\lambda_1, \dots \lambda_p$ de A são positivos.
- A^{-1} existe
- $\det(A) > 0$

Def. A é dita idempotente se $AA^T = A^2 = A$

Teorema da decomposição espectral

Toda matriz simetrica $A_{p\times p}$ pode ser escrita como

$$A = E \Lambda E^T \quad , \text{ onde } E = [e_1 \; e_2 \; \cdots \; e_p] \text{ e } \Lambda = \begin{bmatrix} \lambda_1 & & 0 \\ & \lambda_2 & \\ 0 & & \ddots \; \lambda_p \end{bmatrix}$$

$$= \sum_{i=1}^{p} \lambda_i e_i e_i^T$$

* e_i = autovetor associado ao i^{th} autovalor ortonormalizado.

Note que iremos fazer

$$\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \cdots \geq \lambda_p$$

Exemplo: decompondo $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$

$$\det(A - \lambda I) = \begin{vmatrix} 2-\lambda & 1 \\ 1 & 2-\lambda \end{vmatrix} = (2-\lambda)^2 - 1 \Rightarrow \begin{cases} \lambda_1 = 3 \\ \lambda_2 = 1 \end{cases}$$

Para $\lambda_1 = 3$ o autovetor é $\begin{pmatrix}1\\1\end{pmatrix} \Rightarrow e_1 = \begin{pmatrix}1/\sqrt{2}\\1/\sqrt{2}\end{pmatrix}$

Para $\lambda_2 = 1$, $e_2 = \begin{pmatrix}1/\sqrt{2}\\-1/\sqrt{2}\end{pmatrix}$

Def. Decomposição em valores singulares.

Dada $A_{p\times q}$ A pode ser escrita como $A = U\Lambda V^T$

onde U é a matriz ortogonal de ordem $p\times p$ de vetores singulares a esquerda (AA^T)

e V é a matriz ortogonal de ordem $q\times q$ de vet sing a direita (A^TA)

e $\Lambda_{p\times q}$ é a matriz onde a diag. principal contém os quadrados dos autovalores.

Tomando $M < \min(p\times q)$

$U_m = (U_1\ U_2 \dots U_m)$ $\quad \Lambda_{m\times m} = \begin{bmatrix}\lambda_1 & & 0\\ & \lambda_2 & \\ 0 & & \ddots\ \lambda_m\end{bmatrix}$

$V^T = (V_1\ V_2 \dots V_m)$

$$A \cong A_m \cong U_m \Lambda_m V_m^T = \sum^m \lambda_i U_i V_i^T$$

A_m é a MELHOR aproximação de A de ordem M.

Análise de Componentes Principais* (Apenas p/ variáveis numéricas)

Def. Dado um vetor aleatório p-dimensional $\tilde{x} = [x_1\ x_2\ \cdots\ x_p]^T$ com $Cov(x) = \Sigma$, os componentes principais são um novo sistema de coordenadas $[Y_1\ Y_2\ \cdots\ Y_p]^T$

Tal que
$$Y_1 = u_1^T x = u_{11}x_1 + u_{12}x_2 + \cdots + u_{1p}x_p$$
$$Y_2 = u_2^T x = u_{21}x_1 + u_{22}x_2 + \cdots + u_{2p}x_p$$
$$\vdots$$
$$Y_p = u_p^T x = u_{p1}x_1 + u_{p2}x_2 + \cdots + u_{pp}x_p$$

os vetores u_i, $i = 1, \cdots, p$ definem as direções dos nums direcionados.

os CPs (Componentes Principais) tem duas propriedades Importantes:

- São não correlacionados entre si, ou seja $Cov(Y_i, Y_j) = 0$, $\forall i \neq j$

- Suas variâncias são decrescentes, isso é:

$$Var(Y_1) \geq Var(Y_2) \geq Var(Y_3) \geq \cdots \geq Var(Y_p)$$

$\Rightarrow$ Análise de CP serve pl tornar x em y que é melhor de interpretar, menor dimensão etc.

26 of 24 3ª aula

Retomando na análise de componentes principais

$$Y_1 = u_1^T x = u_{11}x_1 + u_{12}x_2 + \cdots + u_{1p}x_p$$

$$Y_2 = u_2^T x = \cdots \quad Y_3 = \cdots \quad \cdots \quad Y_p = u_p^T x$$

propriedades: * $Cov(Y_i, Y_j) = 0$, $i \neq j$

* $Var(Y_1) \geq Var(Y_2) \geq \cdots \geq Var(Y_p)$

Conteúdo novo:

!! Queremos centralizar os dados (1º passo)

$$x^c = x - \mu$$

$$x = x^c$$

Exemplo. Supondo que Victor coletou notas dos alunos em duas avaliações (1 prova + 1 trabalho; X_1 e X_2)

$$x = \begin{bmatrix} X_1 - E(X_1) \\ X_2 - E(X_2) \end{bmatrix}$$



*Relembrando de GA

$$X = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

matriz de rotação de eixos: $[u_1(\theta) \; u_2(\theta)]$

$$u = \begin{bmatrix} \cos\theta & -\text{sen}\theta \\ \text{sen}\theta & \cos\theta \end{bmatrix}$$

$$\Rightarrow Y_1 = u_1^T(\theta)X = \cos\theta X_1 + \text{sen}\theta X_2$$

$$Y_2 = u_2^T(\theta)X = -\text{sen}\theta X_1 + \cos\theta X_2$$

Transformamos o problema de encontrar a direção de maior informação (maior variabilidade), no problema de escolher θ tal que Y_1 aponte pl tal direção.

$$Var(Y_1) = Var(u_1^T X) = u_1^T Var(X) u_1$$

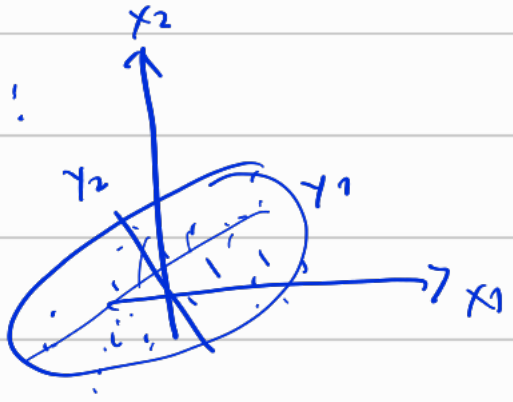
$$= \underset{1\times 2}{[\cos\theta \;\; \text{sen}\theta]} \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix} \begin{bmatrix} \cos\theta \\ \text{sen}\theta \end{bmatrix}$$

$$= [\cos\theta\,\sigma_{11} + \text{sen}\theta\,\sigma_{21} \quad \cos\theta\,\sigma_{21} + \text{sen}\theta\,\sigma_{22}] \begin{bmatrix} \cos\theta \\ \text{sen}\theta \end{bmatrix}$$

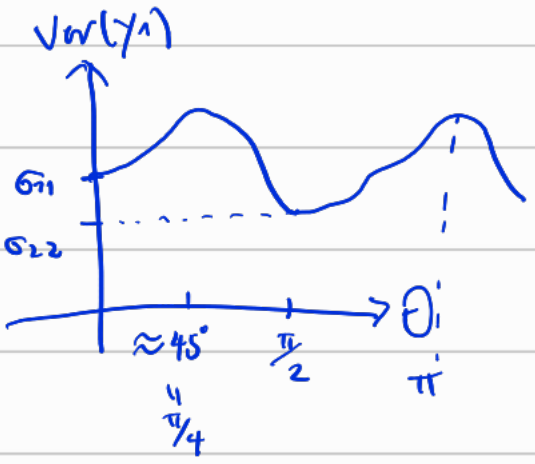
$$= \cos^2\theta\,\sigma_{11} + \text{sen}\theta\cos\theta\,\sigma_{21} + \cos\theta\,\text{sen}\theta\,\sigma_{21} + \text{sen}^2\theta\,\sigma_{22}$$

$$= \cos^2\theta\,\sigma_{11} + 2\cdot\sigma_{12}\,\text{sen}\theta\cos\theta + \text{sen}^2\theta\,\sigma_{22}$$

exemplo:



⇒



A solução dos componentes principais.

$Y_1 = u_1^T x$. o componente principal Y_1 é tal que $Var(Y_1)$ seja maxima a solução é

$$u_1^* = \underset{u_1}{\operatorname{argmax}}\ Var(Y_1) = \underset{u_1}{\operatorname{argmax}}\ u_1^T \Sigma u_1$$. como resolver?

* Restrição a $\|u\|^2 = u^T u = 1$

Problema de otimização: use multiplicador de lagrange

Lagrangiano:

$$L(u_1, \lambda_1) = u_1^T \Sigma u_1 - \lambda (u_1^T u_1 - 1)$$

$$\Rightarrow \frac{\partial L}{\partial u_1} = 2\Sigma u_1 - 2\lambda u_1 = 0 \Rightarrow \Sigma u_1 = \lambda u_1 \quad \triangle$$

* def de autovalor

⇒ basta escolher u_1 como o autovetor associado ao maior autovalor ⇒ $u_1 = e_1$

Passo fantástico

△ multiplica por u_1^T $\Rightarrow u_1^T \Sigma u_1 = u_1^T \lambda_1 u_1$

$= Var(Y_1) = \lambda_1$

e $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$

Para $Y_2 = u_2^T x$

$$u_2^* = \arg\max Var(Y_2) = \arg\max u_2^T \Sigma u_2$$

Sujeito a

$$\begin{cases} u_2^T u_2 = 1 \\ e_1^T u_2 = 0 \end{cases}$$

Lagrangiano:

$$L(u_2, \lambda_2, \phi) = u_2 \Sigma u_2 - \lambda(u_2^T u_2 - 1) - \phi(e_1^T u_2 - 0)$$

$$\Rightarrow \frac{\partial L}{\partial u_2} = 2\Sigma u_2 - 2\lambda u_2 - \phi e_1 = 0 \quad (\cdot e_1^T)$$

$$= e_1^T 2\Sigma u_2 - e_1^T 2\lambda_2 u_2 - e_1^T \cdot \phi e_1 = 0$$

$$= 2(e_1^T \Sigma u_2 - e_1^T \lambda u_2) = \phi$$

$$\Rightarrow 2 \cdot (\lambda_1 e_1^T u_2) = \phi \quad \Rightarrow 2\lambda_1 e_1^T u_2 - \phi = 0 \quad \Rightarrow \phi = 0$$

* com e_1^T sendo autovetor, temos $e_1^T \Sigma = \lambda_1 e_1^T$

$\Sigma e_1 = \lambda_1 e_1$

Sabendo $\phi = 0$, retomando na derivada:

$$\frac{\partial L}{\partial u_2} = 2\Sigma u_2 - 2\lambda_2 u_2 = 0 \Rightarrow \Sigma u_2 = \lambda_2 u_2$$

$\Rightarrow u_2$ é o autovetor associado ao autovalor λ_2.

Temos que $(\cdot u_2^T)$: $u_2^T \Sigma u_2 = u_2^T \lambda_2 u_2 = \lambda_2 = Var(Y_2)$

---

26 08 26 4ª aula

Retomando em assunto de componentes principais:

vimos que $Y_1 = c_1^T x$ $\quad Var(Y_1) = \lambda$

$\vdots$

Na prática: a decomposição espectral de Σ fornece todos os p cp's

$$\Sigma = E \Lambda E^T \quad E = [e_1 \; e_2 \cdots e_p], \quad \Lambda = \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_p \end{bmatrix}$$

* voltando um pouco

Def. Variância Total

Seja $Var(X) = \Sigma$. $VT(X) = \sum_{i=1}^{p} Var(X_i) = tr(\Sigma)$

Proposição (Conservação de variância) Se $Y_1, \dots, Y_p$ são cp's de X, então $\sum_{i=1}^{p} Var(Y_i) = \sum_{i=1}^{p} Var(X_i)$

Dem: $\sum_{i=1}^{p} Var(X_i) = Tr(\Sigma) = Tr(E\Lambda E^T) = Tr(E^T E\Lambda) = Tr(\Lambda)$

$= \sum_{i=1}^{p} \lambda_i = \sum_{i=1}^{p} Var(Y_i)$

Exemplo: Suponha que observamos $n=5$ pares de dados (já centralizados) X_1 e X_2.

$$X = \begin{bmatrix} -2 & -2 \\ -1 & 1 \\ 0 & 0 \\ 1 & -1 \\ 2 & 2 \end{bmatrix}_{5\times 2}$$

Vamos obter os cp $X = (X_1\ X_2)^T$

$$S = \frac{X^T X}{n-1} \Rightarrow s_{11} = \frac{\sum_{i1}^{5} x_{i1}^2}{4} = 2{,}5 = s_{22} = \sum_{i=1}^{5} x_{i2}^2$$

$$s_{12} = \frac{1}{4} \cdot \sum_{i=1}^{5} x_{i1} x_{i2} = \frac{6}{4} = 1{,}5 \Rightarrow S = \begin{bmatrix} 2{,}5 & 1{,}5 \\ 1{,}5 & 2{,}5 \end{bmatrix}$$

$\Rightarrow \det(S-\lambda I) = \det\begin{pmatrix} 2,5-\lambda & 1,5 \\ 1,5 & 2,5-\lambda \end{pmatrix} \Rightarrow (2,5-\lambda)^2 = 1,5^2$

$\Rightarrow \lambda = 1 \quad , \lambda = 4 \quad \Rightarrow \lambda_1 = 4 \text{ e } \lambda_1 = 1$

observa que: $v_T = 5$ e $\frac{\lambda_1}{v_T} = \frac{4}{5} = 80\%$

↑ direção que tem 80% dos info (:!!)

Exercício 4:

R: $\Sigma = \begin{bmatrix} 1 & a \\ a & 1 \end{bmatrix} \quad a \in (0,1)$

Vamos mostrar que $var(y_1)$ é diretamente proporcional a a. (maior correlação $\Leftrightarrow$ mais info contida em y_1)

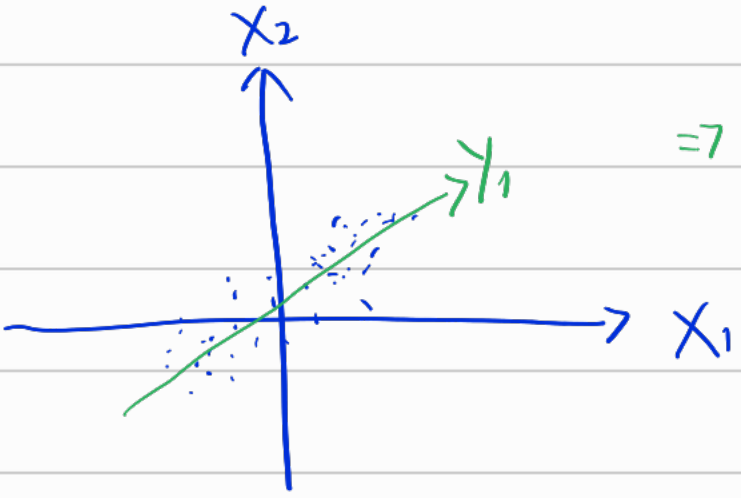
$\det(\Sigma - \lambda I) = (1-\lambda)^2 - a^2 = 0 \Rightarrow 1-\lambda = a$

$\Rightarrow 1-\lambda = \pm a \Rightarrow \lambda = 1+a \text{ e } \lambda = 1-a$

$\Rightarrow \lambda_1 = 1+a$ e $\lambda_2 = 1-a$

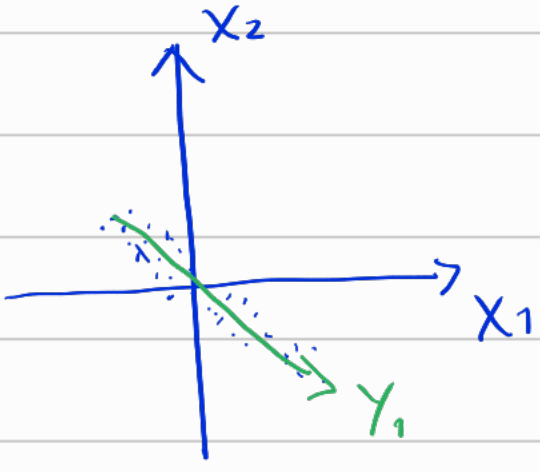
$\Rightarrow \uparrow Var(Y_1) = \lambda_1 = 1+a \uparrow$

Imagine que:



$\Rightarrow Y_1 = X_1 + X_2$

Oi!



$\Rightarrow Y_1 = X_1 - X_2$

Redução de dimensão

	Var	Var. acumulada	
$Y_1 = e_1^T x$	λ_1	λ_1 / V_T	
$Y_2 = e_2^T x$	λ_2	$\lambda_1+\lambda_2 / V_T$	
⋮	⋮	⋮	
$Y_p = e_p^T x$	λ_p	1	(um número razoável)

Método de Kaiser

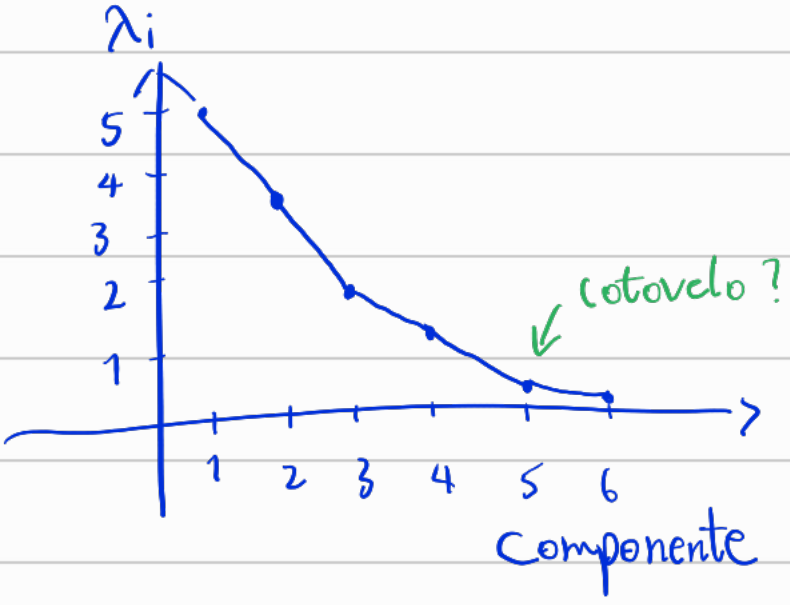
Note que se a ACP é feita sob R

Var Total de $R = V_T(R) = p = Tr(R)$.

$\Rightarrow \forall x_i$, a proporção da variância relativa a variável é $1/p$

O método de Kaiser sugere que um componente é "bom" e deve ser mantido se esse componente carrega mais informação que uma única variável ou seja se $\lambda_i > 1$.

Critério do cotovelo



26 08 21 5ª aula

Interpretação dos componentes principais

Temos $\Sigma = E \Lambda E^T$;

$$Y_1 = e_1^T x = e_{11}x_1 + \cdots + e_{1p}x_p$$

↳ "carga" / loading

Visto que um CP é composto por pesos dados as variáveis originais, as interpretações vão decorrer da grandeza desses pesos.

$$* \; E = [e_1 \; e_2 \cdots e_p] = \begin{bmatrix} e_{11} & e_{21} & \cdots & e_{p1} \\ \vdots & \vdots & \ddots & \vdots \\ e_{1p} & e_{2p} & \cdots & e_{pp} \end{bmatrix}$$

Proposição

Se $Y_j = e_j^T x$ é o k^{th} CP. Então a correlação

$$Corr(Y_j, X_k) = \frac{e_{jk}\sqrt{\lambda_k}}{\sqrt{\sigma_{jj}}}$$

Dem: $Cov(Y_k, x) = cov(e_k^T x, x) = cov(x, e_k^T x) = Cov(x,x)e_k$

$$= \Sigma e_k = \lambda_k e_k = \begin{bmatrix} Cov(Y_k, X_1) \\ \vdots \\ Cov(Y_k, X_p) \end{bmatrix}$$

e_k é autovetor

$$\Rightarrow Cov(Y_k, X_j) = \lambda_k e_{kj} \Rightarrow Corr(Y_k, X_j) = \frac{\lambda_k e_{kj}}{\sqrt{\lambda_k}\sqrt{\sigma_{jj}}} = \frac{\sqrt{\lambda_k}\, e_{kj}}{\sqrt{\sigma_{jj}}}$$

Scores (Dados projetados)

Def: Dada a matriz de dados X (centralizado) e a respectiva matriz de autovetores E de Σ então a matriz scores (ou a matriz de dados projetados) é:

$$T = XE = [t_1 \; t_2 \; \cdots \; t_p]$$

Ex: $X = \begin{bmatrix} -2 & -1 & 0 & 1 & 2 \\ -2 & 1 & 0 & -1 & 2 \end{bmatrix}^T \Rightarrow \lambda_1 = 4 \text{ e } \lambda_2 = 1$

$e_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ e $e_2 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ -1 \end{bmatrix}$ $\quad y_1 = e_1^T x = \frac{1}{\sqrt{2}} x_1 + \frac{1}{\sqrt{2}} x_2$

$$\Rightarrow T = XE = \begin{bmatrix} -2 & -2 \\ -1 & 1 \\ 0 & 0 \\ 1 & -1 \\ 2 & 2 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{\sqrt{2}} \cdot \begin{bmatrix} -4 & 0 \\ 0 & -2 \\ 0 & 0 \\ 0 & 2 \\ -4 & 0 \end{bmatrix}$$

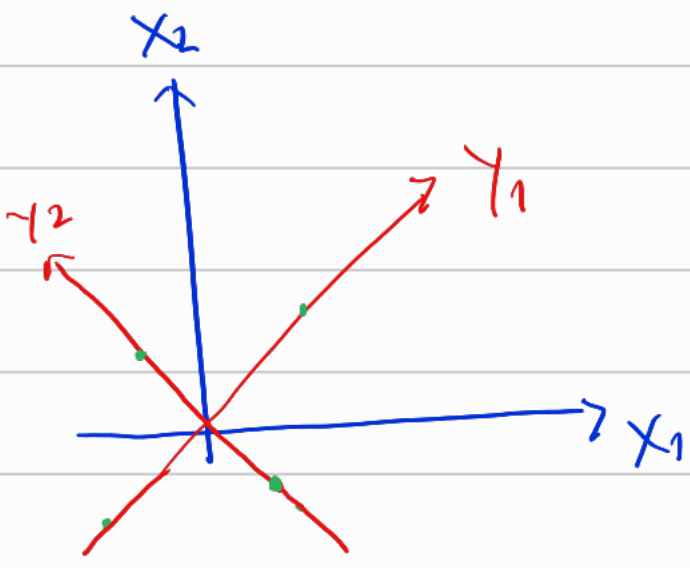
260902 6ª aula

Relembrando que

Escores = dados transformados / projetados

voltando no ex:

$$X = \begin{bmatrix} -2 & -1 & 0 & 1 & 2 \\ -2 & 1 & 0 & -1 & 2 \end{bmatrix}^T \Rightarrow T = XE = \frac{1}{\sqrt{2}} \begin{bmatrix} 4 & 0 & 0 & 0 & 4 \\ 0 & -2 & 0 & 0 & 2 \end{bmatrix}^T$$





Reconstrução dos dados

- processo da ACP é revertível

$$T = XE \Rightarrow TE^T = XEE^T = X$$

observe que $X = TE^T = \sum_{K=1}^{p} t_K e_K^T$

$n \times 1 \quad 1 \times p$

Se dados de dimensão reduzido: $\tilde{X}_q$ (de p dim → q dim)

$$\Rightarrow \sum_{k=1}^{q} t_k e_k^T = T_q E_q^T \quad (n \times q \; q \times p)$$

T_q: q primeiras colunas de T

E_q: q primeiros autovetores

$\tilde{X}_q$ é a melhor aproximação de posto q para X segundo a norma de Frobenius. ($\|X - \tilde{X}_q\|$ é mínima)

* $\|A\| = \sqrt{\sum_{i=1}^{} \sum_{j=1}^{} a_{ij}^2}$

Sum Ting Wong

Heidi 'N' Closet

Proposição (Erro de reconstrução)

Se $\tilde{X}_q$ é a aproximação de posto q de X pelo ACP, então

$$\frac{1}{n-1}\left\| X-\tilde{X}_q \right\|_F^2 = \sum_{k=q+1}^{p} \lambda_k$$

Retomando no exemplo

$$X=\begin{bmatrix} -2 & -1 & 0 & 1 & 2 \\ -2 & 1 & 0 & -1 & 2 \end{bmatrix} \qquad T_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} -4 & 0 & 0 & 0 & 4 \end{bmatrix}$$

$$e_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$\tilde{X}_1 = t_1 e_1^T = \frac{1}{2}\begin{bmatrix} -4 \\ 0 \\ 0 \\ 0 \\ 4 \end{bmatrix}\begin{bmatrix} 1 & 1 \end{bmatrix} = \begin{bmatrix} -2 & -2 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \\ 2 & 2 \end{bmatrix}$$

$$\frac{1}{n-1}\left\| X-\tilde{X}_q \right\|_F^2 = 1 = \lambda_2$$

curiosidade do Eric: $T_2 = \frac{1}{\sqrt{2}}\begin{bmatrix} 0 & -2 & 0 & 2 & 0 \end{bmatrix}$ $e_2 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ -1 \end{bmatrix}$

Lara (the best)

$$t_2 e_2^T = \frac{1}{2}\begin{bmatrix} 0 \\ -2 \\ 0 \\ 2 \\ 0 \end{bmatrix}\begin{bmatrix} 1 & -1 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ -1 & 1 \\ 0 & 0 \\ 1 & -1 \\ 0 & 0 \end{bmatrix}$$

$\Rightarrow$ note $X = t_1 e_1^T + t_2 e_2^T$

Logo 7ª aula

Apresentação do Paulo; Raul; Eric; Vinicius Ferrari.

* Cuidados a tomar: escala das variáveis; biplot; ordem de apresentação: mostrar os CP's, explicar o que são, interpretar, depois mostrar gráficos.

Apresentação da Deda, Carol, Rael, Carina

reconstrução de matriz de correlação?

motivo = Qual. procedimento = Como.

$\hookrightarrow \Sigma = E \Lambda E^T = \sum \lambda_i e_i e_i^T = \underbrace{\lambda_1 e_1 e_1^T + \cdots}_{\text{reconstruído}} + \lambda_k e_k e_k^T$

Novos métodos p/ ACP

SVD: $X = U \Delta V^T$

ou

$$X^T X = (U \Delta \Delta^T) U^T$$

$$\Rightarrow T = U\Delta$$

↗

fasível sem E

! ACP de kernel

usa $k(x_i, x_j) = \exp(-1|x_i - x_j|^2)$ em XX^T p/ os produtos internos.

26/09/14 8ª aula

Análise de correspondência

Def: Tabela de contingência

Sejam X e Y variáveis categóricas com I e J níveis

* $\sum_i \sum_j n_{ij} = n$

X \ Y	1	2	...	J	
1	n_{11}	n_{12}	...	n_{1J}	$\sum_j n_{1j}$
2	n_{21}	n_{22}	...	n_{2J}	$\sum_j n_{2j}$
⋮	⋮	⋮	⋱	⋮	⋮
I	n_{I1}	n_{I2}		n_{IJ}	$\sum_j n_{Ij}$
	$\sum_i n_{i1}$	$\sum_i n_{i2}$	...	$\sum_i n_{iJ}$	$\sum_i \sum_j n_{ij}$

n_{ij} representa o numero de ocorrência cruzada dos níveis i, j de X, Y.

Denotamos a tabela por N.

Def: Matriz de correspondência.

Dado que um estudo tem n respondentes, a matriz de correspondência é $P = \frac{1}{n} N$.

Ou seja, cada entrada de P carrega a proporção amostral de respectivos níveis.

$$\sum_j n_{ij} = n_{i\cdot} \Rightarrow \frac{n_{i\cdot}}{n} = p_{i\cdot}$$

$$\sum_i n_{ij} = n_{\cdot j} \Rightarrow \frac{n_{\cdot j}}{n} = p_{\cdot j}$$

$$\Rightarrow P = \begin{bmatrix} \frac{n_{11}}{n} & \frac{n_{12}}{n} & \cdots & \frac{n_{1J}}{n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{n_{I1}}{n} & \frac{n_{I2}}{n} & \cdots & \frac{n_{IJ}}{n} \end{bmatrix} \begin{matrix} p_{1\cdot} \\ \\ p_{I\cdot} \end{matrix}$$

$p_{\cdot 1} \quad p_{\cdot 2} \quad \cdots \quad p_{\cdot J}$

As proporções marginais das linhas e colunas são

$$\underset{\sim}{r} = (p_{1\cdot}, p_{2\cdot}, \cdots, p_{I\cdot})^T \qquad \underset{\sim}{c} = (p_{\cdot 1} \; p_{\cdot 2} \; \cdots \; p_{\cdot J})^T$$

Exemplo: Coletamos respostas sobre $n=300$ respondentes de faixas etárias distintas sobre suas preferências em serviços de streaming. Os resultados são:

Faixa Etária \ Serviço Streaming	Netflix	Prime	HBO MAX	Disney+	Total Marginal
Jovem	45	15	10	30	100
Adulto	30	45	15	10	100
Idoso	15	20	55	10	100
Total Marginal	90	80	80	50	300

carga / loading

matriz de correspondência:

$$P = \begin{bmatrix} 0{,}15 & 0{,}05 & 0{,}033 & 0{,}1 \\ 0{,}10 & 0{,}15 & 0{,}05 & 0{,}033 \\ 0{,}05 & 0{,}067 & 0{,}183 & 0{,}033 \end{bmatrix} \quad r = \begin{bmatrix} 1/3 \\ 1/3 \\ 1/3 \end{bmatrix}$$

$$c = [0{,}3 \quad 0{,}267 \quad 0{,}267 \quad 0{,}167]^T$$

O modelo de independência

Definição: Duas variáveis categóricas são independentes se probabilidades cruzadas forem iguais ao produto das marginais.

$$P = r c^T \quad \Rightarrow \text{decomposição de posto 1.}$$

$I \times 1 \quad 1 \times J$

Isso significa que sob independência tem posto 1.

Se houver dependência, $P \neq rc^T$

$\underbrace{\Delta} = P - rc^T$ * sob independência, $\Delta = 0_{I \times J}$.

matriz de

resíduos de dependência

* Se $r_{ij} = 0{,}8 \Rightarrow \Delta_{ij} = 0{,}05$ e se $r_{ij} = 0{,}05 \Rightarrow \Delta_{ij} = 0{,}05$

$r_{ij} \overset{\text{sob indep}}{=} 0{,}75$ $\quad$ $r_{ij} \overset{\text{sob indep}}{=} 0{,}10$

Então percebe-se Δ é uma medida ingênua, pois os desvios em Δ desconsideram diferentes "popularidade" de respostas.

Para isso devemos considerar as marginais:

* Vamos denotar $D_r = \text{diag}(r)$ e $D_c = \text{diag}(c)$.

Definição: matriz de desvios padronizado.

$$S = D_r^{-\frac{1}{2}}(P - rc^T)D_c^{-\frac{1}{2}} \Rightarrow S_{ij} = \frac{p_{ij} - r_i c_j}{\sqrt{r_i c_j}}$$

Definição: Inércia Total (= Bagunça sob hipótese de independência)

A Inércia Total de uma tabela de contingência é dada por

$$\phi^2 = \sum_j \sum_i s_{ij}^2 = Tr(S^T S) = \|S\|_F^2$$

é evidente que sob independência, $\phi^2 = 0$.

* $\chi^2 = n \sum\sum s_{ij}^2 \Rightarrow \phi^2 = n\chi^2$

Análise de correspondência simples ($p = 2$)

A ACS se baseia na decomposição da matriz de desvios padronizados S pela SVD.

$S = U \Lambda V^T$ U são os vetores singulares a esquerda (AA^T)

V são os vetores singulares a direita (A^TA)

* $U \Lambda V^T = \sum_{k=1}^{K} \lambda_k u_k v_k^T$

K é o posto de S que é dado por $\min(I-1, J-1)$.

*Devaneio: $P = rc^T$ sob indep.

se dependencia: $P \cong rc^T + \lambda_1 u_1 v_1^T + \cdots + \cdots$

26 09 16 10ª aula

Retomando

Faixa Etária \ Serviço Streaming	Netflix	Prime	HBO MAX	Disney+	Total Marginal
Jovem	45	15	10	30	100
Adulto	30	45	15	10	100
Idoso	15	20	55	10	100
Total Marginal / Carga / Loading	90	80	80	50	300

$P = \frac{1}{n} N$

matriz de correspondência:

$$P = \begin{bmatrix} 0{,}15 & 0{,}05 & 0{,}033 & 0{,}1 \\ 0{,}10 & 0{,}15 & 0{,}05 & 0{,}033 \\ 0{,}05 & 0{,}067 & 0{,}183 & 0{,}033 \end{bmatrix} \quad \underset{\sim}{r} = \begin{bmatrix} 1/3 \\ 1/3 \\ 1/3 \end{bmatrix}$$

$$\underset{\sim}{c} = [0{,}3 \quad 0{,}267 \quad 0{,}267 \quad 0{,}167]^T$$

$$\Rightarrow \underset{\sim}{c}\underset{\sim}{r}^T = \begin{bmatrix} 1/3 \\ 1/3 \\ 1/3 \end{bmatrix} [0{,}3 \quad 0{,}267 \quad 0{,}267 \quad 0{,}167]$$

$$= \begin{bmatrix} 0,1 & 0,089 & 0,089 & 0,056 \\ 0,1 & 0,089 & 0,089 & 0,056 \\ 0,1 & 0,089 & 0,089 & 0,056 \end{bmatrix}$$

Relembre:

Inércia total: $\phi^2 = \sum\sum s_{ij}^2$

ϕ^2 é uma medida generalizada de desvios c/ relação a independência

* podemos fazer $S_{IJ} = U \Lambda V^T$ (decomposição por valores singulares)

Proposição

Seja S a matriz de desvios padronizados com SVD $S = U \Lambda V^T$, então

$$\phi^2 = \sum_{k=1}^{K} \lambda_k^2 \quad \text{onde} \quad K = \min(I-1; J-1)$$

Dem:
$$\phi^2 = \sum_{k=1}^{K} \lambda_k^2 = tr(S^T S) = tr\left((U \Lambda V^T)^T U \Lambda V^T\right)$$
$$= tr(V \Lambda^T U^T U \Lambda V^T) = tr(V \Lambda^T \Lambda V^T)$$
$$= tr(V^T V \Lambda^T \Lambda) = tr(\Lambda^2) = \sum_{k=1}^{K} \lambda_k^2$$

no exemplo de serviços de streaming, $K = 2$ pois $I = 3$

$\Rightarrow I - 1 = 2$

posto sendo 2 $\Rightarrow \lambda_3 = 0$ (último valor singular é 0)

python:

$\lambda_1 = 0,4720$ $\lambda_2 = 0,3117$

$\Rightarrow \phi^2 \simeq 0,32$

*

Valor singular (λ)	Inerci principal	Razão (%)
0,472	0,2228	69,63
0,3117	0,0972	30,37

Perfis e distância

R = N marginalizado nas linhas (soma das linhas da 1)

no exemplo. $R = \frac{N}{100} = \begin{bmatrix} 0,45 & 0,15 & 0,1 & 0,3 \\ 0,3 & 0,45 & 0,15 & 0,1 \\ 0,15 & 0,2 & 0,55 & 0,1 \end{bmatrix} \begin{matrix} 1 \\ 1 \\ 1 \end{matrix}$

(e $P = \frac{N}{300}$)

Def:

$$R = D_r^{-1} P \quad (\text{ou} \quad D_{r_{(n)}}^{-1} N) \quad = \text{matriz de perfis linha}$$

Def:

$$C = P D_c^{-1} \quad (\text{ou} \quad N D_{a_{(n)}}^{-1}) \quad = \text{matriz de perfis coluna}$$

no exemplo: $C = \begin{bmatrix} 0,5 & 0,17 & 0,125 & 0,6 \\ 0,33 & 0,56 & 0,188 & 0,2 \\ 0,167 & 0,25 & 0,686 & 0,2 \end{bmatrix}$

$\mathbb{1}$ $\mathbb{1}$ $\mathbb{1}$ $\mathbb{1}$

$D_c = \text{diag}(\underset{\sim}{c})$, $D_r = \text{diag}(\underset{\sim}{r})$

26 09 21 11ª aula

retomando

Perfis e distâncias

$R = D_r^{-1} P$ e $C = P D_c^{-1}$

Proposição:

Sob a hipótese de indep, temos:

$P = \underset{\sim}{r}\underset{\sim}{c}^T \iff R = \mathbb{1}\underset{\sim}{c}^T \iff C = \underset{\sim}{r}\mathbb{1}^T$

Vem: $R = D_r^{-1} P = D_r^{-1} (r c^T) = D_r^{-1} r (c^T) = 1 c^T$

$C = P D_c^{-1} = (r c^T) D_c^{-1} = r c^T D_c^{-1} = r 1^T$

Definição: Distância Qui-quadrado.

a distância Qui-Quadrado entre dois níveis-linha i e i' ou entre dois níveis-coluna j e j' é.

$$d_\chi^2(i,i') = (r_i - r_{i'})^T D_c^{-1} (r_i - r_{i'})$$

ou

$$d_\chi^2(j,j') = (c_j - c_{j'})^T D_r^{-1} (c_j - c_{j'})$$

* $R = \begin{bmatrix} r_1^T \\ r_2^T \\ r_3^T \\ \vdots \\ r_I^T \end{bmatrix}$ ou $R = [c_1\ c_2\ c_3\ c_4 \cdots c_J]$

Proposição

$$\phi^2 = \sum_{i=1}^{I} r_i d_\chi^2(i, c)$$

ou

$$\phi^2 = \sum_{j=1}^{J} c_j d_\chi^2(j, r)$$

onde $r = [r_1\ r_2 \cdots r_I]^T$ ← números

↳ perfil médio da linha

e $c^T = [c_1\ c_2 \cdots c_J]$

Dem: Vamos lembrar que $\phi^2 = \sum\sum s_{ij}^2 = tr(S^T S) = tr(SS^T)$

$$S = D_r^{1/2} (P - r c^T) D_c^{1/2} \Rightarrow \phi^2 = tr\left(D_r^{1/2} (P - r c^T) D_c^{1/2} \cdot D_c^{1/2} (P - r c^T)^T D_r^{1/2} \right)$$

* $P - r c^T = R - 1 c^T$

$$= tr\left(D_r^{1/2} (R - 1\underset{\sim}{c}^T) D_c (R - 1\underset{\sim}{c}^T) D_r^{1/2} \right) = tr\left(D_r (R - 1\underset{\sim}{c}^T) D_c (R - 1\underset{\sim}{c}^T)^T \right)$$

$= \cdots$ pulou a demonstração ∴

Relembrando que:

$$S = U \Lambda V^T \qquad \Lambda = \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_K \end{bmatrix} \qquad K = \min(I-1, J-1)$$

$$= \sum_{k=1}^{K} \lambda_k \underset{\sim}{u}_k \underset{\sim}{v}_k^T \qquad \text{e} \sum \lambda_k^2 = \phi^2$$

então elemento a elemento, temos:

$$s_{ij} = \sum_{k=1} \lambda_k \cdot u_{ik} v_{jk}$$

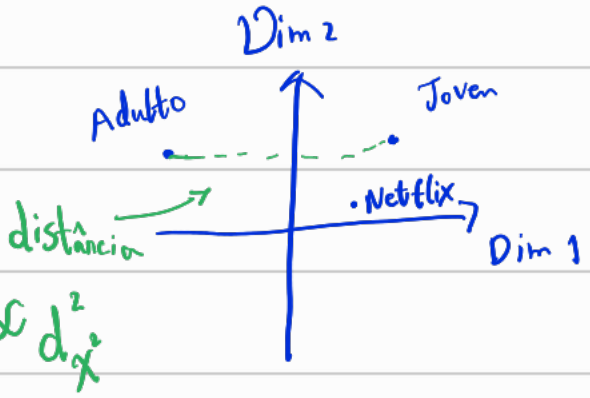
p/ $K = 2$:

$$s_{ij} = \lambda_1 u_{i1} v_{j1} + \lambda_2 u_{i2} v_{j2}$$

* em $K = 2$, os elementos de U representam os perfis linhas:

no exemplo com $K=2$: Jovem: (u_{11}, u_{12}) e Adultos (u_{21}, u_{22})

e Netflix: (v_{11}, v_{12}), Prime: (v_{21}, v_{22})



$\Rightarrow \propto d_{\chi^2}^2$

* só faz distância de linha com linha e de coluna com coluna mas não de linha com coluna

26 09 23 11ª aula

Def. Coordenadas principais

Dada uma matriz de desvios ponderados:

$S = U \Lambda V^T$, definimos $F = D_r^{-1/2} U \Lambda$ e $G = D_c^{-1/2} \Lambda V$

F: coordenadas principais das linhas

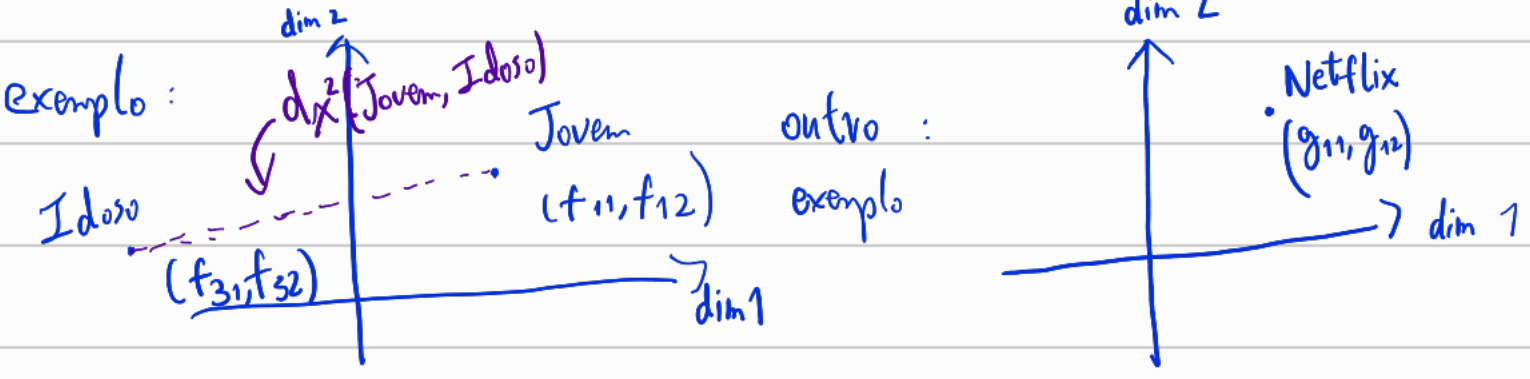
G: coordenadas principais das colunas

Proposição: A distância euclidiana entre as coordenadas de dois níveis linha ou dois níveis coluna. Reproduzem a d_{χ^2} entre eles. Ou seja

$$\| f_i - f_{i'} \|^2 = \sum_{k=1}^{K} | f_{ik} - f_{i'k} |^2 = d_{\chi^2}(i, i')$$

ou

$$\| g_j - g_{j'} \|^2 = \sum_{k=1}^{K} | g_{jk} - g_{j'k} |^2 = d_{\chi^2}(j, j')$$



* Quando pontos estão na origem, isso quer dizer que a independência está satisfeita. $\Leftrightarrow S = 0_{I \times J}$

Note: $s_{jk} = \sum \lambda_k u_{ik} v_{jk}$

representação de distância ao quadrado do perfil em relação à origem usando cos:

$$\cos_{i1}^2 + \cos_{i2}^2 = \frac{f_{i1}^2 + f_{i2}^2}{\sum f_{ik}^2} \quad \dots$$

26 09 28 12ª aula

Análise de Correspondência múltipla (ACM)

Def: Matriz Indicadora

Dados $p \geq 3$.

⇒ Vamos criar variáveis categóricas $X_1, X_2, \dots, X_p$ onde J_q indica a quantidade de níveis de X_q. $J = \sum_{q=1}^{p} J_q$

exemplo moradia
1 centro
2 Bairro
3 rural
⋮

$$\Rightarrow Z = \begin{array}{c} \\ 1 \\ 2 \\ \vdots \\ n \end{array} \begin{array}{c} \begin{array}{cc} X_1 & X_2 \quad \cdots \quad X_p \end{array} \\ \left[\begin{array}{cc} \underbrace{\quad}_{J_1 \text{ colunas}} & \underbrace{\quad}_{J_2 \text{ colunas}} \\ & \\ & \\ & \end{array}\right] \end{array} \begin{array}{l} \\ p \\ p \\ p \end{array}$$

$n_{11} n_{12} \cdots n_{1J_1} \quad n_{21} n_{22} \cdots n_{2J_2} \cdots \cdots$

$[z_{ij}] \in \{0,1\}$ ← Respondente ∈ nível; Respondente ∉ nível

Exemplo de Z:

	onde mora			Transporte Fav			Tempo Trajeto		
	Centro	Bairro	Rural	Carro	Onibus	Bike	Curto	Longo	
$Z =$	1	0	0	0	0	1	1	0	$p=3$
	1	0	0	0	1	0	0	1	3
	0	1	0	0	0	1	0	1	3
	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	3
	n_{11}	n_{12}	n_{13}	n_{21}	n_{22}	n_{23}	n_{31}	n_{32}	

se usar o mesmo raciocínio de se independência: $\hat{P} = rC^T$, $P = \frac{Z}{np}$

com $C = \begin{bmatrix} n_{11}/np \\ \vdots \\ n_{ij}/np \\ \vdots \end{bmatrix}$ e $r = \begin{bmatrix} P/np = 1/n \\ 1/n \\ \vdots \\ 1/n \end{bmatrix}$

mas como as respostas são 0 ou 1: isso não dá certo.

O que importa nesse caso é o mapa de correspondências

e $\phi^2 = \frac{J - Q}{Q}$

* nesse caso com $p \not\parallel 3$ a distancia euclidiana do mapa de correspondencia e as inércias perdem a interpretação.

Escolha de dimensões

note que $\frac{\phi^2}{K} = \frac{(J-Q)/Q}{J-Q} = \frac{1}{Q}$

K = posto da matriz Z

Critério de Benzécri: escolhe os eixos que tem $\lambda_K > 1/Q$.

Tabela de Burt

$$B = Z^T Z = \begin{bmatrix} Z_1^T Z_1 & \cdots & Z_1^T Z_Q \\ \vdots & \ddots & \vdots \\ Z_Q^T Z_1 & \cdots & Z_Q^T Z_Q \end{bmatrix}$$

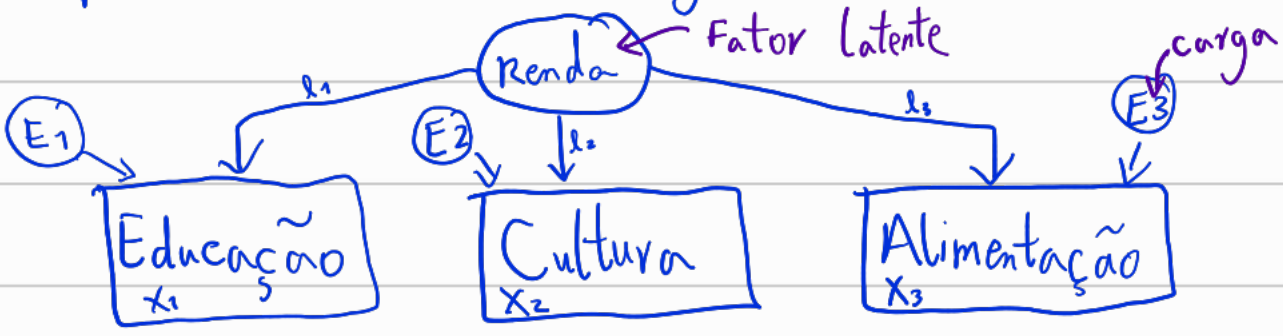
no exemplo:

$B =$	onde mora	Transporte	Tempo
onde mora	n_{cidade} 0 0	n_{cidade} e carro	n_{cidade} e ônibus
Transporte	0 n_{bairro} 0		
Tempo	0 0 n_{rural}		

26/09/30 13ª aula

Análise Fatorial

Exemplo: famílias e seus gastos em:



$$Y_1 = e_{11}X_1 + e_{12}X_2 + e_{13}X_3$$

Modelo fatorial Ortogonal

Def. Seja X um vetor aleatório com p variáveis observadas, com média μ e cov Σ. O modelo fatorial ortogonal com $m < p$ é

$$\underset{p\times 1}{X} - \underset{p\times 1}{\mu} = \underset{p\times m}{L}\ \underset{m\times 1}{F} + \underset{p\times 1}{\varepsilon}$$

L: cargas; F: fatores comuns; ε: fatores específicos

$$L = \begin{bmatrix} l_{11} & l_{12} & \cdots & l_{1m} \\ l_{21} & l_{22} & \cdots & l_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ l_{p1} & l_{p2} & \cdots & l_{pm} \end{bmatrix} \qquad F = \begin{bmatrix} F_1 \\ F_2 \\ \vdots \\ F_m \end{bmatrix}$$

Modelo ortogonal pressupõe:

① $E[F] = 0$ e ② $Cov[F] = I_m \Rightarrow Var(F_i) = 1$.

$Var(l_i F_i) = l_i^2 \, Var(F_i)$

③ $E[\varepsilon] = 0$ e ④ $cov[\varepsilon] = diag(\psi_1, \psi_2, \ldots, \psi_p)$ ⑤ $Cov(F, \varepsilon) = 0$

ψ''

Teorema: Sob as suposições acima, temos que

$$\Sigma = LL^T + \psi$$

Dem: $\Sigma = Cov(X) = E\left((X-\mu)(X-\mu)^T\right) = E\left[(LF+\varepsilon)(LF+\varepsilon)^T\right]$

$= E[LFF^TL^T + LF\varepsilon^T + \varepsilon F^TL^T + \varepsilon\varepsilon^T]$

$= L\,E[FF^T]L^T + LE[F\varepsilon^T] + E[\varepsilon F^T]L^T + E[\varepsilon\varepsilon^T]$

$= LL^T + 0 + 0 + \psi = LL^T + \psi$ ∎

* Note que $\Sigma = \begin{bmatrix} \sigma_{11} & \boxed{\sigma_{12}} & \cdots \\ \vdots & \sigma_{22} & \vdots \\ \vdots & \cdots & \vdots \end{bmatrix}$ Já que ψ é diagonal

e $\sigma_{jj} = \sum_{l=1}^{m} l_{jl}^2 + \psi_j$

$\sigma_{jj'} = Cov(X_j, X_{j'}) = \sum_{k=1}^{m} l_{jk} l_{j'k} \quad \forall j \neq j'$

Note que essa fatoração induz a fatoração das variâncias das variáveis originais.

$$Var[X_j] = \sigma_{jj} = \sum_{k=1}^{m} l_{jk}^2 + \psi_j$$

$$= \text{comunalidade} + \text{variabilidade específica}$$

Padronizando: Seja $D^{-1} = diag(\sigma_{11}, \sigma_{22}, \dots \sigma_{pp})$

$\Rightarrow$ Seja $D^{-1}(x-\mu) = Z$ a nossa padronização, temos que

$$= D^{-1}(LF + \varepsilon)$$

$$Z = D^{-1}LF + D^{-1}\varepsilon$$

$$= L_Z F + \varepsilon_Z$$

Exemplo. Para os gastos familiares, temos que a matriz de correlações amostrais é:

$$R = \begin{bmatrix} 1 & 0,56 & 0,48 \\ & 1 & 0,42 \\ & & 1 \end{bmatrix} \begin{matrix} \text{Educação} \\ \text{Cultura} \\ \text{Alimentação} \end{matrix}$$

$\Rightarrow \rho_{12} = l_{11}l_{21} = 0,56$ $\quad \Rightarrow l_{11} = \dfrac{0,56}{l_{21}}$, $l_{31} = 0,48 \cdot \dfrac{l_{21}}{0,56}$

$\rho_{13} = l_{11}l_{31} = 0,48$

$\rho_{23} = l_{21}l_{31} = 0,42$

$$\Rightarrow l_{21} \cdot \left(\frac{0,48}{0,56} \cdot l_{21} \right) = 0,42 \quad \Rightarrow l_{21}^2 = \frac{0,42}{0,48} \cdot 0,56 = \frac{0,6 \cdot 0,7}{0,6 \cdot 0,8} \cdot 0,7 \cdot 0,8$$

$$\Rightarrow l_{21} = 0,7$$

$$\Rightarrow l_{11} = 0,8$$

$$l_{31} = 0,6$$

$$\Rightarrow L = \begin{bmatrix} 0,8 \\ 0,7 \\ 0,6 \end{bmatrix} \qquad LL^T = \begin{bmatrix} 0,64 & 0,56 & 0,48 \\ 0,42 & 0,49 & 0,56 \\ 0,48 & 0,42 & 0,36 \end{bmatrix}$$

$$R = LL^T + \Psi$$

$$\Rightarrow \Psi = R - LL^T$$

$$\Rightarrow \Psi = \begin{bmatrix} 0,36 & 0 & \\ & 0,51 & \\ 0 & & 0,64 \end{bmatrix}$$