Teste dos Postos Sinalizados de Wilcoxon

Danilo Lopes

lopes@ufscar.br

Estatística Não Paramétrica

Unidade 3

UFSCar

2 de setembro de 2026

Motivação

Seja θ a mediana populacional e suponha que desejamos testar

$$H_0 : \theta = \theta_0$$

contra

$$H_1 : \theta > \theta_0 \qquad \text{ou} \qquad H_1 : \theta < \theta_0 \qquad \text{ou} \qquad H_1 : \theta \neq \theta_0$$

O Teste da Mediana (Teste do Quantil, algumas vezes chamado de Teste do Sinal) possui o problema de considerar apenas se cada observação é $> \theta_0$ ou $\leq \theta_0$, mas não a sua magnitude.

Desenvolvido em 1945 pelo estatístico Frank Wilcoxon, o teste dos postos sinalizados incorpora tanto o sinal quanto a magnitude na análise, sob o preço de fazer a suposição adicional de simetria na distribuição, representando um ganho considerável de poder no teste.

Métodos baseados em postos

Muitos métodos não paramétricos são baseados em postos em vez dos dados observados.

O posto R_i de uma observação Y_i é a sua posição quando as observações $Y_1, \ldots, Y_n$ são ordenadas da menor para a maior:

$$R_i = \sum_{k=1}^{n} I(Y_k \leq Y_i)$$

caso não haja empates (como é o caso de variáveis contínuas).

Em caso de empates, o procedimento é atribuir postos como se todas as observações fossem diferentes e em seguida atribuir a média dos postos correspondentes àquelas observações de mesmo valor.

Por que postos?

O uso de postos proporciona robustez contra outliers:

- Observações: 175, 169, 190
- Postos: 2, 1, 3

- Observações: 175, 169, 490
- Postos: 2, 1, 3

- Observações: 175, 175, 190
- Postos: 1,5, 1,5, 3

Teste dos Postos Sinalizados de Wilcoxon

Dados: Sejam $X_1, \ldots, X_n$ os valores observados.

Suposições:

- Os X_i's são mutuamente independentes.
- Cada X_i possui uma distribuição contínua e simétrica em torno da mesma mediana θ.

Note que as distribuições dos X_i's não precisam ser necessariamente iguais, mas precisam apenas ter a mesma mediana.

Como as distribuições são simétricas, θ também é a média populacional.

Teste dos Postos Sinalizados de Wilcoxon

Estatística de Teste: Seja R_i o posto de $D_i = |X_i - \theta_0|$. Defina varíaveis indicadoras:

$$Z_i = \begin{cases} 1, & \text{se } X_i > \theta_0 \\ 0, & \text{se } X_i < \theta_0 \end{cases}$$

A estatística de teste T^+ é a soma dos postos sinalizados positivos:

$$T^+ = \sum_{i=1}^{n} R_i Z_i$$

Alternativamente, T^+ pode ser escrita como

$$T^+ = \sum_{j=1}^{n} j W_j$$

onde $W_j = I(D_{(j)}$ corresponde a algum $X_i > \theta_0)$.

Exemplo 1

O tempo de vida (em semanas) de um grupo de 10 pacientes com um específico linfoma foi acompanhado com o objetivo de monitorar o progresso de pacientes depois de um tratamento.

Os tempos de vida (depois do tratamento até a morte) observados foram: 49, 58, 75, 110, 112, 132, 151, 276, 281, 362*. O asterisco denota uma observação censurada.

Teste se o tempo de sobrevida mediano é de 200 semanas.

Cálculo de T^+

i	X_i	$D_i = \lvert X_i - 200 \rvert$	R_i	Z_i
1	49	151	9	0
2	58	142	8	0
3	75	125	7	0
4	110	90	6	0
5	112	88	5	0
6	132	68	2	0
7	151	49	1	0
8	276	76	3	1
9	281	81	4	1
10	362^*	> 162	10	1

j	W_j
1	0
2	0
3	1
4	1
5	0
6	0
7	0
8	0
9	0
10	1

$$T^+ = \sum R_i Z_i = 9 \times 0 + 8 \times 0 + \ldots + 4 \times 1 + 10 \times 1 = 17$$

$$= \sum j W_j = 1 \times 0 + 2 \times 0 + \ldots + 9 \times 0 + 10 \times 1 = 17$$

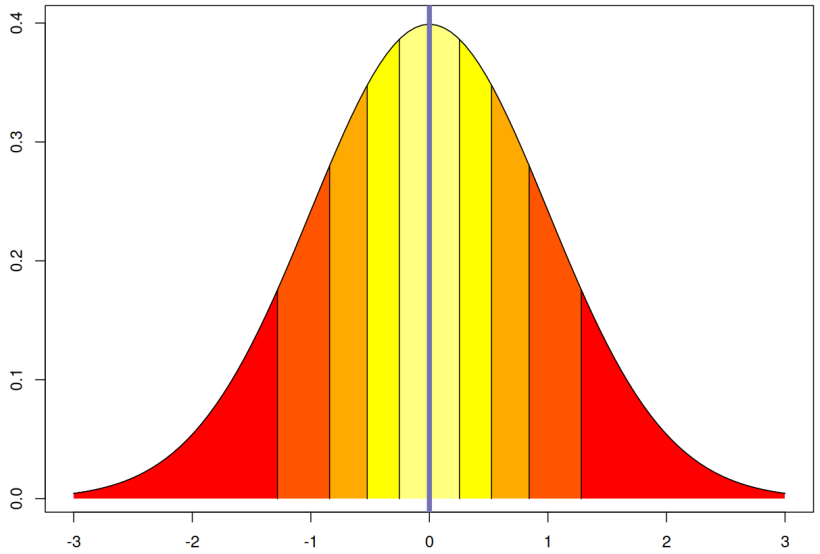
Intuição para T^+ (no exemplo abaixo, $X_i \sim N(0,1)$)

Distribuição de D_i

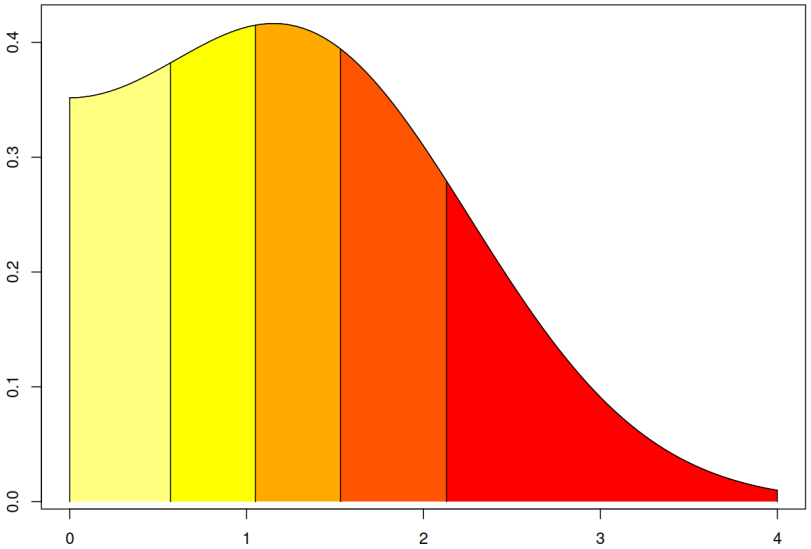
Distribuição de X_i

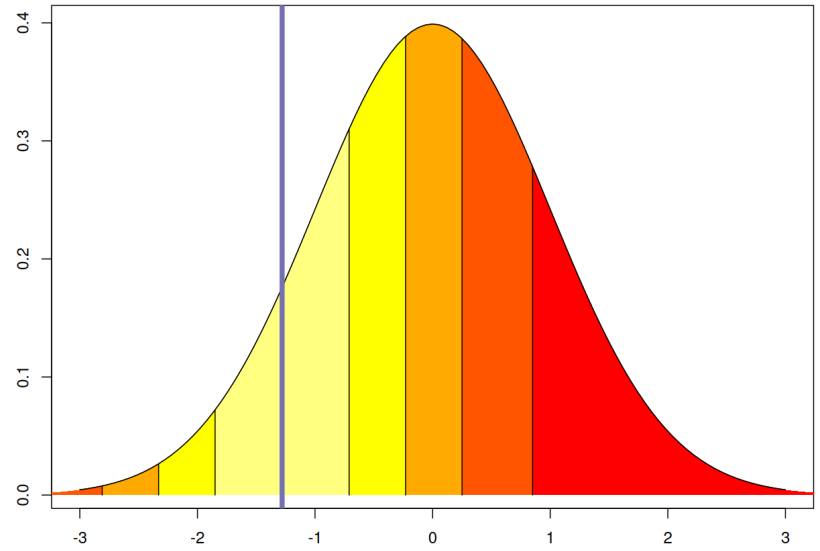
$\theta_0 = 0$





$\theta_0 = -1{,}28$





Distribuição de T^+ sob H_0

Sob H_0, o menor valor que T^+ pode assumir é 0 (zero), quando todos os X_i's estão abaixo de θ_0, e o maior valor que T^+ pode assumir é $\sum_{i=1}^{n} i = \frac{n(n+1)}{2}$, quando todos todos os X_i's estão acima de θ_0.

Além disso, é possível demostrar (Hettmansperger, 1984) que $W_1, \ldots, W_n \overset{i.i.d.}{\sim}$ Bernoulli$(1/2)$. Portanto

$$E(T^+) = E\left(\sum_{j=1}^{n} jW_j\right) = \sum_{j=1}^{n} j\frac{1}{2} = \frac{\sum_{j=1}^{n} j}{2} = \frac{n(n+1)}{4}$$

$$\text{Var}(T^+) = \text{Var}\left(\sum_{j=1}^{n} jW_j\right) = \sum_{j=1}^{n} j^2\left(\frac{1}{2}\right)^2 = \frac{n(n+1)(2n+1)}{24}$$

Distribuição de T^+ sob H_0

Como T^+ é completamente determinada pelos valores dos W_j's, as suas probabilidades podem ser determinadas em função das probabilidades dos W_j's.

Seja $(w_1, w_2, \ldots, w_n) \in \{0,1\}^n$ uma possível realização do vetor aleatório $(W_1, W_2, \ldots, W_n)$. Note que este vetor possui distribuição uniforme discreta sob H_0:

$$P(W_1 = w_1, \ldots, W_n = w_n) = \prod_{j=1}^{n} P(W_j = w_j) = \prod_{j=1}^{n} \frac{1}{2} = \frac{1}{2^n}$$

Portanto, sob H_0:

$$P(T^+ = t) = \frac{u(t)}{2^n}$$

onde $u(t)$ é o número de realizações possíveis que resultam em $T^+ = t$ (infelizmente sem fórmula fechada).

Distribuição de T^+ sob H_0

Toda realização $(w_1, w_2, \ldots, w_n)$ possui uma realização "oposta" (conjugada) que é obtida a partir da troca dos valores 0 (zero) e 1.

A estatística T^+ desta realização conjugada é

$$T^+ = \sum_{j=1}^{n} j(1 - W_j) = \sum_{j=1}^{n} j - \sum_{j=1}^{n} jW_j = \frac{n(n+1)}{2} - \sum_{j=1}^{n} jW_j$$

onde $\frac{n(n+1)}{2}$ é o valor máximo que a estatística pode assumir e $\sum_{j=1}^{n} jW_j$ é o valor de T^+ na realização original.

Como as realizações são equiprováveis, isto implica que a distribuição de T^+ é simétrica em torno de sua esperança $\frac{n(n+1)}{4}$, o que significa que apenas metade da distribuição precisa ser determinada.

Exemplo de Construção da Distribuição de T^+ sob H_0 $(n = 4)$

	j				
	1	2	3	4	T^+
W_j	1	1	1	1	10
	0	1	1	1	9
	1	0	1	1	8
	1	1	0	1	7
	1	1	1	0	6
	0	0	1	1	7
	0	1	0	1	6
	0	1	1	0	5

	j				
	1	2	3	4	T^+
W_j	0	0	0	0	0
	1	0	0	0	1
	0	1	0	0	2
	0	0	1	0	3
	0	0	0	1	4
	1	1	0	0	3
	1	0	1	0	4
	1	0	0	1	5

t	0	1	2	3	4	5	6	7	8	9	10	Total
$u(t)$	1	1	1	2	2	2	2	2	1	1	1	$2^4 = 16$
$P(T^+ = t)$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{2}{16}$	$\frac{2}{16}$	$\frac{2}{16}$	$\frac{2}{16}$	$\frac{2}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	1

Desta maneira, a distribuição de T^+, sob H_0 , quando $n = 4$ é dada por:

$$p_{T^+}(t) = P_0(T^+ = t) \begin{cases} 1/16, & \text{para } t = 0, 1, 2, 8, 9, 10 \\ 2/16, & \text{para } t = 3, 4, 5, 6, 7 \\ 0, & \text{caso contrário.} \end{cases}$$

Para diferentes valores de n, a distribuição de T^+ é determinada da mesma maneira. As funções `dsignrank` e `psignrank` do `R` fornecem probabilidades para diferentes valores de n.

Exercício: Construa a distribuição de T^+, sob H_0, quando $n = 3$.

Hipóteses do Teste dos Postos Sinalizados de Wilcoxon

Teste Bilateral: $H_0 : \theta = \theta_0 \qquad H_1 : \theta \neq \theta_0$

- Rejeita-se H_0 se $T^+ \geq t_{\alpha/2}$ ou se $T^+ \leq \dfrac{n(n+1)}{2} - t_{\alpha/2}$.

Teste Unilateral de Cauda Inferior: $H_0 : \theta = \theta_0 \qquad H_1 : \theta < \theta_0$

- Rejeita-se H_0 se $T^+ \leq \dfrac{n(n+1)}{2} - t_{\alpha}$.

Teste Unilateral de Cauda Superior: $H_0 : \theta = \theta_0 \qquad H_1 : \theta > \theta_0$

- Rejeita-se H_0 se $T^+ \geq t_{\alpha}$.

onde t_α é obtido a partir do comando `qsignrank` no `R`.

Exemplo 1

O tempo de vida (em semanas) de um grupo de 10 pacientes com um específico linfoma foi acompanhado com o objetivo de monitorar o progresso de pacientes depois de um tratamento.

Os tempos de vida (depois do tratamento até a morte) observados foram: 49, 58, 75, 110, 112, 132, 151, 276, 281, 362*. O asterisco denota uma observação censurada.

Teste se o tempo de sobrevida mediano é de 200 semanas.

Mais uma forma alternativa da estatística T^+

$$
\begin{aligned}
T^+ &= \sum_{i=1}^{n} R_i Z_i = \sum_{i=1}^{n} \left[\sum_{k=1}^{n} I(D_k \leq D_i) \right] I(X_i > \theta_0) \\
&= \sum_{i=1}^{n} \sum_{k=1}^{n} I(|X_k - \theta_0| \leq |X_i - \theta_0|) I(X_i > \theta_0) \\
&= \sum_{i=1}^{n} \sum_{k=1}^{n} I(|X_k - \theta_0| \leq X_i - \theta_0)
\end{aligned}
$$

Note que, se $X_i > \theta_0$, então $|X_i - \theta_0| = X_i - \theta_0$; além disso, se $X_i < \theta_0$, a indicadora $I(|X_k - \theta_0| \leq X_i - \theta_0)$ vale zero para qualquer X_k.

Mais uma forma alternativa da estatística T^+

$$T^+ = \sum_{i=1}^{n}\sum_{k=1}^{n} I(|X_k - \theta_0| \leq X_i - \theta_0) = \sum_{i=1}^{n}\sum_{k=1}^{n} I(\theta_0 - X_i \leq X_k - \theta_0 \leq X_i - \theta_0)$$

$$= \sum_{i=1}^{n}\sum_{k=1}^{n} I(2\theta_0 - X_i \leq X_k \leq X_i) = \sum_{i=1}^{n}\sum_{k=1}^{n} I(X_k \geq 2\theta_0 - X_i) I(X_k \leq X_i)$$

$$= \sum_{i=1}^{n}\sum_{k=1}^{n} I(\bar{X}_{ik} \geq \theta_0) I(X_k \leq X_i) = \sum_{i=1}^{n}\sum_{k=1}^{i} I(\bar{X}_{ik} \geq \theta_0)$$

onde $\bar{X}_{ik} = (X_i + X_k)/2$ são as chamadas médias de Walsh, ou médias pareadas. Note que, para $k < i$:

$$I(\bar{X}_{ik} \geq \theta_0) I(X_k \leq X_i) + I(\bar{X}_{ki} \geq \theta_0) I(X_i \leq X_k) = I(\bar{X}_{ik} \geq \theta_0)$$

Estimador de Hodges-Lehmann

O Estimador de Hodges-Lehmann (pseudomediana) é uma medida robusta e não paramétrica de locação ou tendência central.

É obtido a partir da inversão matemática do teste dos postos sinalizados de Wilcoxon.

Sob hipótese nula, a distribuição de T^+ é simétrica em torno do seu valor esperado:

$$T^+(\theta_0) = \sum_{i=1}^{n} \sum_{k=1}^{i} I(\bar{X}_{ik} \geq \theta_0) \approx E(T^+) = \frac{n(n+1)}{4}$$

que é igual a metade do número de termos no somatório duplo. Se desejamos que metade das médias de Walsh sejam maiores que θ_0, então $\hat{\theta}$ deve dividir a lista ordenada de médias de Walsh em duas partes iguais:

$$\hat{\theta}_{HL} = \text{mediana} \left\{ \frac{X_i + X_k}{2} \middle| \, 1 \leq k \leq i \leq n \right\}$$

Intervalo de Confiança de Hodges-Lehmann

Seja $P(T^+ < a) = P(T^+ \leq a-1) \leq \alpha/2$ e $N = n(n+1)/2$ o número de médias de Walsh.

Sejam $\bar{X}_{(1)} \leq \ldots \leq \bar{X}_{(N)}$ os valores ordenados das médias $(X_i + X_k)/2$, $1 \leq k \leq i \leq n$, usadas no cálculo de $\hat{\theta}_{HL}$.

Então, para toda distribuição simétrica contínua de X:

$$P(\bar{X}_{(a)} \leq \theta \leq \bar{X}_{(N+1-a)}) \geq 1 - \alpha$$

Conover (1999) recomenda a inclusão dos extremos do intervalo com base em estudos sobre quando a suposição de continuidade não é verdadeira.

Demonstração do Intervalo de Confiança

Como $T^+ = \sum_{i=1}^{n} \sum_{k=1}^{i} I(\bar{X}_{ik} \geq \theta)$, temos que

$$\begin{aligned} P(\bar{X}_{(r)} \leq \theta) &= P(\text{pelo menos } r \text{ valores } \bar{X}_j\text{'s} \leq \theta) \\ &= P(N - T^+ \geq r) = P(T^+ \leq N - r) = P(T^+ \geq r) \end{aligned}$$

pois a distribuição de T^+ é simétrica.

Se $r < s$, temos que $[\bar{X}_{(r)} \leq \theta] \supseteq [\bar{X}_{(s)} \leq \theta]$. Portanto

$$\begin{aligned} P(\bar{X}_{(r)} \leq \theta \leq X_{(r)}) &= P([\bar{X}_{(r)} \leq \theta] \cap [\bar{X}_{(s)} \leq \theta]^c) = P([\bar{X}_{(r)} \leq \theta] \setminus [\bar{X}_{(s)} \leq \theta]) \\ &= P(\bar{X}_{(r)} \leq \theta) - P(\bar{X}_{(s)} \leq \theta) = P(T^+ \geq r) - P(T^+ \geq s) \\ &= P(r \leq T^+ < s) = 1 - P(T^+ < r) - P(T^+ \geq s) \end{aligned}$$

Desejamos que ambos $P(T^+ < r) \leq \alpha/2$ e $P(T^+ \geq s) \leq \alpha/2$. Basta escolher $r = a$ e, usando simetria, $s = N - (a-1) \quad \Rightarrow \quad s = N + 1 - a$.

Exemplo

Sete medições da razão entre a massa da Terra e a da Lua foram obtidas a partir de sete diferentes satélites.

Satélite	X
Mariner 2 (Venus)	81,3001
Mariner 4 (Mars)	81,3015
Mariner 5 (Venus)	81,3006
Mariner 6 (Mars)	81,3011
Mariner 7 (Mars)	81,2997
Pioneer 6	81,3005
Pioneer 7	81,3021

Construa uma estimativa pontual e um intervalo de pelo menos 95% de confiança para a razão mediana.

Exemplo

Para facilitar o cálculo, ordenamos as medições e construimos uma matriz triangular com as médias de Walsh:

	81,2997	81,3001	81,3005	81,3006	81,3011	81,3015	81,3021
81,2997	81,2997	81,2999	81,3001	81,30015	81,3004	81,3006	81,3009
81,3001		81,3001	81,3003	81,30035	81,3006	81,3008	81,3011
81,3005			81,3005	81,30055	81,3008	81,3010	81,3013
81,3006				81,3006	81,30085	81,30105	81,30135
81,3011					81,3011	81,3013	81,3016
81,3015						81,3015	81,3018
81,3021							81,3021

Como $N = n(n+1)/2 = 28$, a estimativa pontual é dada por

$$\hat{\theta}_{HL} = \frac{\bar{X}_{(14)} + \bar{X}_{(15)}}{2} = \frac{81{,}3008 + 81{,}3008}{2} = 81{,}3008$$

Exemplo

Executando o seguinte comando no R:

```
> cbind(0:3,psignrank(0:3, 7))
     [,1]      [,2]
[1,]    0 0.0078125
[2,]    1 0.0156250
[3,]    2 0.0234375
[4,]    3 0.0390625
```

obtemos $a = 3$; portanto $L = \bar{X}_{(3)} = 81{,}3001$ e $U = \bar{X}_{(26)} = 81{,}3016$. Assim,

$$[81{,}3001; 81{,}3016]$$

é um intervalo de $95{,}3\%$ de confiança para a razão mediana.